

Hayashi

A Language for Applied Econometrics

Flávio de Vasconcellos Corrêa^{*}

Versão 0.2.10

12 de agosto de 2026

Livro e documentação licenciados sob CC BY-SA 4.0

^{*}Mestre em Economia Aplicada pelo Programa de Pós-Graduação em Organizações e Mercados (PPGOM), Universidade Federal de Pelotas (UFPel).

Prefácio

HAYASHI nasceu de uma insatisfação concreta: as ferramentas existentes para econometria aplicada exigem que o pesquisador escolha entre expressividade e desempenho, entre uma sintaxe próxima da notação estatística e a capacidade de automatizar análises complexas.

Stata tem a sintaxe certa, mas é proprietário, fechado e não é uma linguagem de propósito geral. R tem o ecossistema certo, mas a sintaxe é inconsistente e o modelo de dados é surpreendente para quem vem de Stata. Python tem a flexibilidade certa, mas os pacotes estatísticos tratam econometria como subcaso da aprendizagem de máquina.

HAYASHI é uma linguagem interpretada, de propósito geral, construída especificamente para análise econométrica. A sintaxe homenageia Stata nos lugares certos e adota idiomas modernos onde Stata mostra sua idade. O motor é escrito em Rust — sem máquina virtual, sem *garbage collector*, sem tempo de inicialização perceptível.

Este livro documenta tanto a linguagem quanto o núcleo econométrico: da estrutura de tipos e controle de fluxo aos estimadores de séries temporais, inferência causal e métodos avançados. É um retrato do estado atual do projeto — um documento vivo, que evolui com o software.

Um projeto de um desenvolvedor — e de toda a comunidade

HAYASHI é, até o momento, obra de um único desenvolvedor. Isso tem consequências práticas que o leitor deve conhecer.

Do lado positivo, há coerência de design: cada decisão de sintaxe, cada interface de estimador, cada mensagem de erro foi tomada com o mesmo conjunto de valores

em mente. Não há comitês, não há *bikeshedding*, não há camadas de compatibilidade acumuladas por décadas. O código é enxuto porque ninguém adicionou nada “só para não perder”.

Do lado da limitação, um par de olhos — por mais criterioso que seja — não vê tudo. O projeto conta com três camadas de verificação: testes unitários cobrindo os primitivos da linguagem; scripts de integração que exercitam a HAYASHI como caixa preta; e scripts *DGP* (processo gerador de dados) para cada estimador, onde o parâmetro verdadeiro é conhecido e a recuperação pode ser verificada numericamente. Ainda assim, casos de borda existem, e alguns certamente escaparam.

Licença. HAYASHI é software livre, distribuído sob os termos da **GNU General Public License versão 3** (GPL v3). Isso significa que você pode usar, estudar, modificar e redistribuir o programa — inclusive para fins comerciais — desde que qualquer trabalho derivado seja igualmente livre. O código-fonte é público e pertence, no sentido mais literal, a quem o usa.

A escolha da GPL v3 não é acidental. Ferramentas econométricas proprietárias criam dependência institucional: universidades e laboratórios ficam reféns de licenças, de políticas de preço e de decisões corporativas sobre o que o software pode ou não fazer. Software livre quebra esse ciclo. HAYASHI deve ser acessível ao pesquisador em qualquer lugar do mundo, independentemente de financiamento.

Colaboradores e testadores são bem-vindos. Se você encontrou um resultado inesperado, um estimador que não converge quando deveria, uma mensagem de erro obscura ou simplesmente uma sintaxe que poderia ser mais clara — isso é informação valiosa. Abra uma *issue* no repositório. Se quiser ir além, uma correção bem testada ou um novo capítulo de documentação é contribuição tão legítima quanto qualquer linha de código Rust.

O projeto precisa especialmente de pessoas dispostas a testar HAYASHI em dados reais: séries de tempo com sazonalidade, painéis desbalanceados, modelos com multicolinearidade, dados com missings. Esses são os casos que os scripts DGP não cobrem, porque dados sintéticos são, por construção, bem-comportados.

HAYASHI só se torna robusto com uso. E uso honesto — que inclui reportar o que quebra — é a forma mais direta de colaborar.

Junho de 2026.

Sumário

Prefácio	i
I A Linguagem	1
1 Introdução	3
1.1 O que é Hayashi	3
1.2 Filosofia de design	3
1.3 Hayashi e Stata	4
1.4 Hayashi e R / Python	5
1.5 Programa de validação empírica	5
1.6 Estrutura deste livro	5
2 Instalação	7
2.1 Requisitos	7
2.2 Via Cargo (recomendado)	7
2.3 Binários pré-compilados	7
2.4 Compilação a partir do código-fonte	8
2.5 Verificando a instalação	8
2.6 Kernel Jupyter	8
3 O REPL	9
3.1 O que é o REPL	9
3.2 Saindo do REPL	9
3.3 Navegação e histórico	9
3.4 Expressões no REPL	10
3.5 Executando scripts	10
3.6 Formato de erros	10

4	Kernel Jupyter	11
4.1	O que é o kernel Jupyter	11
4.2	Compilação e instalação	11
4.3	Usando o kernel	12
4.3.1	JupyterLab	12
4.3.2	Jupyter Notebook	12
4.3.3	Executando células	12
4.3.4	Jupyter Console	12
4.4	Desinstalação	12
4.5	Limitações em ambientes hospedados	13
5	Tipos e Valores	15
5.1	Tipos primitivos	15
5.1.1	Int	15
5.1.2	Float	15
5.1.3	Bool	16
5.1.4	Nil	16
5.2	Strings	16
5.3	Listas	17
5.4	Dicionários	17
5.5	DataFrame	17
5.6	Conversões	17
5.7	Verificação de Tipos	18
6	Variáveis e Escopos	19
6.1	Declaração com <code>let</code>	19
6.2	Constantes com <code>const</code>	19
6.3	Atribuição	20
6.4	Escopos	20
6.5	Variáveis especiais	21
6.6	Blocos expressão	22
6.7	Controle de saída	22
7	Operadores	25
7.1	Aritméticos	25
7.2	Comparação	25
7.3	Lógicos	26
7.4	Operador <code>in</code>	26

7.5	Operador pipe >	26
7.6	Precedência	27
8	Controle de Fluxo	29
8.1	if / else	29
8.2	match	29
8.3	Bloco de expressão	31
9	Laços	33
9.1	for	33
9.2	while	34
9.3	break e continue	34
9.4	Laços com DataFrames	34
9.5	parallel for	35
10	Funções	39
10.1	Declaração	39
10.2	Funções como valores	40
10.3	Closures	40
10.4	Recursão	40
10.5	Parâmetros opcionais e valores padrão	41
10.6	Escopo de funções	41
10.7	const dentro de funções	41
11	Tratamento de Erros	43
11.1	Modelo de erros	43
11.2	try / catch	43
11.3	Erros comuns e suas mensagens	44
11.4	Sugestões automáticas	44
11.5	Re-lançamento de erros	45
12	Strings e F-Strings	47
12.1	Literais de string	47
12.2	Operações com strings	47
12.3	F-Strings	48
12.4	Multiline strings	49
13	Listas e Dicionários	51
13.1	Listas	51

13.1.1	Criação	51
13.1.2	Acesso por índice	51
13.1.3	Comprimento	51
13.1.4	Mutação	52
13.1.5	Slicing	52
13.1.6	Iteração	52
13.1.7	Funções funcionais	52
13.2	Ranges	52
13.2.1	<code>chain</code>	53
13.2.2	Composição com closures	53
13.2.3	Comparação com outras linguagens	54
13.2.4	Nota sobre desempenho	54
13.3	Dicionários	54
13.3.1	Criação	54
13.3.2	Acesso	55
13.3.3	Inserção e atualização	55
13.3.4	Verificando chave	55
13.3.5	Dicionários como retorno de funções	55
13.3.6	Iteração sobre dicionários	56
14	DataFrames	57
14.1	O que é um DataFrame	57
14.2	Semântica de cópia (COW)	57
14.3	Criando DataFrames	58
14.4	Salvando DataFrames	61
14.5	Inspecionando DataFrames	62
14.6	Variáveis especiais	63
14.7	Operadores de séries temporais	63
15	Manipulação de Dados	65
15.1	<code>generate</code> e <code>mutate</code>	65
15.2	Geradores de variáveis aleatórias	65
15.3	<code>filter</code>	66
15.4	<code>select</code> e <code>drop</code>	66
15.5	<code>rename</code>	67
15.6	<code>sort</code>	67
15.7	<code>dropna</code>	67
15.8	<code>ffill</code>	67

15.9	<code>append</code>	67
15.10	<code>rbind</code>	68
15.11	<code>collapse</code> e <code>group_by</code>	68
15.12	<code>pivot_longer</code> e <code>pivot_wider</code>	68
15.13	<code>replace</code>	69
15.14	<code>tabulate</code>	69
15.15	Auxiliares de arquivo	69
15.16	<code>rolling</code>	70
15.17	<code>tidy</code> e <code>glance</code>	70
16	O Operador Pipe	71
16.1	Sintaxe básica	71
16.2	Semântica com DataFrames	71
16.3	COW e pipes	72
16.4	Encadeamento longo	73
16.5	Uso de placeholders	73
16.6	Pipe com closures	73
17	Módulos, Pacotes e Plugins	75
17.1	O Sistema de Módulos do Hayashi	75
17.1.1	O comando <code>source</code>	75
17.1.2	O comando <code>import</code>	75
17.2	Gerenciador de Pacotes e Publicação no GitHub	76
17.2.1	Comandos do CLI	76
17.2.2	Estrutura Padrão de um Pacote	76
17.3	Desenvolvimento de Plugins Avançados	77
17.3.1	1. Plugins de Script (.hay)	77
17.3.2	2. Plugins Nativos (Exclusivos em Rust)	77
17.3.3	3. Plugins WebAssembly (WASM - Para demais linguagens)	79
18	Depuração	81
18.1	Iniciando uma sessão de debug	81
18.2	Inspecionando resultados de modelos	81
18.2.1	Filhos	82
18.3	Estimadores suportados	82
18.4	Debug pela linha de comando	83

II Econometria Aplicada	85
19 Estatística Descritiva e Momentos	87
19.1 Valor esperado	87
19.2 Variância e desvio padrão	87
19.3 Momentos condicionais	88
19.4 Covariância	89
19.5 Correlação	89
19.5.1 Escalar entre duas variáveis	89
19.5.2 Matriz de correlação	90
19.6 Mediana e quantis	90
19.7 Sumário detalhado	91
19.8 Referência rápida	92
19.9 Exemplo completo	92
20 Mínimos Quadrados Ordinários	95
20.1 O modelo	95
20.2 O estimador	95
20.3 Propriedades	96
20.4 Verificação por DGP	96
20.5 Erros padrão	99
20.6 Inferência	99
20.7 Sintaxe	100
20.8 Fórmula	100
20.8.1 Transformações	101
20.8.2 Interações	101
20.8.3 <code>I(expr)</code> — expressões aritméticas arbitrárias	102
20.8.4 Variável categórica: <code>C()</code>	102
20.9 Opções de erro padrão	103
20.10 Amostra condicional	103
20.11 Capturando o resultado	103
20.12 Pós-estimação	103
20.12.1 <code>predict</code>	103
20.12.2 <code>vif</code>	104
20.12.3 <code>test</code>	104
20.12.4 <code>lincom</code>	104
20.12.5 <code>margins</code>	104
20.12.6 Diagnósticos de especificação	104

20.12.7	Diagnósticos de resíduos	105
20.12.8	Diagnósticos de influência	106
20.12.9	Comparação de modelos	106
20.13	Tabela de resultados com esttab	106
20.14	Bootstrap	107
21	Variáveis Instrumentais	109
21.1	O problema de endogeneidade	109
21.2	Condições de identificação	109
21.3	O estimador 2SLS	110
21.4	Variância assintótica	110
21.5	Instrumentos fracos	111
21.6	Verificação por DGP	111
21.7	Sintaxe	113
21.7.1	Transformações e interações nas fórmulas	113
21.8	Opções de erro padrão	114
21.9	Capturando o resultado	114
21.10	Diagnóstico de instrumentos fracos	114
21.11	Testes de pós-estimação de IV	115
21.11.1	Sargan / Hansen J — sobreidentificação	115
21.11.2	Durbin-Wu-Hausman — endogeneidade	115
21.12	Valores ajustados	115
21.13	Tabela comparativa	115
22	Dados em Painel	117
22.1	O modelo	117
22.2	Efeitos Fixos	117
22.3	Efeitos Aleatórios	118
22.4	Teste de Hausman	118
22.4.1	Hausman robusto	118
22.5	Verificação por DGP	119
22.6	Sintaxe	121
22.7	Opções de erro padrão	121
22.8	Capturando resultados	122
22.9	Diagnósticos de painel	122
22.9.1	OLS agrupado vs. Efeitos Aleatórios	122
22.9.2	OLS agrupado vs. Efeitos Fixos	122
22.9.3	Efeitos Fixos vs. Efeitos Aleatórios	123

22.9.4	Correlação serial e dependência cross-section	123
22.9.5	Arellano-Bond m1/m2	123
23	Diferenças em Diferenças	125
23.1	O modelo	125
23.2	Forma de regressão	125
23.3	Hipótese de tendências paralelas	125
23.4	Verificação por DGP	126
23.5	Sintaxe	128
23.6	Capturando o resultado	128
23.7	Event study (DiD dinâmico)	128
23.8	Local Projections Difference-in-Differences	129
24	Logit e Probit	131
24.1	O modelo de variável latente	131
24.2	Interpretação dos coeficientes	131
24.3	Verificação por DGP	132
24.4	Sintaxe	133
24.5	Previsão de probabilidades	134
24.6	Diagnósticos de classificação	134
24.6.1	Tabela de classificação	134
24.6.2	ROC e AUC	134
24.6.3	Hosmer-Lemeshow	134
24.6.4	Linktest	135
25	Regressão Quantílica	137
25.1	O modelo	137
25.2	O estimador	137
25.3	Vantagens sobre o OLS	138
25.4	Verificação por DGP	138
25.5	Sintaxe	139
25.6	Capturando o resultado	140
26	Regressão com Descontinuidade	141
26.1	O modelo	141
26.2	Identificação	141
26.3	O estimador	142
26.4	Verificação por DGP	142
26.5	Sintaxe	144

26.6	Capturando o resultado	144
26.7	Validação empírica	145
27	Método Generalizado dos Momentos	147
27.1	O framework	147
27.2	O estimador dois passos	148
27.3	Teste J de sobreidentificação	148
27.4	Verificação por DGP	148
27.5	Sintaxe	150
27.6	Capturando o resultado	150
III	Séries Temporais	151
28	AR, MA e ARMA	153
28.1	Processos estocásticos e estacionariedade	153
28.2	Processo $AR(p)$	153
28.3	Processo $MA(q)$	154
28.4	Processo $ARMA(p, q)$	154
28.5	Verificação por DGP	154
28.6	Seleção de ordem	156
28.7	Sintaxe	157
28.8	Validação empírica	158
29	ARIMA e Raiz Unitária	159
29.1	Processos integrados	159
29.2	Teste de Dickey-Fuller Aumentado	159
29.3	O modelo ARIMA	160
29.4	Verificação por DGP	160
29.5	Fluxo de trabalho	162
29.6	Sintaxe	162
29.7	Validação empírica	163
30	VAR e Causalidade de Granger	165
30.1	O modelo VAR	165
30.2	Causalidade de Granger	165
30.3	Função de Resposta ao Impulso	166
30.4	Verificação por DGP	166
30.5	Seleção de defasagens	168

30.6	Sintaxe	169
30.7	Validação empírica	169
31	Cointegração e VECM	171
31.1	Relação de longo prazo entre séries $I(1)$	171
31.2	Teste de Engle-Granger	171
31.3	Modelo de Correção de Erros (VECM)	172
31.4	Verificação por DGP	172
31.5	Sintaxe	174
31.6	Validação empírica	175
32	GARCH e Volatilidade Condicional	177
32.1	Heterocedasticidade condicional	177
32.2	Teste ARCH-LM	177
32.3	Verificação por DGP	178
32.4	Variantes: EGARCH e GJR-GARCH	179
32.5	Sintaxe	180
32.6	Validação empírica	181
IV	Inferência Causal	183
33	Propensity Score Matching	185
33.1	Seleção em observáveis	185
33.2	Verificação por DGP	186
33.3	Sintaxe	187
33.4	Validação empírica	188
34	Controle Sintético	189
34.1	O problema do caso único	189
34.2	Verificação por DGP	190
34.3	Sintaxe	193
34.4	Validação empírica	194
V	Resposta Qualitativa e Dependência Limitada	195
35	Modelos de Contagem	197
35.1	Dados de contagem e a inadequação do OLS	197
35.2	Verificação por DGP	198

35.3	Sintaxe	199
35.4	Validação empírica	200
36	Modelos de Resposta Limitada	201
36.1	Censura e truncagem	201
36.2	Verificação por DGP	202
36.3	Sintaxe	203
36.4	Validação empírica	204
37	Modelos de Escolha Múltipla	205
37.1	Resposta ordinal e nominal	205
37.2	Verificação por DGP	206
37.3	Sintaxe	207
37.4	Validação empírica	207
38	Análise de Sobrevivência	209
38.1	Tempos de falha e censura	209
38.2	Verificação por DGP	210
38.3	Sintaxe	211
VI	Métodos Avançados	213
39	Painel Avançado I — GMM, PCSE e GEE	215
39.1	Limitações dos estimadores estáticos	215
39.2	Verificação por DGP	216
39.3	Sintaxe	217
40	Regressões Aparentemente Não-Relacionadas	219
40.1	O estimador de Zellner	219
40.2	Verificação por DGP	219
40.3	Sintaxe	221
40.4	Validação empírica	221
41	Regularização e Seleção de Variáveis	223
41.1	O problema de dimensionalidade	223
41.2	Verificação por DGP	224
41.3	Sintaxe	225
41.4	Validação empírica	226

42 Bootstrap	227
42.1 Inferência por reamostragem	227
42.2 Verificação por DGP	227
42.3 Sintaxe	228
43 Análise Multivariada	231
43.1 Redução de dimensionalidade e estrutura latente	231
43.2 Verificação por DGP	232
43.3 Sintaxe	234
44 Modelos Lineares Generalizados	235
44.1 A família exponencial	235
44.2 Verificação por DGP	236
44.3 Sintaxe	237
45 Modelos de Mudança de Regime	239
45.1 Heterogeneidade estrutural ao longo do tempo	239
45.2 Verificação por DGP	239
45.3 Sintaxe	240
46 Filtros e Decomposição de Séries Temporais	243
46.1 Separação de componentes	243
46.2 Verificação por DGP	244
46.3 Sintaxe	245
47 VAR Estrutural	247
47.1 Da forma reduzida à estrutura	247
47.2 Verificação por DGP	247
47.3 Sintaxe	249
VII Métodos Complementares	251
48 Inferência Clássica	253
48.1 Testes de hipóteses paramétricos e não-paramétricos	253
48.2 Verificação por DGP	254
48.3 Sintaxe	255
49 Painel Avançado II	257
49.1 Além do FE e RE básicos	257

49.2	Verificação por DGP	258
49.3	Sintaxe	259
49.4	Painel não-linear via GEE	259
50	Raízes Unitárias II	261
50.1	Além do ADF: PP e Zivot-Andrews	261
50.2	Verificação por DGP	262
50.3	Sintaxe	262
51	Decomposição de Séries II	265
51.1	STL e Christiano-Fitzgerald	265
51.2	Verificação por DGP	266
51.3	Sintaxe	267
52	SVAR com Restrições de Longo Prazo	269
52.1	Identificação de Blanchard-Quah	269
52.2	Verificação por DGP	270
52.3	Sintaxe	271
53	Estimação Local e Ponderada	273
53.1	Pesos, janelas e suavização	273
53.2	Verificação por DGP	274
53.3	Sintaxe	275
54	AutoReg e ARDL	277
54.1	Modelos com defasagens em y e em x	277
54.2	Verificação por DGP	278
54.3	Sintaxe	282
55	Filtro de Kalman	283
55.1	Estado oculto e observação ruidosa	283
55.2	Verificação por DGP	284
55.3	Sintaxe	286
VIII	Aprendizado de Máquina e Econometria Espacial	289
56	Aprendizado de Máquina Supervisionado	291
56.1	Por que aprendizado de máquina em uma linguagem de econometria?	291
56.2	Random Forest	291

56.3	Gradient Boosting e XGBoost	292
56.4	Perceptron Multicamadas	292
56.5	LSTM e Transformer para séries	293
56.6	Processo Gaussiano	293
56.7	Quando preferir qual?	293
57	Aprendizado de Máquina Causal	295
57.1	Da previsão aos efeitos de tratamento	295
57.2	Causal Forest	295
57.3	DR-Learner e TMLE	296
57.4	Orthogonal Random Forest	296
57.5	Controle Sintético Bayesiano	297
57.6	Double Machine Learning	297
57.7	Escolhendo um método	297
58	Econometria Espacial	299
58.1	Por que espacial?	299
58.2	A matriz de pesos espaciais	299
58.3	SAR espacial	299
58.4	SEM espacial	300
58.5	Durbin espacial e extensões em painel	300
58.6	Interpretando efeitos diretos e indiretos	301
58.7	Notas práticas	301
59	Modelos Bayesianos e de Fronteira	303
59.1	Regressão linear bayesiana	303
59.2	Análise de fronteira estocástica	303
59.3	Fronteira estocástica bayesiana	304
59.4	Quando usar cada um	304
60	Agrupamento e Redução de Dimensionalidade	307
60.1	Métodos não supervisionados	307
60.2	K-Means	307
60.3	Agrupamento hierárquico e DBSCAN	308
60.4	Modelos de Mistura Gaussiana	308
60.5	Embeddings não lineares	308
60.6	Agrupamento espectral	309
60.7	PCA, fator e biplot	309
60.8	Estimativa de densidade kernel	309

61 Volatilidade e Dependência Avançadas	311
61.1 Além do GARCH	311
61.2 Volatilidade Estocástica	311
61.3 Correlação Condicional Dinâmica	312
61.4 Copulas	312
61.5 Wavelets	312
61.6 Processos de Hawkes	313
62 Testes Diagnósticos	315
62.1 Após uma regressão	315
62.2 Heterocedasticidade	315
62.3 Autocorrelação	315
62.4 Normalidade	316
62.5 Especificação	316
62.6 Outliers e influência	316
62.7 Multicolinearidade	316
62.8 Raiz unitária	317
62.9 Cointegração	317
62.10 Testes não paramétricos	317
63 Séries Temporais e Dinâmica de Painel Avançadas	319
63.1 Parâmetros variantes no tempo	319
63.2 VAR de limiar e de mudança de regime Markov	319
63.3 Dinâmicas assimétricas e não lineares	320
63.4 Coeficientes funcionais	320
63.5 Bayesian VAR e VAR de frequência mista	320
63.6 VAR em painel	321
64 Finanças	323
64.1 Fama-MacBeth	323
64.2 Sorts de portfólio	323
64.3 Notas práticas	324
65 Equações Estruturais e Multivariadas	325
65.1 SUR	325
65.2 Três estágios de mínimos quadrados	325
65.3 MANOVA	326
65.4 Correlação canônica	326
65.5 Modelos aumentados por fatores	326

65.6 FM-OLS	327
66 Métodos Recentes	329
66.1 DiD linear com adoção escalonada	329
66.2 Synthetic DiD e CUPED	329
66.3 Regressão MIDAS	330
67 Métodos Robustos, Flexíveis e Imputação	331
67.1 M-estimadores robustos	331
67.2 Modelos Lineares Generalizados	331
67.3 GEE	332
67.4 Regressão Beta	332
67.5 GAM e lowess	332
67.6 Imputação múltipla	333
68 Espaço de Estados, Suavização Exponencial e Modelos Mistos	335
68.1 Componentes não observados	335
68.2 Suavização exponencial	335
68.3 Modelos mistos	336
68.4 Kalman e séries temporais estruturais	336
69 Outros Estimadores e Aliases	337
69.1 Comandos não cobertos em detalhe	337
69.2 Modelos discretos e de painel adicionais	337
69.3 Séries temporais adicionais	337
69.4 Variantes espaciais adicionais	338
69.5 Testes e diagnósticos adicionais	338
69.6 Testes pós-estimação	339
69.7 Aliases	339
Instalação Avançada	341
69.8 Compilação com suporte a ODBC	341
69.9 Variáveis de ambiente	341
69.10 Módulos e funcionalidades opcionais	341
69.11 Integração com editores	342
69.12 Compilação de desenvolvimento	342
Referência Rápida	345
69.13 Tipos	345

69.14	Operadores	345
69.15	Operadores de séries temporais	345
69.16	Palavras-chave	346
69.17	Funções auxiliares	346
69.18	Estatística descritiva	347
69.19	Manipulação de DataFrames	347
69.20	Auxiliares de arquivo e I/O	348
69.21	Declaração de estrutura	349
69.22	Geradores aleatórios	349
69.23	Regressão linear e extensões	351
69.24	Dados em painel	351
69.25	Inferência causal	352
69.26	Variáveis dependentes especiais	352
69.27	Análise de sobrevivência	353
69.28	Séries temporais	353
69.29	Filtros e decomposição	353
69.30	Análise multivariada	354
69.31	Agrupamento e redução de dimensionalidade	354
69.32	Testes de hipóteses	356
69.33	Aprendizado de máquina e ML causal	357
69.34	Econometria espacial	357
69.35	Apresentação de resultados	358
69.36	Construção de painel (fórmulas)	358
69.37	Atalhos do REPL	358
Código Equivalente por Plataforma		359
69.38	OLS — DGP sem ruído e comparação com variável omitida	359
69.39	IV — Endogeneidade com instrumento válido	361
69.40	Painel — FE, RE e Hausman	362
69.41	Logit e Probit	363
69.42	Modelos de contagem	364
69.43	Tobit e Heckman	364
69.44	Modelos multinomiais ordenados	365
69.45	Regularização (LASSO, Ridge, Elastic Net)	366
69.46	Análise de sobrevivência	367
69.47	SVAR — Cholesky e Blanchard-Quah	367
69.48	Filtros de decomposição	368
69.49	PSM e Controle Sintético	369

69.50	Resumo comparativo	370
69.51	Matriz de validação	373
	Índice Remissivo	375

Parte I

A Linguagem

Capítulo 1

Introdução

1.1 O que é Hayashi

HAYASHI é uma linguagem de programação interpretada projetada para análise econométrica aplicada. O nome homenageia Fumio Hayashi, cujo livro *Econometrics* (2000) é referência canônica na área.

A linguagem tem três objetivos centrais:

1. **Sintaxe familiar** para quem usa Stata — comandos como `generate`, `summarize`, `regress` funcionam como esperado.
2. **Programação de propósito geral** — funções, closures, estruturas de controle, módulos. Não é apenas um conjunto de comandos estatísticos.
3. **Desempenho sem configuração** — o interpretador é escrito em Rust; não há JVM, não há GC, não há dependências de runtime.

1.2 Filosofia de design

Semântica clara antes de sintaxe concisa

Quando uma operação muta um objeto, ela deve ser visivelmente imperativa. Quando retorna um valor novo, deve parecer funcional. HAYASHI distingue essas duas formas de maneira consistente:

```
1 // imperativo: altera df no lugar (Stata-style)
2 generate df z = x^2
3
4 // funcional: retorna novo DataFrame, df inalterado
```

```
5 let df2 = generate(df, z = x^2)
```

Listing 1.1: Forma imperativa × forma funcional

Copy-on-Write para DataFrames

DataFrames usam semântica de *copy-on-write* (COW): atribuir um DataFrame a outra variável cria um alias barato. A cópia real só acontece no momento da mutação. Isso permite compartilhamento eficiente sem surpresas:

```
1 load "dados.csv" as df
2 let baseline = df           // alias, sem cópia
3
4 let transformado = df |> generate(z = x^2) |> filter(z > 10)
5 // baseline ainda não tem coluna z
```

Listing 1.2: COW em ação

Mensagens de erro como documentação

Erros em HAYASHI incluem o trecho de código que os causou, o número da linha e, quando possível, uma sugestão de correção (*did you mean?*). Um erro bem formatado é mais útil que um manual.

1.3 Hayashi e Stata

HAYASHI não é um clone de Stata. A sintaxe de comandos de dados é inspirada em Stata porque essa sintaxe é boa — próxima da linguagem que economistas usam naturalmente. Mas HAYASHI é uma linguagem completa: tem funções de primeira classe, closures, recursão, tratamento de erros estruturado.

A tabela abaixo resume as diferenças centrais:

Aspecto	Stata	Hayashi
Licença	Proprietário	GPL-3.0
Funções	Limitadas	Primeira classe
Closures	Não	Sim
Tipos	Implícitos	Explícitos em funções
DataFrames	Um por vez	Múltiplos, COW
Modularização	do	source
Desempenho	C	Rust

1.4 Hayashi e R / Python

R e Python têm ecossistemas imensos. HAYASHI não compete com eles no volume de pacotes disponíveis — compete na clareza da sintaxe para a tarefa específica de econometria aplicada. Um script de regressão com dados de painel em HAYASHI tem menos ruído visual que o equivalente em qualquer outra linguagem.

1.5 Programa de validação empírica

HAYASHI inclui um programa de validação reproduzível no diretório `validation/`. Cada caso executa um script HAYASHI e o compara, dentro de tolerâncias declaradas, com implementações de referência em R e Python (`statsmodels`). Os casos usam tanto datasets reais públicos quanto DGPs simulados retirados dos capítulos deste livro.

Para executar a validação completa:

```
1 python -m venv validation/.venv
2 validation/.venv/bin/pip install -r validation/requirements.
   txt
3 hay validate
```

Listing 1.3: Executar o programa de validação

O estado atual de cada caso está registrado em `validation/MATRIX.md`.

1.6 Estrutura deste livro

Este volume cobre a Parte I: a linguagem em si.

Capítulos 2–3 Instalação e uso do REPL.

Capítulos 4–12 Sistema de tipos, variáveis, operadores, controle de fluxo, funções, erros, strings, listas e dicionários.

Capítulos 13–15 DataFrames, manipulação de dados e o operador pipe.

Capítulo 16 Modularização com `source`.

A Parte II cobrirá estatística descritiva, estimadores de OLS, IV, painel, séries de tempo, modelos de variável dependente limitada e testes de hipótese.

Capítulo 2

Instalação

2.1 Requisitos

HAYASHI é distribuído como binário estático para Linux, macOS e Windows. Não há dependências de runtime: o executável `hay` é autossuficiente.

- Linux x86-64 ou ARM64
- macOS 12+ (Intel ou Apple Silicon)
- Windows 10+ (x86-64)

2.2 Via Cargo (recomendado)

Se Rust está instalado:

```
cargo install hayashi-lang
```

O binário `hay` será instalado em `$HOME/.cargo/bin`. Confirme que esse diretório está no `PATH`.

```
hay --version
```

2.3 Binários pré-compilados

Disponíveis na página de releases do repositório: <https://github.com/sheep-farm/hayashi/releases>

Baixe o arquivo correspondente à sua plataforma, descompacte e coloque o binário `hay` em algum diretório do `PATH`.

2.4 Compilação a partir do código-fonte

```
git clone https://github.com/sheep-farm/hayashi
cd hayashi
cargo build --release
# binário em target/release/hay
```

2.5 Verificando a instalação

```
hay --version
hay --help
```

Para executar um script:

```
hay meu_script.hay
```

Para entrar no REPL interativo:

```
hay
```

2.6 Kernel Jupyter

O HAYASHI também fornece um kernel Jupyter. Para compilá-lo e instalá-lo a partir do código-fonte:

```
cargo build --release --bin hay-kernel --features native
./target/release/hay-kernel --install
```

Depois inicie o JupyterLab ou Jupyter Notebook e selecione o kernel **Hayashi**. Veja o capítulo correspondente para mais detalhes.

Nota

No Arch Linux com Omarchy/Hyprland, `$HOME/.cargo/bin` já costuma estar no `PATH` se o shell foi configurado com `rustup`. Caso contrário, adicione ao `.bashrc` ou `.zshrc`: `export PATH="$HOME/.cargo/bin:$PATH"`

Capítulo 3

O REPL

3.1 O que é o REPL

REPL (*Read-Eval-Print Loop*) é o modo interativo de HAYASHI. Cada linha digitada é avaliada imediatamente e o resultado é exibido. É o ambiente ideal para explorar dados, testar expressões e prototipar análises.

```
hay

Hayashi 0.2.10-dev - Applied Econometrics Language
In honor of Fumio Hayashi. Type 'exit' or Ctrl-D to quit.

hay>
```

3.2 Saindo do REPL

Comando	Efeito
exit	Sai do REPL
Ctrl-D	Sai do REPL (EOF)
Ctrl-C	Cancela a linha atual

3.3 Navegação e histórico

O REPL usa `rustyline` e suporta:

- Seta para cima/baixo: histórico de comandos
- Ctrl-R: busca no histórico

- Ctrl-A / Ctrl-E: início/fim da linha
- Ctrl-C: cancela a linha atual
- Ctrl-D: sai do REPL (equivalente a `exit`)

O histórico é persistido entre sessões em `$HOME/.hay_history`.

3.4 Expressões no REPL

Qualquer expressão válida pode ser digitada diretamente:

```
1 hay> 2 + 2
2 4
3
4 hay> let x = 10
5 hay> x * 3
6 30
7
8 hay> let s = "olá, mundo"
9 hay> s
10 "olá, mundo"
```

Listing 3.1: Sessão interativa básica

3.5 Executando scripts

Scripts `.hay` são arquivos de texto com uma instrução por linha. Para executar:

```
hay analise.hay
```

A saída vai para `stdout`. Erros vão para `stderr`.

3.6 Formato de erros

HAYASHI exibe erros com contexto visual:

```
error: line 3: undefined variable 'y' - did you mean 'x'?
  3  display y + 1
    ^^^^^^^^^^^^^
```

O trecho de código, a linha e uma sugestão (quando disponível) facilitam a correção sem precisar contar linhas manualmente.

Capítulo 4

Kernel Jupyter

4.1 O que é o kernel Jupyter

O HAYASHI inclui um kernel Jupyter nativo, chamado `hay-kernel`. Ele permite executar código HAYASHI dentro de notebooks Jupyter, do JupyterLab ou de qualquer frontend compatível com o protocolo Jupyter.

Diferente do REPL, o kernel mantém o estado entre células: variáveis, funções e dados definidos em uma célula ficam disponíveis nas células seguintes do mesmo notebook.

4.2 Compilação e instalação

O kernel faz parte do repositório HAYASHI e é compilado com a feature `native`:

```
cd hayashi
cargo build --release --bin hay-kernel --features native
```

Depois, instale o especificação do kernel:

```
./target/release/hay-kernel --install
```

Isso registra o kernel em `$HOME/.local/share/jupyter/kernels/hayashi/` (ou o diretório equivalente na plataforma).

Verifique se o kernel aparece na lista:

```
jupyter kernelspec list
```

A saída deve conter uma linha como:

```
hayashi    ~/.local/share/jupyter/kernels/hayashi
```

4.3 Usando o kernel

4.3.1 JupyterLab

Inicie o JupyterLab:

```
jupyter lab
```

Crie um novo notebook e selecione o kernel **Hayashi** no launcher ou no menu de kernel.

4.3.2 Jupyter Notebook

Inicie o Jupyter Notebook:

```
jupyter notebook
```

Crie um novo notebook e escolha **Hayashi** na lista de kernels.

4.3.3 Executando células

As células aceitam código HAYASHI diretamente:

```
1 let x = 1 + 2
2 print(x)
```

Listing 4.1: Exemplo de célula no Jupyter

A saída 3 é exibida logo abaixo da célula. Variáveis persistem entre células:

```
1 let y = x * 10
2 print(y)
```

Listing 4.2: Célula posterior com a mesma sessão

4.3.4 Jupyter Console

Se estiver instalado, o console também pode ser usado:

```
jupyter console --kernel=hayashi
```

4.4 Desinstalação

Remova o diretório do especificação do kernel:

```
rm -rf ~/.local/share/jupyter/kernels/hayashi
```

4.5 Limitações em ambientes hospedados

Google Colab, Kaggle Notebooks e ambientes similares não permitem registrar kernels personalizados de forma simples e o runtime é efêmero. Nessas situações, a alternativa prática é subir um binário pré-compilado `hay` e chamá-lo de células Python, eventualmente com uma magic cell como `%%hay`.

Veja o capítulo ?? para um exemplo de gambiarra funcional.

Capítulo 5

Tipos e Valores

HAYASHI é dinamicamente tipado: variáveis não têm tipo declarado, mas cada valor carrega seu tipo em tempo de execução. O sistema de tipos é coerente — operações entre tipos incompatíveis produzem erros claros em vez de coerções silenciosas.

5.1 Tipos primitivos

5.1.1 Int

Inteiro de 64 bits com sinal. Literais inteiros são escritos sem ponto decimal:

```
1 let n = 42
2 let negativo = -7
3 let grande = 1_000_000    // _ como separador visual
```

5.1.2 Float

Ponto flutuante de 64 bits (IEEE 754). Requer ponto decimal ou notação científica:

```
1 let pi = 3.14159
2 let e = 2.71828
3 let pequeno = 1.5e-10
```

Operações aritméticas entre Int e Float promovem para Float:

```
1 let x = 3 / 2    // 1 (divisão inteira)
2 let y = 3 / 2.0  // 1.5
3 let z = 3.0 / 2  // 1.5
```

Divisão de Float por zero retorna `inf` ou `-inf`, nunca um erro — seguindo IEEE 754:

```
1 display 1.0 / 0.0    // inf
2 display -1.0 / 0.0   // -inf
3 display 0.0 / 0.0    // nan
```

Nota

Divisão de Int por zero produz erro de runtime. Divisão de Float por zero segue IEEE 754 e retorna `inf`.

5.1.3 Bool

Verdadeiro ou falso. Literais: `true` e `false`.

```
1 let ativo = true
2 let encerrado = false
```

Operadores lógicos: `and`, `or`, `not`.

5.1.4 Nil

Ausência de valor. Algumas funções retornam `nil` quando não há resultado relevante (por exemplo, `push` que muta uma lista no lugar).

```
1 let nada = nil
2 display nada    // nil
```

5.2 Strings

Strings são sequências de caracteres Unicode delimitadas por aspas duplas:

```
1 let nome = "Hayashi"
2 let caminho = "/home/usuario/dados.csv"
```

Sequências de escape: `\n` (nova linha), `\t` (tab), `\"` (aspas), `\\` (barra).

F-strings permitem interpolação de expressões:

```
1 let ano = 2026
2 display f"Publicado em {ano}"    // Publicado em 2026
```

5.3 Listas

Coleções ordenadas de valores de qualquer tipo, delimitadas por colchetes:

```
1 let numeros = [1, 2, 3, 4, 5]
2 let misto   = [1, "dois", true, nil]
3 let vazia   = []
```

5.4 Dicionários

Mapeamentos chave-valor. Chaves e valores podem ser de qualquer tipo:

```
1 let config = {"host": "localhost", "porta": 5432}
2 let vazio  = {}
```

Acesso por chave:

```
1 config["host"] // "localhost"
```

5.5 DataFrame

O tipo central de HAYASHI. Um DataFrame é uma tabela bidimensional com colunas nomeadas. Cada coluna é um vetor de Float (valores ausentes representados por NaN).

```
1 input x y
2   1   2
3   3   4
4   5   6
5 end
```

Listing 5.1: Criando um DataFrame inline

DataFrames são discutidos em profundidade no Capítulo 14.

5.6 Conversões

HAYASHI não faz coerção implícita entre tipos. Conversões devem ser explícitas:

```
1 let s = str(42)           // "42"
2 let n = int("7")          // 7
3 let f = float("3.14")     // 3.14
```

Tentar somar um `Int` com uma `String` produz erro de tipo:

```
1 42 + "3"  
2 // error: type mismatch - expected Int or Float, got String
```

5.7 Verificação de Tipos

Para verificar dinamicamente o tipo de um valor, HAYASHI oferece funções embutidas de verificação que retornam um booleano:

```
1 is_nil(nil)           // true  
2 is_int(42)            // true  
3 is_float(3.14)        // true  
4 is_bool(true)         // true  
5 is_str("ola")          // true (ou is_string)  
6 is_list([1, 2])       // true  
7 is_dict({"a": 1})      // true  
8 is_df(df)              // true (ou is_dataframe)  
9 is_fn(|x| x)           // true (ou is_function)
```

Além disso, a função `type(x)` (ou `typeof(x)`) retorna o tipo do valor como uma string (ex: `"int"`, `"float"`, `"nil"`, etc.).

Capítulo 6

Variáveis e Escopos

6.1 Declaração com `let`

Toda variável é declarada com `let`. A declaração vincula um nome a um valor:

```
1 let x = 10
2 let nome = "João"
3 let ativo = true
```

`let` sem atribuição inicial não existe em HAYASHI — toda variável é inicializada no momento da declaração.

Redeclaração

Uma variável pode ser redeclarada com `let` no mesmo escopo. O novo valor substitui o anterior sem afetar outras variáveis que apontem para o valor antigo:

```
1 let x = 5
2 let y = x      // y aponta para 5
3 let x = 99     // x agora é 99; y continua 5
4 display y      // 5
```

6.2 Constantes com `const`

`const` declara um nome que não pode ser redeclarado nem atribuído no mesmo escopo. Útil para valores de configuração ou parâmetros fixos:

```
1 const ALPHA = 0.05
2 const NOME_PROJETO = "LAFI"
```

Tentar atribuir a uma constante produz erro de compilação:

```
1 const N = 100
2 N = 200      // error: cannot assign to constant 'N'
```

Nota

const em HAYASHI é avaliado em tempo de execução, não em tempo de compilação. A distinção de **let** é puramente de mutabilidade de ligação, não de desempenho.

6.3 Atribuição

Após declaração com **let**, a variável pode ser reatribuída com **=**:

```
1 let contador = 0
2 contador = contador + 1
3 contador = contador + 1
4 display contador      // 2
```

Operadores compostos de atribuição:

```
1 let n = 10
2 n += 5      // n = 15
3 n -= 3      // n = 12
4 n *= 2      // n = 24
5 n /= 4      // n = 6
```

6.4 Escopos

Escopos são delimitados por blocos `{ }`. Variáveis declaradas dentro de um bloco existem apenas até o final dele:

```
1 let x = 1
2
3 {
4   let y = 2
5   display x      // 1 - x é visível aqui
6   display y      // 2
7 }
8
9 display x      // 1
```

```
10 display y      // error: undefined variable 'y'
```

Listing 6.1: Variáveis locais a um bloco

Escopos em funções

Cada chamada de função cria um novo escopo. Parâmetros e variáveis locais são destruídos quando a função retorna:

```
1 fn soma(a, b) {
2   let resultado = a + b
3   return resultado
4 }
5
6 display soma(3, 4)      // 7
7 display resultado      // error: undefined variable 'resultado'
```

Captura de escopo exterior (closures)

Funções anônimas (closures) capturam variáveis do escopo onde foram definidas:

```
1 let base = 100
2
3 let adicionar = fn(x) {
4   return x + base    // captura 'base' do escopo exterior
5 }
6
7 display adicionar(20) // 120
```

6.5 Variáveis especiais

`_n` e `_N` em contextos de dados

Dentro de `generate` e `mutate`, duas variáveis implícitas estão disponíveis:

- `_n`: índice da linha atual (começando em 1)
- `_N`: número total de linhas do DataFrame

```
1 input x
2   10  20  30
3 end
4
5 generate df id = _n      // [1, 2, 3]
6 generate df peso = 1/_N  // [0.333, 0.333, 0.333]
```

Listing 6.2: Uso de `_n` e `_N`

`_` (descarte)

O identificador `_` descarta um valor sem criar uma ligação:

```
1 for _ in 1..5 {
2   display "iteração"
3 }
```

6.6 Blocos expressão

Um bloco pode ser usado como expressão. Ele avalia uma sequência de statements e retorna o valor da última expressão. Variáveis declaradas dentro do bloco são locais a ele:

```
1 let df = {
2   let raw = load("dados.csv")
3   generate raw y = log(x)
4   keep(raw, ["date", "y"])
5   raw
6 }
```

Listing 6.3: Bloco expressão retornando um valor

Após o bloco, `df` está disponível, mas `raw` não.

6.7 Controle de saída

`quietly on` suprime a saída automática de statements e estimadores. `print(...)` e `display ...` continuam aparecendo. `quietly off` restaura a saída normal. A flag respeita escopo:

```
1 quietly on
2
3 let df = {
4   let a = load("a.csv")
5   let b = load("b.csv")
6   let m = merge(a, b, key=id, type=inner)
7   generate m z = x - y
8   m
9 }
10
11 quietly off
12
13 ols(z ~ x, df)
14 print("pronto")
```

Listing 6.4: quietly on/off com escopo

Dentro do bloco, `quietly off` habilitaria temporariamente a saída; ao sair do bloco, ela volta para `quietly on`.

Capítulo 7

Operadores

7.1 Aritméticos

Operador	Operação	Exemplo
+	Adição	$3 + 2 \rightarrow 5$
-	Subtração	$5 - 3 \rightarrow 2$
*	Multiplicação	$4 * 3 \rightarrow 12$
/	Divisão	$7 / 2 \rightarrow 3$ (inteiros)
^	Potência	$2^{10} \rightarrow 1024$
%	Módulo	$7 \% 3 \rightarrow 1$

Divisão entre dois `Int` é inteira (truncamento em direção a zero). Para divisão real, ao menos um operando deve ser `Float`:

```
1 7 / 2      // 3
2 7 / 2.0    // 3.5
3 7.0 / 2    // 3.5
```

7.2 Comparação

Operador	Significado	Exemplo
==	Igual	$3 == 3 \rightarrow \text{true}$
!=	Diferente	$3 != 4 \rightarrow \text{true}$
>	Maior	$5 > 3 \rightarrow \text{true}$
<	Menor	$3 < 5 \rightarrow \text{true}$
>=	Maior ou igual	$3 >= 3 \rightarrow \text{true}$
<=	Menor ou igual	$2 <= 3 \rightarrow \text{true}$

7.3 Lógicos

```
1 true and false    // false
2 true or false     // true
3 not true          // false
```

`and` e `or` têm avaliação em curto-circuito: o segundo operando não é avaliado se o resultado já é determinado pelo primeiro.

7.4 Operador in

Verifica pertencimento a uma lista:

```
1 let regioes = ["norte", "sul", "centro"]
2 "sul" in regioes    // true
3 "leste" in regioes  // false
```

Funciona também com ranges:

```
1 5 in 1..10    // true
2 15 in 1..10   // false
```

7.5 Operador pipe |>

O operador `|>` passa o valor da esquerda como primeiro argumento da função à direita:

```
1 // sem pipe
2 display filter(df, x > 5)
3
4 // com pipe - mais legível
5 df |> filter(x > 5) |> display
```

O pipe tem semântica especial com DataFrames: quando usado sem atribuição explícita (`let`), o resultado é atribuído de volta à variável de origem:

```
1 let df = load("dados.csv")
2
3 // atualiza df no lugar
4 df |> filter(x > 0) |> sort(x)
5
6 // cria df2, df permanece inalterado
```



```
7 let df2 = df |> filter(x > 0)
```

Este comportamento é discutido em detalhe no Capítulo 16.

7.6 Precedência

Da menor para a maior prioridade:

1. or
2. and
3. not
4. == != > < >= <=
5. + -
6. * / %
7. ^ (associa à direita)
8. Unário -
9. Chamada de função, indexação, acesso a campo

Use parênteses para clareza quando a precedência não for óbvia:

```
1 2 + 3 * 4          // 14  (multiplicação primeiro)
2 (2 + 3) * 4        // 20
```


Capítulo 8

Controle de Fluxo

8.1 if / else

```
1 let nota = 7.5
2
3 if nota >= 7 {
4   display "aprovado"
5 } else if nota >= 5 {
6   display "recuperação"
7 } else {
8   display "reprovado"
9 }
```

Listing 8.1: Estrutura básica de if/else

if como expressão

`if` pode ser usado como expressão — retorna o valor do bloco escolhido:

```
1 let status = if nota >= 7 { "aprovado" } else { "reprovado" }
2 display status
```

Quando usado como expressão, os dois ramos devem ter o mesmo tipo (ou ambos `nil`).

8.2 match

`match` compara um valor contra múltiplos padrões. O primeiro padrão que casa é executado:

```
1 let codigo = 2
2
3 match codigo {
4   1 => display "iniciante"
5   2 => display "intermediário"
6   3 => display "avançado"
7   _ => display "desconhecido"
8 }
```

Listing 8.2: match com literais

O padrão `_` é o caso padrão (*wildcard*) — casa com qualquer valor.

match com strings

```
1 let uf = "RS"
2
3 match uf {
4   "RS" => display "Rio Grande do Sul"
5   "SP" => display "São Paulo"
6   "RJ" => display "Rio de Janeiro"
7   _    => display f"UF desconhecida: {uf}"
8 }
```

match como expressão

```
1 let descricao = match codigo {
2   1 => "iniciante"
3   2 => "intermediário"
4   _ => "avançado"
5 }
```

Múltiplos valores por braço

```
1 match codigo {
2   1 | 2    => display "básico"
3   3 | 4    => display "avançado"
4   _       => display "outro"
5 }
```

8.3 Bloco de expressão

Um bloco `{ }` é uma expressão que avalia para o último valor produzido dentro dele:

```
1 let resultado = {  
2   let a = 10  
3   let b = 20  
4   a + b      // este é o valor do bloco  
5 }  
6 display resultado    // 30
```


Capítulo 9

Laços

9.1 for

Itera sobre uma sequência. A variável de iteração é visível dentro do bloco e *persiste* após o laço com o último valor assumido:

```
1 for i in 1..4 {  
2     display i    // 1, 2, 3 (4 não incluído)  
3 }  
4 display i    // 3 - variável persiste após o laço
```

Listing 9.1: for sobre range

Range exclusivo e inclusivo

HAYASHI segue a mesma convenção de Rust:

```
1 for i in 1..3 { }    // 1, 2    (exclusivo: não inclui o  
    fim)  
2 for i in 1..=3 { }   // 1, 2, 3 (inclusivo: inclui o fim)
```

Ranges também são expressões que avaliam para listas — ver Seção [13.2](#).

Iterando sobre listas

```
1 let frutas = ["maçã", "banana", "uva"]  
2  
3 for fruta in frutas {  
4     display fruta  
5 }
```

Descartando a variável de iteração

Quando o índice não importa:

```
1 for _ in 1..3 {  
2   display "repetição"  
3 }
```

9.2 while

Executa enquanto a condição for verdadeira:

```
1 let n = 1  
2  
3 while n <= 5 {  
4   display n  
5   n += 1  
6 }
```

Listing 9.2: while básico

Atenção

HAYASHI não detecta laços infinitos. Um `while true { }` sem `break` executará indefinidamente. Use `Ctrl-C` para interromper.

9.3 break e continue

`break` interrompe o laço imediatamente. `continue` avança para a próxima iteração:

```
1 for i in 1..10 {  
2   if i == 3 { continue }    // pula o 3  
3   if i == 7 { break }      // para no 7  
4   display i  
5 }  
6 // exibe: 1, 2, 4, 5, 6
```

Listing 9.3: break e continue

9.4 Laços com DataFrames

`for` pode iterar sobre listas produzidas por funções de dados:


```

1 load "vendas.csv" as df
2
3 for uf in ["RS", "SP", "RJ"] {
4   let sub = filter(df, estado == uf)
5   display f"{uf}: {count(sub)} obs"
6 }

```

Listing 9.4: Iterando sobre grupos

9.5 parallel for

Variante concorrente do `for`. As iterações executam em paralelo entre threads; o valor de retorno de cada iteração (última expressão ou `return` explícito) é coletado em uma lista.

Como expressão (preferido — o resultado vai para uma variável nomeada):

```

1 let resultados = parallel for t in tickers {
2   let sub = filter(df, ticker == t)
3   nrow(sub)
4 }
5 // resultados é uma lista de valores nrow

```

Listing 9.5: parallel for como expressão

Como statement (o resultado é armazenado na variável de iteração):

```

1 parallel for t in tickers {
2   let sub = filter(df, ticker == t)
3   nrow(sub)
4 }
5 // t agora contém uma lista de valores nrow

```

Listing 9.6: parallel for como statement

O parâmetro opcional `threads=N` limita o número de threads trabalhadoras (padrão: todas as CPUs disponíveis):

```

1 let resultados = parallel for t in tickers, threads=4 {
2   load "data.db" as sub, query=f"SELECT * FROM p WHERE t='{t
3   }'"
4   nrow(sub)
5 }

```

Listing 9.7: Limite de threads

Modelo de isolamento

Cada thread recebe seu próprio interpretador com um **snapshot** do ambiente externo (apenas valores send-safe são capturados). O auto-display é suprimido dentro das threads — apenas chamadas explícitas a `print()` produzem saída. Isso tem consequências importantes:

- **Leituras do escopo externo funcionam:** variáveis definidas antes do `parallel for` são visíveis dentro do corpo.
- **Escritas no escopo externo são silenciosamente descartadas:** reatribuir uma variável externa dentro do corpo não tem efeito sobre o escopo externo. A mutação existe apenas no ambiente local da thread e é perdida quando a thread termina.
- **Auto-display é suprimido:** a última expressão do corpo é coletada como resultado, não impressa. Use `print()` explicitamente se precisar de saída de iterações individuais.

```
1 let n = 0
2 parallel for i in 1..3 {
3   n = 10           // sem efeito sobre n externo
4   i * 2
5 }
6 print(n)           // ainda 0
```

Listing 9.8: Mutações são descartadas

Atenção

Trate o corpo como uma **função pura**: leia variáveis externas, compute um resultado, e faça `return` dele. Não confie em efeitos colaterais para propagar valores para fora.

O que pode e não pode ser capturado

Tipo	Capturável?	Motivo
Int, Float, Str, Bool	Sim	Primitivos, copiados por valor
List, Dict (send-safe)	Sim	Arc, leitura compartilhada
DataFrame, Series	Sim	Arc, operações são funcionais
UserFn	Sim	Arc
Resultados de modelos (ols, iv, rolling, ...)	Não	Contêm Rc, não são Send

Resultados de modelos do escopo externo não podem ser capturados. Compute modelos **dentro** do corpo:

```

1 // ERRADO: m contém Rc, será rejeitado
2 let m = ols(y ~ x, df)
3 parallel for i in 1..10 { predict(m, newdata) }
4
5 // CORRETO: computar dentro do corpo
6 parallel for i in 1..10 {
7   let sub = filter(df, grupo == i)
8   let m = ols(y ~ x, sub)
9   tidy(m)
10 }
```

Listing 9.9: Modelos devem ser computados dentro

Pular iterações e agregação

Use `return nil` para pular uma iteração. Entradas `nil` são mantidas na lista de resultados (em ordem). Combine com `rbind()` para agregar DataFrames por iteração — `rbind` ignora silenciosamente entradas `nil`:

```

1 let resultados = parallel for i in 0..n, threads=8 {
2   let t = tickers[i]
3   if t == "SPY" { return nil }
4   let df_t = calcular_betas(t)
5   df_t
6 }
7 let todos = rbind(resultados)
```

Listing 9.10: parallel for + rbind

Capítulo 10

Funções

10.1 Declaração

Funções são declaradas com `fn`:

```
1 fn quadrado(x) {  
2     return x^2  
3 }  
4  
5 display quadrado(5)    // 25
```

Listing 10.1: Função básica

Retorno implícito

A última expressão de uma função é retornada automaticamente:

```
1 fn quadrado(x) {  
2     x^2    // return implícito  
3 }
```

Múltiplos parâmetros

```
1 fn media(a, b) {  
2     (a + b) / 2.0  
3 }  
4  
5 display media(10, 20)    // 15.0
```

10.2 Funções como valores

Funções são valores de primeira classe — podem ser atribuídas a variáveis, passadas como argumento e retornadas por outras funções:

```
1 fn aplicar(f, x) {  
2   f(x)  
3 }  
4  
5 fn dobro(n) { n * 2 }  
6  
7 display aplicar(dobro, 7)    // 14
```

Listing 10.2: Função como argumento

10.3 Closures

Closures são funções anônimas que capturam o ambiente onde foram definidas:

```
1 let multiplicador = fn(fator) {  
2   fn(x) { x * fator }    // captura 'fator'  
3 }  
4  
5 let triplo = multiplicador(3)  
6 display triplo(10)    // 30
```

Listing 10.3: Closure básica

Closures como argumentos

```
1 fn aplicar_dois(f, a, b) {  
2   f(a) + f(b)  
3 }  
4  
5 let soma_quadrados = aplicar_dois(fn(x) { x^2 }, 3, 4)  
6 display soma_quadrados    // 9 + 16 = 25
```

10.4 Recursão

Funções podem chamar a si mesmas:

```

1 fn fat(n) {
2   if n <= 1 { return 1 }
3   n * fat(n - 1)
4 }
5
6 display fat(10)    // 3628800

```

Listing 10.4: Fatorial recursivo

Nota

HAYASHI não otimiza recursão em cauda (*tail-call optimization*). Para sequências longas, prefira laços.

10.5 Parâmetros opcionais e valores padrão

HAYASHI não tem parâmetros opcionais nativos, mas o padrão idiomático é usar `nil` como sentinela e verificar explicitamente:

```

1 fn formatar(valor, casas) {
2   let c = if casas == nil { 2 } else { casas }
3   // ...
4 }

```

10.6 Escopo de funções

Funções declaradas com `fn` no nível de módulo ficam disponíveis em todo o arquivo. Funções declaradas dentro de blocos são locais ao bloco:

```

1 {
2   fn local(x) { x + 1 }
3   display local(5)    // 6
4 }
5 display local(5)    // error: undefined function 'local'

```

10.7 const dentro de funções

`const` pode ser usado dentro de funções para fixar valores que não devem mudar durante a execução:

```
1 fn calcular_imc(peso, altura) {  
2   const FORMULA = "peso / altura^2"  
3   peso / altura^2  
4 }
```


Capítulo 11

Tratamento de Erros

11.1 Modelo de erros

HAYASHI distingue dois tipos de erro:

Erros de parse Detectados antes da execução, ao analisar o código. Incluem linha e trecho do código.

Erros de runtime Ocorrem durante a execução — variável indefinida, tipo errado, divisão por zero, chave ausente.

Ambos os tipos exibem o trecho de código e a linha, facilitando a localização:

```
error: line 5: undefined variable 'rendimento' - did you mean
      'rendimento_bruto'?
5    display rendimento * 12
      ~~~~~
```

11.2 try / catch

Erros de runtime podem ser capturados com `try/catch`:

```
1 try {
2   let resultado = 10 / 0
3   display resultado
4 } catch e {
5   display f"Erro capturado: {e}"
6 }
```

Listing 11.1: try/catch básico

A variável `e` dentro do `catch` contém a mensagem de erro como string.

Capturando erros de arquivo

```
1 try {  
2   load "dados_inexistentes.csv" as df  
3 } catch e {  
4   display f"Arquivo não encontrado: {e}"  
5 }
```

try como expressão

`try/catch` pode retornar um valor:

```
1 let valor = try {  
2   int("não é um número")  
3 } catch _ {  
4   -1  
5 }  
6 display valor    // -1
```

11.3 Erros comuns e suas mensagens

Situação	Mensagem típica
Variável não declarada	undefined variable 'x' - did you mean 'y'?
Função não existe	undefined function 'foo' - did you mean 'for'?
Tipo errado	type mismatch - expected Int, got String
Índice fora de limite	index 5 out of bounds (len=3)
Chave ausente em dict	key 'nome' not found in dict
Divisão por zero (Int)	division by zero
Arquivo não encontrado	file not found: 'caminho.csv'

11.4 Sugestões automáticas

Quando o nome de uma variável ou função é parecido com algo existente, HAYASHI sugere a correção:

```
error: undefined function 'regres' - did you mean 'regress'?
```

As sugestões usam distância de edição (*Levenshtein*) sobre uma lista de todos os nomes definidos no escopo e nas funções embutidas.

11.5 Re-lançamento de erros

Para propagar um erro capturado:

```
1 try {  
2     operacao_arriscada()  
3 } catch e {  
4     display f"log: {e}"  
5     error(e)      // re-lança o erro  
6 }
```

A função `error(msg)` lança um erro de runtime com a mensagem fornecida.

Capítulo 12

Strings e F-Strings

12.1 Literais de string

Strings são delimitadas por aspas duplas:

```
1 let s = "Olá, mundo"
2 let caminho = "/home/usuario/dados.csv"
3 let vazia = ""
```

Sequências de escape

Sequência	Significado
\n	Nova linha
\t	Tabulação
\r	Retorno de carro
\"	Aspas duplas literais
\\	Barra invertida literal

12.2 Operações com strings

Concatenação

```
1 let nome = "Hayashi"
2 let versao = "0.2"
3 let titulo = nome + " " + versao // "Hayashi 0.2"
```

Comprimento

```
1 let s = "econometria"
2 display len(s)      // 11
```

Conversões

```
1 let n = str(42)      // "42"
2 let f = str(3.14)    // "3.14"
3 let b = str(true)    // "true"
```

Comparação

Strings são comparadas lexicograficamente com `==`, `!=`, `<`, `>`, `<=`, `>=`.

12.3 F-Strings

F-strings permitem interpolar expressões arbitrárias dentro de uma string. O prefixo `f` indica interpolação; expressões entre `{ }` são avaliadas e convertidas para string:

```
1 let municipio = "Pelotas"
2 let pop = 328_000
3
4 display f"{municipio} tem {pop} habitantes"
5 // Pelotas tem 328000 habitantes
6
7 display f"Média: {(10 + 20 + 30) / 3.0:.2f}"
8 // Média: 20.00
```

Listing 12.1: F-strings

Expressões em f-strings

Qualquer expressão pode ser interpolada — variáveis, operações aritméticas, chamadas de função:

```
1 let n = 5
2 display f"{n}^2 = {n^2}"
3 // 5^2 = 25
4
```

```
5 display f"raiz de {n} = {sqrt(n):.4f}"  
6 // raiz de 5 = 2.2361
```

F-strings em display

`display` aceita opções `end=` e `sep=` para controlar o terminador e o separador entre múltiplos valores:

```
1 display "a", "b", "c" sep=", " // a, b, c  
2 display "linha" end="" // linha (sem quebra)
```

12.4 Multiline strings

HAYASHI não tem literal de string multiline. Use concatenação explícita:

```
1 let sql = "SELECT * FROM dados " +  
2           "WHERE ano = 2026 " +  
3           "ORDER BY uf"
```


Capítulo 13

Listas e Dicionários

13.1 Listas

13.1.1 Criação

```
1 let nums = [1, 2, 3, 4, 5]
2 let nomes = ["RS", "SP", "RJ"]
3 let misto = [1, "dois", true]
4 let vazia = []
```

13.1.2 Acesso por índice

Índices começam em 0. Índices negativos contam a partir do fim:

```
1 let xs = [10, 20, 30, 40]
2 display xs[0]      // 10
3 display xs[3]      // 40
4 display xs[-1]     // 40 (último)
5 display xs[-2]     // 30
```

Acesso fora dos limites produz erro de runtime:

```
1 xs[10]
2 // error: index 10 out of bounds (len=4)
```

13.1.3 Comprimento

```
1 len([1, 2, 3])    // 3
```

13.1.4 Mutação

`push` adiciona ao final da lista (muta no lugar, retorna `nil`):

```
1 let lista = [1, 2, 3]
2 push(lista, 4)
3 display lista      // [1, 2, 3, 4]
```

Atenção

`push` é uma função mutante — altera `lista` diretamente e retorna `nil`. Não faça `let nova = push(lista, 4)`.

`pop` remove e retorna o último elemento:

```
1 let ultimo = pop(lista)
```

13.1.5 Slicing

```
1 let xs = [0, 1, 2, 3, 4, 5]
2 display slice(xs, 1, 4)      // [1, 2, 3]   (índices 1..3)
```

13.1.6 Iteração

```
1 for x in [10, 20, 30] {
2   display x * 2
3 }
```

13.1.7 Funções funcionais

```
1 let xs = [1, 2, 3, 4, 5]
2
3 let dobrados = map(xs, fn(x) { x * 2 })
4 let pares    = filter(xs, fn(x) { x % 2 == 0 })
5 let soma     = reduce(xs, 0, fn(acc, x) { acc + x })
```

13.2 Ranges

Ranges são expressões que produzem listas de inteiros. A sintaxe segue Rust:

```

1 let a = 1..5           // [1, 2, 3, 4]   (exclusivo)
2 let b = 1..=5          // [1, 2, 3, 4, 5] (inclusivo)

```

Listing 13.1: Ranges como listas

Por serem listas normais, ranges funcionam com qualquer função que aceite lista:

```

1 map(1..=5, fn(x) { x^2 })           // [1, 4, 9, 16, 25]
2 filter(1..10, fn(x) { x % 2 == 0 }) // [2, 4, 6, 8]
3 len(1..100)                         // 99

```

13.2.1 chain

`chain` concatena múltiplas listas (ou ranges) em uma só:

```

1 chain(1..3, 9..=11)           // [1, 2, 9, 10, 11]
2 chain(1..=3, [10, 20], 5..7) // [1, 2, 3, 10, 20, 5, 6]

```

Listing 13.2: chain com ranges e listas

Uso típico em laços sobre sequências não-contíguas:

```

1 for lag in chain(1..=3, 6..=8) {
2   display f"lag {lag}"
3 }

```

13.2.2 Composição com closures

Ranges, `chain` e closures compõem naturalmente em uma única expressão. A sintaxe `|x| expr` define uma closure sem a cerimônia de `fn`:

```

1 let r = map(chain(1..=10, 5..9, 56..70), |n| n * 3)

```

Listing 13.3: Expressão composta — única linha

O pipe também funciona no cabeçalho do `for`, compondo transformações antes de entrar no corpo do laço:

```

1 for i in chain(1..=10, 20..=25) |> filter(|n| (n % 2) == 0) {
2   display i
3 }

```

Listing 13.4: Pipeline no cabeçalho do for

13.2.3 Comparação com outras linguagens

A tabela abaixo mostra como as principais linguagens expressariam o mesmo pipeline:

Linguagem	Forma
Python	<code>filter(lambda n: n%2==0, chain(range(1,11), range(5,9), range(56,70)))</code>
Rust	<code>(1..=10).chain(5..9).chain(56..70).filter(n n%2==0)</code>
Haskell	<code>filter even \$ [1..10] ++ [5..8] ++ [56..69]</code>
Julia	<code>Iterators.filter(n->n%2==0, Iterators.flatten([1:10,5:8,56:69]))</code>
R	<code>Filter(function(n) n%%2==0, c(1:10, 5:8, 56:69))</code>
Hayashi	<code>chain(1..=10,5..9,56..70) > filter(n (n%2)==0)</code>

HAYASHI é a única linguagem em que o pipeline é estritamente da esquerda para a direita, sem imports, sem namespaces e com `chain` variádico que trata todos os argumentos simetricamente.

13.2.4 Nota sobre desempenho

`chain` materializa os ranges em uma lista antes de iterar. `for i in 1..N`, por outro lado, itera diretamente sem alocar nada.

`chain` é para sequências não-contíguas pequenas — lags, anos, grupos de variáveis. Esse é o seu único caso de uso legítimo. Qualquer sequência contígua é simplesmente `1..N` ou `1..=N`.

13.3 Dicionários

13.3.1 Criação

```
1 let config = {
2   "host": "localhost",
3   "porta": 5432,
4   "ssl": true
5 }
6
7 let vazio = {}
```

Chaves podem ser strings ou inteiros. Valores podem ser de qualquer tipo.

13.3.2 Acesso

```
1 config["host"]      // "localhost"
2 config["porta"]     // 5432
```

Chave ausente produz erro:

```
1 config["usuario"]
2 // error: key 'usuario' not found in dict
```

Use `try/catch` para acesso seguro:

```
1 let user = try { config["usuario"] } catch _ { "anonimo" }
```

13.3.3 Inserção e atualização

```
1 let d = {"a": 1}
2 // d é imutável; d2 = {"a":1, "b":2}
3 let d2 = dict_set(d, "b", 2)
```

`dict_set` é funcional — retorna um novo dicionário sem mutar o original.

13.3.4 Verificando chave

```
1 "host" in config    // true
2 "senha" in config   // false
```

13.3.5 Dicionários como retorno de funções

Funções de análise frequentemente retornam dicionários com múltiplos resultados:

```
1 load "dados.csv" as df
2 let stats = summarize(df, renda)
3
4 display stats["mean"]    // média
5 display stats["sd"]      // desvio padrão
6 display stats["N"]       // número de observações
```

Listing 13.5: `summarize` retorna dicionário

13.3.6 Iteração sobre dicionários

```
1 let d = {"a": 1, "b": 2, "c": 3}
2
3 for key in keys(d) {
4     display f"{key} = {d[key]}"
5 }
```

Capítulo 14

DataFrames

14.1 O que é um DataFrame

Um DataFrame é uma tabela bidimensional com colunas nomeadas. Em HAYASHI, cada coluna é um vetor de ponto flutuante de 64 bits. Valores ausentes são representados por NaN (*Not a Number*).

O DataFrame é o tipo central da linguagem — praticamente toda análise econométrica começa com um DataFrame carregado de alguma fonte.

14.2 Semântica de cópia (COW)

DataFrames usam *copy-on-write* (COW): atribuir um DataFrame a outra variável cria um alias que compartilha os mesmos dados internos. A cópia real ocorre apenas no momento em que um dos dois é modificado.

```
1 load "painel.csv" as df
2
3 let baseline = df          // alias barato, sem cópia
4
5 let df2 = df |> generate(z = x^2)    // df2 tem 'z', df não
6 let df3 = df |> filter(ano > 2000)  // df3 filtrado, df
   intacto
7
8 // baseline == df original em qualquer ponto
```

Listing 14.1: COW: baseline preservado

Esta semântica permite criar variantes de análise sem custo de memória até que uma modificação real seja necessária.

14.3 Criando DataFrames

Bloco `input`

Para pequenos datasets inline — ideal para exemplos e testes:

```
1 input x y z
2   1   2  10
3   3   4  20
4   5   6  30
5 end
```

Listing 14.2: input block

O bloco `input` cria um DataFrame chamado `df` por padrão. O número de colunas é definido pelo cabeçalho; cada linha de dados deve ter o mesmo número de valores.

Nota

`input` aceita apenas valores numéricos. Use `.` para representar valores ausentes. Para dados com colunas de texto, use `load`.

`dataframe(n)` — DataFrame vazio pré-dimensionado

Cria um DataFrame vazio com um número fixo de linhas. Útil para pré-dimensionar antes de preenchê-lo com `generate`:

```
1 let df = dataframe(1000)
2
3 generate df u = rnormal(0, 1)
4 generate df treat = rbernoulli(0.5)
```

Listing 14.3: DataFrame pré-dimensionado

`load` — arquivos externos

```
1 load "dados.csv" as vendas
2 load "painel.dta" as painel // formato Stata
3 load "resultado.parquet" as df
4 load "planilha.xlsx" as df // primeira aba
5 load "planilha.xlsx" sheet="Dados" as df
6 load "base.db" as df, table=precos
7 load "base.db" as df, query="SELECT * FROM precos WHERE ano >
   2020"
```



```
8 load "dados.csv" as df, sep=";"
```

Listing 14.4: Carregando arquivos

Formatos suportados: CSV, TSV, JSON, Parquet, Stata (.dta), Excel (.xlsx/.xls/.ods), SQLite, ODBC. URLs HTTP(S) são baixadas automaticamente.

Projeção de colunas e filtro de linhas (columns=, where=)

Para arquivos grandes, carregar todas as colunas e linhas em RAM pode ser desperdício ou inviável. As opções `columns=` e `where=` fazem *pushdown* da projeção e do filtro para a fonte de dados: apenas as colunas pedidas e as linhas que casam com o predicado são materializadas em memória.

```
1 load "cotacoes.parquet" as aapl, columns=[ticker, date,
    adj_close], where="ticker == \"AAPL\""
2 load "base.db" as df, table=precos, columns=[data, close],
    where="close > 100"
3 load "survey.csv" as df, where="age >= 18 && region == \"
    South\""
4 load "painel.dta" as df, columns=[id, year, y], where="year
    >= 2000"
5 load "planilha.xlsx" as df, columns=[name, score], where="
    score > 75"
```

Listing 14.5: Pushdown de colunas e filtro

Fonte	columns=	where=	Mecanismo de pushdown
Parquet	sim	sim	Arrow ProjectionMask + RowFilter + <i>row group pruning</i>
SQLite	sim	sim	SELECT cols FROM t WHERE pred
ODBC	sim	sim	idem SQLite
CSV / TSV	sim	sim	projeção no loop, predicado linha a linha
DTA	sim	sim	projeção em <code>read_record</code> , predicado linha a linha
Excel	sim	sim	projeção após <code>worksheet_range</code> , filtro nas células
JSON	ainda não	ainda não	—

Passar `columns=` ou `where=` para um load JSON retorna erro. `query=` não pode ser combinado com `columns=` ou `where=` — se você precisa de SQL customizado, escreva a projeção e o filtro dentro da própria string de `query`.

Sintaxe de `columns=`

Aceita uma lista de nomes de colunas (identificadores ou strings):

```
1 columns=[ticker, date, adj_close]
2 columns=["ticker", "date", "adj_close"]
3 columns=ticker                // coluna única também aceita
```

Os nomes são validados contra o *schema* da fonte antes de qualquer dado ser lido; colunas inexistentes produzem erro listando as disponíveis.

Sintaxe de `where=`

`where=` aceita uma expressão Hayashi da forma `coluna OP literal`, combinada com `&&`, `||`, `!` e `in [...]`. A expressão é parseada pelo parser do Hayashi e normalizada em um `RowPredicate` que cada loader avalia (ou empurra para a fonte).

```
1 where="ticker == \"AAPL\""                // igualdade
   de string
2 where="preco > 100"                        // comparação
   numérica
3 where="preco > 100 && volume > 1e6"        // AND
4 where="ticker in [\"AAPL\", \"MSFT\"]"      // pertinência
5 where="!(setor == \"Financeiro\")"         // negação
6 where="ano >= 2022 && produto == \"Soja\""  // combinado
```

Operadores suportados: `==`, `!=`, `>`, `>=`, `<`, `<=`, `in`, `&&` (e), `||` (ou), `!` (não). Comparações devem ser `coluna OP literal` — comparar duas colunas não é suportado (use `generate + filter` para isso).

Nota

Em arquivos Parquet grandes, o *pushdown* de filtro é especialmente eficaz: o predicado é avaliado durante o *scan* do *row group*, antes de qualquer dado ser decodificado para a memória. Em um arquivo de 837 MB com 30 milhões de linhas e 8.292 *tickers*, carregar `columns=[ticker, date, adj_close]`, `where="ticker == \"AAPL\"` reduziu o pico de RAM de ~7,5 GB (carga *eager* completa) para ~4 MB.

Row group pruning por estatísticas (Parquet)

Além do `RowFilter` (que avalia o predicado em cada linha durante o *scan*), o loader do Parquet lê as estatísticas de min/max de cada *row group* nos metadados do arquivo

e pula *row groups* inteiros onde o predicado não pode casar. Isso é especialmente eficaz quando os dados estão ordenados ou agrupados pela coluna filtrada.

No mesmo arquivo de 799 MB com 30 milhões de linhas e 8.292 *row groups* ordenados por *ticker*, `where="ticker == \"AAPL\"` podou 8.291 de 8.292 *row groups*, reduzindo o tempo de carga de ~62 s (*full scan*) para ~312 ms (212× mais rápido) com ~60 MB de RAM.

Nota

Para *point lookups* (buscar um único valor, como um *ticker* específico), SQLite com índice B-tree em (*ticker*, *date*) ainda é mais rápido (~42 ms, ~26 MB de RAM) porque faz *seek* direto sem ler metadados de todos os *row groups*. Para análise colunar completa (todas as linhas, poucas colunas), Parquet com *pruning* é superior devido à compressão colunar.

Tipos temporais no Parquet

Colunas do tipo `Timestamp(s|ms|μs|ns)`, `Date32` e `Date64` no Parquet são convertidas para **strings ISO 8601**: `YYYY-MM-DD` quando a parte de tempo é meia-noite, ou `YYYY-MM-DDTHH:MM:SS` caso contrário. O Hayashi não possui tipo *Date* nativo, então a representação textual é a mais prática para econometria — permite extração de componentes via `substr` e conversão para *timestamp* Unix quando necessário.

```
1 load "cotacoes.parquet" as df, columns=[ticker, date, close]
2
3 generate df ano = substr(date, 0, 4)           // "2024" (
   vetorial)
4 generate df mes = substr(date, 5, 2)           // "03" (
   vetorial)
```

Listing 14.6: Extrair componentes de datas

Nota

`substr()` é vetorial e funciona dentro de `generate`, produzindo colunas de string. Já `date()` e `datetime()` são funções escalares — aceitam uma única string ISO e retornam um `Float` (segundos desde 1970-01-01). Exemplo: `let ts = date("2024-03-15")`.

14.4 Salvando DataFrames

```
1 save df "saida.csv"
2 save df "saida.parquet"
3 save df "saida.dta"
4 save df "saida.xlsx"
```

14.5 Inspeccionando DataFrames

display

Exibe as primeiras linhas do DataFrame:

```
1 display df
2 display df, 20    // exibe até 20 linhas
```

describe

Exibe a estrutura: número de observações, variáveis e tipos:

```
1 describe df
```

Saída típica:

```
DataFrame: 1250 obs, 8 vars
  ano      Float  (0 missing)
  uf       Float  (0 missing)
  renda    Float  (12 missing)
  gini     Float  (3 missing)
```

count e nrow

Retorna o número de linhas:

```
1 let n = count(df)           // total de observações
2 let n2 = nrow(df)           // alias de count(df)
3 // contagem condicional
4 let n3 = count(df, renda > 1000)
```

14.6 Variáveis especiais

Dentro de comandos que operam linha a linha (`generate`, `mutate`, `filter`), duas variáveis implícitas estão disponíveis:

Número da linha atual (começa em 1).

Total de linhas do DataFrame.

```
1 generate df id = _n           // 1, 2, 3, ..., N
2 generate df peso = 1.0/_N     // peso uniforme
```

14.7 Operadores de séries temporais

Dentro de expressões de `generate` (forma imperativa), operadores especiais para séries temporais estão disponíveis:

Operador	Significado	Exemplo
<code>L.x</code>	Lag (valor anterior)	<code>L.pib</code> $\rightarrow$ <code>pib_{t-1}</code>
<code>-N-nF.x</code>	Lead (valor seguinte)	<code>F.taxa</code> $\rightarrow$ <code>taxa_{t+1}</code>
<code>D.x</code>	Diferença primeira	<code>D.pib</code> $\rightarrow$ <code>pib_t - pib_{t-1}</code>
<code>L2.x</code>	Lag de ordem 2	<code>L2.pib</code> $\rightarrow$ <code>pib_{t-2}</code>

```
1 generate df dpib = D.pib      // variação do PIB
2 generate df pib_lag = L.pib   // PIB defasado um período
```

Listing 14.7: Operadores de séries temporais

Capítulo 15

Manipulação de Dados

15.1 `generate` e `mutate`

Criam ou substituem colunas. As duas formas são equivalentes em resultado; diferem na semântica de mutação:

Forma	Semântica	Exemplo
<code>generate df col = expr</code>	Imperativa (muta <code>df</code>)	estilo Stata
<code>let df2 = generate(df, col = expr)</code>	Funcional (df inalterado)	estilo funcional
<code>df > generate(col = expr)</code>	Pipe assign-back (muta <code>df</code>)	encadeamento

```
1 load "dados.csv" as df
2
3 generate df lrenda = log(renda)
4 generate df renda2 = renda^2
5 generate df dummy = if(renda > 1000, 1, 0)
```

Listing 15.1: `generate`: forma imperativa

```
1 let df2 = mutate(df, lrenda = log(renda), renda2 = renda^2)
2 // df não possui lrenda nem renda2
3 // df2 as possui
```

Listing 15.2: `mutate`: forma funcional

15.2 Geradores de variáveis aleatórias

Todas as distribuições abaixo estão disponíveis dentro de expressões `generate`. Elas respeitam a semente global definida por `set_seed` e retornam um valor por linha,

propagando parâmetros escalares para o comprimento do DataFrame.

```
1 set_seed(42)
2 let df = dataframe(1000)
3
4 generate df u = rnormal(0, 1)
5 generate df treated = rbernoulli(0.5)
6 generate df duration = rexponential(1)
```

Listing 15.3: Simulando dados

Contínuas: `rnormal`, `rlognormal`, `rskewnormal`, `rcauchy`, `rstudentt` (alias `rt`), `rchisq`, `rf`, `rbeta`, `rgamma`, `rexponential`, `rweibull`, `rpareto`, `rpert`, `rtriangular`, `rfrechet`, `rgumbel`, `rinversegaussian`, `rnig`, `runiform`.

Discretas: `rbernoulli`, `rbinomial`, `rpoisson`, `rgeometric`, `rhypergeometric`, `rzeta`, `rzipf`.

Nota

`rgeometric(p)` retorna o número de falhas antes do primeiro sucesso, com suporte $\{0, 1, 2, \dots\}$.

15.3 filter

Seleciona linhas que satisfazem uma condição:

```
1 let recentes = filter(df, ano >= 2010)
2 let ricos = filter(df, renda > 5000 and uf == "SP")
```

A forma imperativa usa `keep`:

```
1 keep df if ano >= 2010
```

15.4 select e drop

```
1 // mantém só essas colunas
2 let slim = select(df, ano, uf, renda)
3 let sem_id = drop(df, id, codigo)           // remove essas
      colunas
```


15.5 rename

```
1 rename df antiga nova
2 // renomeia renda_familiar → renda
3 rename df renda_familiar renda
```

15.6 sort

```
1 sort df ano // ascendente
2 sort df renda desc // descendente
3 sort df uf ano desc // múltiplas colunas
```

15.7 dropna

Remove linhas com valores ausentes:

```
1 dropna df // remove linhas com qualquer NaN
2 // remove linhas com NaN em renda ou gini
3 dropna df renda gini
```

15.8 ffill

Forward-fill substitui NaN pelo último valor não ausente. Útil quando uma série mensal ou trimestral precisa ser expandida para frequência diária:

```
1 let daily = merge(asset, rf, key=date, type=left)
2 let daily = ffill(daily)
```

Listing 15.4: Preenchendo uma taxa mensal em dados diários

15.9 append

Empilha dois DataFrames verticalmente:

```
1 let df_total = append(df_2024, df_2025)
```

As colunas devem ser compatíveis. Colunas ausentes em um dos DataFrames são preenchidas com NaN.

15.10 rbind

Concatena uma *lista* de DataFrames verticalmente em uma única passada. Entradas `nil` são silenciosamente ignoradas — útil ao combinar resultados de `parallel for` onde algumas iterações retornam `nil`:

```
1 let resultados = parallel for i in 0..n, threads=8 {
2   let t = tickers[i]
3   if t == "SPY" { return nil }
4   let df_t = calcular_betas(t)
5   df_t
6 }
7 let todos_betas = rbind(resultados)
```

Listing 15.5: `rbind` com `parallel for`

15.11 collapse e group_by

`group_by` agrega por grupos:

```
1 let media_uf = group_by(df, uf,
2   renda_media = mean(renda),
3   n            = count()
4 )
```

Listing 15.6: Agregação por grupo

`collapse` é a forma imperativa estilo Stata:

```
1 collapse df (mean) renda gini, by(uf ano)
```

15.12 pivot_longer e pivot_wider

```
1 let longo = pivot_longer(df,
2   cols = ["t1", "t2", "t3"],
3   names = "trimestre",
4   values = "valor"
5 )
```

Listing 15.7: Formato largo para longo

```

1 let largo = pivot_wider(df,
2   id       = "municipio",
3   names    = "ano",
4   values   = "pib"
5 )

```

Listing 15.8: Formato longo para largo

15.13 replace

Substitui valores condicionalmente:

```

1 // zera valores negativos
2 replace df renda = 0 if renda < 0
3 replace df gini = . if gini > 1      // marca como missing

```

15.14 tabulate

Tabela de frequências:

```

1 tabulate df uf
2 tabulate df uf ano    // tabulação cruzada

```

15.15 Auxiliares de arquivo

Pequenos auxiliares para scripts que persistem dados ou verificam cache:

```

1 ensure_dir("cache")      // cria diretório se não
                            // existir
2 if file_exists("cache/dados.csv") {
3   load "cache/dados.csv" as df
4 } else {
5   let df = download(...)
6   export(df, "csv", "cache/dados.csv")
7 }
8
9 write("texto bruto", "nota.txt") // escreve string em
                                 // arquivo

```

Listing 15.9: Auxiliares de cache

15.16 rolling

`rolling` estima OLS em uma janela móvel. É útil para visualizar coeficientes que variam no tempo ou testar a estabilidade de parâmetros. Uma coluna `date` opcional armazena o rótulo do final de cada janela.

```
1 let roll = rolling(y ~ x1 + x2, df, window=252, date=date)
2 let betas = tidy(roll)
3 print(betas)
```

Listing 15.10: OLS rolante com rótulos de data

15.17 tidy e glance

Essas funções convertem objetos de modelo em DataFrames. `tidy` retorna um DataFrame organizado com coeficientes, erros-padrão e intervalos de confiança. Para modelos `rolling`, retorna uma linha por janela com colunas `date`, `r2` e uma coluna de coeficiente por variável. `glance` retorna um resumo de uma linha com estatísticas de ajuste.

Ambas as funções suportam todos os tipos de modelo: OLS, IV, logit, probit, ordenado, multinomial, painel (FE, RE, PCSE, GLS, GLSAR, Arellano-Bond, SystemGMM), séries temporais (ARIMA, AutoReg, ARDL, GARCH, VAR, VECM, VARMA, ETS, Kalman), sobrevivência (Cox, KM), causal (DiD, Threshold), multivariada (SUR, 3SLS), regularização (ridge, lasso, elasticnet), entre outros.

```
1 let m = ols(y ~ x1 + x2, df)
2 let coefs = tidy(m)
3 let summary = glance(m)
```

Listing 15.11: Tidy e glance

Capítulo 16

O Operador Pipe

16.1 Sintaxe básica

O operador `|>` passa o valor à sua esquerda como primeiro argumento da função à sua direita:

```
1 expr |> f(args...)
2 // equivale a: f(expr, args...)
```

Sem pipe:

```
1 display sort(filter(df, renda > 0), renda desc)
```

Com pipe:

```
1 df |> filter(renda > 0) |> sort(renda desc) |> display
```

O pipe permite ler transformações na ordem em que ocorrem, da esquerda para a direita (ou de cima para baixo), sem aninhamento de parênteses.

16.2 Semântica com DataFrames

O comportamento do pipe com DataFrames segue uma regra única:

Forma	Efeito
<code>df > f(...)</code>	Assign-back: <code>df</code> recebe o resultado
<code>let df2 = df > f(...)</code>	Funcional: <code>df</code> inalterado, <code>df2</code> é novo

Assign-back

Quando o pipe começa com uma variável (`df |> ...`) e não há `let`, o resultado é atribuído de volta à variável de origem:

```
1 load "dados.csv" as df
2
3 df |> filter(ano >= 2010)
4     |> dropna
5     |> sort(renda desc)
6
7 // df agora é o resultado de todas as transformações
```

Listing 16.1: Assign-back: df é modificado

Forma funcional com let

```
1 load "dados.csv" as df
2
3 let df_limpo = df
4     |> filter(ano >= 2010)
5     |> dropna
6
7 // df está intacto; df_limpo é a versão filtrada
```

Listing 16.2: let preserva o original

16.3 COW e pipes

A semântica COW garante que o assign-back é eficiente: enquanto df e df_limpo compartilham os mesmos dados (antes de qualquer mutação), nenhuma cópia de memória ocorre. A cópia real acontece apenas quando os dados divergem.

```
1 load "painel.csv" as df
2 let baseline = df           // alias barato
3
4 df |> filter(tratamento == 1) // modifica df, não baseline
5
6 display count(baseline)      // todas as obs originais
7 display count(df)           // só o grupo de tratamento
```

Listing 16.3: Preservando baseline com let

16.4 Encadeamento longo

O pipe é especialmente útil em pipelines de limpeza e transformação:

```

1 load "pnad.csv" as pnad
2
3 let amostra = pnad
4   |> filter(idade >= 18 and idade <= 65)
5   |> filter(horas_trab > 0)
6   |> dropna
7   |> generate(lrenda = log(renda + 1))
8   |> generate(exp = idade - anos_estudo - 6)
9   |> generate(exp2 = exp^2)
10  |> sort(uf ano)
11
12 display count(amostra)

```

Listing 16.4: Pipeline completo de preparação

16.5 Uso de placeholders

Se você precisar passar o valor da esquerda para uma posição específica de argumento diferente da primeira, pode utilizar o caractere underscore (`_`) como placeholder:

```

1 expr |> f(a, _)
2 // equivale a: f(a, expr)

```

Isso é particularmente útil ao passar DataFrames para estimadores (como `ols` ou `iv`), onde o DataFrame não é o primeiro argumento:

```

1 let modelo = df |> ols(y ~ x1 + x2, _)

```

16.6 Pipe com closures

O operador `|>` também funciona com closures:

```

1 let resultado = 5 |> fn(x) { x^2 + 1 }
2 display resultado // 26

```


Capítulo 17

Módulos, Pacotes e Plugins

17.1 O Sistema de Módulos do Hayashi

Em HAYASHI, o compartilhamento e a organização de código são feitos através de dois comandos principais: `source` e `import`.

17.1.1 O comando `source`

O comando `source` executa um arquivo `.hay` diretamente no contexto atual. Todas as definições (funções e variáveis) do arquivo ficam visíveis no escopo global de quem o executa, sem namespaces:

```
1 source "lib/utils.hay"
2 let resultado = minha_funcao_util(10)
```

Listing 17.1: Uso básico de `source`

17.1.2 O comando `import`

O comando `import` carrega um módulo isolando suas funções sob um `**namespace**` usando o delimitador `::`. Isso evita conflitos de nomes e organiza melhor o código:

```
1 // Importa e usa o nome do arquivo como namespace padrão
2 import("lib/matematica.hay")
3 let r1 = matematica::calcular_media([10, 20, 30])
4
5 // Importa definindo um alias customizado
6 import("lib/matematica.hay", as=mat)
7 let r2 = mat::calcular_media([10, 20, 30])
8
```

```
9 // Importa apenas funções específicas diretamente para o
   escopo local
10 import("lib/matematica.hay", only=["calcular_media"])
11 let r3 = calcular_media([10, 20, 30])
```

Listing 17.2: Importando com namespace

17.2 Gerenciador de Pacotes e Publicação no GitHub

O HAYASHI utiliza o ****GitHub diretamente como registro de pacotes****. Isso elimina a necessidade de um repositório centralizado proprietário e promove a distribuição descentralizada de código aberto.

17.2.1 Comandos do CLI

Para gerenciar pacotes de terceiros pelo terminal do sistema operacional, use:

```
hay install usuario/repositorio -- Instala um pacote do
    GitHub (-y para pular prompt de sobrescrita)
hay remove usuario/repositorio -- Desinstala um pacote (
    deleta arquivos, pastas e metadados)
hay list -- Lista pacotes e plugins
    instalados
hay check-plugin [user/repo] -- Verifica a integridade/
    versao contra o repositorio remoto
hay update [user/repo] [-y] -- Atualiza o(s) pacote(s)
    para a versao mais recente (-y pula prompt)
```

17.2.2 Estrutura Padrão de um Pacote

Os pacotes do Hayashi são baseados em convenção e exigem configuração zero:

- **Pacotes de Script:** Basta fazer push de seus scripts `.hay` para a raiz de um repositório no GitHub (ex: `github.com/joao/financas/juros.hay`).
- **Plugins Nativos:** Configure um workflow do GitHub Actions para compilar e subir os binários gerados (`.so`, `.dll`, `.dylib` ou `.wasm`) como assets em um GitHub Release.

Depois de subir seu pacote no GitHub, qualquer usuário do mundo poderá instalar e usar no Hayashi, seja pela CLI ou diretamente dentro de um script:

```

1 // No terminal do sistema operacional:
2 // hay install joao/financas
3
4 // Dentro do proprio script Hayashi:
5 install("joao/financas")
6 import("joao/financas/juros")
7 let taxa = finanzas::calcular_taxa(1000, 12)

```

Listing 17.3: Instalando e importando um pacote

A função `install("usuario/repositorio")` também aceita os argumentos opcionais `version` (para uma versão específica, ex.: `version="v1.2.3"`) e `force=true` (para sobrescrever uma instalação existida sem prompt).

17.3 Desenvolvimento de Plugins Avançados

Para necessidades que exigem alta performance ou integração com outras linguagens, o Hayashi suporta três tipos de plugins sob a mesma sintaxe de `import`:

17.3.1 1. Plugins de Script (.hay)

Desenvolvidos em Hayashi puro. Úteis para funções econométricas compostas e utilitários rápidos.

17.3.2 2. Plugins Nativos (Exclusivos em Rust)

Os plugins nativos são desenvolvidos em Rust para garantir máxima performance e segurança de memória. Eles se comunicam com o Hayashi através de uma FFI C-string JSON estável e desacoplada.

Para facilitar o desenvolvimento, você deve usar o SDK oficial `hayashi-plugin-sdk`. O SDK fornece macros de procedimento para gerar automaticamente todo o boilerplate FFI unsafe e lidar com a serialização/deserialização JSON:

```

1 use hayashi_plugin_sdk::{hayashi_fn, hayashi_plugin};
2
3 // A macro #[hayashi_fn] lida automaticamente com a (de)
   serialização JSON.

```

```

4 // Você pode usar tipos padrão do Rust (Vec, HashMap, String,
   // primitivos, etc.).
5 #[hayashi_fn]
6 pub fn distance_to_point(lats: Vec<f64>, lons: Vec<f64>,
   ref_lat: f64, ref_lon: f64) -> Vec<f64> {
7     lats.iter()
8         .zip(lons.iter())
9         .map(|(&lat, &lon)| {
10         // calculo da distancia de Haversine
11         let r = 6371.0;
12         let d_lat = (ref_lat - lat).to_radians();
13         let d_lon = (ref_lon - lon).to_radians();
14         let a = (d_lat / 2.0).sin().powi(2)
15             + lat.to_radians().cos() * ref_lat.to_radians()
16               .cos() * (d_lon / 2.0).sin().powi(2);
17         let c = 2.0 * a.sqrt().atan2((1.0 - a).sqrt());
18         r * c
19     })
20     .collect()
21 }
22 // Gera as funções necessárias para limpeza de memória via
   // FFI
23 hayashi_plugin!();

```

Listing 17.4: Desenvolvendo um plugin nativo usando o SDK

Compilado como um `cdylib`, você pode publicar seu plugin criando uma tag (ex: `v0.1.0`) no GitHub. O workflow de GitHub Actions irá compilar o plugin para Linux (`.so`), macOS (`.dylib`) e Windows (`.dll`), fazendo o upload deles como assets do release.

Qualquer usuário pode instalá-lo pela CLI ou dentro de um script:

```

hay install john/spatial          // no terminal do sistema
operacional
install("john/spatial")          // dentro de um script Hayashi

```

O gerenciador de pacotes baixa automaticamente o binário correto correspondente ao sistema operacional e arquitetura do usuário.

Você pode então carregá-lo e nomear seu namespace no Hayashi:

```

1 import("john/spatial", as=geo)

```

```

2 let dist = geo::distance_to_point(df["lat"], df["lon"],
    -30.03, -51.22)
3 generate df dist_poa = dist

```

Considerações de Segurança e Memória: JSON ABI vs. Zero-Copy FFI

Embora a ABI JSON baseada em C-strings padrão ofereça um desacoplamento e segurança extremos (já que evoluções no esquema JSON não quebram layouts de memória física), ela pode se tornar um gargalo ao compartilhar grandes volumes de dados (Big Data) devido ao overhead de serialização.

Para mitigar esse problema, o Hayashi suporta compartilhamento de memória zero-copy transparente utilizando o formato FFI do Apache Arrow para trocas complexas de arrays e dataframes. Isso é feito de forma automática passando ponteiros de structs FFI (`FFI_ArrowArray` e `FFI_ArrowSchema`). Contudo, desenvolvedores devem buscar o equilíbrio ideal:

- **JSON C String:** Oferece máximo desacoplamento, segurança e compatibilidade de versão binária entre diferentes compilações de compiladores. Indicado para rotinas de controle, pequenos volumes de dados e extensibilidade geral.
- **Apache Arrow Zero-Copy:** Oferece máxima velocidade e zero overhead de alocação de memória. Indicado para cálculos de uso intensivo de dados, inferência de redes neurais ou grandes estimações econométricas. Exige uma coordenação estrita do ciclo de vida de memória (prevenção manual de bugs de liberação dupla na fronteira FFI).

Esta dualidade representa uma decisão de projeto intencional da linguagem Hayashi. Limitar o suporte a zero-copy estritamente a DataFrames e colunas homogêneas protege o ecossistema contra o perigo de quebras de compatibilidade binária (ABI) em estruturas de controle e dados complexas, as quais são leves para serializar via JSON C String. Dessa forma, mantém-se a estabilidade e a facilidade de manutenção de longo prazo da linguagem sem comprometer a performance no tráfego de dados volumosos.

17.3.3 3. Plugins WebAssembly (WASM - Para demais linguagens)

Para desenvolvedores utilizando outras linguagens (como C, Go, Zig, etc.), a compilação deve ser feita obrigatoriamente para WebAssembly (`.wasm`). Esses arquivos são

executados de forma totalmente isolada (sandboxed) através de um motor WASM integrado ao Hayashi, garantindo segurança total (qualquer falha no plugin não derruba o Hayashi) e portabilidade multiplataforma instantânea.

O plugin WASM deve exportar as funções `alloc(size: i32) -> i32` e `dealloc(ptr: i32, size: i32)` para gerenciar a passagem de strings JSON na memória linear do WASM, e a função do plugin deve retornar um `i64` contendo o ponteiro (nos 32 bits superiores) e o tamanho (nos 32 bits inferiores) da string JSON de retorno.

Capítulo 18

Depuração

HAYASHI inclui um servidor do Debug Adapter Protocol (DAP) embutido. Com a extensão do VS Code é possível definir breakpoints, executar passo a passo e inspecionar variáveis.

18.1 Iniciando uma sessão de debug

Certifique-se de que o binário `hay` esteja no `PATH`. No VS Code abra um arquivo `.hay`, vá ao painel **Run and Debug**, escolha a configuração **”Debug Hayashi script”** e inicie a depuração.

Por baixo dos panos o VS Code executa:

```
hay dap script.hay
```

O servidor DAP suporta breakpoints, *step over/in/out*, *continue*, escopos (Locals / Globals) e inspeção de variáveis.

18.2 Inspeccionando resultados de modelos

Quando a execução pausa, os objetos de modelo se expandem no painel Variables com um resumo curto e filhos estruturados.

```
result: OLS(k=2, n=10000), R2=1.0000
  coefficients    DataFrame(2 rows, 7 cols)
  fit             Dict(13 entries)
  residuals       Series(residuals: 10000 values)
  fitted_values   Series(fitted_values: 10000 values)
  params          Series(params: 2 values)
  std_errors      Series(std_errors: 2 values)
```

```
test_values      Series(test_values: 2 values)
p_values         Series(p_values: 2 values)
conf_lower       Series(conf_lower: 2 values)
conf_upper       Series(conf_upper: 2 values)
```

18.2.1 Filhos

coefficients Tabela de coeficientes como DataFrame: `variable`, `coef`, `std_err`, `t` ou `z`, `p_value`, `conf_low`, `conf_high`.

fit Estatísticas de ajuste específicas do modelo como Dict (R^2 , pseudo R^2 , log-verossimilhança, AIC/BIC, `n_obs`, `df_resid`, etc.).

params, **std_errors**, **test_values**, **p_values** Vetores brutos de coeficientes como Series.

conf_lower / **conf_upper** Limites do intervalo de confiança, quando disponíveis.

residuals / **fitted_values** Apenas para OLS.

18.3 Estimadores suportados

A expansão estruturada funciona para os seguintes tipos de resultado:

- Corte transversal: OLS, IV/2SLS, regressão quantílica, GMM, GLSAR
- Painel: efeitos fixos, efeitos aleatórios, PCSE, PanelGLS, FE-2SLS, Arellano-Bond, system GMM
- Binário: logit e probit
- Contagem: Poisson, binomial negativa, ZIP/ZINB
- Limitada: Tobit, logit/probit ordenado, logit multinomial
- Outros GLM: GLM, RLM, regressão beta, modelos mistos / HLM
- Sistemas: SUR e three-stage least squares (cada equação é um nó filho)

Nota

Modelos de séries temporais (ARIMA, GARCH, VAR, etc.) ainda aparecem como texto simples no debugger, sem filhos estruturados.

18.4 Debug pela linha de comando

Você também pode iniciar o servidor DAP manualmente para testes ou integração com outros editores:

```
hay dap script.hay
```

Ele lê mensagens DAP da `stdin` e escreve respostas na `stdout`. A extensão do VS Code gerencia o protocolo automaticamente.

Parte II

Econometria Aplicada

Capítulo 19

Estatística Descritiva e Momentos

Este capítulo apresenta as ferramentas de estatística descritiva do HAYASHI como expressões da teoria das probabilidades. Cada função mapeia diretamente para um conceito teórico, tornando o código legível tanto para quem vem da matemática quanto para quem vem do Stata ou R.

19.1 Valor esperado

O valor esperado $E(X)$ de uma variável aleatória discreta é a média ponderada de seus valores. Para dados observados, o estimador natural é a média amostral:

$$\hat{E}(X) = \bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

Em HAYASHI, `mean` aceita uma lista ou uma coluna de `DataFrame`:

```
1 // sobre lista
2 let xs = [2.0, 4.0, 4.0, 4.0, 5.0, 5.0, 7.0, 9.0]
3 display mean(xs)    // 5.0
4
5 // sobre coluna de DataFrame
6 load "dados.csv" as df
7 display mean(df, renda)
```

Listing 19.1: $E(X)$ sobre lista e sobre coluna

19.2 Variância e desvio padrão

A variância amostral e o desvio padrão amostral são:

$$\widehat{\text{Var}}(X) = s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2 \quad s = \sqrt{s^2}$$

O divisor $n - 1$ (correção de Bessel) produz um estimador não viesado de σ^2 . Todas as funções de HAYASHI usam essa convenção.

```
1 display variance(df, renda)    // s2
2 display sd(df, renda)         // s
```

Listing 19.2: Variância e desvio padrão

Nota

`sd` e `std` são aliases — ambos calculam o desvio padrão amostral com divisor $n - 1$.

Para obter ambos de uma vez, `summarize` retorna um dicionário com todos os momentos:

```
1 let stats = summarize(df, renda)
2
3 display stats["mean"]      // média
4 display stats["sd"]       // desvio padrão
5 display stats["variance"]  // variância
6 display stats["min"]      // mínimo
7 display stats["max"]      // máximo
8 display stats["N"]        // número de observações
```

19.3 Momentos condicionais

O valor esperado condicional $E(X \mid C)$ restringe o cálculo a um subconjunto da amostra sem criar um DataFrame auxiliar. A opção `if` = está disponível em todas as funções de agregação escalar:

```
1 // E(renda | setor == "publico")
2 display mean(df, renda, if = setor == "publico")
3
4 // Var(renda | setor == "publico")
5 display variance(df, renda, if = setor == "publico")
6
7 // DP(renda | setor == "publico")
8 display sd(df, renda, if = setor == "publico")
```

Listing 19.3: Momentos condicionais com `if =`

A condição é avaliada linha a linha no `DataFrame` — qualquer expressão booleana sobre colunas é válida:

```
1 display mean(df, salario, if = educ >= 12 and sexo == 1)
2 display sd(df, renda, if = uf == "RS" or uf == "SC")
```

Listing 19.4: Condições compostas

Dica

`if` = não altera o `DataFrame`. Para criar uma amostra permanente use `filter`; para um cálculo pontual use `if =`.

19.4 Covariância

A covariância amostral entre X e Y mede a variação conjunta:

$$\widehat{\text{Cov}}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})$$

```
1 display cov(df, educ, salario)
2
3 // condicional: apenas trabalhadores formais
4 display cov(df, educ, salario, if = formal == 1)
```

Listing 19.5: Covariância entre duas colunas

Nota

$\text{Cov}(X, X) = \text{Var}(X)$. Para verificar: `cov(df, x, x)` devolve o mesmo que `variance(df, x)`.

19.5 Correlação

19.5.1 Escalar entre duas variáveis

O coeficiente de correlação de Pearson normaliza a covariância pelo produto dos desvios padrão:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\text{DP}(X) \text{DP}(Y)} \in [-1, 1]$$

`corr_pair` devolve esse escalar diretamente:

```
1 display corr_pair(df, educ, salario)
2
3 // condicional: setor privado
4 display corr_pair(df, educ, salario, if = setor == "privado")
```

Listing 19.6: Correlação escalar

19.5.2 Matriz de correlação

Para explorar todas as relações entre múltiplas variáveis use `correlate`:

```
1 // todas as variáveis numéricas
2 correlate(df)
3
4 // subconjunto explícito
5 correlate(df, educ, exp, salario)
6
7 // com p-values (* p<0.1 ** p<0.05 *** p<0.01)
8 pwcrr(df, educ, exp, salario)
```

Listing 19.7: Matriz de correlação completa

Nota

`correlate` imprime a matriz mas não retorna um valor — use `corr_pair` quando precisar do escalar em um cálculo.

19.6 Mediana e quantis

A mediana é o valor central da distribuição ordenada, menos sensível a valores extremos que a média.

```
1 display median(df, renda)
2
3 // condicional
4 display median(df, renda, if = regioao == "Sul")
```

Listing 19.8: Mediana

Quantis generalizam a mediana para qualquer ponto $p \in [0, 1]$ da distribuição:


```

1 display quantile(df, renda, 0.25)    // 1º quartil
2 display quantile(df, renda, 0.50)    // mediana
3 display quantile(df, renda, 0.75)    // 3º quartil
4 display quantile(df, renda, 0.90)    // percentil 90

```

Listing 19.9: Quantis

quantile aceita `if` =:

```

1 // Percentil 90 da renda entre trabalhadores com ensino
  superior
2 display quantile(df, renda, 0.90, if = educ >= 16)

```

Ambas as funções aceitam listas diretamente:

```

1 let xs = [3.0, 1.0, 4.0, 1.0, 5.0, 9.0, 2.0, 6.0]
2 display median(xs)           // 3.5
3 display quantile(xs, 0.75)   // 5.25

```

19.7 Sumário detalhado

`summarize` com `detail=true` expande o dicionário de retorno para incluir assimetria, curtose e toda a grade de percentis:

```

1 let s = summarize(df, renda, detail=true)
2
3 display s["mean"]           // média
4 display s["sd"]             // desvio padrão
5 display s["p25"]            // 1º quartil
6 display s["p50"]            // mediana
7 display s["p75"]            // 3º quartil
8 display s["p90"]            // percentil 90
9 display s["p99"]            // percentil 99
10 display s["skew"]           // assimetria
11 display s["kurt"]           // curtose

```

Listing 19.10: summarize com detail

19.8 Referência rápida

Notação	Hayashi	Formas
$E(X)$	<code>mean(df, x)</code>	<code>lista / df / if =</code>
$\text{Var}(X)$	<code>variance(df, x)</code>	<code>lista / df / if =</code>
$\text{DP}(X)$	<code>sd(df, x)</code>	<code>lista / df / if =</code>
$\text{Cov}(X, Y)$	<code>cov(df, x, y)</code>	<code>df / if =</code>
$\rho(X, Y)$	<code>corr_pair(df, x, y)</code>	<code>df / if =</code>
$\text{Med}(X)$	<code>median(df, x)</code>	<code>lista / df / if =</code>
$Q_p(X)$	<code>quantile(df, x, p)</code>	<code>lista / df / if =</code>
	<code>correlate(df, x, y, ...)</code>	matriz de correlação (display)
	<code>summarize(df, x)</code>	dicionário completo de momentos

19.9 Exemplo completo

O trecho abaixo ilustra o uso conjunto dessas funções em uma análise exploratória típica antes de estimar um modelo:

```

1 load "pnad.csv" as df
2
3 // visão geral
4 summarize(df, renda)
5 summarize(df, educ)
6 correlate(df, renda, educ, exp)
7
8 // momentos por grupo
9 display mean(df, renda, if = sexo == 1)      // homens
10 display mean(df, renda, if = sexo == 0)      // mulheres
11
12 display sd(df, renda, if = sexo == 1)
13 display sd(df, renda, if = sexo == 0)
14
15 // distância entre mediana e média: sinal de assimetria
16 display mean(df, renda)
17 display median(df, renda)
18
19 // associação linear
20 display cov(df, educ, renda)
21 display corr_pair(df, educ, renda)

```

```
22  
23 // concentração no topo  
24 display quantile(df, renda, 0.90)  
25 display quantile(df, renda, 0.99)
```

Listing 19.11: Análise exploratória — renda e educação

Capítulo 20

Mínimos Quadrados Ordinários

20.1 O modelo

Considere o modelo de regressão linear:

$$y = X\beta + \varepsilon$$

onde y é um vetor $n \times 1$ de observações da variável dependente, X é uma matriz $n \times k$ de regressores (a primeira coluna é identicamente 1, correspondendo ao intercepto), β é um vetor $k \times 1$ de parâmetros desconhecidos, e ε é um vetor $n \times 1$ de erros.

Hipóteses de Gauss-Markov

1. **Linearidade:** $y = X\beta + \varepsilon$.
2. **Posto completo:** $\text{rank}(X) = k$ (sem multicolinearidade perfeita).
3. **Exogeneidade estrita:** $E[\varepsilon \mid X] = 0$.
4. **Homocedasticidade:** $\text{Var}[\varepsilon \mid X] = \sigma^2 I_n$.
5. **Não-autocorrelação:** $\text{Cov}[\varepsilon_i, \varepsilon_j \mid X] = 0$ para $i \neq j$.

Sob H1–H3 o OLS é não-viesado. Sob H1–H5 é BLUE (Teorema de Gauss-Markov).

20.2 O estimador

O estimador OLS minimiza a soma dos quadrados dos resíduos:

$$\hat{\beta} = \arg \min_{\beta} (y - X\beta)'(y - X\beta)$$

A condição de primeira ordem $X'(y - X\beta) = 0$ — as *equações normais* — tem solução analítica:

$$\boxed{\hat{\beta} = (X'X)^{-1}X'y}$$

Os resíduos são $\hat{e} = y - X\hat{\beta} = M_X y$, onde $M_X = I - X(X'X)^{-1}X'$ é a matriz de resíduos (simétrica e idempotente).

20.3 Propriedades

Sob H1–H3:

$$E[\hat{\beta}] = \beta$$

Sob H1–H5, a variância condicional do estimador é:

$$\text{Var}[\hat{\beta} \mid X] = \sigma^2(X'X)^{-1}$$

O estimador não-viesado da variância do erro é:

$$s^2 = \frac{\hat{e}'\hat{e}}{n - k}$$

e portanto $\widehat{\text{Var}}[\hat{\beta}] = s^2(X'X)^{-1}$.

20.4 Verificação por DGP

A prova mais direta de que o estimador está correto é definir um DGP (*data-generating process*) com parâmetros conhecidos, gerar dados a partir dele e verificar que o OLS os recupera.

Escolha os parâmetros verdadeiros:

$$\beta_0 = 2,5 \quad \beta_1 = 1,8 \quad \beta_2 = -0,7$$

e gere $n = 1000$ observações *sem* termo de erro ($\varepsilon = 0$):

$$y_i = 2,5 + 1,8 x_{1i} - 0,7 x_{2i}$$

Com $\varepsilon = 0$ as hipóteses de Gauss-Markov são satisfeitas de forma exata, e o OLS

deve recuperar $(\beta_0, \beta_1, \beta_2)$ com precisão de máquina.

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df x1 = rnormal()
9 generate df x2 = rnormal()
10 generate df y = 2.5 + 1.8*x1 - 0.7*x2
11 ols(y ~ x1 + x2, df)

```

Listing 20.1: DGP sem ruído — verificação numérica

Saída real do interpretador:

```

===== OLS Regression Results =====
Dep. Variable:          y || R-squared:          1.0000
Model:                  OLS || Adj. R-squared:    1.0000
Covariance Type:        Non-Robust || F-statistic: 0.0000
No. Observations:       1000 || Prob (F-statistic): 1.0000e0
Df Residuals:           997 || Log-Likelihood:    31513.9419
AIC:                    -63021.8837 || BIC:         -63007.1605

-----
Variable |      coef |      std err |      t |      P>|t| | [0.025  0.975]
-----
const   |    2.5000 |    0.0000 | 6.17e+15 |    0.000 |    2.5000  2.5000
x1       |    1.8000 |    0.0000 | 3.36e+15 |    0.000 |    1.8000  1.8000
x2       |   -0.7000 |    0.0000 |-1.28e+15 |    0.000 |   -0.7000 -0.7000
=====

```

O OLS recupera exatamente $(\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2) = (2,5; 1,8; -0,7)$. O erro padrão zero e o $R^2 = 1$ são esperados: sem ruído, os dados estão exatamente sobre o hiperplano definido por β , e o estimador é numericamente exato até a precisão de ponto flutuante.

Nota

A estatística F aparece como 0.0 e o p-valor como 1.0 neste caso — artefato numérico de 0/0 quando $SQR = 0$. As estatísticas t são da ordem de 10^{15} pelo mesmo motivo: numerador finito dividido por denominador de precisão de máquina. Em presença de ruído ($\varepsilon \neq 0$) todas as estatísticas assumem valores finitos e interpretáveis.

Efeito de má-especificação

O mesmo DGP permite verificar o que acontece ao omitir x_2 . Estimam-se dois modelos e comparam-se com `esttab`:

```
1 let m1 = ols(y ~ x1 + x2, df)
2 let m2 = ols(y ~ x1, df)
3 esttab(m1, m2)
```

Listing 20.2: Modelo correto vs. x_2 omitido

	(1)	(2)
	OLS	OLS
x1	1.8000*** (0.0000)	1.7422*** (0.0224)
x2	-0.7000*** (0.0000)	
Constant	2.5000*** (0.0000)	2.1810*** (0.0129)
N	1000	1000
R ²	1.0000	0.8585
Adj. R ²	1.0000	0.8583
* p<0.10 ** p<0.05 *** p<0.01		

O coeficiente de x_1 mal se altera ($1.8000 \rightarrow 1.7422$) porque x_1 e x_2 são gerados independentemente — a correlação amostral é próxima de zero. Já a constante distorce de 2.5000 para 2.1810 porque absorve $\hat{\beta}_2 \bar{x}_2$, e a média amostral de x_2 não é exatamente zero mesmo com $n = 1000$.

Nota

Viés de variável omitida (OVB) *requer correlação* entre o regressor incluído e o omitido. Sem correlação, a omissão apenas infla os erros padrão e reduz o R^2 (perda de eficiência, não de consistência). Para o tratamento formal de endogeneidade e instrumentos, veja o Capítulo 21.

20.5 Erros padrão

Clássico

Assume homocedasticidade. A matriz de covariância estimada é $s^2(X'X)^{-1}$ e o erro padrão do coeficiente j é $se_j = s \sqrt{[(X'X)^{-1}]_{jj}}$.

Robusto à heterocedasticidade

Quando $\text{Var}[\varepsilon_i \mid x_i] = \sigma_i^2$ (heterocedasticidade), o estimador sanduíche fornece inferência válida.

HC1 (White com correção de graus de liberdade):

$$\hat{V}_{\text{HC1}} = \frac{n}{n-k} (X'X)^{-1} \left(\sum_{i=1}^n \hat{\varepsilon}_i^2 x_i x_i' \right) (X'X)^{-1}$$

HC3 (mais conservador, recomendado em amostras pequenas):

$$\hat{V}_{\text{HC3}} = (X'X)^{-1} \left(\sum_{i=1}^n \frac{\hat{\varepsilon}_i^2}{(1-h_{ii})^2} x_i x_i' \right) (X'X)^{-1}$$

onde $h_{ii} = x_i'(X'X)^{-1}x_i$ é o *leverage* da observação i .

Clusterizado

Quando os erros são correlacionados dentro de grupos $g = 1, \dots, G$:

$$\hat{V}_{\text{cl}} = \frac{G(n-1)}{(G-1)(n-k)} (X'X)^{-1} \left(\sum_{g=1}^G X_g' \hat{\varepsilon}_g \hat{\varepsilon}_g' X_g \right) (X'X)^{-1}$$

20.6 Inferência

Teste t sobre um coeficiente

Sob $H_0: \beta_j = \beta_j^0$:

$$t_j = \frac{\hat{\beta}_j - \beta_j^0}{\text{se}(\hat{\beta}_j)} \xrightarrow{d} t_{n-k}$$

Teste F sobre restrições lineares

Para $R\beta = r$ com q restrições:

$$F = \frac{(R\hat{\beta} - r)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - r)}{q s^2} \xrightarrow{d} F_{q, n-k}$$

Nota

Com erros robustos ou clusterizados, $\hat{V}$ substitui $s^2(X'X)^{-1}$ no cálculo do teste F .

20.7 Sintaxe

```
1 ols(fórmula, df)
2 ols(fórmula, df, cov=tipo)
3 ols(fórmula, df, cov=cluster, cluster=coluna)
4 ols(fórmula, df, if = condição)
```

Alias: `reg()` é equivalente a `ols()`.

20.8 Fórmula

A fórmula segue a notação $y \sim x1 + x2 + \dots$:

```
1 input df
2 Y X
3 10 2
4 12 3
5 8 1
6 15 5
7 11 2
8 14 4
9 end
10
11 ols(Y ~ X, df)
```

Listing 20.3: OLS básico

A constante é incluída automaticamente. Para múltiplas variáveis:

```
1 ols(Y ~ X1 + X2 + X3, df)
```

A fórmula pode ser passada como string:

```
1 let formula = "Y ~ X1 + X2"
2 ols(formula, df)
```

20.8.1 Transformações

Qualquer função suportada pela linguagem pode ser usada diretamente no RHS da fórmula — o interpretador avalia a expressão *antes* de passar os dados ao estimador, de modo que o Greeners recebe apenas colunas numéricas planas.

```
1 // log de uma variável
2 ols(Y ~ log(X), df)
3
4 // raiz quadrada
5 ols(Y ~ sqrt(X), df)
6
7 // múltiplas transformações
8 ols(Y ~ log(K) + log(L), df)
9
10 // termo quadrático (equivalente a I(X^2))
11 ols(Y ~ X + X^2, df)
```

Listing 20.4: Transformações em regressores

O nome do coeficiente na tabela de resultados reflete a expressão original: `log(K)`, `sqrt(X)`, etc.

20.8.2 Interações

O operador `:` cria um termo de interação (produto *element-wise*) entre dois regressores. Cada lado pode ser uma expressão arbitrária:

```
1 // interação entre variáveis simples
2 ols(Y ~ X1 + X2 + X1:X2, df)
3
4 // interação de transformações - log(K)*log(L)
5 ols(Y ~ log(K) + log(L) + log(K):log(L), df)
6
7 // apenas o termo de interação
8 ols(Y ~ log(K):log(L), df)
```

Listing 20.5: Interações

O operador `*` é açúcar sintático para expansão completa (`x1*x2` $\equiv$ `x1 + x2 + x1:x2`):

```
1 // equivalente: ols(Y ~ X1 + X2 + X1:X2, df)
2 ols(Y ~ X1 * X2, df)
```

20.8.3 `I(expr)` — expressões aritméticas arbitrárias

A função `I(...)` isola uma expressão aritmética composta dentro da fórmula, protegendo os operadores `+`, `-` e `*` do significado especial que têm na gramática de fórmulas:

```
1 // quadrado de X
2 ols(Y ~ X + I(X^2), df)
3
4 // interação linear construída explicitamente
5 ols(Y ~ X1 + X2 + I(X1 * X2), df)
6
7 // combinação linear de variáveis
8 ols(Y ~ I(X1 + X2), df)
```

Listing 20.6: Termos arbitrários com `I()`

Nota

`I(X^2)` e `X^2` são equivalentes quando `X^2` aparece sozinho como termo (fora de interações e adições de nível superior). Use `I(...)` para eliminar qualquer ambiguidade ou quando a expressão contém `+` ou `*`.

20.8.4 Variável categórica: `C()`

`C(var)` instrui o estimador a tratar `var` como categórica, gerando dummies automáticas (categoria de referência = primeira por ordem lexicográfica):

```
1 ols(Y ~ X + C(regiao), df)
```

20.9 Opções de erro padrão

Opção	Fórmula
(padrão)	$s^2(X'X)^{-1}$
cov=robust	HC1 (sanduíche White)
cov=HC1	idem
cov=HC3	HC3 (leverage-ajustado)
cov=cluster, cluster=col	clusterizado por col

```

1  ols(Y ~ X, df)                                // clássico
2  ols(Y ~ X, df, cov=robust)                     // HC1
3  ols(Y ~ X, df, cov=HC3)                        // HC3
4  ols(Y ~ X, df, cov=cluster, cluster=id)        // clusterizado

```

Listing 20.7: Variantes de erro padrão

20.10 Amostra condicional

A opção `if` = restringe a estimação a um subconjunto sem modificar o DataFrame:

```

1  ols(Y ~ X, df, if = grupo == 1)

```

20.11 Capturando o resultado

```

1  let m = ols(Y ~ X, df)
2  display m

```

Quando atribuído, `ols()` não imprime a tabela — apenas armazena o modelo.

20.12 Pós-estimação

20.12.1 predict

```

1  let m = ols(Y ~ X, df)
2
3  //  $\hat{y} = X\hat{\beta}$ 
4  let yhat = predict(m, "xb")
5  //  $\hat{e} = y - X\hat{\beta}$ 
6  let ehat = predict(m, "residuals")

```

Aliases aceitos: "fitted" para valores ajustados; "resid" ou "e" para resíduos.

20.12.2 vif

O VIF do regressor j é $VIF_j = 1/(1 - R_j^2)$, onde R_j^2 é o R^2 da regressão de x_j sobre os demais regressores. Valores acima de 10 indicam multicolinearidade severa.

```
1 let m = ols(Y ~ X1 + X2 + X3, df)
2 vif(m)
```

20.12.3 test

Teste F de restrições lineares $H_0 : R\beta = r$:

```
1 let m = ols(Y ~ X1 + X2 + X3, df)
2 test(m, X2 = 0, X3 = 0)      // H0: X2 = X3 = 0
```

20.12.4 lincom

Combinação linear $c'\hat{\beta}$ com erro padrão $\sqrt{c'\hat{V}c}$:

```
1 let m = ols(Y ~ X1 + X2, df)
2 lincom(m, X1 + X2)
```

20.12.5 margins

Efeitos marginais médios. No OLS linear $\partial E[y]/\partial x_j = \beta_j$, equivalente aos coeficientes.

```
1 let m = ols(Y ~ X, df)
2 margins(m)
```

20.12.6 Diagnósticos de especificação

RESET de Ramsey

Testa erro de especificação adicionando potências de $\hat{y}$ como regressores:

```
1 reset(m)                // potência padrão 3
2 reset(m, power=2)       // apenas  $\hat{y}^2$ 
```

CUSUM — estabilidade estrutural

Teste CUSUM (Brown, Durbin, Evans 1975) usando resíduos recursivos. Verifica se a soma cumulativa dos resíduos recursivos permanece dentro dos limites de 5% de significância:

```
1 cusumtest(m)
```

Rejeita H_0 (estabilidade) se a soma cumulativa cruza os limites — indica quebra estrutural no período amostral.

20.12.7 Diagnósticos de resíduos

Heterocedasticidade

```
1 test(m, "white")      // White (1980) - geral
2 test(m, "bp")         // Breusch-Pagan - forma linear
3 gqtest(m, split=0.2)  // Goldfeld-Quandt - comparação de vari
                        âncias
```

O Goldfeld-Quandt divide a amostra em dois grupos (omitindo a fração central `split`) e compara as variâncias dos resíduos via estatística F .

Autocorrelação

```
1 test(m, "dw")         // Durbin-Watson - AR(1)
2 bgodfrey(m, lags=4)   // Breusch-Godfrey - AR(p) de ordem
                        arbitrária
```

Autocorrelação e PACF dos resíduos

```
1 let a = acf(m, lags=10) // FAC dos resíduos
2 let p = pacf(m, lags=10) // FAC parcial dos resíduos
3 ljungbox(m, lags=10)    // teste conjunto de autocorrelaçã
                        o
```

`acf` e `pacf` retornam listas de tamanho `lags + 1` (elemento 0 é sempre 1.0). Aceitam também `acf(df, var, lags=20)` para séries brutas. Para visualização ASCII, use `acfplot` e `pacfplot`.

Normalidade

```
1  jb(m)                                // Jarque-Bera (assimetria + curtose)
2  swilk(df, residuals)                 // Shapiro-Wilk
```

20.12.8 Diagnósticos de influência

```
1  influence(m)                         // DFBETAS, DFFITS, Cook's D,
    alavancagem
2  leverage(m)                         // apenas diagonal da hat matrix
```

20.12.9 Comparação de modelos

```
1  estat(m1, m2, m3)                   // tabela AIC/BIC com pesos de
    Akaike
2  let w = akaike_weights(m1, m2) // pesos como dict {modelo:
    peso}
```

`akaike_weights` retorna um dicionário com os pesos de Akaike $w_i = \frac{e^{-\Delta_i/2}}{\sum_j e^{-\Delta_j/2}}$, onde $\Delta_i = \text{AIC}_i - \min_j \text{AIC}_j$. Suporta OLS, logit/probit, Poisson, NegBin, Tobit, Ordered, Mixed e Zero-Inflated.

Teste de razão de verossimilhanças

Compara dois modelos aninhados — o restrito é caso especial do irrestrito:

```
1  let m1 = ols(Y ~ X1, df)
2  let m2 = ols(Y ~ X1 + X2, df)
3  lrtest(m1, m2) // H0: m1 é adequado (X2 = 0)
```

A estatística é $\text{LR} = -2(\ln L_r - \ln L_u) \sim \chi^2(\text{df})$, onde $\text{df} = k_u - k_r$. Rejeitar H_0 indica que o modelo irrestrito ajusta significativamente melhor. Funciona com qualquer estimador que reporte log-verossimilhança: OLS, logit/probit, Poisson, NegBin, Tobit, Ordered, Mixed, ZI, GLM, GARCH, ARIMA.

20.13 Tabela de resultados com `esttab`

```
1  let m1 = ols(Y ~ X, df)
2  let m2 = ols(Y ~ X, df, cov=robust)
```



```
3 let m3 = ols(Y ~ X1 + X2, df)
4
5 esttab(m1, m2, m3)
```

Listing 20.8: Comparação de especificações

```
1 eststo(ols(Y ~ X, df))
2 eststo(ols(Y ~ X1 + X2, df))
3 esttab()
```

20.14 Bootstrap

Erros padrão por bootstrap — alternativa não-paramétrica:

```
1 bootstrap(ols, Y ~ X, df, n=1000)
2 bootse(m, n=500)
```


Capítulo 21

Variáveis Instrumentais

21.1 O problema de endogeneidade

Considere o modelo estrutural:

$$y = X_1\beta_1 + X_2\beta_2 + \varepsilon$$

onde X_1 são regressores exógenos ($n \times k_1$) e X_2 são regressores potencialmente endógenos ($n \times k_2$). O OLS é viesado e inconsistente quando:

$$E[\varepsilon \mid X_2] \neq 0 \iff \text{plim } \hat{\beta}_{\text{OLS}} \neq \beta$$

As causas mais comuns são:

- **Variável omitida** correlacionada com X_2 : se $y = X\beta + W\gamma + u$ e W é omitida, então $\varepsilon = W\gamma + u$ e $\text{Cov}(X_2, \varepsilon) \neq 0$.
- **Simultaneidade**: y e X_2 são determinados conjuntamente.
- **Erro de medida clássico**: $X_2 = X_2^* + \nu$, com X_2^* verdadeiro; o atenuante é $\text{plim } \hat{\beta} = \beta \cdot \sigma_{X^*}^2 / \sigma_X^2 < \beta$.

21.2 Condições de identificação

Seja Z a matriz $n \times L$ de instrumentos (incluindo X_1 como instrumentos incluídos). Um instrumento válido satisfaz duas condições:

1. **Relevância**: $\text{rank}(E[z_i x_i']) = k$, onde $k = k_1 + k_2$. Na prática: X_2 é correlacionado com Z na primeira etapa.

2. **Exogeneidade (restrição de exclusão):** $E[z_i \varepsilon_i] = 0$. Os instrumentos excluídos afetam y *somente* através de X_2 .

O modelo é identificado quando $L \geq k$ (condição de ordem). Para $L = k$ (identificação exata) o estimador IV é único; para $L > k$ (sobreidentificação) o 2SLS é eficiente na classe dos estimadores IV.

21.3 O estimador 2SLS

Defina a matriz de projeção sobre o espaço coluna de Z :

$$P_Z = Z(Z'Z)^{-1}Z'$$

O estimador de Mínimos Quadrados em Dois Estágios (2SLS) é:

$$\hat{\beta}_{2SLS} = (X'P_ZX)^{-1}X'P_Zy$$

Interpretação em dois estágios

Primeiro estágio — projeta cada coluna de X_2 sobre Z :

$$X_2 = Z\hat{\Pi} + \hat{V}, \quad \hat{\Pi} = (Z'Z)^{-1}Z'X_2$$

Segundo estágio — regride y sobre $\hat{X} = P_ZX = [X_1, \hat{X}_2]$:

$$\hat{\beta}_{2SLS} = (\hat{X}'X)^{-1}\hat{X}'y$$

Atenção

Nunca execute os dois estágios manualmente como OLS sequencial. Os erros padrão do segundo estágio estarão errados porque $\hat{X}_2$ é estimado. Use sempre `iv()`, que corrige a variância automaticamente.

21.4 Variância assintótica

Sob exogeneidade e relevância, $\hat{\beta}_{2SLS}$ é consistente e assintoticamente normal:

$$\sqrt{n}(\hat{\beta}_{2SLS} - \beta) \xrightarrow{d} \mathcal{N}(0, \sigma^2 Q_{XZ}^{-1} Q_{ZZ} Q_{XZ}^{-1'})$$

onde $Q_{XZ} = E[x_i z_i']$ e $Q_{ZZ} = E[z_i z_i']$.

O estimador da variância é:

$$\widehat{\text{Var}}[\hat{\beta}_{2\text{SLS}}] = s_{\text{IV}}^2 (X'P_Z X)^{-1}, \quad s_{\text{IV}}^2 = \frac{\hat{e}_{2\text{SLS}}' \hat{e}_{2\text{SLS}}}{n - k}$$

As mesmas correções sanduíche do OLS (HC1, HC3, clustered) aplicam-se substituindo X por $\hat{X} = P_Z X$.

21.5 Instrumentos fracos

Um instrumento é fraco quando a correlação com X_2 é baixa. O viés do 2SLS em relação ao OLS é aproximadamente:

$$\frac{\text{Viés}_{2\text{SLS}}}{\text{Viés}_{\text{OLS}}} \approx \frac{1}{F + 1}$$

onde F é a estatística F da primeira etapa. Para $F < 10$ (regra de Staiger & Stock, 1997) o instrumento é considerado fraco.

A **estatística de Cragg-Donald** generaliza para múltiplos regressores endógenos:

$$CD = \frac{n - L}{L - k_1} \cdot \lambda_{\min}$$

onde $\lambda_{\min}$ é o menor autovalor da matriz de concentração. Stock & Yogo (2005) tabelam valores críticos para viés máximo relativo de 5%, 10%, 20% e 30% em relação ao OLS.

21.6 Verificação por DGP

O mesmo método do Capítulo 20 se aplica ao IV: define-se um DGP com endogeneidade conhecida, estima-se OLS e IV, e verifica-se que o IV corrige o viés.

Estrutura do DGP

Sejam z e v variáveis aleatórias independentes $\sim \mathcal{N}(0, 1)$. Defina ε como o *resíduo* da projeção de v sobre $[1, z]$:

$$\varepsilon = v - \delta_0 - \delta_1 z, \quad \delta_1 = \frac{\text{Cov}_n(z, v)}{\text{Var}_n(z)}, \quad \delta_0 = \bar{v} - \delta_1 \bar{z}$$

Por construção $\sum \varepsilon_i = 0$ e $\sum z_i \varepsilon_i = 0$, ou seja, $Z' \varepsilon = 0$ *exatamente* na amostra. Então:

$$x = 0,8z + \varepsilon \quad y = 1,5 + 2,0x + 0,7\varepsilon$$

O erro estrutural $0,7\varepsilon$ cria endogeneidade ($\text{Cov}(x, 0,7\varepsilon) \neq 0$), mas como $Z'\varepsilon = 0$ exatamente, as condições de momento do IV são satisfeitas sem ruído amostral. Resultado: IV recupera (β_0, β_1) com precisão de máquina — o mesmo que OLS fez sem ruído no Capítulo 20.

O viés do OLS é previsível:

$$\text{plim } \hat{\beta}_{\text{OLS}} = \beta_1 + \frac{\text{Cov}(x, \varepsilon)}{\text{Var}(x)} \approx 2,0 + \frac{0,7}{0,64 + 1} \approx 2,43$$

Script

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df z = rnormal()
9 generate df v = rnormal()
10 let d1 = cov(df, z, v) / variance(df, z)
11 let d0 = mean(df, v) - d1 * mean(df, z)
12 generate df eps = v - d0 - d1*z
13 generate df x = 0.8*z + eps
14 generate df y = 1.5 + 2.0*x + 0.7*eps
15 let m_ols = ols(y ~ x, df)
16 let m_iv = iv(y ~ x, ~ z, df)
17 esttab(m_ols, m_iv)

```

Listing 21.1: DGP com endogeneidade — OLS vs. IV

Saída real do interpretador:

	(1)	(2)
	OLS	IV/2SLS
x	2.4303*** (0.0108)	2.0000*** (0.0280)
const		1.5000*** (0.0129)

Constant	1.3273***	
	(0.0058)	
N	1000	1000
R ²	0.9807	
Adj. R ²	0.9807	

* p<0.10 ** p<0.05 *** p<0.01

O IV recupera $(\hat{\beta}_0, \hat{\beta}_1) = (1,5000, 2,0000)$ com precisão de máquina. O OLS superestima β_1 em +0,43 (2.4303 vs. 2.0000), consistente com o viés assintótico previsto de +0,43. O R^2 não é reportado para IV pois não tem interpretação padrão sob endogeneidade.

21.7 Sintaxe

```
1 iv(fórmula_estrutural, fórmula_instrumentos, df)
2 iv(fórmula_estrutural, fórmula_instrumentos, df, cov=tipo)
```

A *fórmula estrutural* especifica a equação de interesse. A *fórmula dos instrumentos* lista os instrumentos excluídos após ~:

```
1 // equação estrutural: y ~ x (x é endógeno)
2 // instrumento excluído: z
3 iv(y ~ x, ~ z, df)
```

Listing 21.2: IV básico — um instrumento

Para múltiplos regressores endógenos e instrumentos:

```
1 iv(y ~ x1 + x2, ~ z1 + z2, df)
```

21.7.1 Transformações e interações nas fórmulas

As mesmas transformações e interações disponíveis no OLS (Seção 20.8.1–20.8.3) funcionam igualmente nas fórmulas estrutural e de instrumentos do IV:

```
1 // regressor endógeno transformado
2 iv(Y ~ log(X2), ~ Z, df)
3
4 // interação de transformações na equação estrutural
5 iv(Y ~ log(K) + log(L) + log(K):log(L), ~ Z1 + Z2, df)
```

```

6
7 // instrumento transformado
8 iv(Y ~ X2, ~ log(Z), df)

```

Listing 21.3: IV com transformações e interações

Nota

Os regressores exógenos incluídos (X_1) não precisam ser listados na fórmula dos instrumentos — são adicionados automaticamente como seus próprios instrumentos.

21.8 Opções de erro padrão

As mesmas opções de `cov=` disponíveis no OLS aplicam-se ao IV:

```

1 iv(y ~ x, ~ z, df) // clássico
2 iv(y ~ x, ~ z, df, cov=robust) // HC1
3 iv(y ~ x, ~ z, df, cov=HC3) // HC3
4 iv(y ~ x, ~ z, df, cov=cluster, cluster=id) // clusterizado

```

21.9 Capturando o resultado

```

1 let m_iv = iv(y ~ x, ~ z, df)
2 display m_iv

```

21.10 Diagnóstico de instrumentos fracos

```

1 weak_iv(y ~ x, ~ z, df)

```

Listing 21.4: Teste de instrumentos fracos

A função reporta:

- Estatística F da primeira etapa (por variável endógena)
- Estatística de Cragg-Donald CD
- Valores críticos de Stock & Yogo (2005) para viés relativo de 5%–30%
- Referência: $F > 10$ (Staiger & Stock, 1997)

21.11 Testes de pós-estimação de IV

21.11.1 Sargan / Hansen J — sobreidentificação

Quando há mais instrumentos que variáveis endógenas (sobreidentificação), testa-se a exogeneidade dos instrumentos:

```
1 estat_overid(y ~ x1 + x_endog, ~ z1 + z2, df)
```

H_0 : instrumentos são exógenos (válidos). A estatística de Sargan é $n \cdot R^2$ da regressão dos resíduos IV sobre os instrumentos, distribuída como $\chi^2(L - K)$, onde L é o número de instrumentos e K o de regressores. Rejeitar H_0 indica que os instrumentos podem ser inválidos. Não se aplica quando o modelo é exatamente identificado ($L = K$).

21.11.2 Durbin-Wu-Hausman — endogeneidade

Testa se a variável suspeita é realmente endógena, comparando OLS e IV:

```
1 estat_endog(y ~ x1 + x_endog, ~ z1 + z2, df)
```

H_0 : regressores são exógenos (OLS é consistente). Usa a abordagem de regressão aumentada: adiciona os resíduos do primeiro estágio à equação estrutural e testa sua significância via F . Se rejeitar H_0 , IV é necessário; se não rejeitar, OLS é consistente e preferível (mais eficiente).

21.12 Valores ajustados

```
1 let m_iv = iv(y ~ x, ~ z, df)
2 //  $\hat{y} = X\hat{\beta}_{\{2SLS\}}$ 
3 let yhat = predict(m_iv, "xb")
```

21.13 Tabela comparativa

O fluxo típico quantifica o viés de endogeneidade comparando OLS e IV:

```
1 load "dados.csv" as df
2
3 let m_ols = ols(salario ~ educ, df)
4 let m_iv = iv(salario ~ educ, ~ distancia, df, cov=robust)
5
```

```
6 // diagnóstico da primeira etapa
7 weak_iv(salario ~ educ, ~ distancia, df)
8
9 // tabela comparativa
10 esttab(m_ols, m_iv)
```

Listing 21.5: Fluxo completo de análise IV

Se $\hat{\beta}^{IV} > \hat{\beta}^{OLS}$, o viés do OLS é negativo — o que é consistente com erro de medida atenuante ou com variável omitida que deprime tanto X_2 quanto y .

Capítulo 22

Dados em Painel

22.1 O modelo

Um painel observa n indivíduos ao longo de T períodos. O modelo geral é:

$$y_{it} = \alpha_i + X_{it}\beta + \varepsilon_{it}, \quad i = 1, \dots, n; \quad t = 1, \dots, T$$

onde α_i é o **efeito individual não observado** — características fixas no tempo que diferem entre indivíduos (habilidade, cultura, localização). O OLS em corte transversal ou empilhado ignora α_i , tratando-o como parte do erro:

$$\text{plim } \hat{\beta}_{\text{OLS}} = \beta + \frac{\text{Cov}(x_{it}, \alpha_i)}{\text{Var}(x_{it})}$$

O viés só desaparece se $\text{Cov}(x_{it}, \alpha_i) = 0$ — hipótese forte na maioria das aplicações.

22.2 Efeitos Fixos

O estimador **within** elimina α_i subtraindo a média temporal de cada indivíduo:

$$\tilde{y}_{it} = y_{it} - \bar{y}_i, \quad \tilde{X}_{it} = X_{it} - \bar{X}_i$$

O estimador de Efeitos Fixos é então o OLS sobre as variáveis desmediadas:

$$\boxed{\hat{\beta}_{\text{FE}} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y}}$$

Como a transformação within anula α_i para qualquer valor de $\text{Cov}(x_{it}, \alpha_i)$, o estimador é consistente mesmo sob endogeneidade do efeito individual. A variância

é:

$$\widehat{\text{Var}}[\hat{\beta}_{\text{FE}}] = s_{\text{FE}}^2(\tilde{X}'\tilde{X})^{-1}, \quad s_{\text{FE}}^2 = \frac{\hat{\varepsilon}'\hat{\varepsilon}}{nT - n - k}$$

Atenção

Variáveis que não variam no tempo (sexo, raça, região de nascimento) são eliminadas pela transformação within. FE não pode estimar seu efeito. Use RE ou estimadores híbridos nesses casos.

22.3 Efeitos Aleatórios

Se $\alpha_i \sim \text{IID}(0, \sigma_\alpha^2)$ e $\text{Cov}(x_{it}, \alpha_i) = 0$, α_i é parte do erro composto $v_{it} = \alpha_i + \varepsilon_{it}$. A estrutura de erros implica GLS com quasi-desmediação:

$$y_{it}^* = y_{it} - \theta \bar{y}_i, \quad \theta = 1 - \frac{\sigma_\varepsilon}{\sqrt{\sigma_\varepsilon^2 + T\sigma_\alpha^2}} \in [0, 1)$$

O estimador RE é o OLS sobre y_{it}^* e X_{it}^* . É mais eficiente que FE sob H_0 : $\text{Cov}(x_{it}, \alpha_i) = 0$, mas *inconsistente* quando a hipótese falha.

22.4 Teste de Hausman

O teste de Hausman compara FE (consistente sempre) com RE (consistente sob H_0 , eficiente):

$$H_0 : \text{Cov}(x_{it}, \alpha_i) = 0 \implies \text{plim}(\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}}) = 0$$

A estatística é:

$$H = (\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}})' [\widehat{\text{Var}}(\hat{\beta}_{\text{FE}}) - \widehat{\text{Var}}(\hat{\beta}_{\text{RE}})]^{-1} (\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}}) \xrightarrow{d} \chi^2(k)$$

Rejeitar H_0 indica que RE é inconsistente — use FE.

22.4.1 Hausman robusto

O teste de Hausman clássico requer que o estimador RE seja eficiente sob H_0 . Sob heterocedasticidade ou clustering, isso falha e a estatística pode ser negativa ou enganosa. A versão robusta (Cameron & Trivedi 2005; Wooldridge 2010) usa a covariância robusta das diferenças dos coeficientes:

$$H_{\text{robust}} = (\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}})' [\widehat{\text{Var}}_{\text{robust}}(\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}})]^{-1} (\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}}) \xrightarrow{d} \chi^2(k)$$

```
1 hausman_robust(m_fe, m_re)
```

Listing 22.1: Teste de Hausman robusto

Alias: `hausman_r`.

22.5 Verificação por DGP

Recuperação exata (sem ruído)

O DGP usa 100 indivíduos $\times$ 10 períodos ($n = 1000$). O efeito fixo $\alpha_i = 0,05 \cdot i$ é determinístico e correlacionado com x :

$$x_{it} = \alpha_i + u_{it}, \quad u \sim \mathcal{N}(0, 1) \quad y_{it} = 1,0 + 2,0 x_{it} + \alpha_i \quad (\varepsilon = 0)$$

Sem ruído idiossincrático a transformação within elimina α_i exatamente, e FE recupera β com precisão de máquina:

```
1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df id = (_n - 1) % 100 + 1
9 generate df alpha = id * 0.05
10 generate df u = rnormal()
11 generate df x = alpha + u
12 generate df y = 1.0 + 2.0*x + alpha
13 let m_ols = ols(y ~ x, df)
14 let m_fe = fe(y ~ x, df, id=id)
15 esttab(m_ols, m_fe)
```

Listing 22.2: FE com efeito fixo correlacionado — sem ruído

(1)	(2)
OLS	FE

x	2.9663*** (0.0060)	2.0000*** (0.0000)
Constant	0.6002*** (0.0202)	
N	1000	1000
R ²	0.9959	
Adj. R ²	0.9959	
* p<0.10 ** p<0.05 *** p<0.01		

O OLS superestima β em +0,97 porque $\text{Cov}(x, \alpha) = \text{Var}(\alpha) > 0$. O FE recupera 2,0000 exatamente.

Hausman com ruído

Com ruído idiossincrático $\varepsilon \sim \mathcal{N}(0,1)$, o FE permanece consistente e o RE é inconsistente (pois α_i ainda é correlacionado com x). O Hausman deve rejeitar H_0 :

```

1 // mesmo DGP; adiciona ruído idiossincrático
2 generate df e = rnormal()
3 generate df y2 = 1.0 + 2.0*x + alpha + e
4 let m_fe2 = fe(y2 ~ x, df, id=id)
5 let m_re2 = re(y2 ~ x, df, id=id)
6 esttab(m_fe2, m_re2)
7 hausman(m_fe2, m_re2)

```

Listing 22.3: Hausman — FE vs RE com efeito correlacionado

	(1) FE	(2) RE
x	2.0977*** (0.0338)	2.9347*** (0.0118)
const		1.1930*** (0.0399)
N	1000	0
* p<0.10 ** p<0.05 *** p<0.01		

```

Hausman Test: FE vs RE
H: efeitos individuais não correlacionados com regressores

Coeficientes Comuns
  Variável      _FE      _RE Δ
  x          2.0977    2.9347  -0.8369
Estatística
  2(1) = 698.1711    p = 0.0000    ***
Conclusão
  Rejeita H → use EFEITOS FIXOS (RE pode ser inconsistente)

```

O RE absorve o efeito de α_i no coeficiente de x (2.9347), replicando o viés do OLS. O Hausman rejeita H_0 com $p < 0,001$ — a endogeneidade do efeito individual é detectada.¹

22.6 Sintaxe

```

1 fe(fórmula, df, id=col)
2 re(fórmula, df, id=col)
3 hausman(modelo_fe, modelo_re)

```

A coluna `id` identifica o indivíduo. O FE remove automaticamente o intercepto (absorvido pelos efeitos individuais).

```

1 load "painel.csv" as df
2
3 let m_fe = fe(salario ~ educ + exp, df, id=id)
4 let m_re = re(salario ~ educ + exp, df, id=id)
5
6 esttab(m_fe, m_re)
7 hausman(m_fe, m_re)

```

Listing 22.4: Fluxo completo

22.7 Opções de erro padrão

¹O FE recupera 2.0977, não 2.0000, porque a transformação within elimina α_i mas não ε_{it} . Com ruído idiossincrático presente, o estimador é consistente mas não exato — o mesmo motivo pelo qual OLS e IV divergem de seus parâmetros verdadeiros quando $\varepsilon \neq 0$.

```
1 fe(y ~ x, df, id=id) // clássico
2 fe(y ~ x, df, id=id, cov=robust) // HC1
3 // cluster por indivíduo
4 fe(y ~ x, df, id=id, cov=cluster, cluster=id)
```

Nota

Em painéis, erros clusterizados por indivíduo (`cluster=id`) são o padrão recomendado: corrigem heterocedasticidade e correlação serial dentro do indivíduo simultaneamente.

22.8 Capturando resultados

```
1 let m = fe(y ~ x, df, id=id)
2 display m
3 let yhat = predict(m, "xb")
```

22.9 Diagnósticos de painel

A escolha entre OLS agrupado, Efeitos Fixos e Efeitos Aleatórios depende de testes formais. Hayashi implementa todos os testes padrão da literatura.

22.9.1 OLS agrupado vs. Efeitos Aleatórios

Breusch-Pagan LM (`bptest`): testa $H_0 : \sigma_u^2 = 0$ (não há efeito de painel — OLS agrupado é adequado):

```
1 bptest(df, y ~ x, id="entity")
```

Se rejeitar H_0 , use RE ou FE em vez de OLS agrupado.

22.9.2 OLS agrupado vs. Efeitos Fixos

F-test para FE (`ftest_fe`): testa H_0 : todos os efeitos individuais são zero:

```
1 ftest_fe(df, y ~ x, id="entity")
```

Rejeitar H_0 indica que FE é preferível a OLS agrupado.

22.9.3 Efeitos Fixos vs. Efeitos Aleatórios

Hausman (`hausman`): testa H_0 : RE é consistente (efeitos individuais não correlacionados com regressores):

```
1 hausman(m_fe, m_re)
```

Rejeitar H_0 implica FE (consistente sob correlação); não rejeitar implica RE (mais eficiente).

Mundlak (`mundlak`): generalização do Hausman que aumenta o modelo com médias individuais dos regressores:

```
1 mundlak(df, y ~ x1 + x2, id="entity")
```

22.9.4 Correlação serial e dependência cross-section

Wooldridge (`wooldridge`): testa H_0 : ausência de correlação serial de primeira ordem nos erros idiossincráticos:

```
1 wooldridge(df, y ~ x, id="entity", time="time")
```

Pesaran CD (`pesaran`): testa H_0 : ausência de dependência cross-sectional. Relevante para painéis com N grande onde spillovers espaciais ou de rede podem existir:

```
1 pesaran(df, y ~ x, id="entity", time="time")
```

22.9.5 Arellano-Bond m1/m2

Arellano-Bond (`abtest`): testa correlação serial nos resíduos em primeira diferença. m_1 deve rejeitar H_0 (a FD induz AR(1) por construção); m_2 não deve rejeitar H_0 (valida os instrumentos $y_{i,t-2}$ do GMM):

```
1 abtest(df, y ~ x, id="entity", time="time")
```


Capítulo 23

Diferenças em Diferenças

23.1 O modelo

Diferenças em Diferenças (DiD) estima o efeito causal de um tratamento comparando a variação temporal do grupo tratado com a do grupo controle:

$$\hat{\delta}_{\text{DiD}} = \underbrace{(\bar{Y}_{1,\text{pós}} - \bar{Y}_{1,\text{pré}})}_{\text{variação tratado}} - \underbrace{(\bar{Y}_{0,\text{pós}} - \bar{Y}_{0,\text{pré}})}_{\text{variação controle}}$$

A tabela 2×2 resume os quatro grupos:

	Pré	Pós
Controle ($D = 0$)	μ_{00}	μ_{01}
Tratado ($D = 1$)	μ_{10}	μ_{11}

$$\hat{\delta} = (\mu_{11} - \mu_{10}) - (\mu_{01} - \mu_{00})$$

23.2 Forma de regressão

O estimador DiD é equivalente ao coeficiente da interação em:

$$y_{it} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 \text{Treated}_i + \delta (\text{Treated}_i \times \text{Post}_t) + \varepsilon_{it}$$

onde $\hat{\delta} = \hat{\beta}_3$ é o efeito médio do tratamento sobre os tratados (ATT — *Average Treatment effect on the Treated*).

23.3 Hipótese de tendências paralelas

A identificação do ATT repousa sobre:

$$E[Y_{it}^{(0)} - Y_{is}^{(0)} \mid D_i = 1] = E[Y_{it}^{(0)} - Y_{is}^{(0)} \mid D_i = 0] \quad \forall t \neq s$$

Na ausência do tratamento, tratados e controles teriam a *mesma* tendência temporal. A suposição é não testável no período pós-tratamento, mas pode ser verificada nos períodos pré-tratamento quando há mais de um período disponível.

Atenção

A hipótese de tendências paralelas é mais forte do que parece. Grupos com tendências de crescimento estruturalmente diferentes (ex. regiões em expansão vs. regiões estagnadas) violam a hipótese mesmo que os níveis sejam similares no pré-tratamento.

23.4 Verificação por DGP

Recuperação exata (sem ruído)

O DGP usa 500 indivíduos $\times$ 2 períodos ($n = 1000$). Os primeiros 250 são tratados, os demais são controle. O efeito verdadeiro é $\delta = 3,0$:

$$y_{it} = 1,0 + 0,5 \cdot \text{Post}_t + 3,0 \cdot (D_i \times \text{Post}_t)$$

As quatro médias de célula são $\mu_{00} = 1,0$, $\mu_{01} = 1,5$, $\mu_{10} = 1,0$ e $\mu_{11} = 4,5$, de modo que $\hat{\delta} = (4,5 - 1,0) - (1,5 - 1,0) = 3,0$ exatamente.

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df id      = (_n - 1) % 500 + 1
9 generate df post    = _n > 500
10 generate df treated = id <= 250
11 generate df att     = treated * post
12 generate df y       = 1.0 + 0.5*post + 3.0*att
13 did(y ~ treated + post, df)

```

Listing 23.1: DGP DiD sem ruído — recuperação exata

```

===== Difference-in-Differences (2x2 Canonical) =====
ATT (Effect):                3.0000 || R-squared:
1.0000
Std. Error:                  0.0000 || P-value:
0.0000
t-statistic:                 inf || Observations:
1000

----- Group Means -----
Control Group (Pre):         1.0000 | Control Group (Post):         1.5000
Treated Group (Pre):         1.0000 | Treated Group (Post):         4.5000
Parallel Trend Diff:         0.0000 (If > 0, Control grew more than Treated Pre
=====

```

Com ruído idiossincrático

Adicionando $\varepsilon \sim \mathcal{N}(0, 1)$, o DiD permanece consistente:

```

1 generate df e = rnormal()
2 generate df y = 1.0 + 0.5*post + 3.0*att + e
3 did(y ~ treated + post, df)

```

Listing 23.2: DGP DiD com ruído

```

===== Difference-in-Differences (2x2 Canonical) =====
ATT (Effect):                3.0114 || R-squared:
0.9645
Std. Error:                  0.0358 || P-value:
0.0000
t-statistic:                 84.0942 || Observations:
1000

----- Group Means -----
Control Group (Pre):         1.4842 | Control Group (Post):         2.0099
Treated Group (Pre):         1.4880 | Treated Group (Post):         5.0251
Parallel Trend Diff:         0.0000 (If > 0, Control grew more than Treated Pre
=====

```

O ATT de 3,0114 está próximo do verdadeiro 3,0; o desvio é variância amostral. O *Parallel Trend Diff* próximo de zero confirma que a hipótese de tendências paralelas é satisfeita por construção.

23.5 Sintaxe

```
1 did(outcome ~ treated + post, df)
2 did(outcome ~ treated + post, df, cov=robust)
```

A fórmula requer exatamente duas variáveis no lado direito: a indicadora de grupo (`treated`) e a indicadora de período (`post`). O HAYASHI calcula a interação internamente.

```
1 load "dados.csv" as df
2
3 // cria indicadoras
4 generate df post      = ano >= 2020
5 generate df treated = estado == "RS"
6
7 let m = did(salario ~ treated + post, df, cov=robust)
8 display m
```

Listing 23.3: Fluxo típico de DiD

23.6 Capturando o resultado

```
1 let m = did(y ~ treated + post, df)
2 display m
```

Nota

Para estudos de evento com múltiplos períodos pré e pós-tratamento, o DiD canônico 2×2 pode ser insuficiente. Nesses casos, estime o modelo de regressão com interações período a período e verifique a ausência de efeitos pré-tratamento como teste de tendências paralelas.

23.7 Event study (DiD dinâmico)

O comando `eventstudy` estima um DiD dinâmico com leads e lags, construindo dummies de tempo de evento para cada período relativo ao evento (excluindo o período de referência):

```
1 eventstudy(y ~ event_time + controles, df, ref=-1, min=-5,
            max=5, cov=HC1)
```

- `event_time`: variável com o tempo relativo ao evento ($\dots, -2, -1, 0, 1, 2, \dots$)
- `ref`: período de referência omitido (padrão -1)
- `min`, `max`: limites inferior e superior dos tempos de evento incluídos (padrão -5 e 5)
- Controles opcionais são incluídos após `event_time`

O resultado reporta coeficientes, erros-padrão, estatísticas t e p -values para cada tempo de evento. Os coeficientes dos leads ($t < 0$) testam a hipótese de tendências paralelas: se estatisticamente significativos, indicam violação do pressuposto.

23.8 Local Projections Difference-in-Differences

O comando `lpdid` implementa o estimador de Dube, Girardi, Jordà e Taylor (2025), que combina projeções locais com Diferenças-em-Diferenças para designs de adoção escalonada. Em vez de dummies de tempo de evento, o LP-DiD estima o ATT em cada horizonte h por uma regressão de diferenças longas:

$$\Delta_h y_{it} = \tau_h \Delta_h D_{it} + \text{controles} + \varepsilon_{it},$$

onde $\Delta_h y_{it} = y_{i,t+h} - y_{i,t-\ell}$ é a diferença longa do outcome, ℓ é o período base e D_{it} indica a unidade tratada. A amostra em cada horizonte é restrita a unidades “limpas” (clean controls): nunca tratadas ou ainda não tratadas em $t + h$, conforme a opção `clean_control`.

```
1 let m = lpdid(y ~ unit + time + first_treat, df,  
2             max_pre=5, max_post=8, base_period=-1,  
3             clean_control="not_yet_treated")  
4 print(m.event_coefficients)
```

Listing 23.4: LP-DiD com adoção escalonada absorvente

Os principais argumentos são:

- `outcome ~ unit + time + first_treat`: fórmula com outcome, identificador da unidade, tempo e primeiro período de tratamento (0 indica nunca tratado).
- `max_pre`, `max_post`: número de horizontes pré e pós-tratamento a estimar.
- `base_period`: período base para a diferença longa. Pode ser um inteiro negativo (ex. -1), uma lista de inteiros negativos ou `"all_pre"`.

- `clean_control`: estratégia de controle limpo (`not_yet_treated`, `never_treated`, `first_entry`, `stabilized`).
- `estimand`: estimando alvo `vw` (padrão, variance-weighted), `rw` (equally-weighted via Frisch-Waugh-Lovell) ou `ra` (regression-adjusted imputation).
- `nonabsorbing`: permite que o tratamento ligue e desligue ao longo do tempo. Nesse caso use a variável de tratamento binário `treatment=` em vez de `first_treat`.
- `fixed_composition`: mantém o mesmo conjunto de unidades em todos os horizontes, exigindo controles não tratados em $t + H$.

O objeto de resultado possui três campos principais: `event_coefficients` (tabela horizonte a horizonte), `scalar_coefficients` (ATT médio e ATT pooled) e `fit` (metadados do ajuste).

Capítulo 24

Logit e Probit

24.1 O modelo de variável latente

Quando a variável dependente é binária ($y \in \{0, 1\}$), o modelo linear produz previsões fora do intervalo $[0, 1]$ e erros heterocedásticos por construção. A solução é modelar a probabilidade de $y = 1$ via uma função de distribuição acumulada:

$$P(y_i = 1 \mid x_i) = F(x_i' \beta)$$

A motivação vem do modelo de variável latente:

$$y_i^* = x_i' \beta + \varepsilon_i, \quad y_i = \mathbf{1}[y_i^* > 0]$$

A distribuição de ε determina o modelo:

Modelo	Distribuição de ε	$F(\cdot)$
Logit	Logística($0, \pi^2/3$)	$\Lambda(z) = \frac{1}{1 + e^{-z}}$
Probit	Normal($0, 1$)	$\Phi(z) = \int_{-\infty}^z \phi(t) dt$

A estimação é por Máxima Verossimilhança (MLE). A log-verossimilhança é:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \ln F(x_i' \beta) + (1 - y_i) \ln(1 - F(x_i' \beta)) \right]$$

24.2 Interpretação dos coeficientes

Os coeficientes do Logit e Probit **não são efeitos marginais** — são parâmetros da variável latente, sem unidade interpretável diretamente. Para x_j contínuo, o efeito marginal sobre a probabilidade é:

$$\frac{\partial P(y = 1 \mid x)}{\partial x_j} = f(x' \beta) \beta_j$$

onde $f = F'$ é a densidade da distribuição escolhida. Como $f(x' \beta)$ varia entre observações, reporta-se o **Efeito Marginal Médio** (AME):

$$\text{AME}_j = \frac{1}{n} \sum_{i=1}^n f(x'_i \beta) \beta_j$$

Nota

A relação entre os coeficientes de Logit e Probit é aproximadamente:

$$\hat{\beta}_{\text{Logit}} \approx \frac{\pi}{\sqrt{3}} \hat{\beta}_{\text{Probit}} \approx 1,81 \hat{\beta}_{\text{Probit}}$$

Os AMEs dos dois modelos são tipicamente muito próximos, mesmo com coeficientes em escalas diferentes.

24.3 Verificação por DGP

Consistência do MLE

Ao contrário dos modelos lineares dos capítulos anteriores, Logit e Probit *não admitem recuperação exata* dos parâmetros. A variável binária y é gerada por amostragem de Bernoulli — há aleatoriedade irreduzível mesmo sem adicionar ruído extra. O que se verifica aqui é **consistência**: com $n = 1000$ o MLE deve convergir próximo dos parâmetros verdadeiros.

O DGP usa a parametrização logística com $\beta_0 = -1,0$ e $\beta_1 = 2,0$:

$$x_i \sim \mathcal{N}(0, 1), \quad p_i = \Lambda(-1,0 + 2,0 x_i), \quad y_i \sim \text{Bernoulli}(p_i)$$

Bernoulli individual é gerado por $y_i = \mathbf{1}[u_i < p_i]$, com $u_i \sim \text{Uniforme}(0, 1)$:

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df x = rnormal()
9 generate df lp = -1.0 + 2.0*x

```

```

10 generate df p = 1 / (1 + exp(-lp))
11 generate df u = runiform()
12 generate df y = u < p
13 let m_l = logit(y ~ x, df)
14 let m_p = probit(y ~ x, df)
15 esttab(m_l, m_p)

```

Listing 24.1: DGP logístico — Logit e Probit simultâneos

Os verdadeiros parâmetros são $(\beta_0, \beta_1) = (-1, 0; 2, 0)$ para o DGP Logit com $x_i \sim \mathcal{N}(0, 1)$. As estimativas Probit estão na escala normal do índice latente; portanto, não devem ser numericamente idênticas aos coeficientes Logit mesmo quando os dois modelos descrevem a mesma relação qualitativa.

Efeitos marginais médios

Os coeficientes são apenas parâmetros da variável latente. Para interpretação econômica, usa-se `margins`:

```

1 margins(m_l, df)

```

Listing 24.2: AME do Logit

O efeito marginal é positivo e varia com a probabilidade ajustada; ele é reportado por `margins(m_l, df)` na escala de probabilidade.

24.4 Sintaxe

```

1 logit(y ~ x1 + x2, df)
2 probit(y ~ x1 + x2, df)
3 margins(modelo, df)

```

```

1 load "dados.csv" as df
2
3 let m_l = logit(empregado ~ educ + exp + sexo, df)
4 let m_p = probit(empregado ~ educ + exp + sexo, df)
5
6 esttab(m_l, m_p)
7 margins(m_l, df)

```

Listing 24.3: Fluxo típico — escolha discreta

24.5 Previsão de probabilidades

```
1 let m = logit(y ~ x, df)
2 let phat = predict(m, "pr")      // P(y=1|x) para cada obs
3 let yhat = predict(m, "class")   // classe prevista (0 ou 1)
```

Nota

Use `predict(m, "class")` com limiar padrão de 0,5. Em dados desbalanceados (prevalência baixa), ajuste o limiar com `predict(m, "class", threshold=0.3)`.

24.6 Diagnósticos de classificação

24.6.1 Tabela de classificação

```
1 estat_classification(m)
2 estat_classification(m, threshold=0.3)
```

Computa a tabela 2×2 de classificação no limiar dado (padrão 0,5). Reporta verdadeiros positivos (TP), verdadeiros negativos (TN), falsos positivos (FP), falsos negativos (FN), sensibilidade ($TP/(TP + FN)$), especificidade ($TN/(TN + FP)$) e taxa de correção global.

24.6.2 ROC e AUC

```
1 lroc(m)
```

Computa a área sob a curva ROC (AUC) via estatística de Wilcoxon-Mann-Whitney. Também reporta o coeficiente de Gini ($2 \cdot AUC - 1$). Interpretação: $AUC \geq 0,9$ excelente, $\geq 0,8$ bom, $\geq 0,7$ aceitável, $\geq 0,6$ ruim, $< 0,6$ sem discriminação.

24.6.3 Hosmer-Lemeshow

```
1 estat_gof(m)
2 estat_gof(m, groups=5)
```

Teste de goodness-of-fit de Hosmer-Lemeshow. Divide as observações em *groups* decilas (padrão 10) pela probabilidade prevista e compara observado vs esperado via $\chi^2(g - 2)$. H_0 : o modelo ajusta adequadamente. Rejeitar H_0 ($p < 0,05$) indica mau ajuste.

24.6.4 Linktest

```
1 linktest(m)
```

Teste de erro de especificação (Stata `linktest`). Reestima o modelo usando $\hat{y} = X\hat{\beta}$ (preditor linear) e $\hat{y}^2$ como únicos regressores. H_0 : o modelo está corretamente especificado (coeficiente de $\hat{y}^2 = 0$). Se $\hat{y}^2$ for significativo ($p < 0,05$), há erro de especificação — função de ligação inadequada ou forma funcional incorreta.

Capítulo 25

Regressão Quantílica

25.1 O modelo

O OLS estima $E[y \mid x]$ — a média condicional. A Regressão Quantílica (QR) estima $Q_\tau[y \mid x]$ — o τ -ésimo quantil condicional para qualquer $\tau \in (0, 1)$:

$$Q_\tau(y \mid x) = x' \beta(\tau)$$

O vetor $\beta(\tau)$ varia com τ : cada quantil tem seu próprio conjunto de coeficientes. Com um único modelo é possível descrever a distribuição condicional inteira de y .

25.2 O estimador

O estimador minimiza a **função de perda assimétrica** (check function):

$$\hat{\beta}(\tau) = \arg \min_{\beta} \sum_{i=1}^n \rho_\tau(y_i - x_i' \beta)$$

onde

$$\rho_\tau(u) = \begin{cases} \tau u & \text{se } u \geq 0 \\ (\tau - 1) u & \text{se } u < 0 \end{cases}$$

Para $\tau = 0,5$: $\rho_{0,5}(u) = |u|/2$ — minimização da soma dos desvios absolutos (LAD/mediana). Para $\tau \neq 0,5$, resíduos positivos e negativos recebem pesos assimétricos, deslocando a estimativa para o τ -ésimo quantil.

Nota

Ao contrário do OLS, a QR não tem solução de forma fechada — o problema é um programa linear resolvido por simplex ou métodos de ponto interior. Por isso a inferência padrão usa bootstrap (`boot=`).

25.3 Vantagens sobre o OLS

- **Heterocedasticidade:** quando $\text{Var}[y \mid x]$ varia com x , os slopes $\beta_j(\tau)$ diferem entre quantis. O OLS captura apenas a média ponderada implícita.
- **Robustez:** a função check é linear nos resíduos, não quadrática. Outliers em y influenciam menos $\hat{\beta}(\tau)$ do que $\hat{\beta}_{\text{OLS}}$.
- **Distribuição assimétrica:** salários, renda e preços de ativos têm caudas pesadas à direita. A QR descreve efeitos nas caudas sem suposições sobre a forma da distribuição.

25.4 Verificação por DGP

O DGP abaixo introduz heterocedasticidade multiplicativa: a dispersão de y cresce com x , de modo que o efeito de x é maior nos quantis superiores do que nos inferiores.

$$y_i = 2,0 + 1,5 x_i + (1,0 + 0,8 x_i) \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, 1)$$

O quantil condicional $Q_\tau(y \mid x)$ é crescente em x , e a inclinação $\partial Q_\tau / \partial x$ aumenta com τ : indivíduos nos quantis superiores são mais sensíveis a x do que os do quantil inferior.

```
1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df x = rnormal()
9 generate df e = rnormal()
10 generate df y = 2.0 + 1.5*x + (1.0 + 0.8*x)*e
11 let m_ols = ols(y ~ x, df)
12 let m_q25 = qreg(y ~ x, df, tau=0.25)
```


	(1)	(2)	(3)
(4)			
	OLS	QReg (=0.25)	QReg (=0.50)
QReg (=0.75)			
x	1.9947***	1.8739***	2.0149***
2.2462***			
	(0.0454)	(0.0687)	(0.0833)
(0.0579)			
const		2.1659***	2.4525***
2.6637***			
		(0.0302)	(0.0433)
(0.0369)			
Constant	2.4538***		
	(0.0261)		
N	1000	0	0
0			
R ²	0.6594		
Adj. R ²	0.6591		
* p<0.10 ** p<0.05 *** p<0.01			

A constante também aumenta com τ ($2,17 \rightarrow 2,45 \rightarrow 2,66$), refletindo que os quantis superiores de y estão acima da média para qualquer valor de x .

25.5 Syntaxe

```
1 qreg(y ~ x1 + x2, df, tau=0.5)
2 qreg(y ~ x1 + x2, df, tau=0.5, boot=500)
```

O parâmetro `tau` define o quantil desejado ($\tau \in (0, 1)$, padrão 0,5). O parâmetro `boot` ativa bootstrap para os erros padrão (padrão 200 réplicas).

```
1 load "pnad.csv" as df
2
3 let q10 = qreg(sal ~ edu + exp, df, tau=0.10, boot=500)
4 let q50 = qreg(sal ~ edu + exp, df, tau=0.50, boot=500)
5 let q90 = qreg(sal ~ edu + exp, df, tau=0.90, boot=500)
6 let ols = ols(sal ~ edu + exp, df)
7
8 esttab(ols, q10, q50, q90)
```

Listing 25.2: Fluxo típico — salários em múltiplos quantis

25.6 Capturando o resultado

```
1 let m = qreg(y ~ x, df, tau=0.75)
2 display m
3 let yhat = predict(m, "xb")
```

Capítulo 26

Regressão com Descontinuidade

26.1 O modelo

A Regressão com Descontinuidade (RDD) identifica efeitos causais quando o tratamento é atribuído mecanicamente com base em um limiar de uma variável contínua observável — a **variável de corrida** (*running variable*) x :

$$D_i = \mathbf{1}[x_i \geq c]$$

O estimador explora o fato de que indivíduos imediatamente abaixo e acima do limiar c são comparáveis em tudo, exceto no tratamento recebido. O efeito identificado é o **LATE no limiar** (*Local Average Treatment Effect at the cutoff*):

$$\tau_{\text{RDD}} = \lim_{x \downarrow c} E[y \mid x] - \lim_{x \uparrow c} E[y \mid x]$$

Nota

O RDD *Sharp* (acima) assume que D muda deterministicamente em c . O RDD *Fuzzy* generaliza para quando D aumenta *descontinuamente* em c , sem salto de 0 a 1 — requer um primeiro estágio e equivale a um IV local.

26.2 Identificação

A hipótese central é a **continuidade dos resultados potenciais** em c :

$$E[Y^{(0)} \mid x] \text{ e } E[Y^{(1)} \mid x] \text{ são contínuas em } x = c$$

Isso garante que qualquer descontinuidade em $E[y \mid x]$ no ponto c é causada pelo salto em D , e não por outro fator que também muda em c .

A hipótese é violada se agentes *manipulam* x para ficarem acima ou abaixo do limiar — estudantes que revisam respostas para cruzar o corte de aprovação, por exemplo. O teste de densidades de McCrary (teste de continuidade da densidade de x em c) verifica se há aglomeração suspeita de observações de um lado do limiar.

26.3 O estimador

O estimador padrão é a **regressão local linear** separada em cada lado do limiar, dentro de uma janela (*bandwidth*) h :

$$\hat{\tau} = \hat{\mu}_+ - \hat{\mu}_-$$

onde $\hat{\mu}_+$ e $\hat{\mu}_-$ são os interceptos das regressões locais lineares no lado direito ($x \in [c, c + h)$) e esquerdo ($x \in (c - h, c)$), respectivamente, ponderadas pelo kernel triangular:

$$K\left(\frac{x - c}{h}\right) = \left(1 - \frac{|x - c|}{h}\right) \mathbf{1}[|x - c| \leq h]$$

O *bandwidth* h controla o viés-variância: janelas largas reduzem variância mas aumentam viés (linearidade local pode ser má aproximação); janelas estreitas são mais locais mas têm menos observações. O Hayashi seleciona h automaticamente pelo critério MSE-ótimo (Imbens-Kalyanaraman) quando `bw` não é especificado.

26.4 Verificação por DGP

Recuperação exata (sem ruído)

O DGP usa a variável de corrida $x \sim \text{Uniforme}(-1, 1)$, limiar em $c = 0$ e efeito verdadeiro $\tau = 2,0$. A função de resultados é linear em x dos dois lados do limiar, sem ruído, de modo que a RDD deve recuperar τ exatamente.

$$y_i = 1,0 + 0,5 x_i + 2,0 D_i, \quad D_i = \mathbf{1}[x_i \geq 0]$$

```
1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
```

```

7 df |> filter(_n <= 1000)
8 generate df x = runiform() * 2 - 1
9 generate df d = x >= 0
10 generate df y = 1.0 + 0.5*x + 2.0*d
11 rd(y ~ x, 0.0, df)

```

Listing 26.1: DGP RDD sem ruído — recuperação exata

```

Regressão Descontínua -   Sharp -   Local Linear (p=1)

Outcome: y                      Running var: x
Cutoff: 0.0000   Bandwidth: 0.0571   Kernel: Triangular
Obs total: 72   N esquerda: 37   N direita: 35

Efeito de Tratamento ^():
      2.0000   SE      0.0000   z 2.443e15   P>|z|   0.0000   ***
IC 95%: [2.0000, 2.0000]

*** p<0.01   ** p<0.05   * p<0.10

```

O estimador recupera $\hat{\tau} = 2,0000$ exatamente. O bandwidth de 0,0571 foi selecionado automaticamente — das 1000 observações, 72 estão dentro da janela em torno do cutoff.

Com ruído idiossincrático

Adicionando ε idiossincrático, o LATE permanece identificado:

```

1 generate df e = rnormal()
2 generate df y = 1.0 + 0.5*x + 2.0*d + e
3 rd(y ~ x, 0.0, df)

```

Listing 26.2: DGP RDD com ruído

```

Regressão Descontínua -   Sharp -   Local Linear (p=1)

Outcome: y                      Running var: x
Cutoff: 0.0000   Bandwidth: 0.0741   Kernel: Triangular
Obs total: 94   N esquerda: 43   N direita: 51

```

```
Efeito de Tratamento ^():
      2.0116   SE      0.1191   z    16.893   P>|z|    0.0000   ***
IC 95%: [1.7782, 2.2449]

*** p<0.01   ** p<0.05   * p<0.10
```

Com ruído, $\hat{\tau} = 2,0116$ — o desvio de 2,0 é variância amostral. O IC de 95% $[1,78; 2,24]$ cobre o verdadeiro $\tau = 2,0$. O bandwidth foi 0,0741: com mais variância, o critério MSE-ótimo prefere janela mais estreita para controlar o viés.

26.5 Sintaxe

```
1 rd(y ~ x, cutoff, df)
2 rd(y ~ x, cutoff, df, bw=0.3)
3 rd(y ~ x, cutoff, df, bw=0.3, poly=2)
```

Parâmetro	Padrão	Descrição
cutoff	obrigatório	valor do limiar em x
bw	automático (IK)	largura da janela h
poly	1	grau do polinômio local
kernel	triangular	uniform, epanechnikov

```
1 load "escola.csv" as df
2
3 // pontuação centralizada no limiar 60
4 generate df xc = nota - 60
5
6 let m = rd(aprovado ~ xc, 0.0, df)
7 display m
```

Listing 26.3: Fluxo típico — nota de corte e bolsa

26.6 Capturando o resultado

```
1 let m = rd(y ~ x, 0.0, df)
2 display m
```

Nota

Em aplicações reais, valide o RDD com testes de falsificação: (1) estime o modelo usando *covariáveis pré-tratamento* como desfecho — não deve haver descontinuidade em c ; (2) teste descontinuidades em *limiares placebo* ($c \pm \delta$) — não devem ser significativas; (3) verifique a densidade de x em c (McCrary) para detectar manipulação da variável de corrida.

26.7 Validação empírica

O DGP deste capítulo com variável de corrida uniforme e limiar em 0 é usado no caso de validação `rdd_book` em `validation/cases/`. O caso estima o efeito de tratamento por RDD em HAYASHI e o compara com implementações de referência em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 27

Método Generalizado dos Momentos

27.1 O framework

O Método Generalizado dos Momentos (GMM) unifica os estimadores dos capítulos anteriores sob um único princípio: a identificação via **condições de momento** populacionais.

Um modelo GMM especifica L condições de momento:

$$E[g_i(\beta)] = 0, \quad g_i(\beta) \in \mathbb{R}^L$$

OLS e IV são casos especiais:

Estimador	Condição de momento	Situação
OLS	$E[x_i \varepsilon_i] = 0$	$L = K$, identificado
IV/2SLS	$E[z_i \varepsilon_i] = 0$	$L = K$, identificado
GMM	$E[z_i \varepsilon_i] = 0$	$L > K$, sobreidentificado

Com $L = K$ momentos, resolve-se $g(\hat{\beta}) = 0$ exatamente — equivalente ao IV just-identified. Com $L > K$, o sistema é sobredeterminado e não existe β que zere todos os momentos simultaneamente; o GMM minimiza uma forma quadrática ponderada:

$$\hat{\beta}_{\text{GMM}} = \arg \min_{\beta} n \bar{g}(\beta)' \hat{W}^{-1} \bar{g}(\beta)$$

onde $\bar{g}(\beta) = \frac{1}{n} \sum_i g_i(\beta)$ e $\hat{W}$ é a estimativa consistente da variância assintótica de $\sqrt{n} \bar{g}(\beta)$.

27.2 O estimador dois passos

1. **Primeiro passo:** estima $\hat{\beta}_1$ com $W = I$ (peso uniforme).
2. **Matriz de peso eficiente:** calcula $\hat{W} = \frac{1}{n} \sum_i z_i z_i' \hat{\varepsilon}_i^2$ com resíduos do primeiro passo.
3. **Segundo passo:** reestima $\hat{\beta}_2$ com $\hat{W}^{-1}$ — o estimador GMM eficiente.

O estimador dois passos é assintoticamente eficiente na classe de estimadores GMM com as mesmas condições de momento.

27.3 Teste J de sobreidentificação

Quando $L > K$, é possível testar se os momentos excedentes são válidos. A estatística de Hansen (*J-test*):

$$J = n \bar{g}(\hat{\beta})' \hat{W}^{-1} \bar{g}(\hat{\beta}) \xrightarrow{d} \chi^2(L - K) \quad \text{sob } H_0 : E[g_i(\beta_0)] = 0$$

H_0 é a hipótese de que *todos* os L instrumentos são exógenos. Rejeitar H_0 indica que pelo menos um instrumento é correlacionado com ε — o modelo está mal especificado ou um instrumento é inválido.

Atenção

O teste J é necessário mas não suficiente: não rejeitar não prova que todos os instrumentos são válidos, apenas que as restrições de sobreidentificação são consistentes com os dados.

27.4 Verificação por DGP

OLS, IV e GMM lado a lado

O DGP repete a estrutura do capítulo 21: x é endógeno ($\text{Cov}(x, \varepsilon) \neq 0$), com dois instrumentos válidos z_1 e z_2 . O ε é ortogonalizado contra z_1 in-sample — IV just-identified recupera exatamente; GMM com dois instrumentos é sobreidentificado ($L = 2, K = 1$).

```
1 seed(42)
2 input df
3 id
4 1
```

```

5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df z1 = rnormal()
9 generate df z2 = rnormal()
10 generate df v = rnormal()
11 let d1 = cov(df, z1, v) / variance(df, z1)
12 let d0 = mean(df, v) - d1 * mean(df, z1)
13 generate df eps = v - d0 - d1*z1
14 generate df x = 0.8*z1 + 0.4*z2 + eps
15 generate df y = 1.5 + 2.0*x + 0.7*eps
16 let m_ols = ols(y ~ x, df)
17 let m_iv = iv(y ~ x, ~ z1, df)
18 let m_gmm = gmm(y ~ x, ~ z1 + z2, df)
19 display m_ols
20 display m_iv
21 display m_gmm

```

Listing 27.1: DGP GMM — OLS viesado, IV exato, GMM eficiente

```

Dep. Variable: y    R²=0.9798    N=1000    F=48418.53
const    1.2757***    (0.0077)    x    2.3736***    (0.0108)

Dep. Variable: y    Estimator: 2SLS    N=1000
const    1.5000***    (0.0170)    x    2.0000***    (0.0264)

Dep. Variable: y    GMM Two-Step    N=1000    J=2.5012    Prob(J)=0.1138    DF=1
x0    1.4875***    (0.0145)    x1    2.0206***    (0.0226)

```

OLS é viesado (endogeneidade): $\hat{\beta}_1 = 2,37 \neq 2,0$. IV com z_1 recupera exatamente 2,0000 (ortogonalização in-sample). GMM com $z_1 + z_2$ converge a 2,0206 — consistente, não exato, porque usa dois momentos para estimar um parâmetro. O teste J ($J = 2,50$, $p = 0,11$) não rejeita H_0 : ambos os instrumentos são válidos.

Nota

O Hayashi exibe os coeficientes como **x0** (constante) e **x1** (slope) na saída do GMM. Isso é uma particularidade do display interno — os coeficientes correspondem exatamente à ordem das variáveis da fórmula.

J-test rejeita — instrumento inválido

Se z_2 for contaminado com ε , o teste J detecta a violação:

```
1 // z2b correlacionado com eps: instrumento inválido
```

```

2 generate df z2b = z2 + 0.5*eps
3 let m_bad = gmm(y ~ x, ~ z1 + z2b, df)
4 display m_bad

```

Listing 27.2: Instrumento inválido — J-test rejeita

```

Dep. Variable: y      GMM Two-Step      N=1000      J=152.9417      Prob(J)=0.0000      DF=1
x0      1.3738***      (0.0089)      x1      2.2125***      (0.0124)

```

$J = 152,94$ ($p = 0,000$) rejeita H_0 com alta significância — e os coeficientes são viesados ($\hat{\beta}_1 = 2,21$). O teste J funcionou como alarme: antes de confiar nas estimativas GMM, verifique se J não rejeita.

27.5 Sintaxe

```

1 gmm(y ~ x1 + x2, ~ z1 + z2 + z3, df)
2 gmm(y ~ x1 + x2, ~ z1 + z2 + z3, df, cov=robust)

```

O primeiro lado direito ($\sim x1 + x2$) lista os regressores; o segundo ($\sim z1 + z2 + z3$) lista os instrumentos. Variáveis exógenas em x devem aparecer também como instrumentos de si mesmas.

```

1 load "dados.csv" as df
2
3 // edu é exógena (instrumento de si mesma)
4 // exp é endógena; z1 e z2 são instrumentos para exp
5 let m = gmm(sal ~ edu + exp, ~ edu + z1 + z2, df)
6 display m

```

Listing 27.3: Fluxo típico com variável exógena inclusa

27.6 Capturando o resultado

```

1 let m = gmm(y ~ x, ~ z1 + z2, df)
2 display m
3 let yhat = predict(m, "xb")

```

Parte III

Séries Temporels

Capítulo 28

AR, MA e ARMA

28.1 Processos estocásticos e estacionariedade

Um **processo estocástico** $\{y_t\}$ é estacionário (em covariância) quando:

$$E[y_t] = \mu, \quad \text{Var}[y_t] = \sigma^2, \quad \text{Cov}(y_t, y_{t-k}) = \gamma_k$$

para todo t — média, variância e autocovariâncias dependem apenas da defasagem k , não do tempo t .

O caso mais simples é o **ruído branco** $\varepsilon_t \sim \text{WN}(0, \sigma^2)$: $E[\varepsilon_t] = 0$, $\text{Var}[\varepsilon_t] = \sigma^2$ e $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ para $t \neq s$. Ruído branco é o bloco de construção de todos os modelos desta seção.

28.2 Processo AR(p)

O modelo autorregressivo de ordem p (**AR**(p)) expressa y_t como combinação linear de seus próprios valores passados mais um choque:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

Para o AR(1), a condição de estacionariedade é $|\phi_1| < 1$. Quando satisfeita, a média incondicional é $\mu = c/(1 - \phi_1)$ e a autocorrelação decai geometricamente:

$$\rho_k = \phi_1^k, \quad k = 0, 1, 2, \dots$$

A **Função de Autocorrelação Parcial** (PACF) corta em zero após defasagem p — característica diagnóstica do AR.

28.3 Processo MA(q)

O modelo de médias móveis de ordem q (**MA**(q)) expressa y_t como combinação linear de choques presentes e passados:

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

O MA(q) é sempre estacionário. A **Função de Autocorrelação** (ACF) corta em zero após defasagem q — em contraste com o AR, cuja ACF decai geometricamente. A condição de **invertibilidade** ($|\theta_1| < 1$ para MA(1)) garante representação AR(∞) única.

Nota

Diagnóstico padrão: ACF decai lentamente e PACF corta $\rightarrow$ AR(p); ACF corta e PACF decai lentamente $\rightarrow$ MA(q); ambas decaem $\rightarrow$ ARMA.

28.4 Processo ARMA(p, q)

O ARMA(p, q) combina os dois mecanismos:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

É estacionário quando as raízes do polinômio AR estão fora do círculo unitário e invertível quando as raízes do polinômio MA também estão.

28.5 Verificação por DGP

Como não existe gerador de defasagem em `generate`, os processos são construídos com um laço `while` que preenche y_t linha a linha, usando `mean(..., if = t == k)` como acessor de linha k .

AR(1) com $\phi = 0,7$

```
1 seed(42)
2 input df
3 id
4 1
5 end
```



```

6 for i in 1..=9 { df = append(df, df) }
7 df |> filter(_n <= 500)
8 generate df e = rnormal()
9 generate df y = 0.0
10 generate df t = _n
11 let n = nrow(df)
12 let i = 2
13 while i <= n {
14     let lag_y = mean(df, y, if = t == i - 1)
15     let et     = mean(df, e, if = t == i)
16     replace df y = 0.7 * lag_y + et if t == i
17     i = i + 1
18 }
19 let m = arima(df, y, p=1, d=0, q=0)
20 display m

```

Listing 28.1: DGP AR(1) e estimação

```

===== ARIMA(1,0,0) via Hannan-Rissanen =====
Observations:                494
AIC:                        157.7072    BIC:                        166.1123
Parameters:
    intercept    0.5454    std=0.0557    z=9.786    p=0.000    [0.4362, 0.6547]
    ar.L1         0.6638    std=0.0335    z=19.814    p=0.000    [0.5981, 0.7295]
=====

```

$\hat{\phi}_1 = 0,6638$ com verdadeiro $\phi_1 = 0,7$; o IC 95% [0,60; 0,73] cobre o valor verdadeiro.

MA(1) com $\theta = 0,5$

```

1 generate df y = e
2 let i = 2
3 while i <= n {
4     let lag_e = mean(df, e, if = t == i - 1)
5     replace df y = y + 0.5 * lag_e if t == i
6     i = i + 1
7 }
8 let m = arima(df, y, p=0, d=0, q=1)
9 display m

```

Listing 28.2: DGP MA(1) e estimação

```

===== ARIMA(0,0,1) via Hannan-Rissanen =====
Observations:          493
AIC:                  162.5430    BIC:                  170.9441
Parameters:
  intercept    0.7297    std=0.0128    z=57.014    p=0.000    [0.7046, 0.7548]
  ma.L1         0.5087    std=0.0456    z=11.163    p=0.000    [0.4194, 0.5980]
=====

```

$\hat{\theta}_1 = 0,5087 \approx 0,5$; IC 95% [0,42; 0,60] sobre $\theta_1 = 0,5$.

ARMA(1,1) com $\phi = 0,6$ e $\theta = 0,4$

```

1 generate df y = e
2 let i = 2
3 while i <= n {
4     let lag_y = mean(df, y, if = t == i - 1)
5     let lag_e = mean(df, e, if = t == i - 1)
6     let et     = mean(df, e, if = t == i)
7     replace df y = 0.6*lag_y + et + 0.4*lag_e if t == i
8     i = i + 1
9 }
10 let m = arima(df, y, p=1, d=0, q=1)
11 display m

```

Listing 28.3: DGP ARMA(1,1) e estimação

```

===== ARIMA(1,0,1) via Hannan-Rissanen =====
Observations:          493
AIC:                  159.4217    BIC:                  172.0233
Parameters:
  intercept    0.8073    std=0.0660    z=12.227    p=0.000    [0.6779, 0.9367]
  ar.L1         0.5259    std=0.0380    z=13.831    p=0.000    [0.4514, 0.6004]
  ma.L1         0.4829    std=0.0591    z=8.167     p=0.000    [0.3670, 0.5987]
=====

```

Ambos os parâmetros são recuperados com boa precisão: $\hat{\phi} = 0,53$ (verdadeiro 0,6) e $\hat{\theta} = 0,48$ (verdadeiro 0,4).

28.6 Seleção de ordem

O HAYASHI reporta AIC e BIC automaticamente. O critério prático:

1. Estime modelos com ordens (p, q) em uma grade pequena (ex. $0 \leq p, q \leq 3$).
2. Selecione o modelo com menor AIC (preferência por ajuste) ou BIC (preferência por parcimônia).
3. Verifique que os resíduos são ruído branco.

```

1 let m00 = arima(df, y, p=0, d=0, q=0)
2 let m10 = arima(df, y, p=1, d=0, q=0)
3 let m01 = arima(df, y, p=0, d=0, q=1)
4 let m11 = arima(df, y, p=1, d=0, q=1)
5 esttab(m00, m10, m01, m11)

```

Listing 28.4: Seleção de ordem por AIC

28.7 Sintaxe

```

1 arima(df, y, p=1, d=0, q=0)
2 arima(df, y, p=0, d=0, q=1)
3 arima(df, y, p=1, d=1, q=1)

```

Parâmetro	Padrão	Descrição
p	0	ordem autorregressiva
d	0	grau de diferenciação
q	0	ordem de médias móveis

```

1 load "ipca.csv" as df
2
3 let m = arima(df, inflacao, p=1, d=0, q=1)
4 display m
5 let yhat = predict(m, "xb")

```

Listing 28.5: Fluxo típico com dados reais

Nota

O laço `while` dos DGPs acima é $O(n^2)$ e serve apenas para ilustrar a estrutura do processo. Em uso real, os dados são carregados de arquivo com `load` e o laço não é necessário.

28.8 Validação empírica

Os DGPs deste capítulo são usados como casos de validação automática em `validation/cases/`: `ar_book`, `ma_book` e `arma_book`. Cada caso executa o script HAYASHI e o compara com implementações de referência em R e Python que replicam o estimador Hannan-Rissanen padrão do HAYASHI. Execute `hay validate` para ver o estado atual.

Capítulo 29

ARIMA e Raiz Unitária

29.1 Processos integrados

Um processo $\{y_t\}$ é **integrado de ordem d** — denotado $I(d)$ — quando precisa ser diferenciado d vezes para se tornar estacionário. O caso mais comum em economia é $I(1)$: a primeira diferença é estacionária, mas o nível não.

O caso mais simples de processo $I(1)$ é o **passeio aleatório** (*random walk*):

$$y_t = y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2)$$

A variância cresce com t ($\text{Var}[y_t] = t\sigma^2$), de modo que o processo não é estacionário. A primeira diferença $\Delta y_t = y_t - y_{t-1} = \varepsilon_t$ é ruído branco — portanto $I(0)$.

O passeio aleatório *com deriva* adiciona uma constante μ :

$$y_t = \mu + y_{t-1} + \varepsilon_t$$

com tendência determinística $E[y_t] = y_0 + \mu t$ — modelo básico para preços de ativos, câmbio e muitas séries macroeconômicas.

29.2 Teste de Dickey-Fuller Aumentado

O teste ADF (*Augmented Dickey-Fuller*) testa formalmente a presença de raiz unitária. O modelo auxiliar estimado é:

$$\Delta y_t = \alpha + \delta y_{t-1} + \sum_{j=1}^k \gamma_j \Delta y_{t-j} + \varepsilon_t$$

com hipóteses:

$$H_0 : \delta = 0 \quad (\text{raiz unitária}) \quad H_1 : \delta < 0 \quad (\text{estacionário})$$

A estatística t de $\hat{\delta}$ não segue a distribuição t padrão sob H_0 — usa-se a distribuição de Dickey-Fuller com valores críticos tabelados.

Atenção

Os valores críticos do ADF são **negativos**: rejeita-se H_0 quando a estatística é suficientemente *negativa*. Um valor positivo (ou próximo de zero) não rejeita H_0 — evidência de raiz unitária.

29.3 O modelo ARIMA

O ARIMA(p, d, q) generaliza o ARMA para séries não estacionárias, aplicando d diferenciações antes da estimação:

$$\underbrace{\phi(L)(1-L)^d y_t}_{\text{AR em diferenças}} = c + \underbrace{\theta(L)\varepsilon_t}_{\text{MA}}$$

onde L é o operador de defasagem ($Ly_t = y_{t-1}$) e $(1-L)^d$ é o operador de diferença de ordem d .

Modelo	Notação	Processo
Passeio aleatório	ARIMA(0,1,0)	$\Delta y_t = c + \varepsilon_t$
AR(1) em diferenças	ARIMA(1,1,0)	$\Delta y_t = c + \phi \Delta y_{t-1} + \varepsilon_t$
MA(1) em diferenças	ARIMA(0,1,1)	$\Delta y_t = c + \varepsilon_t + \theta \varepsilon_{t-1}$

29.4 Verificação por DGP

Random walk: ADF não rejeita, AR(1): ADF rejeita

O DGP contrasta os dois casos: passeio aleatório (I(1)) gerado por `cumsum(e)` versus AR(1) estacionário ($\phi = 0,7$) gerado por laço.

```

1 seed(42)
2 input df
3 id
4 1
5 end
```

```

6 for i in 1..=9 { df = append(df, df) }
7 df |> filter(_n <= 500)
8 generate df e = rnormal()
9 generate df rw = cumsum(e)
10 generate df y = 0.0
11 generate df t = _n
12 let n = nrow(df)
13 let i = 2
14 while i <= n {
15     let ly = mean(df, y, if = t == i - 1)
16     let et = mean(df, e, if = t == i)
17     replace df y = 0.7 * ly + et if t == i
18     i = i + 1
19 }
20 adf(df, rw)
21 adf(df, y)

```

Listing 29.1: ADF em passeio aleatório vs. AR(1)

```

===== Augmented Dickey-Fuller Test =====
Variable: rw    Lags used: 7
H: series has a unit root (non-stationary)
Test statistic:    -0.0980
Critical values:  1%=-3.430  5%=-2.860  10%=-2.570
Conclusion: Não rejeita H - raiz unitária presente

===== Augmented Dickey-Fuller Test =====
Variable: y     Lags used: 7
H: series has a unit root (non-stationary)
Test statistic:    -6.4616
Critical values:  1%=-3.430  5%=-2.860  10%=-2.570
Conclusion: REJEITA H - estacionária

```

O passeio aleatório tem estatística $-0,10$ — acima dos valores críticos negativos, não rejeita H_0 . O AR(1) com $\phi = 0,7$ tem estatística $-6,46$ — muito abaixo do valor crítico de 1% ($-3,43$), rejeita H_0 com alta confiança.

Estimação ARIMA(0,1,0) e seleção de ordem

Com a raiz unitária identificada, estima-se com $d = 1$. Três ordens concorrentes para o passeio aleatório verdadeiro:

```
1 let m010 = arima(df, rw, p=0, d=1, q=0)
2 let m110 = arima(df, rw, p=1, d=1, q=0)
3 let m011 = arima(df, rw, p=0, d=1, q=1)
4 display m010
5 display m110
6 display m011
```

Listing 29.2: Seleção de ordem para série I(1)

```
-- ARIMA(0,1,0): AIC=156.77 BIC=160.97
  intercept 0.4863 std=0.0128 z=38.14 p=0.000

-- ARIMA(1,1,0): AIC=158.70 BIC=167.10
  intercept 0.4805 std=0.0253 z=18.96 p=0.000
  ar.L1      0.0120 std=0.0450 z=0.266 p=0.791 [insig.]

-- ARIMA(0,1,1): AIC=157.80 BIC=166.19
  intercept 0.4855 std=0.0128 z=38.07 p=0.000
  ma.L1      0.0058 std=0.0453 z=0.128 p=0.898 [insig.]
```

O modelo verdadeiro ARIMA(0,1,0) tem o menor AIC e BIC. Os termos AR e MA adicionais são insignificantes ($p > 0,7$) — o BIC, que penaliza mais fortemente a complexidade, confirma a parcimônia do modelo simples.

29.5 Fluxo de trabalho

O protocolo padrão para séries temporais univariadas:

1. **Inspecionar** o nível da série — tendência visível sugere não-estacionariedade.
2. **Testar** com ADF — não rejeitar H_0 indica $d \geq 1$.
3. **Diferenciar** uma vez e re-testar com ADF na série diferenciada — confirma $d = 1$.
4. **Selecionar** (p, q) pela grade AIC/BIC sobre a série diferenciada.
5. **Validar** resíduos: devem ser ruído branco.

29.6 Sintaxe


```
1 adf(df, y)
2 adf(df, y, lags=4)
3 arima(df, y, p=0, d=1, q=0)
4 arima(df, y, p=1, d=1, q=1)

1 load "cambio.csv" as df
2
3 adf(df, taxa)
4
5 // se não rejeitar H0: estimar com d=1
6 let m = arima(df, taxa, p=1, d=1, q=0)
7 display m
8 let yhat = predict(m, "xb")
```

Listing 29.3: Fluxo típico com dados reais

29.7 Validação empírica

O DGP de passeio aleatório deste capítulo é usado no caso de validação `arima_book` em `validation/cases/`. O caso estima um ARIMA(1,1,0) em HAYASHI e o compara com as implementações de referência em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 30

VAR e Causalidade de Granger

30.1 O modelo VAR

O modelo Autorregressivo Vetorial (**VAR**(p)) generaliza o AR para sistemas multivariados. Com K variáveis e p defasagens:

$$\mathbf{y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{y}_{t-1} + \cdots + \mathbf{A}_p \mathbf{y}_{t-p} + \boldsymbol{\varepsilon}_t$$

onde $\mathbf{y}_t = (y_{1t}, \dots, y_{Kt})'$ é o vetor de variáveis, $\mathbf{A}_j$ são matrizes $K \times K$ de coeficientes e $\boldsymbol{\varepsilon}_t \sim (0, \Sigma_u)$ é o vetor de choques não correlacionados no tempo mas potencialmente correlacionados entre si.

O VAR é estimado equação por equação via OLS — cada equação é um AR(p) nos K defasados. A condição de estacionariedade exige que todas as raízes características de $\mathbf{A}_1 + \cdots + \mathbf{A}_p$ estejam dentro do círculo unitário.

30.2 Causalidade de Granger

x **causa Granger** y se as defasagens de x têm poder preditivo para y além do que as defasagens de y sozinhas fornecem. Formalmente, testa-se a hipótese:

$$H_0 : A_{12}(1) = A_{12}(2) = \cdots = A_{12}(p) = 0$$

na equação de y_1 , onde $A_{12}(j)$ é o coeficiente de $y_{2,t-j}$.

O teste é um teste F padrão na equação auxiliar:

$$F = \frac{(RSS_r - RSS_u)/p}{RSS_u/(T - 2p - 1)} \sim F(p, T - 2p - 1)$$

Nota

Causalidade de Granger é *previsibilidade*, não causalidade estrutural. x que antecede y e correlaciona com ela passa no teste, mesmo sem relação causal direta.

30.3 Função de Resposta ao Impulso

A **IRF** (*Impulse Response Function*) rastreia o efeito de um choque unitário em y_k sobre todas as variáveis ao longo do tempo.

A representação $MA(\infty)$ do VAR é $\mathbf{y}_t = \sum_{h=0}^{\infty} \mathbf{\Phi}_h \boldsymbol{\varepsilon}_{t-h}$, com $\mathbf{\Phi}_0 = I$ e $\mathbf{\Phi}_h = \mathbf{A}_1 \mathbf{\Phi}_{h-1} + \dots + \mathbf{A}_p \mathbf{\Phi}_{h-p}$. A IRF ortogonalizada usa a decomposição de Cholesky de Σ_u para isolar choques não correlacionados — a **ordenação de Cholesky** (ordem das variáveis) importa.

30.4 Verificação por DGP

O DGP usa um VAR(1) bivariado com estrutura de causalidade assimétrica: y_2 causa y_1 (coeficiente 0,2), mas y_1 causa y_2 fracamente (coeficiente 0,1):

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0,5 & 0,2 \\ 0,1 & 0,6 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=9 { df = append(df, df) }
7 df |> filter(_n <= 300)
8 generate df e1 = rnormal()
9 generate df e2 = rnormal()
10 generate df y1 = 0.0
11 generate df y2 = 0.0
12 generate df t = _n
13 let n = nrow(df)
14 let i = 2
15 while i <= n {
16     let l1 = mean(df, y1, if = t == i - 1)
17     let l2 = mean(df, y2, if = t == i - 1)

```

```

18     let a = mean(df, e1, if = t == i)
19     let b = mean(df, e2, if = t == i)
20     replace df y1 = 0.5*l1 + 0.2*l2 + a if t == i
21     replace df y2 = 0.1*l1 + 0.6*l2 + b if t == i
22     i = i + 1
23 }
24 let m = var(df, y1, y2, lags=1)
25 display m
26 granger(df, y1, y2, lags=1)
27 granger(df, y2, y1, lags=1)
28 irf(m, steps=6)

```

Listing 30.1: DGP VAR(1) — Granger e IRF

Ajuste do modelo

```
VAR(1)   N=299   AIC=-5.0269   BIC=-4.9526
```

```
Sigma_u:
```

```

[ 0.0819  0.0046 ]
[ 0.0046  0.0772 ]

```

A matriz de covariância residual $\hat{\Sigma}_u$ é quase diagonal — os choques ε_1 e ε_2 são praticamente ortogonais, como especificado no DGP.

Causalidade de Granger

```

===== Granger Causality Test =====
H: y2 não causa Granger y1   (lags=1)
F(1, 296) = 9.4437   p = 0.0023
Conclusion: REJEITA H - y2 causa Granger y1

===== Granger Causality Test =====
H: y1 não causa Granger y2   (lags=1)
F(1, 296) = 4.5768   p = 0.0332
Conclusion: REJEITA H - y1 causa Granger y2

```

Ambas as direções rejeitam H_0 : $y_2 \rightarrow y_1$ com $p = 0,002$ e $y_1 \rightarrow y_2$ com $p = 0,033$. O DGP impõe $\phi_{12} = 0,2$ e $\phi_{21} = 0,1$ — a causalidade bidirecional é detectada, embora $y_2 \rightarrow y_1$ seja mais forte.

Resposta ao impulso

IRF - VAR(1) - 6 passos

Impulso: y1

h	y1	y2
1	0.2862	0.0161
2	0.1430	0.0382
3	0.0758	0.0364
4	0.0426	0.0286
5	0.0251	0.0207
6	0.0154	0.0145

Impulso: y2

h	y1	y2
1	0.0000	0.2774
2	0.0405	0.1595
3	0.0432	0.0958
4	0.0352	0.0595
5	0.0260	0.0378
6	0.0183	0.0243

Um choque em y_1 tem efeito rápido sobre y_1 (decai de 0,29 para 0,015 em 6 períodos) e efeito pequeno sobre y_2 . Um choque em y_2 transmite-se progressivamente a y_1 — atinge 0,043 no período 3, depois decai — capturando o canal $\phi_{12} = 0,2$ do DGP.

30.5 Seleção de defasagens

```
1 let m1 = var(df, y1, y2, lags=1)
2 let m2 = var(df, y1, y2, lags=2)
3 let m3 = var(df, y1, y2, lags=3)
4 esttab(m1, m2, m3)
```

Listing 30.2: Comparação por número de defasagens

Seleciona-se a defasagem com menor BIC (parcimônia) ou AIC (ajuste). Com o DGP VAR(1), espera-se que $p = 1$ minimize ambos.

30.6 Sintaxe

```
1 var(df, y1, y2, lags=1)
2 var(df, y1, y2, y3, lags=2)
3 granger(df, y, x, lags=1)
4 irf(m, steps=10)

1 load "macro.csv" as df
2
3 adf(df, pib)
4 adf(df, ipca)
5
6 let m = var(df, pib, ipca, lags=2)
7 granger(df, pib, ipca, lags=2)
8 granger(df, ipca, pib, lags=2)
9 irf(m, steps=12)
```

Listing 30.3: Fluxo típico — PIB e inflação

Nota

O VAR exige séries *estacionárias*. Se as variáveis forem I(1) e cointegradas, o modelo adequado é o VECM (cap. 31). Se forem I(1) mas não cointegradas, diferencie antes de estimar.

30.7 Validação empírica

O DGP VAR(1) deste capítulo corresponde ao caso de validação `var_book` em `validation/cases/`. O caso compara a estimação OLS equação por equação do HAYASHI com referências em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 31

Cointegração e VECM

31.1 Relação de longo prazo entre séries $I(1)$

Duas séries $I(1)$ são **cointegradas** se existe uma combinação linear entre elas que é $I(0)$. Formalmente, y_t e x_t são cointegradas se existe β tal que:

$$u_t = y_t - \beta x_t \sim I(0)$$

A intuição é a de uma *correia*: séries que individualmente seguem passeios aleatórios podem ser atraídas por uma força de equilíbrio de longo prazo. Preços de ativos no mesmo mercado, taxa de câmbio e paridade de poder de compra, juros de curto e longo prazo são exemplos clássicos.

Séries $I(1)$ não cointegradas divergem indefinidamente — a regressão em nível produz **regressão espúria**: R^2 alto e t -estatísticas significativas sem relação causal real.

31.2 Teste de Engle-Granger

O procedimento de Engle-Granger (1987) testa cointegração em dois passos:

1. Estima a **relação de longo prazo** por OLS: $\hat{u}_t = y_t - \hat{\beta}x_t$
2. Aplica o **teste ADF** nos resíduos $\hat{u}_t$ — sob H_0 os resíduos têm raiz unitária (sem cointegração).

Os valores críticos do teste são mais negativos do que os do ADF padrão, pois $\hat{u}_t$ é resíduo estimado, não série diretamente observada.

31.3 Modelo de Correção de Erros (VECM)

Se y_t e x_t são cointegradas, o VECM (*Vector Error Correction Model*) decompõe a dinâmica em componente de curto prazo e ajuste ao equilíbrio de longo prazo:

$$\Delta \mathbf{y}_t = \alpha \underbrace{(\beta' \mathbf{y}_{t-1})}_{\text{desvio do equilíbrio}} + \sum_{j=1}^{p-1} \Gamma_j \Delta \mathbf{y}_{t-j} + \varepsilon_t$$

- β — **vetor cointegrante**: define a relação de equilíbrio de longo prazo $\beta' \mathbf{y}_t = 0$.
- α — **coeficientes de ajuste**: velocidade com que cada variável corrige desvios do equilíbrio. Sinal negativo em α_y significa que y cai quando está acima do equilíbrio.
- Γ_j — **dinâmica de curto prazo**.

O VECM é estimado por ML via procedimento de Johansen, que testa o número de vetores cointegrantes (*rank*) via estatística de traço (*trace*) ou máximo autovalor.

31.4 Verificação por DGP

Caso 1 — cointegrado: $y_t = 2x_t + \varepsilon_t$

x_t é um passeio aleatório ($I(1)$); $\varepsilon_t \sim I(0)$. Logo $y_t - 2x_t = \varepsilon_t \sim I(0)$: as séries são cointegradas com vetor $[1, -2]$.

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..9 { df = append(df, df) }
7 df |> filter(_n <= 300)
8 generate df e1 = rnormal()
9 generate df e2 = rnormal()
10 generate df x = cumsum(e1)
11 generate df y = 2.0*x + e2
12 coint(df, y, x)

```

Listing 31.1: DGP cointegrado e teste de Engle-Granger

```

===== Engle-Granger Cointegration Test =====
Variables: y, x
H: sem cointegração
ADF statistic:      -6.4808
Critical values:   1%=-3.900   5%=-3.340   10%=-3.040
Vetor cointegrante: [0.4778, 2.0002]
Conclusion: REJEITA H - séries cointegradas

```

A estatística $-6,48$ está muito abaixo do valor crítico de 1% ($-3,90$). O vetor cointegrante estimado $[0,48; 2,00]$ recupera $\beta = 2,0$ com precisão.

Caso 2 — não cointegrado: dois passeios aleatórios independentes

```

1 generate df y = cumsum(e2)
2 coint(df, y, x)

```

Listing 31.2: Dois random walks — sem cointegração

```

===== Engle-Granger Cointegration Test =====
Variables: y, x
H: sem cointegração
ADF statistic:      -3.1058
Critical values:   1%=-3.900   5%=-3.340   10%=-3.040
Conclusion: Não rejeita H - sem cointegração

```

VECM — dinâmica de ajuste

Com cointegração confirmada, estima-se o VECM:

```

1 generate df y = 2.0*x + e2
2 let m = vecm(df, y, x, lags=1)
3 display m

```

Listing 31.3: VECM com rank 1

```

===== VECM (Johansen ML) - Rank 1 =====
No. Variables:          2
Observations:           299

----- Cointegration Vectors (Beta) -----
[ 3.6175, -7.2357 ] →   normalizado: [ 1, -2.000 ]

```

```

----- Adjustment Coefficients (Alpha) -----
y:  -0.3133    (corrige desvios do equilíbrio)
x:  -0.0179    (quase exógena - ajuste mínimo)

----- Johansen Eigenvalues (Lambda) -----
          = 0.5017          = 0.0004
=====

```

O vetor cointegrante normalizado $[1, -2,00]$ recupera o verdadeiro $\beta = 2,0$. O coeficiente de ajuste $\hat{\alpha}_y = -0,313$: quando $y_{t-1} > 2x_{t-1}$ (acima do equilíbrio), Δy_t é negativo — y se corrige para baixo. x quase não ajusta ($\hat{\alpha}_x \approx -0,02$), pois é a variável exógena que define o equilíbrio.

31.5 Sintaxe

```

1 coint(df, y, x)
2 coint(df, y, x, lags=4)
3 vecm(df, y, x, lags=1)
4 vecm(df, y1, y2, y3, lags=2)

1 load "cambio.csv" as df
2
3 adf(df, spot)
4 adf(df, forward)
5
6 coint(df, spot, forward)
7
8 // se cointegradas:
9 let m = vecm(df, spot, forward, lags=2)
10 display m

```

Listing 31.4: Fluxo típico — taxa de câmbio e paridade

Nota

O VECM pressupõe que todas as variáveis são $I(1)$ e cointegradas. Verifique com ADF antes de estimar. Se as séries forem $I(1)$ mas não cointegradas, use o VAR em primeiras diferenças (cap. 30).

31.6 Validação empírica

O DGP cointegrado deste capítulo é usado no caso de validação `coint_book` em `validation/cases/`. O caso estima um VECM de posto 1 em HAYASHI e o compara com implementações de referência em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 32

GARCH e Volatilidade Condicional

32.1 Heterocedasticidade condicional

Séries financeiras exibem um fenômeno recorrente: períodos de alta volatilidade tendem a ser seguidos de mais volatilidade, e períodos calmos persistem. Esse *agrupamento de volatilidade* (*volatility clustering*) viola a hipótese de variância condicional constante dos modelos ARMA — a variância de ε_t dado o passado varia ao longo do tempo.

O modelo GARCH(p, q) (Engle 1982; Bollerslev 1986) captura essa dinâmica explicitamente. A especificação GARCH(1,1) é:

$$\varepsilon_t \mid \mathcal{F}_{t-1} \sim (0, h_t) \quad h_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1}$$

onde h_t é a *variância condicional*, α_1 captura o efeito ARCH (reação ao choque passado) e β_1 captura a persistência (memória da volatilidade).

Restrição	Condição	Significado
Variância positiva	$\omega > 0, \alpha_1 \geq 0, \beta_1 \geq 0$	$h_t > 0$ garantido
Estacionariedade	$\alpha_1 + \beta_1 < 1$	variância não explode
Variância incondicional	$\sigma^2 = \omega / (1 - \alpha_1 - \beta_1)$	nível de longo prazo

O caso $\alpha_1 + \beta_1 = 1$ é chamado IGARCH (*integrated*): a volatilidade tem raiz unitária e choques têm efeito permanente.

32.2 Teste ARCH-LM

Antes de estimar um modelo de volatilidade, testa-se se existem efeitos ARCH. O teste de Engle (1982) regride ε_t^2 em seus próprios lags e avalia a significância conjunta:

$$\varepsilon_t^2 = a_0 + a_1 \varepsilon_{t-1}^2 + \cdots + a_m \varepsilon_{t-m}^2 + u_t$$

$$H_0: a_1 = \cdots = a_m = 0 \quad (\text{sem efeitos ARCH})$$

A estatística é $LM = N \cdot R_{\text{aux}}^2 \xrightarrow{d} \chi^2(m)$ sob H_0 .

32.3 Verificação por DGP

O DGP gera um processo ARCH(1) verdadeiro ($\beta = 0$):

$$h_t = 0,3 + 0,5 \varepsilon_{t-1}^2 \quad \varepsilon_t = \sqrt{h_t} z_t \quad z_t \sim (0, 1)$$

A inovação é gerada diretamente como sorteio normal padrão: $z = \text{rnormal}()$, portanto $E[z] = 0$ e $E[z^2] = 1$.

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=9 { df = append(df, df) }
7 df |> filter(_n <= 500)
8 generate df z = rnormal() // z: E[z]=0, E[z^2]
   ]=1
9 generate df e = z
10 generate df t = _n
11 let n = nrow(df)
12 let i = 2
13 while i <= n {
14     let le = mean(df, e, if = t == i - 1)
15     let lz = mean(df, z, if = t == i)
16     replace df e = sqrt(0.3 + 0.5 * le * le) * lz if t == i
17     i = i + 1
18 }
19
20 archtest(df, e, lags=5) // deve rejeitar H
21 let m = garch(df, e, p=1, q=1)
22 display m
23 archtest(m, lags=5) // deve não rejeitar (GARCH

```


captou o ARCH)

Listing 32.1: DGP ARCH(1) e estimação GARCH

Teste ARCH-LM — série bruta

A série bruta deve rejeitar a hipótese nula de ausência de ARCH, confirmando variância condicional variável no processo simulado.

Estimação GARCH(1,1)

O estimador MLE recupera o DGP verdadeiro ($\omega = 0,3$, $\alpha = 0,5$, $\beta = 0$) até a variação de amostra finita. Um $\hat{\beta}$ próximo de zero identifica que o processo é ARCH puro — sem componente GARCH de persistência.¹

ARCH-LM nos resíduos padronizados

Após ajustar o GARCH, os resíduos padronizados $\hat{z}_t = \varepsilon_t / \sqrt{\hat{h}_t}$ devem ser ruído branco em z_t^2 :

Depois do ajuste, o teste ARCH-LM nos resíduos padronizados não deve rejeitar se a especificação de volatilidade captou a heterocedasticidade condicional.

32.4 Variantes: EGARCH e GJR-GARCH

O GARCH simétrico trata choques positivos e negativos igualmente. Em ativos financeiros, choques negativos tendem a aumentar mais a volatilidade do que positivos de mesma magnitude (*efeito de alavancagem*).

O **EGARCH** (Nelson 1991) modela $\ln h_t$:

$$\ln h_t = \omega + \beta_1 \ln h_{t-1} + \alpha_1 \left| \frac{\varepsilon_{t-1}}{\sqrt{h_{t-1}}} \right| + \gamma_1 \frac{\varepsilon_{t-1}}{\sqrt{h_{t-1}}}$$

O parâmetro $\gamma_1 < 0$ captura a assimetria (efeito de alavancagem).

O **GJR-GARCH** (Glosten-Jagannathan-Runkle 1993) adiciona um termo indicador:

$$h_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + \gamma_1 \varepsilon_{t-1}^2 \mathbf{1}[\varepsilon_{t-1} < 0] + \beta_1 h_{t-1}$$

O coeficiente $\gamma_1 > 0$ implica que choques negativos elevam mais a volatilidade.

¹Com $N = 500$, estimativas em amostras finitas não precisam coincidir exatamente com os parâmetros do DGP; com N maior, a convergência melhora.

32.5 Sintaxe

```

1 garch(df, y, p=1, q=1)
2 garch(df, y, p=1, q=1, dist=t)      // erros Student-t
3 egarch(df, y, p=1, q=1)
4 gjrgarch(df, y, p=1, q=1)
5 archtest(df, y, lags=5)              // ARCH-LM na série bruta
6 archtest(modelo, lags=5)             // ARCH-LM nos resíduos
   padronizados

```

Parâmetro	Padrão	Descrição
p	1	ordem ARCH (α)
q	1	ordem GARCH (β)
dist	normal	distribuição: normal ou t
lags	5	lags para ARCH-LM

```

1 load "retornos.csv" as df
2
3 // 1. Verificar agrupamento de volatilidade
4 archtest(df, ret, lags=10)
5
6 // 2. Estimar modelo de volatilidade
7 let m_garch = garch(df, ret, p=1, q=1)
8 let m_gjr   = gjrgarch(df, ret, p=1, q=1)
9
10 // 3. Verificar diagnóstico
11 archtest(m_garch, lags=10)
12
13 // 4. Variância condicional estimada
14 display m_garch

```

Listing 32.2: Fluxo típico — retornos de ativos

Nota

O HAYASHI estima GARCH por MLE assumindo inovações gaussianas (`dist=normal`) ou Student-t (`dist=t`). Para séries com caudas muito pesadas (criptomoedas, câmbio em crises), a distribuição t geralmente melhora o ajuste. Comparar AIC/BIC entre especificações.

32.6 Validação empírica

O DGP ARCH(1) deste capítulo corresponde ao caso de validação `garch_book` em `validation/cases/`. O caso compara os coeficientes MLE do HAYASHI com a referência Python `arch`. Execute `hay validate` para ver o estado atual.

Parte IV

Inferência Causal

Capítulo 33

Propensity Score Matching

33.1 Seleção em observáveis

Em muitos estudos observacionais, a atribuição ao tratamento não é aleatória — indivíduos se selecionam ao tratamento com base em características observáveis X . Se X afeta também o resultado Y , a comparação direta entre tratados e controles produz estimativas viesadas.

O **Propensity Score Matching** (PSM) explora o teorema de Rosenbaum e Rubin (1983): se a atribuição ao tratamento é independente dos resultados potenciais dado X (*ignorabilidade*), então a mesma independência vale dado o propensity score $p(X) = P(D = 1 | X)$:

$$(Y^0, Y^1) \perp D | X \implies (Y^0, Y^1) \perp D | p(X)$$

Isso reduz o problema de dimensão alta (condicionar em X) para um problema unidimensional (condicionar em $\hat{p}$). O PSM:

1. Estima $\hat{p}(X_i)$ via logit (score de propensão).
2. Emparelha cada tratado com o(s) controle(s) mais próximo(s) em $\hat{p}$.
3. Computa o ATT como diferença de médias no grupo emparelhado.

A condição de suporte comum (*overlap*): $0 < p(X) < 1$ para todo X é essencial — unidades com probabilidade 0 ou 1 de tratamento não têm contrafactual no outro grupo.

33.2 Verificação por DGP

O DGP cria confusão via x_1 : quem tem x_1 alto tem maior probabilidade de tratamento e também maior resultado em média. O ATT verdadeiro é $\tau = 2$.

$$P(D = 1 \mid x_1) = 0,3 + 0,4 x_1 \in [0,30, 0,70] \quad y_i = 1 + 2 d_i + 3 x_{1i} + \varepsilon_i$$

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df x1 = runiform()           // x1 ~ U(0,1)
9 generate df u = runiform()           // ruído de
   atribuição
10 generate df d = (0.3 + 0.4*x1) > u    // P(D=1|x1)
   [0.30, 0.70]
11 generate df e = rnormal()
12 generate df y = 1.0 + 2.0*d + 3.0*x1 + e // ATT verdadeiro
   = 2

```

Listing 33.1: DGP com seleção em observáveis

OLS ingênuo vs. OLS com controles

```

1 let m_ols = ols(y ~ d, df)           // sem controle: viesado
2 let m_adj = ols(y ~ d + x1, df)      // com controle: não
   viesado
3 display m_ols
4 display m_adj

```

Listing 33.2: Comparação OLS sem e com controle de x_1

```

OLS sem controle
const 2.9135*** (0.0398)    d 2.2215*** (0.0562)
N=1000 R²=0.6105

```



```

OLS com x1
const  1.5289***  (0.0193)      d  1.9762***  (0.0180)
x1      3.0053***  (0.0317)
N=1000  R2=0.9610

```

O OLS sem controle superestima τ em +0,22 (2.22 vs. 2.0) — viés de variável omitida. Controlando x_1 o OLS recupera $\hat{\tau} = 1,98$, indistinguível de 2.

PSM sem caliper

```

1 let m_psm = psm(y ~ d + x1, df, k=1, boot=200)
2 display m_psm

```

Listing 33.3: PSM 1:1 sem caliper

Sem caliper, o matching aceita pares distantes em $\hat{p}$. O balanceamento pode melhorar pouco e a estimativa pode permanecer viesada se tratados forem pareados com controles ruins.

PSM com caliper

O caliper limita a distância máxima admitida no matching. A regra prática de Cochran e Rubin (1973) é $\text{caliper} = 0,2 \times \sigma_{\hat{p}}$, o que corresponde aproximadamente a 0,05 para scores uniformes.

```

1 let m_cal = psm(y ~ d + x1, df, k=1, caliper=0.05, boot=200)
2 display m_cal

```

Listing 33.4: PSM com caliper = 0.05

Com $\text{caliper} = 0,05$, a estimativa deve se aproximar do ATT verdadeiro ao custo de descartar tratados sem par aceitável. O caliper também deve melhorar o balanceamento ao rejeitar matches distantes no propensity score.¹

33.3 Sintaxe

¹O aviso $\text{SMD} > 0.10$ persiste porque a regra convencional exige $\text{SMD} \leq 0,10$ (Austin 2009). Neste DGP a confusão por x_1 é intensa ($\beta_{x_1} = 3$) e $N = 1000$; com mais observações o caliper poderia ser estreitado para melhorar ainda mais o balanço.

```

1 psm(outcome ~ treatment + cov1 + cov2, df)
2 psm(outcome ~ treatment + cov1 + cov2, df, k=1, caliper=0.05,
    replace=false, boot=200)

```

A fórmula: `outcome ~ treatment + cov1 + cov2 + ....` O primeiro regressor após `~` é a variável de tratamento; os demais são as covariáveis usadas no modelo de propensão.

Opção	Padrão	Descrição
<code>k</code>	1	número de controles por tratado
<code>caliper</code>	nenhum	distância máxima no score de propensão
<code>replace</code>	false	matching com reposição
<code>boot</code>	200	réplicas bootstrap para o SE

```

1 load "beneficiarios.csv" as df
2
3 // Covariáveis de seleção
4 let m = psm(renda ~ tratado + idade + educ + regioao, df,
5             k=1, caliper=0.05, boot=500)
6 display m

```

Listing 33.5: Fluxo típico — avaliação de programa

Nota

O PSM é consistente sob *ignorabilidade* (seleção em observáveis): $\{Y^0, Y^1\} \perp D \mid X$. Variáveis omitidas que afetam simultaneamente D e Y invalidam a identificação — o mesmo problema que torna IV necessário em cap. 21. Ao contrário do DiD (cap. 23), o PSM não elimina confusores não observados constantes no tempo.

33.4 Validação empírica

O dataset `jtrain3` do Wooldridge é usado no caso de validação `psm_jtrain3` em `validation/cases/`. O caso estima o ATT de um programa de treinamento por PSM em HAYASHI e o compara com uma implementação de referência em Python. Execute `hay validate` para ver o estado atual.

Capítulo 34

Controle Sintético

34.1 O problema do caso único

O DiD (cap. 23) e o PSM (cap. 33) dependem de múltiplas unidades tratadas e controles comparáveis. Em muitas aplicações de política, porém, apenas uma unidade recebe o tratamento — um país que adota um programa econômico, um estado que muda sua legislação — e as unidades potencialmente comparáveis são poucas e heterogêneas.

O **Controle Sintético** (Abadie, Diamond e Hainmueller, ADH 2010) constrói um grupo de controle artificial — o *controle sintético* — como uma combinação convexa de unidades doadoras que replica a trajetória da unidade tratada *antes* do tratamento. A ideia central:

$$\hat{Y}_{1t}^{(0)} = \sum_{j=2}^{J+1} w_j^* Y_{jt} \quad w_j^* \geq 0, \quad \sum_{j=2}^{J+1} w_j^* = 1$$

Os pesos $W^* = (w_2^*, \dots, w_{J+1}^*)$ minimizam o erro quadrático médio de predição (*RMSPE*) no período pré-tratamento:

$$W^* = \arg \min_{W \in \Delta^J} \sum_{t=1}^{T_0-1} \left(Y_{1t} - \sum_{j \geq 2} w_j Y_{jt} \right)^2$$

onde Δ^J é o simplexo unitário ($w_j \geq 0, \sum w_j = 1$). O efeito do tratamento no período $t \geq T_0$ é:

$$\hat{\tau}_t = Y_{1t} - \hat{Y}_{1t}^{(0)}$$

A validade do método repousa sobre a qualidade do ajuste pré-tratamento: se o controle sintético acompanha a unidade tratada no período pré-tratamento, a

hipótese de que teria continuado a fazê-lo na ausência do tratamento é plausível — uma forma não paramétrica da hipótese de tendências paralelas.

Nota

A restrição de convexidade ($w_j \geq 0$, $\sum w_j = 1$) evita extrapolação — o controle sintético fica dentro do suporte dos doadores. Isso o distingue do DiD com pesos, que pode atribuir pesos negativos para alcançar o balanço.

34.2 Verificação por DGP

O DGP usa painel de 10 unidades $\times$ 20 períodos. A unidade 1 é tratada a partir do ano 11; as unidades 2–10 são doadoras. O efeito verdadeiro é $\tau = 3,0$ (permanente, a partir de $T_0 = 11$).

$$y_{it} = \alpha_i + 0,3t + 3,0 \cdot \mathbf{1}[i = 1, t \geq 11] + \varepsilon_{it} \quad \alpha_i \in \{2, 3, \dots, 10\}, \quad \alpha_1 = 5$$

O intercepto da unidade tratada ($\alpha_1 = 5$) coincide com o da unidade 5 (doadora), garantindo suporte comum. As inovações $\varepsilon_{it} \sim U(0, 1)$ introduzem ruído que impede o SC de usar apenas a unidade 5 como doadora perfeita.

```

1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=8 { df = append(df, df) }
7 df |> filter(_n <= 200)
8
9 generate df unit = (_n - 1) % 10 + 1
10 generate df year = (_n - (_n - 1) % 10 - 1) / 10 + 1
11
12 // interceptos por unidade: doadores recebem alpha = unit;
   tratado alpha = 5
13 generate df alpha = 0.0
14 let j = 2
15 while j <= 10 {
16     replace df alpha = j * 1.0 if unit == j
17     j = j + 1
18 }
```

```

19 replace df alpha = 5.0 if unit == 1
20
21 generate df d = (unit == 1) * (year >= 11)
22 generate df e = rnormal()
23 generate df y = alpha + 0.3 * year + 3.0 * d + e
24
25 let m = synth("y", 1, 11, df, id="unit", time="year")
26 display m

```

Listing 34.1: DGP: painel 10×20 , tratamento na unidade 1 a partir de $t=11$

Construção do painel em Hayashi

A função `generate` opera sobre o vetor `_n` (linha corrente, 1-indexado). Para um painel $N \times T$ em formato longo (empilhado por unidade), as fórmulas são:

Variável	Expressão
Unidade $(1, \dots, N)$	<code>(_n - 1) % N + 1</code>
Período $(1, \dots, T)$	<code>(_n - (_n-1)%N - 1) / N + 1</code>

Resultado

Controle Sintético - Abadie, Diamond, Hainmueller (2010)

Unidade tratada : 1 Outcome: y
 T (1ª pós-trat): 11 Doadores: 9 T pré: 10 T pós: 10
 RMSPE pré : 0.3347
 RMSPE pós : 2.7056 razão pós/pré: 8.083

Pesos dos doadores ($w > 0.001$):

6	0.4420
3	0.2153
8	0.1747
2	0.1406
7	0.0274

Período	Real	Sintético	Efeito
---------	------	-----------	--------

	1	5.8266	6.0335	
	2	6.5321	6.1112	
	3	6.7458	6.5023	
	4	6.6240	6.8732	
	5	7.4867	7.2037	
	6	7.5689	7.4293	
	7	8.0670	7.6433	
	8	7.8780	8.0722	
	9	8.0202	8.3241	
	10	8.0878	8.6960	
*	11	11.4437	8.8167	2.6270
*	12	12.1888	9.4361	2.7527
*	13	12.0728	9.8984	2.1745
*	14	12.9748	9.5753	3.3995
*	15	12.7653	10.2134	2.5519
*	16	13.2120	10.2424	2.9696
*	17	13.3167	10.6701	2.6465
*	18	13.7205	11.0759	2.6446
*	19	14.3320	11.5282	2.8039
*	20	14.0020	11.7106	2.2913
* pós-tratamento				

Leitura dos resultados

Ajuste pré-tratamento. O RMSPE pré-tratamento é 0,33 em uma série cujo desvio padrão é da ordem de 2.5 — um ajuste razoável dado o ruído do DGP ($N = 200$, apenas 10 doadores). A razão pós/pré = 8.1 sinaliza que a divergência pós-tratamento é *oito vezes* maior do que o erro de ajuste pré-tratamento, rejeitando a hipótese de efeito nulo.

Pesos. O algoritmo distribui os pesos principalmente entre as unidades 6, 3, 8 e 2, em vez de concentrar todo o peso na unidade 5 (que tem $\alpha_5 = 5 = \alpha_1$). Isso ocorre porque o ruído amostral ε_{it} torna a trajetória realizada da unidade 5 uma combinação linear imprecisa da unidade 1 no período pré-tratamento. O SC usa múltiplos doadores para cancelar o ruído.

Efeitos estimados. A média dos efeitos pós-tratamento é:

$$\bar{\hat{\tau}} = \frac{1}{10} \sum_{t=11}^{20} \hat{\tau}_t = 2,69$$

O valor verdadeiro é $\tau = 3,0$; a subestimação de $\sim 10\%$ reflete a imprecisão do ajuste pré-tratamento com apenas 10 doadores e 10 períodos pré.

34.3 Sintaxe

```
1 synth("outcome", treated_id, t0, df, id="col_unidade", time="
   col_tempo")
2 synth("outcome", treated_id, t0, df, id="col", time="col",
   covs=["x1", "x2"])
```

Argumento	Tipo	Descrição
outcome	string	nome da variável de resultado
treated_id	num/str	identificador da unidade tratada
t0	número	primeiro período pós-tratamento
df	DataFrame	painel em formato longo
id=	opção	coluna de identificação de unidade
time=	opção	coluna de período
covs=	lista	covariáveis adicionais para o ajuste

O argumento `covs` permite incluir médias de covariáveis pré-tratamento no critério de minimização, além dos valores da variável de resultado. Útil quando os doadores têm trajetórias similares mas características estruturais distintas.

```
1 load "estados.csv" as df // id, ano, pib, pop, educ
2
3 let m = synth("pib", "SP", 2008, df,
4             id="id", time="ano",
5             covs=["pop", "educ"])
6 display m
```

Listing 34.2: Fluxo típico — avaliação de política estadual

Nota

O CS não fornece inferência assintótica padrão (sem erros-padrão, sem p -values). A inferência é feita via *testes de placebo*: aplica-se o SC a cada unidade doadora "como se" fosse tratada e compara a razão pós/pré. Se a razão para a unidade verdadeiramente tratada for excepcional no conjunto de placebos, o efeito é estatisticamente incomum. O HAYASHI exibe a razão pós/pré como heurística descritiva; testes de placebo são implementados manualmente via loop sobre as unidades.

34.4 Validação empírica

O caso de validação `synth_smoking` em `validation/cases/` estima um controle sintético sobre um painel simulado (10 doadores, 1 unidade tratada, 20 períodos). O caso compara o efeito pós-tratamento médio do HAYASHI com uma implementação de referência em Python. Execute `hay validate` para ver o estado atual.

Parte V

Resposta Qualitativa e Dependência Limitada

Capítulo 35

Modelos de Contagem

35.1 Dados de contagem e a inadequação do OLS

Variáveis de resultado que assumem apenas valores inteiros não negativos ($Y \in \{0, 1, 2, \dots\}$) — número de filhos, visitas ao médico, patentes registradas — violam as premissas do OLS. O OLS pode produzir previsões negativas e é ineficiente: a variância de Y cresce com a média (cauda assimétrica à direita), violando homocedasticidade.

Poisson

O modelo de regressão Poisson especifica:

$$Y_i | x_i \sim \text{Poisson}(\lambda_i) \quad \lambda_i = E[Y_i | x_i] = \exp(\beta_0 + \beta_1 x_i)$$

A função de log-verossimilhança é:

$$\ell(\beta) = \sum_{i=1}^n [y_i (\beta_0 + \beta_1 x_i) - \exp(\beta_0 + \beta_1 x_i) - \ln(y_i!)]$$

Uma propriedade útil: o estimador de Poisson converge para β mesmo que Y não seja estritamente Poisson, contanto que $E[Y | x] = \exp(x'\beta)$ (estimador quasi-MLE; Gourieroux, Monfort e Trognon 1984).

Binomial Negativa

O modelo Poisson impõe $E[Y | x] = \text{Var}[Y | x]$ (equidispersão). Quando a variância supera a média (*superdispersão*), o modelo de Binomial Negativa (NB2) generaliza:

$$\text{Var}[Y | x] = E[Y | x] + \alpha (E[Y | x])^2$$

O parâmetro $\alpha > 0$ captura a superdispersão. Poisson é o caso-limite $\alpha \rightarrow 0$.

Zero-Inflated Negative Binomial (ZINB)

Muitas aplicações apresentam zeros em excesso além do que qualquer modelo de contagem simples prevê — processos de dois estágios: primeiro decide-se se há evento ($D = 1$ com prob. π_i), depois conta-se a frequência. O ZINB combina:

$$P(Y_i = 0) = (1 - \pi_i) + \pi_i (1 + \alpha \lambda_i)^{-1/\alpha} \quad P(Y_i = k) = \pi_i P_{\text{NB}}(k \mid \lambda_i, \alpha) \quad (k \geq 1)$$

35.2 Verificação por DGP

O DGP cria contagens aproximadamente Poisson com $\lambda_i = e^{0.5+x_i}$, $x \sim U(0, 1)$. O estimador deve recuperar $\beta_0 \approx 0,5$ e $\beta_1 \approx 1,0$.

```

1 seed(42)
2 generate df x    = runiform()                // x ~ U
   (0,1)
3 generate df lam = exp(0.5 + 1.0 * x)
4 generate df u    = runiform()
5 generate df y    = floor(lam + u)            //
   contagem 0
6
7 let m_pois = poisson(y ~ x, df)
8 display m_pois
9
10 let m_nb   = nbreg(y_nb ~ x, df)
11 display m_nb
12
13 let m_zinb = zinb(y_zi ~ x, df)
14 display m_zinb

```

Listing 35.1: Poisson, NegBin e ZINB

Poisson

```

===== Poisson Regression Results =====
Dep. Variable:      y    || Log-Likelihood:   102.0744   AIC:   -200.1488
Method:             IRLS || Pseudo R-sq:      0.7709   N:         500

```

	coef	std err	z	P> z	
const	0.5246	0.0602	8.709	0.000	***
x	0.9733	0.0960	10.141	0.000	***

$\hat{\beta}_0 = 0,52 \approx 0,5$ e $\hat{\beta}_1 = 0,97 \approx 1,0$ — estimativas próximas dos valores verdadeiros.

Binomial Negativa

===== Negative Binomial Regression (alpha=0.0010) =====					
	coef	std err	z	P> z	
const	0.4613	0.0177	26.025	0.000	***
x	1.1950	0.0276	43.249	0.000	***

$\hat{\alpha} \approx 0,001$ — mínima superdispersão, NegBin colapsa para Poisson. Com dados genuinamente superdispersos $\hat{\alpha}$ é significativamente positivo.

ZINB

===== Zero-Inflated Negative Binomial (ZINB) Results =====					
---- Count Model ----					
const	0.2994	(0.1347)	**		
x	1.2435	(0.2051)	***		
---- Inflate Model (Logit) ----					
z0	0.4392	(0.2264)	*		
z1	0.5121	(0.3828)			

A equação de inflação de zeros estima a probabilidade de um zero estrutural; a equação de contagem modela o processo condicional ao evento ocorrer.

35.3 Sintaxe

```

1 poisson(y ~ x1 + x2, df)
2 nbreg(y ~ x1 + x2, df)
3 zinb(y ~ x1 + x2, df)
4 zinb(y ~ x1 + x2, df, inflate = z1 + z2) // equação de infla
    ção separada

```

Estimador	Quando usar
<code>poisson</code>	contagens com equidispersão; quasi-MLE robusto
<code>nbreg</code>	superdispersão ($\hat{\alpha}$ sig. positivo)
<code>zinb</code>	excesso de zeros além do esperado por NB

Nota

Coefficientes de Poisson e NB são log-razões: $\beta_1 = 1$ implica que um aumento unitário em x multiplica a contagem esperada por $e^1 \approx 2,72$. Para obter *efeitos marginais médios* (AME): use `margins(modelo)`.

35.4 Validação empírica

O dataset `fertil2` do Wooldridge é usado nos casos de validação `poisson_fertil2` e `nbreg_fertil2` em `validation/cases/`. Os casos estimam modelos de Poisson e Binomial Negativa para o número de filhos no HAYASHI e comparam coeficientes e erros-padrão com implementações de referência em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 36

Modelos de Resposta Limitada

36.1 Censura e truncagem

Em muitas aplicações o resultado só é observado para parte da amostra: salários de mulheres que trabalham (seleção), horas de lazer truncadas em zero (censura), gastos com bens de luxo (muitos zeros, mas não zeros estruturais). O OLS aplicado à variável censurada é viesado mesmo com erros gaussianos.

Tobit — censura em zero

O modelo Tobit (Tobin 1958) especifica uma variável latente:

$$y_i^* = x_i' \beta + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2) \quad y_i = \max(0, y_i^*)$$

O OLS sobre y_i (ignorando a censura) subestima β porque os zeros "achata" a distribuição condicional. O estimador de máxima verossimilhança (MLE) usa a função de verossimilhança completa:

$$\ell(\beta, \sigma) = \sum_{y_i=0} \ln \Phi\left(-\frac{x_i' \beta}{\sigma}\right) + \sum_{y_i>0} \ln \phi\left(\frac{y_i - x_i' \beta}{\sigma}\right) - \ln \sigma$$

Heckman — seleção amostral

O modelo de seleção amostral de Heckman (1979) separa:

1. **Equação de seleção:** $s_i = \mathbf{1}[\gamma_0 + \gamma_1 z_i + v_i > 0]$
2. **Equação de resultado:** $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, observada apenas quando $s_i = 1$.

Se $\text{Cov}(\varepsilon_i, v_i) \neq 0$, o OLS sobre a sub-amostra selecionada é viesado. A correção de Heckman (dois passos) adiciona a *Razão Inversa de Mills* (IMR) $\lambda_i = \phi(\hat{\gamma}'z_i)/\Phi(\hat{\gamma}'z_i)$ como regressor para controlar o viés de seleção.

36.2 Verificação por DGP

```

1 seed(42)
2 generate df x      = rnormal()
3 generate df z      = rnormal()
4 generate df e      = (rnormal() - 0.5) * 1.7321 // ~ N(0,1)
5 generate df v      = (rnormal() - 0.5) * 1.7321
6
7 // Tobit: y* = 1 + 2*x + e; y = max(0, y*)
8 generate df ystar  = 1.0 + 2.0 * x + e
9 generate df y_tobit = ystar * (ystar > 0)
10
11 // Heckman: selecionado se 0.5 + 1.5*z + v > 0
12 generate df s      = (0.5 + 1.5 * z + v) > 0
13 generate df y_out  = (1.0 + 2.0 * x + e) * s

```

Listing 36.1: DGP Tobit e Heckman

Tobit

```

1 let m_tobit = tobit(y_tobit ~ x, df)
2 display m_tobit

```

Tobit - MLE (censura inferior em 0)

Obs: 500 Censuradas: 0 Não-cens.: 500 Log-L: -359.2116 : 0.4963

Variável	coef	SE	z	P> z	
const	0.9050	0.0442	20.470	0.0000	***
x	2.1956	0.0787	27.913	0.0000	***
sigma	0.4963				

O Tobit recupera $\hat{\beta}_0 = 0,905 \approx 1,0$ e $\hat{\beta}_1 = 2,196 \approx 2,0$, parâmetros da variável latente y^* . Com zero censura neste DGP (todos $y^* > 0$), equivale ao OLS — o teste do modelo é verificado pela capacidade do MLE de convergir e recuperar $\sigma \approx 0,5$.

Heckman

```
1 let m_heck = heckman(y_out ~ x, s ~ z, df)
2 display m_heck
```

Heckman Two-Step - Heckman (1979)

Obs (total): 500 Seleccionadas: 484
 : 0.3608 _: 0.4971 = ~ _: 0.1793

Equação de resultado (y | z=1)

Variável	coef	SE	z	P> z	
const	0.9092	0.0455	20.001	0.0000	***
x	2.1821	0.0804	27.142	0.0000	***
lambda (IMR)	0.1793	0.1917	0.935	0.3495	

Equação de seleção: const 0.1752 z 8.6806**

O coeficiente da IMR não é significativo ($p = 0,35$) — esperado, pois no DGP $\text{Cov}(\varepsilon, v)$ é fraco ($\rho = 0,36$). Com $N = 500$, a potência para detectar correlação moderada é limitada. A equação de resultado recupera corretamente $\hat{\beta}_1 \approx 2,18$.

36.3 Sintaxe

```
1 tobit(y ~ x1 + x2, df)                                // censura
   em 0 (padrão)
2 tobit(y ~ x1 + x2, df, ll=0, ul=10)                   // censura
   dupla [0, 10]
3 heckman(y ~ x1 + x2, s ~ z1 + z2, df)                 // dois
   passos
```

Opção	Descrição
l1	limite inferior de censura (padrão: 0)
u1	limite superior de censura (padrão: nenhum)

Atenção

Para que o Heckman identifique o modelo, a equação de seleção deve conter pelo menos uma variável **exclusa** do resultado (z mas não x). Sem exclusão, o modelo é identificado só por não-linearidade funcional — estimativas instáveis.

36.4 Validação empírica

O dataset `mroz` é usado no caso de validação `heckman_mroz` em `validation/cases/`. O caso estima o modelo Heckman de dois passos em HAYASHI e o compara com uma implementação de Heckit em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 37

Modelos de Escolha Múltipla

37.1 Resposta ordinal e nominal

Quando o resultado assume mais de duas categorias, duas estruturas são possíveis:

- **Resposta ordinal:** categorias com ordem natural (muito insatisfeito, neutro, muito satisfeito; nível educacional). Modelos ordenados (logit/probit) preservam essa estrutura.
- **Resposta nominal:** categorias sem ordem (escolha de modal de transporte; tipo de emprego). Logit multinomial sem restrição de ordem.

Logit e Probit Ordenados

O modelo supõe uma variável latente $y^* = x'\beta + \varepsilon$ e cortes $c_1 < c_2 < \dots < c_{J-1}$:

$$y = j \iff c_{j-1} < y^* \leq c_j$$

O logit ordenado usa $\varepsilon \sim \text{Logistic}(0, 1)$; o probit ordenado usa $\varepsilon \sim N(0, 1)$. Ambos estimam β e os cortes por MLE.

Logit Multinomial

Para J alternativas, com alternativa $j = J$ como base:

$$P(y_i = j \mid x_i) = \frac{\exp(\alpha_j + \beta_j' x_i)}{1 + \sum_{k=1}^{J-1} \exp(\alpha_k + \beta_k' x_i)} \quad j = 1, \dots, J-1$$

Os coeficientes (α_j, β_j) medem o efeito de x sobre as chances relativas de j versus a alternativa base.

37.2 Verificação por DGP

```

1 seed(42)
2 generate df x      = rnormal()
3 generate df e      = (rnormal() - 0.5) * 1.7321
4 generate df ystar = 1.5 * x + e
5 // Categorias 1, 2, 3 com cortes em 0.0 e 1.0
6 generate df y_ord = 1 + (ystar >= 0.0) + (ystar >= 1.0)
7
8 // Multinomial via inverse-CDF
9 generate df denom  = 1.0 + exp(-1.0 + 2.0*x) + exp(0.5)
10 generate df p1     = 1.0 / denom
11 generate df p12    = (1.0 + exp(-1.0 + 2.0*x)) / denom
12 generate df um     = rnormal()
13 generate df y_mlog = 1 + (um >= p1) + (um >= p12)

```

Listing 37.1: DGP para modelos ordenados e multinomial

Ordered Logit

```

1 let m_olog = ologit(y_ord ~ x, df)
2 display m_olog

```

```

===== Ordered Logit Results =====
N=500  Log-L=-396.4473  Pseudo R2=0.1878
----- Coefficients -----
x          4.8137  (0.4633)  z=10.39  ***
Thresholds:  cut1=-0.1472  cut2=3.2191

```

Ordered Probit

```

1 let m_opro = oprobit(y_ord ~ x, df)
2 display m_opro

```

```

===== Ordered Probit Results =====
N=500  Log-L=-392.8369  Pseudo R2=0.1952
----- Coefficients -----
x          2.8683  (0.2603)  z=11.02  ***
Thresholds:  cut1=-0.0768  cut2=1.9076

```

A razão entre coeficientes logit e probit é $4,81/2,87 \approx 1,68$, próximo de $\pi/\sqrt{3} \approx 1,81$ — a relação teórica entre as duas escalas.

Logit Multinomial

```
1 let m_mlog = mlogit(y_mlog ~ x, df)
2 display m_mlog
```

```
===== Multinomial Logit Regression Results =====
N=500   Log-L=-513.7171   Pseudo R²=0.0448   AIC=1035.43
----- y=1 vs base y=3 -----
const   -0.0809   (0.2024)
x        -0.9006   (0.4069)   *
----- y=2 vs base y=3 -----
const   -1.5279   (0.2542)   ***
x        2.0825   (0.4119)   ***
```

Para $y = 2$ versus base $y = 3$: $\hat{\beta}_x = 2,08$ (DGP verdadeiro: $\beta_{x,2} - \beta_{x,3} = 2,0$). O sinal negativo de x em $y = 1$ vs $y = 3$ reflete que x alto aumenta as chances de $y = 2$ (que tem $e^{0,5}$ de probabilidade base) relativo a $y = 1$.

37.3 Sintaxe

```
1 ologit(y ~ x1 + x2, df)
2 oprobit(y ~ x1 + x2, df)
3 mlogit(y ~ x1 + x2, df)
4 mlogit(y ~ x1 + x2, df, base=1) // alternativa base explícita
```

Nota

O logit multinomial impõe a propriedade de **independência de alternativas irrelevantes** (IIA): a razão de probabilidades entre duas alternativas não depende das demais. Para dados de painel de escolha com alternativas correlacionadas, use `clogit` (cap. 49).

37.4 Validação empírica

O dataset `beauty` do Wooldridge é usado nos casos de validação `ologit_beauty` e `oprobit_beauty` em `validation/cases/`, e o dataset `AER::TravelMode` é usado no

caso `mlogit_mode`. Os casos estimam modelos de logit ordenado, probit ordenado e logit multinomial no HAYASHI e comparam os coeficientes com implementações de referência em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 38

Análise de Sobrevivência

38.1 Tempos de falha e censura

A análise de sobrevivência modela o *tempo até um evento* T — falência de empresa, morte, abandono escolar. O desafio central é a **censura à direita**: quando a observação termina antes do evento, sabemos apenas $T > c$ (tempo de observação c), não o tempo exato.

Dois conceitos fundamentais:

$$S(t) = P(T > t) \quad (\text{função de sobrevivência}) \qquad h(t) = \lim_{\delta \rightarrow 0} \frac{P(t \leq T < t + \delta \mid T \geq t)}{\delta} \quad (\text{função de}$$

$S(t)$ decresce de 1 para 0; $h(t)$ mede a taxa instantânea de falha dado que o indivíduo sobreviveu até t .

Kaplan-Meier

O estimador não-paramétrico de Kaplan-Meier (1958) estima $S(t)$ sem premissas distribucionais:

$$\hat{S}(t) = \prod_{t_j \leq t} \left(1 - \frac{d_j}{n_j}\right)$$

onde d_j é o número de eventos no tempo t_j e n_j o número em risco imediatamente antes.

Cox — Hazard Proporcional

O modelo de Cox (1972) especifica:

$$h(t \mid x_i) = h_0(t) \exp(\beta' x_i)$$

A função de hazard baseline $h_0(t)$ é deixada não-paramétrica. Os coeficientes β são estimados pela verossimilhança parcial, sem especificar h_0 . O exponencial e^{β_j} é a *razão de hazard*: um aumento unitário em x_j multiplica o hazard por e^{β_j} .

38.2 Verificação por DGP

O DGP usa tempos de falha Weibull com parâmetro de forma 1,5 e hazard proporcional em $x \in \{0, 1\}$. O verdadeiro log-hazard ratio é $\beta_x = 0,8$.

```
1 seed(42)
2 generate df x      = rbernoulli(0.5)
3 generate df u      = runiform()
4 generate df t_true = exp(-ln(u) / exp(0.8 * x)) // Weibull,
    beta=0.8
5 generate df c      = 3.0
6 generate df time    = t_true * (t_true <= c) + c * (t_true > c
    )
7 generate df event   = (t_true <= c)
8
9 let m_km = km(time, event, df)
10 display m_km
11
12 let m_cox = cox(time ~ x, df, event=event)
13 display m_cox
```

Listing 38.1: DGP de sobrevivência — Weibull com hazard proporcional

Kaplan-Meier

```
===== Kaplan-Meier Survival Estimate =====
Observations:          300
Events:                246
Median survival:       1.6319
```

A mediana de sobrevivência é 1,63: metade dos indivíduos experimenta o evento antes desse tempo.

Cox

```
===== Cox Proportional Hazards Model =====
Observations: 300   Events: 246   Log-Likelihood: -1235.9213
Concordance:   0.6725
-----
Variable |      coef |   std err |      z | P>|z| | exp(coef)
x        |   0.7018 |   0.1306 |   5.372 | 0.000 |    2.0174
```

$\hat{\beta}_x = 0,702$ (verdadeiro: 0,8) — dentro do intervalo de confiança. O hazard ratio estimado $e^{0,702} = 2,02$: indivíduos com $x = 1$ têm hazard instantâneo duas vezes maior do que $x = 0$. O índice de concordância $C = 0,67$ indica discriminação moderada (0,5 = aleatório, 1,0 = perfeito).

38.3 Sintaxe

```
1 km(time, event, df) // Kaplan-Meier
2 cox(time ~ x1 + x2, df, event=col_evento) // Cox PH
```

A coluna `event` deve ser 1 para evento e 0 para censura.

Nota

O modelo de Cox assume *hazards proporcionais*: $h(t \mid x = 1)/h(t \mid x = 0)$ é constante no tempo. Violações podem ser detectadas via resíduos de Schoenfeld ou interações com $\ln(t)$.

Parte VI

Métodos Avançados

Capítulo 39

Painel Avançado I — GMM, PCSE e GEE

39.1 Limitações dos estimadores estáticos

O cap. 22 apresentou FE e RE para painéis com efeito individual constante. Três extensões importantes surgem em aplicações empíricas:

1. **Dinâmica:** quando $y_{i,t-1}$ é regressor, FE é viesado (*viés de Nickell*): $\hat{\rho}_{FE} \xrightarrow{p} \rho - O(1/T)$. O estimador Arellano-Bond usa GMM em primeiras diferenças para contornar.
2. **Dependência cross-seccional:** quando erros de diferentes unidades são correlacionados (dados macroeconômicos de países), os SEs OLS e FE são inválidos. PCSE (Beck e Katz 1995) corrige.
3. **Dados não-gaussianos em painel:** GEE (Liang e Zeger 1986) estende modelos de margem para dados de painel com famílias exponenciais.

Arellano-Bond (AB)

O estimador diff-GMM de Arellano e Bond (1991) toma primeiras diferenças para eliminar o efeito individual:

$$\Delta y_{it} = \rho \Delta y_{i,t-1} + \beta \Delta x_{it} + \Delta \varepsilon_{it}$$

Instrumentos: $y_{i,t-2}, y_{i,t-3}, \dots$ são válidos para $\Delta y_{i,t-1}$ pois são não correlacionados com $\Delta \varepsilon_{it}$, contanto que os erros em nível não sejam serialmente correlacionados de ordem 2 (teste m_2).

39.2 Verificação por DGP

```

1 seed(42)
2 generate df unit = (_n - 1) % 50 + 1
3 generate df t    = (_n - (_n-1) % 50 - 1) / 50 + 1
4 generate df alpha = unit * 0.05           // efeito individual
      correlacionado com x
5 generate df x     = alpha + (rnormal() - 0.5) * 1.7321
6 generate df e     = (rnormal() - 0.5) * 1.7321
7 generate df y     = 1.0 + 1.0 * x + alpha + e // verdadeiro:
      b=1.0
8
9 // OLS viesado (mistura alpha_i com x)
10 let m_ols = ols(y ~ x, df)
11
12 // FE consistente (elimina alpha_i)
13 let m_fe  = fe(y ~ x, df, id=unit)
14
15 // AB-GMM (dinâmico com lags como instrumentos)
16 let m_ab  = ab(y ~ x, df, id=unit, time=t, lags=2)
17
18 // PCSE
19 let m_pcse = pcse(y ~ x, df, id=unit, time=t)
20
21 // GEE
22 let m_gee  = gee(y ~ x, df, id=unit)

```

Listing 39.1: DGP de painel com endogeneidade via efeito individual

OLS vs. FE

```

OLS:  const=1.330  x=1.736***  (viés: +0.74 por mistura de alpha_i)
FE:   x=1.089***  (próximo de 1.0 - efeito real)

```

Arellano-Bond

```

===== Arellano-Bond Diff-GMM (One-Step) =====
Observations: 900  Entities: 50  Instruments: 3  Sargan df: 1

```

```

Variable      |      Coef | Std Err |      z | P>|z|
LD.y          | -0.0242 |  0.0472 | -0.512 |  0.608Δ
x             |  1.0604 |  0.0464 | 22.869 |  0.000 ***

Sargan: ²(1)=0.7549  p=0.3849  (instrumentos válidos)
AB m1: z=-6.22  p=0.000 ***  (AR(1) esperado em FD)
AB m2: z=0.001  p=0.999  (sem AR(2) - instrumentos OK)

```

AB estima $\hat{\beta}_{\Delta x} = 1,06 \approx 1,0$. O lag $\hat{\rho}_{LD.y} \approx 0$ confirma que o DGP não tem dinâmica real. O teste de Sargan não rejeita a validade dos instrumentos; m_2 não rejeita a ausência de autocorrelação de ordem 2.

PCSE

```

PCSE:  const=1.330  SE=0.0637  x=1.736  SE=0.0498
      (SEs maiores que OLS - corrige correlação cross-seccional)

```

GEE

```

GEE:  const=1.330 (SE robust=0.0612)  x=1.736 (SE robust=0.0330)
Scale: 0.3966  QIC: 399.8152

```

GEE com estrutura de correlação exchangeable fornece estimativas de margem (populacionais), com SEs robustos para dependência intra-grupo.

39.3 Sintaxe

```

1 ab(y ~ x, df, id=unit, time=t, lags=2)
2 pcse(y ~ x, df, id=unit, time=t)
3 gee(y ~ x, df, id=unit)
4 gee(y ~ x, df, id=unit, family=binomial, corstr=exchangeable)

```

Estimador	Pressuposto	Quando usar
ab	erros i.i.d. em nível	painel dinâmico com pequeno T
pcse	corr. cross-seccional	macro painel (N pequeno, T médio)
gee	margem populacional	painel com outcome não-gaussiano

Capítulo 40

Regressões Aparentemente Não-Relacionadas

40.1 O estimador de Zellner

Quando se estima um sistema de M equações com os mesmos (ou diferentes) regressores e os erros são correlacionados entre equações, o OLS equação a equação é ineficiente. O estimador **SUR** (*Seemingly Unrelated Regressions*) de Zellner (1962) explora essa correlação via GLS conjunto.

Sistema de M equações:

$$y_m = X_m \beta_m + \varepsilon_m, \quad m = 1, \dots, M$$

Empilhando: $Y = X\beta + \varepsilon$, com $E[\varepsilon\varepsilon'] = \Sigma \otimes I_n$, onde Σ é a matriz de covariância entre-equações ($M \times M$).

O estimador GLS conjunto:

$$\hat{\beta}_{\text{SUR}} = (X'(\Sigma^{-1} \otimes I)X)^{-1} X'(\Sigma^{-1} \otimes I)Y$$

Ganho de eficiência: $\text{SUR} \geq \text{OLS}$ quando Σ tem elementos fora da diagonal não nulos — i.e., quando os erros das equações são correlacionados. Se Σ for diagonal ou se os regressores forem idênticos, $\text{SUR} = \text{OLS}$.

40.2 Verificação por DGP

DGP com dois erros fortemente correlacionados ($\rho = 0,7$):

$$y_1 = 1 + 2x_1 + \varepsilon_1 \quad y_2 = 0,5 + 1,5x_2 + \varepsilon_2$$

$$\text{Cov}(\varepsilon_1, \varepsilon_2) = 0,7 \sigma_1 \sigma_2$$

```

1 seed(42)
2 generate df x1 = rnormal()
3 generate df x2 = rnormal()
4 generate df e1 = (rnormal() - 0.5) * 1.7321
5 generate df e2 = 0.7 * e1 + 0.7141 * (rnormal() - 0.5) *
  1.7321
6 generate df y1 = 1.0 + 2.0 * x1 + e1
7 generate df y2 = 0.5 + 1.5 * x2 + e2
8
9 let m_ols1 = ols(y1 ~ x1, df)
10 let m_ols2 = ols(y2 ~ x2, df)
11 esttab(m_ols1, m_ols2)
12
13 let m_sur = sur(df, y1 ~ x1, y2 ~ x2)
14 display m_sur

```

Listing 40.1: DGP SUR e comparação com OLS equação a equação

OLS equação a equação

	(1)	(2)
	OLS	OLS
x1	2.1956*** (0.0788)	
x2		1.5097*** (0.0779)
Constant	0.9050***	0.4879***
N	500	500
R ²	0.6091	0.4300

SUR

```

                Seemingly Unrelated Regressions (SUR)
      Cross-Equation Error Correlation  $\Sigma()$ :
[  0.2463    0.1689 ]
[  0.1689    0.2419 ]

Equation: y1 -   const=0.9513   x1=2.1003***   R2=0.6080
Equation: y2 -   const=0.4591   x2=1.5653***   R2=0.4294

```

A correlação estimada entre erros é $\hat{\Sigma}_{12}/\sqrt{\hat{\Sigma}_{11}\hat{\Sigma}_{22}} = 0,169/\sqrt{0,246 \times 0,242} \approx 0,69$, próximo do verdadeiro 0,7. O SUR ganha eficiência via corte nos SEs: $\hat{\sigma}_{\text{SUR}}(x_1) < \hat{\sigma}_{\text{OLS}}(x_1)$.

40.3 Sintaxe

```

1 sur(df, y1 ~ x1 + x2, y2 ~ x3 + x4)
2 sur(df, y1 ~ x1, y2 ~ x2, y3 ~ x3)           // 3 equações

```

O primeiro argumento é o DataFrame; os demais são fórmulas (uma por equação).

Nota

Se todas as equações tiverem os mesmos regressores, SUR = OLS e não há ganho de eficiência. O ganho é máximo quando os regressores são ortogonais entre equações e a correlação entre erros é alta.

40.4 Validação empírica

O dataset de investimento `grunfeld` do Wooldridge é usado no caso de validação `sur_grunfeld` em `validation/cases/`. O caso estima um sistema SUR de duas equações no HAYASHI e compara os coeficientes com implementações de referência em R e Python. Execute `hay_validate` para ver o estado atual.

Capítulo 41

Regularização e Seleção de Variáveis

41.1 O problema de dimensionalidade

Com k regressores e N pequeno, o OLS sofre de *overfitting*: ajusta o ruído da amostra além do sinal, elevando o erro fora da amostra. Quando $k > N$, o OLS nem sequer é identificado. A regularização penaliza a magnitude dos coeficientes, trocando viés por variância reduzida.

LASSO

O LASSO (Tibshirani 1996) minimiza:

$$\hat{\beta}^{\text{LASSO}} = \arg \min_{\beta} \left\{ \sum (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^k |\beta_j| \right\}$$

A penalidade ℓ_1 força coeficientes pequenos a zero exatamente, fazendo *seleção de variáveis* automática. O caminho de regularização — LASSO para diferentes λ — revela quais variáveis entram conforme λ decresce de ∞ (modelo nulo) a 0 (OLS).

Ridge

A penalidade ℓ_2 do Ridge (Hoerl e Kennard 1970) encolhe coeficientes em direção a zero sem zerá-los:

$$\hat{\beta}^{\text{Ridge}} = (X'X + \lambda I)^{-1} X'y$$

Útil quando muitas variáveis têm pequeno efeito (contínuo de preditores fracos).

Não realiza seleção de variáveis.

Elastic Net

O Elastic Net (Zou e Hastie 2005) combina ℓ_1 e ℓ_2 :

$$\min_{\beta} \left\{ \sum (y_i - x_i' \beta)^2 + \lambda \left[\rho \sum |\beta_j| + (1 - \rho) \sum \beta_j^2 \right] \right\}$$

Herda seleção de variáveis do LASSO e estabilidade em grupos correlacionados do Ridge.

41.2 Verificação por DGP

DGP com 10 regressores, apenas x_1 e x_2 com efeito não-nulo. $N = 200$ — regime onde regularização importa.

```
1 seed(42)
2 // 10 regressores; y = 1 + 2*x1 + 3*x2 + 0*(x3..x10) + e
3 generate df x1 = rnormal()
4 ...
5 generate df y = 1.0 + 2.0*x1 + 3.0*x2 + e
6
7 let m_ols = ols(y ~ x1+x2+x3+x4+x5+x6+x7+x8+x9+x10, df)
8 let m_lasso = lasso(y ~ x1+x2+x3+x4+x5+x6+x7+x8+x9+x10, df,
9   alpha=0.1)
10 let m_ridge = ridge_reg(y ~ x1+x2+x3+x4+x5+x6+x7+x8+x9+x10,
11   df, alpha=0.5)
let m_enet = enet(y ~ x1+x2+x3+x4+x5+x6+x7+x8+x9+x10, df,
  alpha=0.5)
```

Listing 41.1: DGP esperso — 2 de 10 variáveis ativas

OLS

```
OLS: R²=0.801 (bom ajuste na amostra, mas x3..x10 poluem com coef não-nulos)
const=0.68 x1=1.93*** x2=2.88*** x3=0.17 x4=0.07 ... x10=-0.11
```

LASSO

```
LASSO =0.1: R²=0.772  vars ativas: 2
      x1=1.552  x2=2.506  x3..x10 = 0.000  (zerando corretamente)
```

Com $\alpha = 0,1$ o LASSO identifica os dois preditores verdadeiros e zera os oito irrelevantes.

Ridge

```
Ridge =0.5: R²=0.801
      x1=1.878  x2=2.793  x3=0.172  x4=0.081  ...
      (encolhe mas não zera nenhum)
```

Elastic Net

```
ElasticNet =0.5 l1_ratio=0.5: R²=0.589  vars ativas: 2
      x1=0.789  x2=1.550  x3..x10 = 0.000
```

Elastic Net também seleciona x_1 e x_2 , mas com maior penalização total (combinando ℓ_1 e ℓ_2) os coeficientes ficam mais encolhidos.

41.3 Sintaxe

```
1 lasso(y ~ x1 + x2 + x3, df, alpha=0.1)      // alpha = lambda
   de penalização
2 ridge_reg(y ~ x1 + x2 + x3, df, alpha=0.5)
3 enet(y ~ x1 + x2 + x3, df, alpha=0.5)      // alpha =
   mistura L1/(L1+L2)
```

Parâmetro	LASSO	Ridge / Enet
alpha	penalização λ	penalização λ
alpha=0	OLS	Ridge puro (Enet)
alpha=1	L1 máximo	L1 puro (Enet)

Nota

O valor ótimo de α é tipicamente escolhido por validação cruzada (k -fold). Em amostras pequenas, LASSO com α via *BIC-LASSO* tende a ser mais conservador do que via CV.

41.4 Validação empírica

O dataset de preços de imóveis `hprice1` do Wooldridge é usado nos casos de validação `ridge_hprice1`, `elasticnet_hprice1` e `lasso_hprice1` em `validation/cases/`. Os casos estimam regressões Ridge, Elastic Net e LASSO no HAYASHI e comparam os coeficientes com implementações de referência em R e Python. Execute `hay validate` para ver o estado atual.

Capítulo 42

Bootstrap

42.1 Inferência por reamostragem

Os erros-padrão analíticos derivados da teoria assintótica assumem, em geral, que os resíduos seguem uma distribuição específica (normal, homocedástica, i.i.d.). O **bootstrap** de Efron (1979) substitui premissas distribucionais por reamostragem: replica o processo de estimação B vezes em amostras com reposição do próprio conjunto de dados.

Bootstrap de pares

A abordagem mais simples reamostra pares (y_i, x_i) :

1. Para $b = 1, \dots, B$: amostrar n observações com reposição.
2. Estimar $\hat{\theta}^{(b)}$ na amostra reamostrada.
3. $\widehat{SE}_{\text{boot}} = \text{sd}(\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(B)})$.

O IC percentil bootstrap de 95% é o intervalo $[Q_{0,025}, Q_{0,975}]$ da distribuição empírica de $\hat{\theta}^{(b)}$.

Vantagem: válido sem saber a distribuição de $\hat{\theta}$ — robusto a erros não-gaussianos, heterocedasticidade e amostras pequenas onde a aproximação normal é ruim.

42.2 Verificação por DGP

DGP com erro uniforme em $[-2, 2]$ — não-gaussiano. Com $N = 200$, o SE analítico do OLS pode subestimar a variância real.

```
1 seed(42)
2 generate df x = rnormal()
3 generate df e = (rnormal() - 0.5) * 4.0      // U(-2, 2) - não
      gaussiano
4 generate df y = 1.0 + 2.0 * x + e
5
6 // OLS padrão
7 let m_ols = ols(y ~ x, df)
8 display m_ols
9
10 // Bootstrap
11 let m_boot = bootstrap("ols", y ~ x, df, reps=500)
12 display m_boot
```

Listing 42.1: Comparação SE analítico vs. bootstrap

OLS analítico

```
OLS: R²=0.178
  const=1.046  SE=0.157  x=1.828  SE=0.279
```

Bootstrap ($B = 500$)

Bootstrap SE - ols (n=500/500)					
Variável ^		SE orig.	SE boot	IC inf	IC sup
const	1.0462	0.1566	0.1545	0.7235	1.3710
x	1.8276	0.2787	0.2679	1.3313	2.3910

SE bootstrap (0,155 e 0,268) e analítico (0,157 e 0,279) são similares aqui, indicando que os SEs analíticos do OLS são adequados mesmo com erros uniformes quando $N = 200$. A concordância valida a implementação: ambos convergem para o mesmo desvio-padrão assintótico.

42.3 Sintaxe

```

1 // bootstrap genérico - qualquer estimador implementado
2 bootstrap("ols", y ~ x, df, reps=500)
3 bootstrap("logit", y ~ x, df, reps=500)
4 bootstrap("qreg", y ~ x, df, reps=500, q=0.5)
5
6 // alias bootse
7 bootse(y ~ x, df, reps=500) // ols por padrão
  (legado)

```

Opção	Padrão	Descrição
reps / n	1000	número de réplicas bootstrap
alpha	0.05	nível para ICs (bilateral)

Nota

O estimador de bootstrap também pode estimar SEs do PSM (cap. 33), onde a distribuição assintótica do ATT é não-padrão. Nesse contexto, o bootstrap de pares é consistente (Abadie e Imbens 2008).

Capítulo 43

Análise Multivariada

43.1 Redução de dimensionalidade e estrutura latente

Quando se observa um vetor de variáveis $\mathbf{v} = (v_1, \dots, v_p)'$ que compartilham variação comum, é útil resumir essa variação em poucas dimensões. Duas abordagens se complementam:

- **PCA:** maximiza variância explicada por componentes ortogonais (solução algébrica — decomposição espectral da matriz de covariância).
- **Análise Fatorial:** modela variáveis como combinação linear de fatores latentes não-observados + unicidade (parte idiossincrática).

Análise de Componentes Principais (PCA)

$$\mathbf{v} = W\mathbf{f} + \mathbf{e} \quad W = \text{eigenvectors de } \Sigma_v$$

O j -ésimo componente principal $PC_j = w_j'\mathbf{v}$ captura a j -ésima maior fração da variância total. Os eigenvalues medem a variância de cada PC; a soma de todos os eigenvalues é $\text{tr}(\Sigma_v) = \sum \text{Var}(v_j)$.

Análise Fatorial

$$\mathbf{v} = \Lambda\mathbf{f} + \boldsymbol{\delta} \quad \mathbf{f} \perp \boldsymbol{\delta}$$

Λ são as *cargas fatoriais* (loadings): λ_{ij} mede o quanto o fator j contribui para v_i . A *comunalidade* $h_i^2 = \sum_j \lambda_{ij}^2$ é a fração da variância de v_i explicada pelos fatores comuns.

Correlação Canônica

Dadas duas baterias de variáveis $X = (x_1, \dots, x_p)$ e $Y = (y_1, \dots, y_q)$, a análise canônica encontra vetores a e b tais que $\text{Corr}(a'X, b'Y)$ é maximizada. Fornece $\min(p, q)$ pares canônicos.

43.2 Verificação por DGP

DGP com 2 fatores latentes e 5 variáveis observadas.

```
1 seed(42)
2 generate df f1 = rnormal()
3 generate df f2 = rnormal()
4 // v1, v2: cargas altas em f1; v3, v4: cargas altas em f2; v5
   : ambos
5 generate df v1 = 0.9*f1 + 0.1*f2 + e1
6 generate df v2 = 0.8*f1 + 0.2*f2 + e2
7 generate df v3 = 0.1*f1 + 0.9*f2 + e3
8 generate df v4 = 0.2*f1 + 0.8*f2 + e4
9 generate df v5 = 0.5*f1 + 0.5*f2 + e5
10
11 let m_pca = pca(df, v1, v2, v3, v4, v5, n=2)
12 display m_pca
13
14 let m_fac = factor(df, v1, v2, v3, v4, v5, n=2, rotation=
   varimax)
15 display m_fac
16
17 let m_can = cancorr(df, xvars=["v1", "v2"], yvars=["v3", "v4", "
   v5"])
18 display m_can
```

Listing 43.1: DGP fatorial e análise multivariada

PCA

Principal Component Analysis

Componente	Var Expl.	% Acum.	Eigenvalue
PC1	0.5939	0.5939	2.9695
PC2	0.2437	0.8377	1.2187

Loadings:

	PC1	PC2
v1	0.677	-0.641
v2	0.808	-0.450
v3	0.693	0.623
v4	0.790	0.466
v5	0.868	-0.002

PC1 (59,4% da variância) tem cargas positivas em todas as variáveis — captura o componente comum. PC2 (24,4%) contrasta o grupo f_1 (v1, v2) com o grupo f_2 (v3, v4). Os dois PCs somam 83,8% da variância total.

Análise Fatorial

Factor Analysis - Varimax			
Variável	F1	F2	Comunalit.
v1	0.027	-0.932	0.869
v2	0.255	-0.889	0.856
v3	0.931	-0.048	0.869
v4	0.888	-0.228	0.841
v5	0.613	-0.614	0.753

Após rotação varimax, F1 carrega em v3 e v4 (associados ao fator latente f_2); F2 carrega em v1 e v2 (fator f_1). Comunalidades acima de 0,75 confirmam que os fatores comuns explicam grande parte da variância individual.

Correlação Canônica

```

===== Canonical Correlation Analysis =====
Observations: 300  Wilks' Lambda: 0.5396  F=35.54  p=0.000
    CC1: 0.6706    CC2: 0.1396
X vars: v1, v2  |  Y vars: v3, v4, v5
=====

```

A primeira correlação canônica $\hat{\rho}_1 = 0,671$ captura a associação entre o bloco $\{v1, v2\}$ e o bloco $\{v3, v4, v5\}$ através do fator latente compartilhado.

43.3 Sintaxe

```
1  pca(df, v1, v2, v3, ..., n=2)                // n
    componentes a reter
2  factor(df, v1, v2, v3, ..., n=2, rotation=none) // rotation:
    none / varimax
3  cancrr(df, xvars=["x1","x2"], yvars=["y1","y2"])
```


Capítulo 44

Modelos Lineares Generalizados

44.1 A família exponencial

Os Modelos Lineares Generalizados (Nelder e Wedderburn 1972) unificam OLS, Logit, Poisson e muitos outros estimadores sob um arcabouço comum. Três componentes definem um GLM:

1. **Componente aleatório:** $Y_i \sim$ família exponencial com média μ_i .
2. **Preditor linear:** $\eta_i = x_i' \beta$.
3. **Função de ligação:** $g(\mu_i) = \eta_i$, que conecta média à escala linear.

Família	Link padrão	Variância	Aplicação
Gaussiana	identidade	σ^2	OLS
Binomial	logit	$\mu(1 - \mu)$	dados binários
Poisson	log	μ	contagens
Gamma	log	μ^2/ϕ	dados positivos com caudas

A estimação por IRLS (Iteratively Reweighted Least Squares) é eficiente e converge rapidamente.

GLM Gamma — dados positivos com caudas pesadas

Gastos, tamanho de empréstimos e durações seguem distribuições assimétricas à direita com variância proporcional ao quadrado da média. O GLM Gamma com link log modela $E[Y \mid x] = \exp(x' \beta)$ com $\text{Var}[Y \mid x] \propto \mu^2$.

PPML — comércio internacional

O estimador PPML (Poisson Pseudo MLE) de Santos Silva e Tenreyro (2006) usa a equação de estimação Poisson mesmo quando Y não é inteira (ex: valores de comércio). Ele é robusto a zeros e a heterocedasticidade multiplicativa — problemas comuns em equações gravitacionais de comércio.

44.2 Verificação por DGP

```
1 seed(42)
2 generate df x = rnormal()
3 generate df mu = exp(0.5 + 1.0 * x)
4 // Gamma: média=mu, variância ~ mu^2 (simulado via lognormal)
5 generate df y_gamma = mu * exp(rnormal() * 0.6)
6
7 let m_gamma = glm(y_gamma ~ x, df, family=gamma, link=log)
8 display m_gamma
9
10 // PPML com dados de "comércio" (mistura zeros e positivos)
11 generate df x2 = rnormal()
12 generate df trade = round(exp(0.3 + 1.2*x + 0.8*x2) * (
    runiform() > 0.2))
13 let m_ppml = glm(trade ~ x + x2, df, family=poisson, link=log
    )
14 display m_ppml
```

Listing 44.1: GLM Gamma e PPML

GLM Gamma

O modelo Gamma deve recuperar estimativas positivas de intercepto e inclinação, próximas ao DGP de média logarítmica, com a dispersão resumindo a variância relativa remanescente.

PPML

PPML deve recuperar efeitos positivos para as duas covariáveis enquanto lida com os zeros da variável `trade`.

44.3 Sintaxe

```

1 glm(y ~ x, df, family=gaussian, link=identity) // OLS via
  GLM
2 glm(y ~ x, df, family=binomial, link=logit)    // Logit via
  GLM
3 glm(y ~ x, df, family=gamma, link=log)         // Gamma com
  link log
4 glm(y ~ x, df, family=poisson, link=log)       // Poisson /
  PPML

```

Família	Links disponíveis
gaussian	identity, log, inverse
binomial	logit, probit, cloglog
poisson	log, identity, sqrt
gamma	log, identity, inverse

Capítulo 45

Modelos de Mudança de Regime

45.1 Heterogeneidade estrutural ao longo do tempo

Muitas séries econômicas exibem mudanças estruturais: diferentes médias, volatilidades ou dinâmicas em distintos períodos. Dois enfoques capturam essa heterogeneidade:

- **Markov Switching** (Hamilton 1989): regime latente segue uma cadeia de Markov. A probabilidade de transição entre regimes é estimada pelo algoritmo EM junto com os parâmetros de cada regime.
- **Threshold Regression** (Hansen 1997): mudança de regime é determinada por uma variável observável (variável limiar q) cruzar um limiar γ estimado.

Markov-Switching AR(p)

$$y_t = \mu_{S_t} + \sum_{k=1}^p \phi_k^{(S_t)} (y_{t-k} - \mu_{S_t}) + \sigma_{S_t} \varepsilon_t$$

onde $S_t \in \{1, \dots, K\}$ é o regime latente com probabilidades de transição $P(S_t = j \mid S_{t-1} = i) = p_{ij}$. O parâmetro μ_{S_t} é o intercepto do regime, $\phi_k^{(S_t)}$ são os coeficientes AR e σ_{S_t} é o desvio-padrão do regime.

45.2 Verificação por DGP

DGP com dois regimes alternantes:

- Regime 1 (expansão): $\mu_1 = 1,0$, $\phi_1 = 0,30$, $\sigma_1 = 0,5$
- Regime 2 (recessão): $\mu_2 = -1,0$, $\phi_2 = 0,70$, $\sigma_2 = 1,5$

```

1 seed(42)
2 generate df t      = _n
3 generate df regime = (t % 60 < 40)    // ~2/3 no regime 1
4 // y recursivo com parâmetros condicionais ao regime
5 ...
6 let m_ms = markov(df, y, k=2, p=1)
7 display m_ms

```

Listing 45.1: DGP Markov Switching AR(1) e estimação

Markov Switching

```

===== Markov Switching AR(1) - 2 regimes =====
Observations: 299    Log-L: -155.76    AIC: 327.51    BIC: 357.12
----- Transition Matrix -----
[ 0.9493    0.0507 ]
[ 0.0251    0.9749 ]
----- Regime 0 (Recessão) -----
Intercept: -1.2864    AR.L1: 0.6169    Variance: 0.5141
----- Regime 1 (Expansão) -----
Intercept:  0.9946    AR.L1: 0.2956    Variance: 0.0625
----- Expected Durations -----
Regime 0: 19.7 períodos    Regime 1: 39.9 períodos

```

O modelo recupera os dois regimes com boa precisão:

- Regime 0 (recessão): $\hat{\mu} = -1,29$ (verdadeiro: $-1,0$), $\hat{\phi} = 0,62$ (verdadeiro: $0,7$). Duração esperada 19,7 períodos.
- Regime 1 (expansão): $\hat{\mu} = 0,99 \approx 1,0$, $\hat{\phi} = 0,30$ (verdadeiro: $0,3$). Duração esperada 39,9 períodos.

A matriz de transição indica alta persistência de ambos os regimes ($p_{00} = 0,95$, $p_{11} = 0,97$) — a série raramente troca de regime, condizente com o DGP (60% do tempo no regime 1).

45.3 Sintaxe

```

1 markov(df, y, k=2, p=1)    // k regimes, AR de ordem p

```

Opção	Padrão	Descrição
k	2	número de regimes
p	1	ordem AR dentro de cada regime

Nota

O número de regimes k é fixo e deve ser especificado a priori. Critérios de informação (AIC, BIC) comparados entre modelos com $k = 2$ e $k = 3$ guiam essa escolha. Para dados com $N < 200$, $k > 3$ raramente é identificado de forma confiável.

Capítulo 46

Filtros e Decomposição de Séries Temporais

46.1 Separação de componentes

Uma série temporal pode ser decomposta em:

$$y_t = \tau_t + c_t + s_t + \varepsilon_t$$

onde τ_t é a tendência, c_t o componente cíclico, s_t a sazonalidade e ε_t o ruído idiossincrático. Filtros lineares extraem um ou mais desses componentes a partir da série observada.

Filtro Hodrick-Prescott (HP)

O filtro HP (Hodrick e Prescott 1997) separa tendência de ciclo minimizando:

$$\min_{\{\tau_t\}} \left\{ \sum_{t=1}^T (y_t - \tau_t)^2 + \lambda \sum_{t=2}^{T-1} [(\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1})]^2 \right\}$$

O parâmetro λ penaliza variações na segunda diferença da tendência. Valores canônicos: $\lambda = 1600$ (trimestral), 100 (anual), 14400 (mensal).

Filtro Baxter-King (BK)

O filtro BK (Baxter e King 1999) extrai um componente de *banda de frequência*: retém variações periódicas entre $[p_L, p_H]$ períodos e elimina tendência e frequências altas. Para ciclos de negócios: $p_L = 6$, $p_H = 32$ trimestres (1,5 a 8 anos).

Suavização Exponencial Holt-Winters (ETS)

O modelo ETS (*Error-Trend-Seasonal*) de Holt e Winters combina: equações de nível, tendência e sazonalidade atualizadas recursivamente com pesos exponencialmente decrescentes. Parâmetros (α, β, γ) controlam a velocidade de adaptação de cada componente.

46.2 Verificação por DGP

DGP com tendência linear, ciclo anual e sazonalidade semestral, $T = 120$ meses.

```
1 seed(42)
2 generate df t          = _n
3 generate df trend      = 0.05 * t
4 generate df cycle      = 0.5 * sin(t * 3.14159 / 12)
5 generate df season     = 0.3 * sin(t * 3.14159 / 6)
6 generate df noise      = (rnormal() - 0.5) * 0.3
7 generate df y          = 10.0 + trend + cycle + season + noise
8
9 hprescott(df, y, lambda=1600)
10 display df
11
12 baxter_king(df, y, low=6, high=32, k=12)
13 display df
14
15 let m_hw = holtwinters(df, y, trend=add, seasonal=add, period
16                    =12)
16 display m_hw
```

Listing 46.1: Séries com tendência, ciclo e sazonalidade

Hodrick-Prescott

```
hpfilter: =1600 → y_trend e y_cycle adicionadas a df
t=1: y=10.34 y_trend=10.56 y_cycle=-0.22
t=2: y=10.62 y_trend=10.56 y_cycle= 0.06
...
```

O HP adiciona colunas `y_trend` (tendência suavizada) e `y_cycle` (ciclo = resíduo).

Baxter-King

O BK adiciona `y_cycle` com o componente de banda de frequência. Os primeiros e últimos $k = 12$ períodos ficam como NaN — custo dos filtros de duas pontas.

Holt-Winters ETS

```
===== ETS(A,A,A) =====
Observations:      120
Alpha:             0.8000      (nível)
Beta:              0.0500      (tendência)
Gamma:             0.6000      (sazonalidade)
SSE:               5.3570
AIC:               -339.09
BIC:               -291.70
=====
```

O modelo ETS(A,A,A) — erros aditivos, tendência aditiva, sazonalidade aditiva — ajusta os parâmetros de suavização (α, β, γ) minimizando SSE. α alto (0,80) indica resposta rápida do nível.

46.3 Sintaxe

```
1 hprescott(df, var, lambda=1600)           // adiciona
   var_trend e var_cycle
2 baxter_king(df, var, low=6, high=32, k=12) // adiciona
   var_cycle
3 holtwinters(df, var, trend=add, seasonal=add, period=12)
4 ets(df, var, trend=add, seasonal=add, period=12) // alias
```

Filtro	Output	Uso típico
HP	tendência + ciclo	macro trimestral
BK	ciclo de banda	análise de negócios
Holt-Winters	modelo ETS + previsão	previsão de curto prazo

Nota

O filtro HP em dados de ponta (*end-of-sample*) sofre do *end-point problem*: tendência e ciclo são revisados conforme novos dados chegam. O BK evita esse problema ao usar uma janela simétrica (custo: perde k observações em cada extremo).

Capítulo 47

VAR Estrutural

47.1 Da forma reduzida à estrutura

O VAR da forma reduzida (cap. 30) fornece $K^2 \cdot p + K$ parâmetros livres. A impulso-resposta reduzida mede o efeito de *inovações* u_t sem conteúdo econômico. O SVAR recupera *choques estruturais* ε_t (oferta, demanda, política monetária) impondo restrições que refletem teoria econômica:

$$A y_t = A_1^* y_{t-1} + \cdots + B \varepsilon_t \quad \varepsilon_t \sim (0, I_K)$$

Identificação de Cholesky

A decomposição triangular inferior de $\Sigma_u = P P'$ impõe uma ordenação causal recursiva: a variável na posição 1 é exógena contemporaneamente; a na posição 2 responde contemporaneamente apenas à primeira; etc.

$$B = P \quad (\text{triangular inferior}) \implies y_{1,t} \perp \varepsilon_{2,t} \text{ no mesmo período}$$

O IRF estrutural $\Theta_h = \Phi_h B$ mede a resposta de $y_{k,t+h}$ a um choque unitário em $\varepsilon_{j,t}$.

47.2 Verificação por DGP

DGP: VAR(1) bivariado com restrição Cholesky verdadeira (y2 responde contemporaneamente a y1, mas não vice-versa).

```
1 seed(42)
2 generate df t = _n
3 // VAR(1): y1 e y2 com coeficientes cruzados
```

```

4 ...
5 replace df y1 = 0.5*ly1 + 0.3*ly2 + e1t          if t == it
6 replace df y2 = 0.2*ly1 + 0.4*ly2 + 0.6*e1t + e2t if t == it
7
8 let m_var = var(df, y1, y2, lags=1)
9 display m_var
10
11 let m_svar = svar(df, y1, y2, lags=1, id=cholesky)
12 display m_svar
13
14 let m_sirf = sirf(m_svar, steps=10)
15 display m_sirf

```

Listing 47.1: DGP estrutural e SVAR Cholesky

VAR reduzido

```

Vector Autoregression (VAR(1)):  Observations=299  AIC=-2.83  BIC=-2.76
Residual Covariance Σ(u):
[ 0.2452   0.1617 ]
[ 0.1617   0.3375 ]

```

SVAR — Matriz B

```

===== SVAR(1) - Cholesky =====
B Matrix (impacto estrutural):
[ 0.4952   0.0000 ]      <- choque 1 afeta y1, não afeta y2 contemporaneamente
[ 0.3265   0.4805 ]      <- choque 2 afeta y2; y2 responde ao choque 1

```

A coluna nula em B_{12} reflete a ordenação Cholesky: o choque 2 não afeta y_1 contemporaneamente. $B_{21} = 0,33$ estima o efeito contemporâneo do choque 1 sobre y_2 (DGP verdadeiro: $0,6 \times \sigma_{\varepsilon_1}$).

IRF estrutural

```

Impulso: Choque 1 (Var0)
h=0:  y1=+0.495  y2=+0.327  (impacto contemporâneo)
h=1:  y1=+0.324  y2=+0.224
h=5:  y1=+0.063  y2=+0.044  (amortecimento progressivo)
h=9:  y1=+0.012  y2=+0.009

```

```

Impulso: Choque 2 (Var1)
  h=0:   y1= 0.000   y2=+0.481   (restrição Cholesky: y1 não responde)
  h=1:   y1=+0.115   y2=+0.170

```

A resposta de y_1 ao choque 2 em $h = 0$ é exatamente zero — restrição de identificação Cholesky aplicada. No horizonte $h = 1$, y_1 começa a responder via o canal VAR defasado.

47.3 Sintaxe

```

1 svar(df, y1, y2, lags=1, id=cholesky)      // SVAR com
   identificação Cholesky
2 svar(df, y1, y2, lags=1, id=longrun)      // BQ: restrições
   de longo prazo
3 sirf(m_svar, steps=10)                    // IRF estrutural

```

Identificação	Restrições
cholesky	triangular inferior — restrições de curto prazo recursivas
longrun	Blanchard-Quah — restrições de longo prazo

Nota

A ordenação das variáveis no SVAR Cholesky é crucial: a variável listada primeiro é tratada como contemporaneamente exógena a todas as demais. A escolha da ordenação deve ser guiada por teoria econômica ou por resultados robustos a permutações da ordem.

Parte VII

Métodos Complementares

Capítulo 48

Inferência Clássica

48.1 Testes de hipóteses paramétricos e não-paramétricos

Os testes apresentados neste capítulo respondem à pergunta: *os dados são consistentes com uma hipótese sobre a distribuição populacional?*

Teste t de Student

Para uma amostra de tamanho n com variância desconhecida, a estatística:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$$

testa $H_0 : \mu = \mu_0$. Para duas amostras independentes, o teste de Welch usa graus de liberdade aproximados pelo método de Satterthwaite, sem assumir homoscedasticidade.

ANOVA de um fator

Generaliza o t -test para $K > 2$ grupos. Decompõe a variação total:

$$\begin{aligned} \text{SS}_{\text{total}} &= \text{SS}_{\text{entre}} + \text{SS}_{\text{dentro}} \\ F &= \frac{\text{SS}_{\text{entre}}/(K-1)}{\text{SS}_{\text{dentro}}/(N-K)} \sim F_{K-1, N-K} \end{aligned}$$

H_0 : todas as médias grupais são iguais.

Kruskal-Wallis

Alternativa não-paramétrica à ANOVA de um fator. Substitui observações por *ranks* e compara as somas de ranks entre grupos. Estatística:

$$H = \frac{12}{N(N+1)} \sum_{k=1}^K \frac{R_k^2}{n_k} - 3(N+1) \sim \chi_{K-1}^2$$

válida mesmo sem normalidade, desde que as distribuições tenham forma similar.

48.2 Verificação por DGP

DGP com 3 grupos de tamanhos distintos; o valor esperado cresce linearmente com o grupo. $N = 300$, $\sigma = 1$.

```
1 seed(42)
2 ...
3 generate df g = (_n <= 150) * 1 + (_n > 150) * 2
4 generate df yg = 2.0 + e + (g - 1) * 0.5 // g=1: mu=2.0, g
   =2: mu=2.5
5
6 // Teste t de uma amostra: H0: mu = 2.0
7 ttest(df, y, mu=2.0)
8
9 // Teste t de dois grupos (Welch): H0: mu(g1) = mu(g2)
10 ttest(df, yg, by=g)
11
12 // Pareado: antes vs depois
13 ttest(df, y_antes, y_depois, paired=true)
14
15 // ANOVA: H0: mu1 = mu2 = mu3
16 anova(df, y3, by=k)
17
18 // Kruskal-Wallis (não-paramétrico)
19 kruskal_wallis(df, y3, by=k)
```

Listing 48.1: Testes de hipóteses

Teste t — uma amostra

```
One-sample t-test: y    H0: mean = 2.0
```

```
t = -0.6946    df = 299    p = 0.4879
```

Não rejeita H_0 — média amostral 1,98 é compatível com 2,0.

Teste t — dois grupos (Welch)

```
Two-sample t-test (Welch): yg by g
  grupo 1: n=150  mean=1.971  SE=0.040
  grupo 2: n=150  mean=2.489  SE=0.041
Welch's t = -9.0552    df = 297.38    p = 0.0000
```

Rejeita H_0 : diferença de 0,52 diferença verdadeira de 0,50.

ANOVA

```
===== One-Way ANOVA
=====
Source          SS      df      MS      F      P>F
-----
Between         51.195      2      25.597    104.037    0.0000
Within          73.074     297      0.246
Total          124.269     299
```

$F = 104,0$, $p < 0,001$: rejeita H_0 com segurança.

Kruskal-Wallis

```
H = 120.38    df = 2    p = 0.0000
```

Confirma a ANOVA sem assumir normalidade.

48.3 Sintaxe

```
1 ttest(df, var, mu=0.0)                // uma amostra
2 ttest(df, var, by=grupo)              // dois grupos (
   Welch)
3 ttest(df, var, by=grupo, unequal=false) // dois grupos (
   Student)
4 ttest(df, var1, var2, paired=true)    // pareado
5 anova(df, var, by=grupo)              // ANOVA de um fator
6 kruskal_wallis(df, var, by=grupo)     // Kruskal-Wallis
```

Nota

O teste de Welch não assume homocedasticidade e é preferível ao t -test clássico de Student em quase todos os casos práticos. A perda de potência é negligenciável quando as variâncias são iguais; o ganho quando diferem é substancial. Caso deseje executar o teste de Student clássico, use a opção `unequal=false`.

Capítulo 49

Painel Avançado II

49.1 Além do FE e RE básicos

Os estimadores do cap. 39 (AB-GMM, PCSE, GEE) lidam com dinâmica e heterocedasticidade. Aqui cobrimos quatro abordagens complementares:

- **FE** — referência; efeitos fixos padrão (within estimator)
- **Mundlak (CRE)** — Correlated Random Effects; testa RE vs FE via γ
- **xtgls** — GLS para painel; flexível quanto à estrutura de Σ
- **mixedlm** — modelo misto com intercepts aleatórios
- **clogit** — logit condicional para variáveis binárias em painel

Estimador de Mundlak (CRE)

Mundlak (1978) mostra que o estimador RE é equivalente ao FE se:

$$\alpha_i = \gamma' \bar{x}_i + u_i \quad u_i \perp x_{it}$$

Regride y_{it} em x_{it} e $\bar{x}_i$ (média por entidade). Se $\hat{\gamma} \neq 0$, o efeito fixo é necessário.

GLS para painel (xtgls)

O GLS de painel especifica uma estrutura para a covariância dos erros entre entidades. Com `panels=hetero`, cada painel tem variância própria σ_i^2 , permitindo heterocedasticidade entre painéis.

Modelo misto (mixedlm)

O modelo linear misto especifica:

$$y_{it} = \beta x_{it} + u_i + \varepsilon_{it} \quad u_i \sim N(0, \sigma_u^2)$$

onde u_i é um efeito aleatório de intercept por entidade. Difere do RE padrão por usar REML e integrar sobre u_i via máxima verossimilhança.

49.2 Verificação por DGP

DGP: painel estático endógeno. $y = 1 + 2x + \alpha_i + \varepsilon$; $\alpha_i = 0,05 \cdot i$ correlacionado com x (via z). $N = 50$ entidades, $T = 20$ períodos.

```

1 seed(42)
2 generate df unit = (_n - 1) % 50 + 1
3 generate df t    = (_n - (_n - 1) % 50 - 1) / 50 + 1
4 generate df alpha = unit * 0.05
5 generate df z     = (rnormal() - 0.5) * 1.7321
6 generate df x     = 0.5 * z + alpha + (rnormal() - 0.5)
7 generate df y     = 1.0 + 2.0 * x + alpha + e
8
9 let m_fe = fe(y ~ x, df, id=unit)
10 let m_mundlak = mundlak(df, y ~ x, id="unit")
11 let m_xtglm = xtglm(y ~ x, df, id=unit, time=t)
12 let m_mixedlm = mixedlm(y ~ x, df, id="unit")
13 generate df yb = (y > 2.5)
14 let m_clogit = clogit(yb ~ x, df, group="unit")

```

Listing 49.1: Painel II: FE, Mundlak, xtglm, mixedlm, clogit

FE (within):	x = 2.041 ***	(verdadeiro: 2.0)
Mundlak:	x = 2.040, (x) = 0.939 ***	→ rejeita RE
xtglm (hetero):	x = 2.768 ***	(tendencioso sem demeaning)
mixedlm:	x = 2.134 ***	(intercept aleatório: $\sigma_u^2 = 0.388$)
clogit (yb ~ x):	x = 1.397 ***	(grupos sem variação descartados)

Teste de Mundlak

O teste $H_0 : \gamma = 0$ (médias não correlacionadas com x) rejeita com $F = 419,96$, $p < 0,001$. Isso confirma que x é endógeno — o estimador RE seria inconsistente e deve-se usar FE.

O `xtgls` sem remoção de FE superestima β pois captura parte do efeito individual. O `mixedlm` fica próximo do FE porque trata α_i como efeito aleatório normal.

49.3 Sintaxe

```

1 fe(y ~ x, df, id=unit)           // Fixed Effects (
    within)
2 mundlak(df, y ~ x, id="unit")    // CRE: inclui mé
    dias de grupo
3 xtgls(y ~ x, df, id=unit, time=t) // GLS para painel
4 xtgls(y ~ x, df, id=unit, time=t, panels="corr") // Σ
    correlacionada
5 mixedlm(y ~ x, df, id="unit")    // modelo misto (
    REML)
6 clogit(yb ~ x, df, group="unit") // logit
    condicional

```

Nota

No `clogit`, grupos onde y não varia (todos 0 ou todos 1) são automaticamente descartados porque não contribuem para a verossimilhança condicional. Isso reduz a amostra efetiva, mas é teoricamente correto.

49.4 Painel não-linear via GEE

Para modelos não-lineares em painel (logit, probit, Poisson), Hayashi oferece wrappers sobre GEE (Generalized Estimating Equations), que estimam modelos population-averaged com correlação intra-grupo flexível:

```

1 xtlogit(yb ~ x1 + x2, df, id="firm", corr="exchangeable")
2 xtprobit(yb ~ x1 + x2, df, id="firm", corr="exchangeable")
3 xtpoisson(y ~ x1 + x2, df, id="firm", corr="exchangeable")

```

Estruturas de correlação disponíveis:

- `independence` — correlação intra-grupo zero

- `exchangeable` — simetria composta (padrão)
- `ar1` — autoregressivo de primeira ordem
- `unstructured` — matriz não-estruturada

Nota

GEE estima efeitos populacionais (marginais), não efeitos condicionais aos efeitos fixos. Para logit com efeitos fixos, use `clogit`.

Capítulo 50

Raízes Unitárias II

50.1 Além do ADF: PP e Zivot-Andrews

O capítulo anterior (cap. 29) cobriu o teste ADF, que corrige para autocorrelação residual por meio de defasagens. Dois problemas permanecem:

1. O ADF é sensível à heterocedasticidade condicional dos erros (GARCH etc.)
2. O ADF tem baixo poder na presença de *quebra estrutural*: uma série estacionária com quebra de nível se parece com um passeio aleatório.

Teste Phillips-Perron (PP)

Phillips e Perron (1988) adotam uma abordagem não-paramétrica: corrigem a estatística ADF para heterocedasticidade e autocorrelação de *qualquer forma* via estimador de Newey-West:

$$Z_\alpha = T(\hat{\rho} - 1) - \frac{T^2 \hat{\sigma}^2}{2 \hat{s}_T^2} (\hat{\lambda}^2 - \hat{\gamma}_0)$$

onde $\hat{s}_T^2$ é a variância de longo prazo estimada com kernel de Bartlett. A distribuição assintótica é idêntica à do ADF (Dickey-Fuller).

Teste Zivot-Andrews (ZA)

Zivot e Andrews (1992) relaxam a hipótese de ausência de quebra estrutural. O teste estima a data de quebra *endogenamente* como o valor que minimiza a estatística t :

$$\hat{t}_B = \arg \min_{\lambda} t_{\alpha}(\lambda), \quad \lambda = t_B/T \in (0.15, 0.85)$$

A equação testada inclui um nível de degrau ou mudança de tendência:

$$\Delta y_t = c + \beta t + \gamma DU_t(\lambda) + \alpha y_{t-1} + \sum_{j=1}^k d_j \Delta y_{t-j} + \varepsilon_t$$

H_0 : raiz unitária sem quebra estrutural.

50.2 Verificação por DGP

```

1 seed(42)
2 // Passeio aleatório: rw_t = rw_{t-1} + e_t
3 // Série estacionária com tendência: stat_t = 0.5*t + e
4 // Série com quebra em t=150: AR(1) + degrau de 3.0
5
6 phillips_perron(df, rw)
7 phillips_perron(df, stat)
8 zivot(df, break_t)

```

Listing 50.1: PP e Zivot-Andrews

```

PP - rw:      Zt = 77.365    VC 5%=-2.860    NÃO rejeita H (
              raiz unitária)
PP - stat:    Zt = 2058     VC 5%=-2.860    NÃO rejeita H (
              trend-stationary)
ZA - break_t: t  = -11.597  VC 5%=-4.800    REJEITA H, quebra
              em obs=147

```

O PP para `stat` (tendência linear + ruído) não rejeita H_0 porque o teste padrão (sem tendência determinística na equação auxiliar) não distingue tendência estocástica de determinística. O ZA identifica corretamente a quebra estrutural em $t = 147$ (próximo ao verdadeiro $t = 150$) e rejeita H_0 .

50.3 Sintaxe

```

1 phillips_perron(df, var)           // PP sem tendência
2 phillips_perron(df, var, trend=true) // PP com tendência
   determinística
3 zivot(df, var)                     // Zivot-Andrews (quebra end
   ógena de nível)
4 zivot(df, var, type="trend")       // quebra na tendência

```

Teste	Correção	Quebra?	VC 5%
ADF	Defasagens paramétricas	Não	-2,86
PP	Newey-West não-param.	Não	-2,86
ZA	PP + quebra endógena	Sim	-4,80

Nota

Séries trend-stationary e séries com quebra estrutural são dois casos onde o ADF/PP pode levar a conclusões erradas. O ZA resolve o segundo; para o primeiro, incluir uma tendência determinística na equação auxiliar (`trend=true`) é suficiente.

Capítulo 51

Decomposição de Séries II

51.1 STL e Christiano-Fitzgerald

O cap. 46 apresentou HP, BK e Holt-Winters. Este capítulo cobre dois métodos adicionais:

STL *Seasonal-Trend decomposition via Loess* (Cleveland et al. 1990): decompõe $y_t = T_t + S_t + R_t$ iterativamente via regressão local (loess). Robusto a outliers; permite sazonalidade variante no tempo.

Christiano-Fitzgerald (CF) Filtro passa-banda assimétrico (2003): extrai frequências em $[p_L, p_H]$ usando pesos de uma janela não-simétrica que se adapta à posição na série. Ao contrário do BK, não perde pontos de borda — o preço é que os pesos mudam a cada observação.

STL: decomposição iterativa

O algoritmo STL alterna entre:

1. *Seasonal loop*: suaviza cada posição sazonal com loess
2. *Trend loop*: suaviza a série dessazonalizada com loess

A convergência produz T_t (tendência), S_t (sazonalidade) e R_t (resíduo) com propriedades de robustez a outliers quando `robust=true`.

Filtro Christiano-Fitzgerald

O CF aplica pesos a_j que satisfazem $\sum_j a_j e^{i\omega j} \approx 1$ para $\omega \in [\omega_L, \omega_H]$ e ≈ 0 fora da banda. Para t nas bordas, os pesos se ajustam para não usar observações futuras.

51.2 Verificação por DGP

DGP: série mensal com tendência linear, ciclo anual e sazonalidade semestral. $T = 120$ meses.

```

1 seed(42)
2 generate df trend = 0.05 * t
3 generate df cycle = 0.5 * sin(t * 3.14159 / 12)
4 generate df season = 0.3 * sin(t * 3.14159 / 6)
5 generate df y      = 10.0 + trend + cycle + season + noise
6
7 stl(df, y, period=12)
8 display df
9
10 christiano_fitzgerald(df, y, low=6, high=32)
11 display df

```

Listing 51.1: STL e Christiano-Fitzgerald

STL

```

Seasonal Decomposition (STL)
  Observations: 120
  Trend mean:   13.0243
  Seasonal std:  0.1943
  Residual std:  0.1868

```

O STL adiciona colunas `y_trend`, `y_seasonal` e `y_resid` ao DataFrame. Residual std < 0,2 — o ruído verdadeiro ($\sigma = 0,3$) é bem separado dos demais componentes.

Christiano-Fitzgerald

```

cffilter: períodos [6,32] → y_cycle adicionada a df
  t=1: y_cycle = 1.04
  t=6: y_cycle = 1.19      (ciclo anual dominante)
  t=12: y_cycle = 0.87

```

O CF retém variações periódicas entre 6 e 32 meses (1,5 a 8 anos — ciclos de negócios). A vantagem sobre o BK é que todas as 120 observações são mantidas (sem trimagem de pontas).

51.3 Sintaxe

```

1 stl(df, var, period=12)                                // adiciona
   trend, seasonal, resid
2 christiano_fitzgerald(df, var, low=6, high=32) // adiciona
   var_cycle

```

Filtro	Tipo	Perda de borda	Sazonalidade
HP	passa-baixo	Sim (ponta)	Não
BK	passa-banda	Sim (k cada lado)	Não
CF	passa-banda	Não	Não
STL	decomposição	Não	Sim

Nota

A função `hamilton` no Hayashi refere-se ao modelo de Markov Switching de Hamilton (1989), *não* ao filtro de Hamilton (2018) (cap. 45). O filtro Hamilton 2018 — que propõe substituir o HP por uma regressão OLS com 4 defasagens e horizonte $h = 8$ — não está implementado separadamente.

Capítulo 52

SVAR com Restrições de Longo Prazo

52.1 Identificação de Blanchard-Quah

O cap. 47 (SVAR Cholesky) impõe restrições de *curto prazo*: a variável na posição 1 não é afetada contemporaneamente pela segunda. Blanchard e Quah (1989) propõem uma alternativa via restrições de *longo prazo*: choques permanentes e transitórios.

A ideia central: na macroeconomia, um choque de oferta tem efeito permanente sobre o produto (y), enquanto um choque de demanda tem efeito apenas transitório. A restrição:

$$\sum_{h=0}^{\infty} \Theta_h^{(1,1)} = \text{livre}, \quad \sum_{h=0}^{\infty} \Theta_h^{(1,2)} = 0$$

impõe que o choque 2 não afeta y no longo prazo. Essa restrição identifica a decomposição B sem nenhuma restrição de impacto contemporâneo.

Decomposição BQ

Dado o VAR na forma reduzida $y_t = \Phi_1 y_{t-1} + u_t$:

1. Compute a soma $C = (I - \Phi_1)^{-1}$ — multiplicador de longo prazo
2. Fatore $C \Sigma_u C' = F F'$ (Cholesky de F)
3. Extraia $B = C^{-1} F$ — os choques estruturais de longo prazo

52.2 Verificação por DGP

DGP: VAR(1) bivariado onde y_1 é um passeio aleatório (choque 1 permanente), y_2 é estacionária e responde transitoriamente ao choque 1.

```

1 seed(42)
2 // y1_t = y1_{t-1} + e1_t (passeio aleatório)
3 // y2_t = 0.5*y2_{t-1} + 0.4*e1_t + 0.6*e2_t (estacionária)
4
5 let m_bq = svar(df, y1, y2, lags=1, id=longrun)
6 display m_bq
7 let m_irf_bq = sirf(m_bq, steps=20)
8 display m_irf_bq

```

Listing 52.1: SVAR Blanchard-Quah

Matriz B (choques estruturais)

```

SVAR(1) - Long-run restrictions
B Matrix:
[ 0.4907    0.0358 ]
[ 0.1935    0.3031 ]

```

A matriz B não é triangular — ao contrário do Cholesky, as restrições de longo prazo não implicam restrições de impacto contemporâneo.

IRF estrutural

```

Impulso: Choque 1 (permanente)
h= 0:  y1=+0.491  y2=+0.194
h= 1:  y1=+0.464  y2=+0.087
h= 5:  y1=+0.405  y2=-0.003  (efeito em y2 decai)
h=19:  y1=+0.271  y2=-0.005  (y1 retém efeito permanente)

Impulso: Choque 2 (transitório)
h= 0:  y1=+0.036  y2=+0.303
h= 1:  y1=+0.016  y2=+0.144
h= 5:  y1=-0.001  y2=+0.007  (efeito em y1 decai a ~0)
h=19:  y1=-0.001  y2= 0.000  (transitório confirmado)

```

O choque 2 afeta y_1 apenas transitoriamente (soma $\rightarrow 0$), confirmando a restrição de longo prazo. O choque 1 tem efeito acumulado crescente sobre y_1 — coerente com a raiz unitária.

52.3 Sintaxe

```

1 svar(df, y1, y2, lags=1, id=longrun)      // BQ: restrições de
    longo prazo
2 svar(df, y1, y2, lags=1, id=cholesky)     // Cholesky: restriç
    ões contemporâneas
3 sirf(m_svar, steps=20)                    // IRF estrutural

```

Nota

A identificação BQ requer que as variáveis sejam integradas de ordem 1 ($I(1)$). Para séries estacionárias, $(I - \hat{\Phi}_1)^{-1}$ é finito e a decomposição permanente/transitória não tem interpretação natural. Verificar raiz unitária (cap. 29, 50) antes de aplicar BQ.

Capítulo 53

Estimação Local e Ponderada

53.1 Pesos, janelas e suavização

A estimação clássica (OLS, MLE) trata cada observação simetricamente. Três alternativas permitem que o modelo se adapte localmente:

WLS Mínimos quadrados ponderados: observações com menor variância (ou maior relevância) recebem maior peso.

Rolling OLS Estima o modelo em janelas temporais deslizantes, revelando como os coeficientes evoluem ao longo do tempo.

LOWESS Suavização não-paramétrica: para cada ponto x_0 , ajusta uma regressão ponderada localmente usando vizinhos próximos.

WLS (Weighted Least Squares)

O estimador WLS minimiza:

$$\hat{\beta}_{WLS} = \arg \min_{\beta} \sum_{i=1}^n w_i (y_i - x_i' \beta)^2 = (X' W X)^{-1} X' W y$$

onde $W = \text{diag}(w_1, \dots, w_n)$. Se os pesos são proporcionais a $1/\sigma_i^2$ (variâncias dos erros), o WLS é o estimador eficiente sob heterocedasticidade (= GLS para erros independentes).

Rolling OLS

Para séries temporais não-estacionárias nos parâmetros (coeficientes variantes no tempo), o rolling OLS com janela h estima:

$$\hat{\beta}_t = (X'_{t-h:t} X_{t-h:t})^{-1} X'_{t-h:t} Y_{t-h:t}$$

LOWESS

O LOWESS (Cleveland 1979) estima $m(x_0) = E[y|x = x_0]$ localmente:

1. Seleciona os $f \cdot n$ vizinhos mais próximos de x_0
2. Aplica pesos tricúbicos: $w_i = (1 - |d_i|^3)^3$
3. Ajusta uma regressão ponderada (linear ou constante)
4. Itera com re-ponderação robusta (opcional)

53.2 Verificação por DGP

DGP: erro heterocedástico $\varepsilon_i \propto (1 + x_i)$; coeficiente de t pequeno (0,01). $N = 300$ observações.

```

1 seed(42)
2 generate df w = exp(-0.002 * t)           // peso: observações
   recentes mais relevantes
3 generate df e = (rnormal()-0.5)*2*(1+x)    //
   heterocedasticidade em x
4 generate df y = 1.0 + 2.0*x + 0.01*t + e
5
6 let m_ols = ols(y ~ x, df)
7 let m_wls = wls(y ~ x, df, weights="w")
8 let m_rol = rols(y ~ x + t, df, window=50)
9 lowess(df, y, x, frac=0.3)
```

Listing 53.1: WLS, Rolling OLS, LOWESS

```

OLS:  const=2.362, x=2.263*** (ignora heterocedasticidade)
WLS:  const=2.212, x=2.257*** (pesos corrigem variância
   crescente)
Rolling OLS (última janela t=251..300):
   const=1.898, x=2.411, t=0.006
```


LOWESS: `frac=0.30`, 300 obs → `y_hat_lowess` adicionado a `df`

O WLS altera pouco os coeficientes aqui — os pesos temporais compensam o crescimento do erro em x de forma parcial. O rolling OLS revela que o coeficiente de x na última janela (2,41) é ligeiramente maior, sugerindo não-estacionariedade leve.

53.3 Sintaxe

```
1 wls(y ~ x, df, weights="coluna_pesos")           // WLS
2 rols(y ~ x + t, df, window=50)                  // Rolling OLS
3 rolling(y ~ x + t, df, window=50)               // alias
4 lowess(df, y_var, x_var, frac=0.67, it=3)       // LOWESS
```

Nota

O LOWESS recebe como argumento a variável dependente **antes** da independente: `lowess(df, y, x)`. Isso difere de regressões convencionais. O parâmetro `frac` (fração de vizinhos usados em cada ponto) controla a suavização: valores menores → curva mais nervosa; maiores → mais suave.

Capítulo 54

AutoReg e ARDL

54.1 Modelos com defasagens em y e em x

O modelo ARIMA (cap. 29) trata apenas da dinâmica de y . Em economia, porém, o nível atual de y depende não só do próprio passado, mas também de valores correntes e passados de regressores x . O modelo *Autoregressive Distributed Lag* (ARDL) captura exatamente isso.

AutoReg(p): AR puro via OLS

O modelo AR(p) escreve y_t como função linear das próprias defasagens:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t$$

Ao contrário do ARIMA (estimado por MLE), o `autoreg()` estima via OLS. Isso é computacionalmente mais simples e assintoticamente equivalente para processos estacionários. A opção `trend` permite incluir constante e/ou tendência determinística:

trend	Componente determinístico
"c"	Constante (padrão)
"ct"	Constante + tendência linear
"t"	Apenas tendência
"n"	Nenhum

ARDL(p, q): defasagens distribuídas

O modelo $\text{ARDL}(p, q)$ combina p defasagens de y com o valor contemporâneo e q defasagens de cada regressor x :

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=0}^q \beta_j x_{t-j} + \varepsilon_t$$

O **multiplicador de longo prazo** de x sobre y — o efeito total acumulado após todos os ajustes dinâmicos — é:

$$\theta = \frac{\sum_{j=0}^q \beta_j}{1 - \sum_{i=1}^p \phi_i}$$

Para o modelo ser estacionário, exige-se $|\sum_{i=1}^p \phi_i| < 1$.

Relação com o VECM e o teste de Pesaran

Quando y e x são integrados de ordem 1 ($I(1)$), o ARDL pode ser reescrito numa forma de correção de erros. Pesaran, Shin e Smith (2001) propõem o *bounds test*: testa H_0 de ausência de relação de longo prazo via estatística F aplicada ao ARDL irrestrito, comparando com valores críticos tabelados. A vantagem sobre o Johansen (cap. 31) é que o bounds test funciona independentemente de x ser $I(0)$ ou $I(1)$.

54.2 Verificação por DGP

DGP: $y_t = 1 + 2x_t + \varepsilon_t$, sem autocorrelação em y . $N = 300$, $x \sim U(-\sqrt{3}, \sqrt{3})$, $\varepsilon \sim U(-0,5, 0,5)$.

```
1 seed(42)
2 // ... (300 obs, geração de x e e)
3 generate df y = 1.0 + 2.0 * x + 0.5 * (rnormal() - 0.5)
4
5 // AR(2) puro: nenhuma autocorrelação real em y → coefs ~0
6 let m_ar = autoreg(df, y, lags=2)
7 display m_ar
8
9 // AR(1) com tendência determinística
10 let m_ar_ct = autoreg(df, y, lags=1, trend="ct")
11 display m_ar_ct
12
13 // ARDL(1,1)
```

```

14 let m_ardl = ardl(y ~ x, df, lags=1, xlags=1)
15 display m_ardl
16
17 // ARDL(2,2): verifica se defasagens extras são
    significativas
18 let m_ardl2 = ardl(y ~ x, df, lags=2, xlags=2)
19 display m_ardl2

```

Listing 54.1: AutoReg e ARDL

AR(2) puro

```

===== AutoReg(2)
=====
Observations:          298
R-squared:             0.0004
AIC:                  905.2221

----- Coefficients
-----

```

	coef	std err	t
		P> t	
const	0.9904	0.1022	9.6914
	0.0000		
y.L1	0.0007	0.0580	0.0118
	0.9906		
y.L2	-0.0209	0.0581	-0.3597
	0.7193		

```

=====

```

$R^2 = 0,0004$ — as defasagens de y não explicam nada, conforme o DGP (sem autocorrelação verdadeira). Os coeficientes $y.L1$ e $y.L2$ não diferem de zero.

AR(1) com tendência

```

===== AutoReg(1)
=====

```

```

Trend:                                ct
                                     coef      std err          t
                                     P>|t|

-----
const                                0.9275      0.1394      6.6551
    0.0000
trend                                0.0003      0.0007      0.4172
    0.6768
y.L1                                 0.0018      0.0581      0.0310
    0.9753
=====

```

A tendência determinística ($p = 0,68$) e o lag ($p = 0,98$) não são significativos — coerente com um DGP sem tendência nem persistência.

ARDL(1,1)

```

===== ARDL(1, 1)
=====
Observations:                        299
R-squared:                            0.9836
AIC:                                  -318.6638

                                     coef      std err          t
                                     P>|t|

-----
const                                1.0018      0.0594     16.8580
    0.0000
y.L1                                 0.0062      0.0583      0.1061
    0.9155
x1                                   1.9648      0.0148    133.1872
    0.0000
x1.L1                               -0.0078      0.1156     -0.0675
    0.9462
=====

```

O modelo recupera o DGP com precisão: `const` $\approx 1,0$, `x1` $\approx 2,0$. O coeficiente de `x1.L1` não é significativo ($p = 0,95$), confirmando que não há efeito defasado de x no DGP. O multiplicador de longo prazo é:

$$\theta = \frac{1,9648 + (-0,0078)}{1 - 0,0062} \approx 1,97$$

próximo ao valor verdadeiro de 2,0.

ARDL(2,2)

```
===== ARDL(2, 2)
```

```
=====
```

```
Observations:          298
```

```
R-squared:           0.9838
```

```
AIC:                -317.3857
```

	coef	std err	t
		P> t	
const	1.0727	0.0833	12.8843
0.0000			
y.L1	0.0013	0.0582	0.0220
0.9824			
y.L2	-0.0662	0.0582	-1.1385
0.2558			
x1	1.9628	0.0147	133.1320
0.0000			
x1.L1	0.0018	0.1154	0.0154
0.9877			
x1.L2	0.1264	0.1153	1.0968
0.2736			

O AIC do ARDL(2,2) (-317,4) é ligeiramente *maior* (pior) do que o do ARDL(1,1) (-318,7) — as defasagens extras não compensam a perda de graus de liberdade. A seleção por AIC/BIC favorece o modelo mais parcimonioso.

54.3 Sintaxe

```

1 // AR(p) via OLS
2 autoreg(df, var, lags=1) // AR(1) com
  constante
3 autoreg(df, var, lags=p, trend="ct") // AR(p) com
  tendência
4
5 // ARDL(p, q)
6 ardl(y ~ x, df, lags=p, xlags=q) // um regressor
7 ardl(gdp ~ inv + exp, df, lags=2, xlags=2) // múltiplos
  regressores

```

Modelo	Comando	Caso de uso
AR(p)	<code>autoreg(df, y, lags=p)</code>	Dinâmica pura de y
ARIMA(p, d, q)	<code>arima(df, y, p=, d=, q=)</code>	$I(1)$ com MA
ARDL(p, q)	<code>ardl(y~x, df, lags=p, xlags=q)</code>	y e x com defasagens
VECM	<code>vecm(...)</code>	Cointegração multivariada

Nota

Para séries $I(1)$, o ARDL pode ser reescrito numa forma de correção de erros. O bounds test de Pesaran et al. (2001) testa a existência de relação de longo prazo sem exigir que os regressores sejam todos $I(0)$ ou todos $I(1)$ — vantagem sobre o teste de Johansen. A estatística F do teste é acessível via `m_ardl.bounds_test(y, x)` na API Rust do Greeners, mas ainda não está exposta como comando do DSL.

Capítulo 55

Filtro de Kalman

55.1 Estado oculto e observação ruidosa

O filtro de Kalman resolve um problema diferente de todos os modelos anteriores: estimar uma variável *latente* (o “estado”) que não é diretamente observada, com base em medições ruidosas ao longo do tempo.

O modelo de espaço de estados em forma geral é:

$$y_t = H s_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, R) \quad (55.1)$$

$$s_t = F s_{t-1} + R_s \eta_t, \quad \eta_t \sim N(0, Q) \quad (55.2)$$

A equação (55.1) é a **equação de observação**: y_t é o que se mede, s_t é o estado latente e ε_t é o ruído de medição. A equação (55.2) é a **equação de transição**: o estado evolui de acordo com uma dinâmica linear perturbada por η_t .

Modelos pré-definidos

O Hayashi oferece dois modelos prontos para séries escalares:

Local Level (LL):

$$y_t = \mu_t + \varepsilon_t, \quad \mu_t = \mu_{t-1} + \eta_t$$

O estado μ_t é um passeio aleatório — o nível deriva ao longo do tempo. σ_ε controla o ruído de observação; σ_η controla a velocidade com que o nível muda.

Local Linear Trend (LLT):

$$y_t = \mu_t + \varepsilon_t, \quad \mu_t = \mu_{t-1} + \nu_{t-1} + \eta_t, \quad \nu_t = \nu_{t-1} + \zeta_t$$

O estado é bidimensional: nível μ_t e inclinação ν_t . A inclinação varia suavemente ao longo do tempo.

Filtro de Kalman (passo forward)

O filtro processa as observações recursivamente:

1. **Predição:** $\hat{s}_{t|t-1} = F \hat{s}_{t-1|t-1}$, $P_{t|t-1} = F P_{t-1|t-1} F' + R_s Q R_s'$
2. **Inovação:** $v_t = y_t - H \hat{s}_{t|t-1}$, $S_t = H P_{t|t-1} H' + R$
3. **Ganho de Kalman:** $K_t = P_{t|t-1} H' S_t^{-1}$
4. **Atualização:** $\hat{s}_{t|t} = \hat{s}_{t|t-1} + K_t v_t$, $P_{t|t} = (I - K_t H) P_{t|t-1}$

O resultado $\hat{s}_{t|t}$ é o *estado filtrado*: estimativa ótima do estado usando $y_1, \dots, y_t$ (informação até t).

Suavizador de Rauch-Tung-Striebel (passo backward)

Após o filtro, o RTS percorre a série ao contrário e incorpora informação futura:

$$L_t = P_{t|t} F' P_{t+1|t}^{-1}, \quad \hat{s}_{t|T} = \hat{s}_{t|t} + L_t (\hat{s}_{t+1|T} - \hat{s}_{t+1|t})$$

O resultado $\hat{s}_{t|T}$ é o *estado suavizado*: usa *toda* a amostra $y_1, \dots, y_T$. A variância do suavizado é sempre menor ou igual à do filtrado — a informação futura reduz incerteza.

55.2 Verificação por DGP

DGP: nível verdadeiro $\mu_t = 10 + 0,1t$ (tendência linear) observado com ruído $\varepsilon_t \sim N(0, 1)$. $T = 150$.

```
1 seed(42)
2 generate df mu = 10.0 + 0.1 * t
3 generate df y = mu + noise          // noise ~ N(0,1)
4
5 // Local Level (sigma especificado)
6 kalman(df, y, model="ll", sigma_obs=1.0, sigma_state=0.1)
7
8 // Local Linear Trend (sigmas automáticos)
9 kalman(df, y, model="llt")
```

Listing 55.1: Filtro de Kalman: LL e LLT

Saída — Local Level

```
Kalman (ll):  T=150  loglik=-278.1966  sigma_obs=1.0000
             sigma_state=0.1000→
             y_filtered, y_smoothed adicionadas a df
```

Saída — Local Linear Trend

```
Kalman (llt):  T=150  loglik=-219.2354  sigma_obs=0.9663
             sigma_state=0.0966  sigma_slope=0.0097→
             y_filtered, y_smoothed, y_slope_filtered, y_slope_smoothed
             adicionadas a df
```

O loglik do LLT ($-219,2$) é substancialmente maior do que o do LL ($-278,2$) porque o DGP tem tendência linear — o modelo com inclinação livre captura melhor a estrutura dos dados.

Comparação com o estado verdadeiro

Primeiras 8 observações (LLT):

t	mu	y	y_smoothed	y_slope_smoothed
1	10.10	10.19	9.74	0.13
2	10.20	10.35	9.87	0.13
3	10.30	10.77	9.99	0.13
4	10.40	10.07	10.10	0.13
5	10.50	8.89	10.21	0.13
6	10.60	10.31	10.33	0.12
7	10.70	11.52	10.46	0.12
8	10.80	12.01	10.56	0.12

```
summarize y_smoothed:  mean=17.49  sd=4.35
summarize mu:          mean=17.55  sd=4.34
```

O suavizado recupera o nível verdadeiro com precisão notável: média 17,49 vs 17,55. A inclinação suavizada ($y_slope_smoothed \approx 0,13$) é próxima ao valor

verdadeiro de 0,1. A série bruta y oscila em ± 2 ao redor de μ ; o suavizado elimina esse ruído.

Nota

Filtrado vs suavizado: `y_filtered` usa apenas $y_1, \dots, y_t$ — é causal e útil para previsão em tempo real. `y_smoothed` usa $y_1, \dots, y_T$ inteiro — é retrospectivo, mas ótimo para análise histórica. Nos pontos interiores, o suavizado é sempre mais preciso; no último ponto $t = T$, os dois coincidem.

55.3 Sintaxe

```
1 // Local Level
2 kalman(df, y, model="ll")
3 kalman(df, y, model="ll", sigma_obs=1.0, sigma_state=0.1)
4
5 // Local Linear Trend
6 kalman(df, y, model="llt")
7 kalman(df, y, model="llt", sigma_obs=0.5, sigma_state=0.05,
  sigma_slope=0.005)
```

Parâmetro	Padrão	Descrição
<code>model</code>	"ll"	"ll" ou "llt"
<code>sigma_obs</code>	$\text{sd}(\text{diff}(y))/\sqrt{2}$	Desvio-padrão do ruído de observação
<code>sigma_state</code>	<code>sigma_obs</code> $\times$ 0.1	Desvio-padrão do ruído de nível
<code>sigma_slope</code>	<code>sigma_state</code> $\times$ 0.1	Desvio-padrão do ruído de inclinação (LLT)

Colunas adicionadas ao DataFrame:

<code>{var}_filtered</code>	—	Nível filtrado (forward pass)
<code>{var}_smoothed</code>	—	Nível suavizado (RTS)
<code>{var}_slope_filtered</code>	—	Inclinação filtrada (só LLT)
<code>{var}_slope_smoothed</code>	—	Inclinação suavizada (só LLT)

Modelo	Usar quando	Relação
LL	Nível drift sem tendência clara	UCM nível local (cap. 46)
LLT	Tendência variante no tempo	HP filter generalizado estocástico

Nota

O Hayashi usa o suavizador RTS com matrizes fixas especificadas pelo usuário. Para estimação conjunta dos parâmetros de variância (σ_ε , σ_η) via máxima verossimilhança, use o comando `ucm()` (cap. 46), que executa o algoritmo EM sobre a representação de espaço de estados.

Parte VIII

Aprendizado de Máquina e Econometria Espacial

Capítulo 56

Aprendizado de Máquina Supervisionado

56.1 Por que aprendizado de máquina em uma linguagem de econometria?

A econometria clássica é forte quando o objetivo é inferência: estimar um parâmetro, testar uma hipótese ou recuperar um efeito causal. O aprendizado de máquina é mais útil quando o objetivo é previsão: encontrar uma função flexível $\hat{f}(X)$ que aproxime Y bem fora da amostra.

HAYASHI faz a ponte entre os dois. Seus comandos de ML usam a mesma sintaxe de fórmula do OLS ou logit e retornam objetos compatíveis com `predict`, `glance` e `tidy`.

Este capítulo cobre métodos baseados em árvores, redes neurais e um processo gaussiano. Não é um curso completo de ML; mostra como estimar, interpretar e comparar esses modelos dentro do HAYASHI.

56.2 Random Forest

Random Forest (Breiman, 2001) ajusta um conjunto de árvores de decisão em amostras bootstrap, média suas previsões para reduzir variância.

```
1 set_seed(42)
2 let n = 500
3 generate df x1 = rnormal(n)
4 generate df x2 = rnormal(n)
5 generate df y = 2 + 0.5*x1 - 0.3*x2 + 0.4*x1*x2 + rnormal(n)
```

```
6
7 let m_rf = rf(y ~ x1 + x2, df, trees=200, depth=10)
8 print(m_rf)
9
10 let g = glance(m_rf)
11 print(g)
```

Listing 56.1: Regressão com Random Forest

Principais saídas:

- `r2` e `oob_r2`: R^2 dentro da amostra e out-of-bag
- importância de variáveis: redução de impureza atribuível a cada regressor

Use `predict(df, yhat = m_rf)` para obter valores ajustados em um DataFrame.

56.3 Gradient Boosting e XGBoost

Gradient Boosting constrói árvores sequencialmente, cada uma ajustando os resíduos do conjunto anterior. XGBoost (Chen e Guestrin, 2016) estende isso com informação de segunda ordem e regularização.

```
1 let m_xgb = xgboost(y ~ x1 + x2, df, trees=100, depth=4, lr
  =0.1)
2 print(glance(m_xgb))
```

Listing 56.2: Regressão com XGBoost

Boosting tende a superar Random Forest em dados tabulares estruturados, mas é mais sensível a hiperparâmetros e pode sofrer overfit.

56.4 Perceptron Multicamadas

O comando `mlp` ajusta uma rede feed-forward com uma camada oculta, função de ativação sigmoide e backpropagation com momentum.

```
1 let m_mlp = mlp(y ~ x1 + x2, df, hidden=20, lr=0.01, epochs
  =500)
2 print(glance(m_mlp))
```

Listing 56.3: Rede neural

É útil para capturar interações não lineares, mas oferece menos transparência que árvores e geralmente precisa de ajustes.

56.5 LSTM e Transformer para séries

Para séries temporais, `lstm` e `transformer` usam janelas de observações para prever o próximo valor. Eles padronizam o alvo internamente.

```

1 let n = 200
2 generate df y = 0.1*(_n - n/2) + 0.5*sin(2*pi()*_n/20) +
  rnormal(n)
3 let m_lstm = lstm(df, y, seqlen=10, hidden=10, epochs=100,
  forecast=5)
4 print(m_lstm)

```

Listing 56.4: Previsão com LSTM

Esses modelos são determinísticos uma vez fixada a semente, mas sua qualidade preditiva é sensível a convenções. São experimentais.

56.6 Processo Gaussiano

Um Processo Gaussiano define uma distribuição sobre funções. É não paramétrico no sentido de que não fixa uma forma funcional e reporta incerteza em torno de cada previsão.

```

1 let m_gp = gp(y ~ x1 + x2, df)
2 print(m_gp)

```

Listing 56.5: Regressão com Processo Gaussiano

GP é atraente para conjuntos pequenos e quando a propagação de incerteza importa. É mais lento e mais intensivo em memória que métodos baseados em árvores.

56.7 Quando preferir qual?

- **Interpretabilidade + robustez:** Random Forest ou Gradient Boosting
- **Acurácia preditiva com ajuste:** XGBoost
- **Funções não lineares suaves:** MLP ou GP
- **Séries:** LSTM / Transformer
- **Incerteza:** GP ou BART

Todos os comandos aceitam uma fórmula padrão do HAYASHI e retornam um objeto compatível com `predict` e `glance`. Erros padrão geralmente não são reportados porque esses métodos não são projetados para inferência direta sobre coeficientes individuais.

Capítulo 57

Aprendizado de Máquina Causal

57.1 Da previsão aos efeitos de tratamento

Estimadores de aprendizado de máquina também podem ser usados para inferência causal quando o objetivo é estimar um efeito de tratamento $Y(1) - Y(0)$. Os comandos deste capítulo visam duas quantidades:

- o **Efeito Médio do Tratamento (ATE)**
- o **Efeito Médio do Tratamento Condicional (CATE)**, $\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$

Todos exigem um indicador de tratamento d e um conjunto de covariáveis $\mathbf{x}$. Eles não substituem um desenho de pesquisa claro, mas podem ajudar a descobrir efeitos heterogêneos e melhorar a precisão.

57.2 Causal Forest

Causal Forest (Athey e Wager, 2018) adapta Random Forest para estimar efeitos de tratamento heterogêneos. Divide as covariáveis para maximizar a variância dos efeitos estimados entre folhas.

```
1 set_seed(42)
2 let n = 1000
3 generate df x1 = rnormal(n)
4 generate df x2 = rnormal(n)
5 generate df d = (0.5 + 0.3*x1 > runiform(n))
6 generate df y = 1 + 2*x1 - x2 + d*(0.5 + 0.4*x1) + rnormal(n)
7
```

```
8 let m_cf = causalforest(y ~ d, df, x="x1,x2", trees=200,  
    depth=5)  
9 print(m_cf)
```

Listing 57.1: Causal Forest

A saída inclui:

- o ATE estimado
- uma distribuição do CATE (média, quartis)
- importância das variáveis

57.3 DR-Learner e TMLE

O **DR-Learner** (Kennedy, 2023) e o **TMLE** (van der Laan e Rubin, 2006) são abordagens duplamente robustas. Cada um constrói um pseudo-resultado a partir de funções nuisance estimadas e depois regredide o pseudo-resultado sobre as covariáveis para recuperar o CATE ou ATE.

```
1 let m_dr = dr_learner(y ~ d, df, x="x1,x2", folds=5)  
2 print(m_dr)
```

Listing 57.2: DR-Learner

```
1 let m_tmle = tmle(y ~ d, df, w="x1,x2")  
2 print(m_tmle)
```

Listing 57.3: TMLE

Métodos duplamente robustos são atraentes porque o ATE permanece consistente se o escore de propensão ou o modelo de resultado estiver bem especificado.

57.4 Orthogonal Random Forest

ORF (Oprescu, Syrgkanis e Wu, 2019) residualisa o tratamento e o resultado em relação às confundidoras antes de rodar uma floresta nos sinais residualizados.

```
1 let m_orf = orf(y ~ d, df, x="x1,x2", w="x1,x2", trees=100,  
    depth=5)  
2 print(m_orf)
```

Listing 57.4: Orthogonal Random Forest

É útil quando o tratamento não é randomizado e a heterogeneidade relevante vem de um subconjunto de covariáveis.

57.5 Controle Sintético Bayesiano

`bsc` implementa uma versão bayesiana do estimador de controle sintético. É apropriado quando uma única unidade tratada é comparada a várias unidades doadoras e o objetivo é um contrafactual com intervalos credíveis.

```
1 // df tem colunas y, c1, c2, ..., t
2 let m_bsc = bsc(df, y, "c1,c2", 25, prior=1.0)
3 print(m_bsc)
```

Listing 57.5: Controle Sintético Bayesiano

A saída reporta o efeito do tratamento τ , seu desvio padrão, um intervalo credível de 95% e os pesos do controle sintético.

57.6 Double Machine Learning

`dml_crossfit` estima o ATE no modelo parcialmente linear

$$Y = \theta D + g(X) + \varepsilon$$

usando validação cruzada K-fold para a função nuisance $g(X)$.

```
1 let m_dml = dml_crossfit(y ~ d, df, x="x1,x2", folds=5)
2 print(m_dml)
```

Listing 57.6: Double Machine Learning

Como a nuisance é estimada em um fold separado, o ATE resultante tem distribuição de taxa $\sqrt{n}$ padrão e erros padrão honestos.

57.7 Escolhendo um método

- **Efeitos heterogêneos:** Causal Forest ou ORF
- **ATE duplamente robusto:** DR-Learner, TMLE, DML
- **Unidade única tratada:** BSC

Todos esses comandos são *experimentais*. A validação contra implementações de referência é parcial ou não suportada para alguns. Use-os para exploração e como complementos a um desenho claro, não como substitutos.

Capítulo 58

Econometria Espacial

58.1 Por que espacial?

Quando as observações estão localizadas no espaço ou conectadas por uma rede, os distúrbios ou resultados podem transbordar de uma unidade para seus vizinhos. Ignorar essa dependência produz erros padrão enviesados, viés de coeficientes e inferência enganosa.

58.2 A matriz de pesos espaciais

Todo modelo espacial no HAYASHI exige uma matriz de pesos W padronizada por linha. Se os dados estão ordenados por unidade, W_{ij} é o peso que a unidade j recebe ao prever o resultado da unidade i .

```
1 // 3 regiões com vizinhos mútuos
2 let W = [[0, 0.5, 0.5],
3         [0.5, 0, 0.5],
4         [0.5, 0.5, 0]]
```

Listing 58.1: Matriz de pesos espaciais

Para grades maiores, gere W a partir do DataFrame ou carregue-a de um arquivo.

58.3 SAR espacial

O modelo Autorregressivo Espacial é

$$y = \rho W y + X\beta + \varepsilon$$

onde ρ é o parâmetro autorregressivo espacial. A estimação usa verossimilhança concentrada: para cada valor em uma grade de ρ , transforma a variável dependente e roda OLS; depois seleciona o ρ que maximiza a log-verossimilhança concentrada.

```

1 let n = 100
2 let W = makeweights(df, "region", type="rook") // ou lista
  de listas
3 generate df x1 = rnormal(n)
4 generate df y = 0.5*x1 + rnormal(n)
5 generate df wy = spatial_lag(W, y)
6 generate df y = y + 0.3*wy
7
8 let m_sar = spatial_sar(y ~ x1, df, w=W)
9 print(m_sar)

```

Listing 58.2: SAR espacial

A saída reporta ρ , β , seus erros padrão e um teste de verossimilhança para $\rho = 0$.

58.4 SEM espacial

O Modelo de Erro Espacial é

$$y = X\beta + u, \quad u = \lambda Wu + \varepsilon$$

Os erros são espacialmente correlacionados, mas o resultado em si não é diretamente influenciado pelos resultados dos vizinhos.

```

1 let m_sem = spatial_sem(y ~ x1, df, w=W)
2 print(m_sem)

```

Listing 58.3: SEM espacial

58.5 Durbin espacial e extensões em painel

O Modelo de Durbin Espacial adiciona regressores defasados espacialmente:

$$y = \rho Wy + X\beta + WX\theta + \varepsilon$$

Ele encaixa SAR ($\theta = 0$) e o modelo de defasagem espacial ($\rho = 0$).

```

1 let m_sdm = spatial_durbin(y ~ x1, df, w=W)

```

```
2 print(m_sdm)
```

Listing 58.4: Durbin espacial

Para dados em painel com efeitos fixos, use as variantes de painel:

```
1 let m_panelsar = spatial_panel_sar(y ~ x1, df, w=W, id="
  region")
2 print(m_panelsar)
```

Listing 58.5: SAR em painel

58.6 Interpretando efeitos diretos e indiretos

No modelo de Durbin Espacial o coeficiente de x não é o efeito total. O efeito total na unidade i inclui o impacto direto β mais o impacto indireto que viaja pela rede através de θ e ρ .

HAYASHI reporta efeitos diretos, indiretos e totais no resumo de `m_sdm` quando disponíveis.

58.7 Notas práticas

- Sempre verifique se W está padronizada por linha; W não padronizada distorce a interpretação de ρ e λ .
- Amostras maiores são necessárias para MLE espacial do que para OLS.
- Modelos espaciais de corte transversal assumem uma rede estável. Modelos espaciais em painel adicionam efeitos fixos, mas ainda exigem W constante no tempo.
- O modelo `spatial_durbin_error` combina regressores defasados espacialmente com um termo de erro espacial.

Capítulo 59

Modelos Bayesianos e de Fronteira

59.1 Regressão linear bayesiana

`bayes_lm` implementa regressão linear bayesiana com priori conjugada Normal-Inversa-Gamma. Com uma priori fraca, recupera as médias posteriori do OLS, mas também reporta desvios padrão posteriores, intervalos credíveis e a probabilidade de cada coeficiente ser positivo.

```
1 set_seed(42)
2 let n = 200
3 generate df x1 = rnormal(n)
4 generate df x2 = rnormal(n)
5 generate df y = 1 + 2*x1 - 1.5*x2 + rnormal(n, 0, 2)
6
7 let m_bayes = bayes_lm(y ~ x1 + x2, df)
8 print(m_bayes)
```

Listing 59.1: Regressão linear bayesiana

A média posterior de cada coeficiente é a média ponderada entre a média a priori e a estimativa OLS, com mais peso nos dados à medida que a amostra cresce. O intervalo credível de 95% é reportado para cada regressor.

59.2 Análise de fronteira estocástica

Modelos de fronteira estocástica separam ruído estatístico de ineficiência técnica ou de custo. A fronteira de produção é

$$y = X\beta + v - u, \quad u \geq 0$$

onde v é o ruído e u é a ineficiência. `sfa_production` estima β , σ_v , σ_u e a eficiência técnica média.

```

1 let n = 300
2 generate df x1 = rnormal(n)
3 generate df x2 = rnormal(n)
4 generate df v = rnormal(n, 0, 0.3)
5 generate df u = abs(rnormal(n, 0, 0.5))
6 generate df y = 1 + 0.8*x1 + 0.6*x2 + v - u
7
8 let m_sfa = sfa_production(y ~ x1 + x2, df)
9 print(m_sfa)

```

Listing 59.2: Fronteira de produção estocástica

Para uma fronteira de custo, o termo de ineficiência é somado em vez de subtraído:

```

1 let m_sfac = sfa_cost(y ~ x1 + x2, df)
2 print(m_sfac)

```

Listing 59.3: Fronteira de custo estocástica

59.3 Fronteira estocástica bayesiana

`bayes_sfa_production` e `bayes_sfa_cost` implementam um amostrador de Gibbs com prioris conjugadas fracas. Eles reportam médias posteriores, desvios padrão e intervalos credíveis de 95% para os coeficientes de regressão e os parâmetros de variância.

```

1 let m_bsfa = bayes_sfa_production(y ~ x1 + x2, df, burn=500,
  draws=1000)
2 print(m_bsfa)

```

Listing 59.4: SFA bayesiano

São mais robustos em amostras pequenas que SFA por máxima verossimilhança, mas a convergência deve ser verificada rodando a cadeia com diferentes valores iniciais e comparando as posteriores.

59.4 Quando usar cada um

- Inferência padrão com incerteza: `bayes_lm`

- Eficiência de produção: `sfa_production`
- Eficiência de custo: `sfa_cost`
- SFA em amostras pequenas ou posteriori completa: `bayes_sfa_production`

Capítulo 60

Agrupamento e Redução de Dimensionalidade

60.1 Métodos não supervisionados

Aprendizado não supervisionado encontra estrutura nos dados sem uma variável alvo. O HAYASHI fornece algoritmos de agrupamento, embutimentos não lineares e ferramentas baseadas em PCA.

60.2 K-Means

K-Means particiona observações em K grupos esféricos. É rápido e escala bem, mas assume grupos de tamanho e forma similares.

```
1 set_seed(42)
2 let n = 300
3 generate df x1 = rnormal(n, 0, 0.7)
4 generate df x2 = rnormal(n, 0, 0.7)
5
6 let m_km = kmeans(df, x="x1,x2", k=3)
7 print(m_km)
```

Listing 60.1: K-Means

Use `m_km.labels` para ler o cluster atribuído e `m_km.centroids` para inspecionar as médias dos clusters.

60.3 Agrupamento hierárquico e DBSCAN

Agrupamento hierárquico constrói uma árvore de grupos aninhados. `hclust` pode ser cortado em qualquer número de grupos.

```
1 let m_hc = hclust(df, x="x1,x2", k=3, linkage="ward")
2 print(m_hc)
```

Listing 60.2: Agrupamento hierárquico

DBSCAN encontra regiões densas e rotula observações esparsas como ruído.

```
1 let m_db = dbscan(df, x="x1,x2", eps=0.8, min=5)
2 print(m_db)
```

Listing 60.3: DBSCAN

60.4 Modelos de Mistura Gaussiana

GMM modela cada cluster como uma gaussiana multivariada. É uma variante suave do K-Means que permite clusters elípticos.

```
1 let m_gmm = gmm_clust(df, x="x1,x2", k=3)
2 print(m_gmm)
```

Listing 60.4: Agrupamento por mistura gaussiana

60.5 Embeddings não lineares

t-SNE e UMAP reduzem dados de alta dimensão para duas ou três dimensões preservando a estrutura local. São úteis para visualização.

```
1 let m_tsne = tsne(df, x="x1,x2,x3", k=2, perplexity=30)
2 print(m_tsne)
```

Listing 60.5: t-SNE

```
1 let m_umap = umap(df, x="x1,x2,x3", k=2, neighbors=15)
2 print(m_umap)
```

Listing 60.6: UMAP

60.6 Agrupamento espectral

Agrupamento espectral usa a estrutura de autovalores de um grafo de similaridade. Pode capturar formas de cluster não convexas onde K-Means falha.

```
1 let m_sc = spectral(df, x="x1,x2", k=3)
2 print(m_sc)
```

Listing 60.7: Agrupamento espectral

60.7 PCA, fator e biplot

PCA e análise fatorial reduzem a dimensionalidade linearmente. biplot visualiza observações e variáveis no mesmo espaço de PCA.

```
1 let m_pca = pca(df, x="x1,x2,x3", n=2)
2 print(m_pca)
```

Listing 60.8: PCA

```
1 let m_biplot = biplot(df, x="x1,x2,x3", type="symmetric")
2 print(m_biplot)
```

Listing 60.9: Biplot

60.8 Estimativa de densidade kernel

kde estima a densidade de uma única variável com um kernel escolhido.

```
1 let m_kde = kde(df, x1, bw=0.5, kernel="gaussian")
2 print(m_kde)
```

Listing 60.10: KDE

Capítulo 61

Volatilidade e Dependência Avançadas

61.1 Além do GARCH

O Capítulo 31 cobriu GARCH, EGARCH e GJR-GARCH. Este capítulo trata de volatilidade estocástica, correlações dinâmicas, copulas, wavelets e processos de pontos auto-excitantes.

61.2 Volatilidade Estocástica

Modelos GARCH modelam a variância condicional como função determinística de erros quadrados passados. A Volatilidade Estocástica (Taylor, 1986) trata o log-volatilidade como um processo AR(1) latente:

$$y_t = \exp(h_t/2)\varepsilon_t, \quad h_t = \mu + \phi(h_{t-1} - \mu) + \eta_t$$

```
1 let n = 500
2 generate df y = 0.02 + rnormal(n, 0, exp(0.5*rnormal(n, 0, 1)
  ))
3
4 let m_sv = sv(df, y, iter=500)
5 print(m_sv)
```

Listing 61.1: Volatilidade Estocástica

`sv` reporta μ , ϕ (persistência), σ_η (volatilidade-da-volatilidade) e o caminho de volatilidade condicional.

61.3 Correlação Condicional Dinâmica

DCC-GARCH (Engle, 2002) combina modelos GARCH(1,1) univariados com uma equação dinâmica para a matriz de correlação condicional. É útil para modelar dependência variante no tempo entre retornos.

```
1 let m_dcc = dcc_garch(y1 ~ y2, df)
2 print(m_dcc)
```

Listing 61.2: DCC-GARCH

A saída inclui os parâmetros DCC (α , β), os parâmetros GARCH univariados, volatilidades condicionais e matrizes de correlação dinâmica.

61.4 Copulas

`copula` estima um modelo bivariado de dependência via Teorema de Sklar. Separa as distribuições marginais da copula que as une.

```
1 let m_cop = copula(y1 ~ y2, df, type="gaussian")
2 print(m_cop)
```

Listing 61.3: Copula

As copulas disponíveis incluem Gaussiana, Clayton, Gumbel e Frank. A saída reporta o τ de Kendall, o ρ de Spearman e o parâmetro da copula.

`tv_copula` estende isso com dependência variante no tempo impulsionada por uma dinâmica tipo GARCH para o parâmetro da copula.

```
1 let m_tvc = tvcopula(y1 ~ y2, df, type="gaussian")
2 print(m_tvc)
```

Listing 61.4: Copula de dependência variante no tempo

61.5 Wavelets

A Transformada Wavelet de Máxima Sobreposição Discreta (MODWT) decompõe uma série em componentes tempo-frequência sem decimação.

```
1 let m_modwt = modwt(df, y, scales=4)
2 print(m_modwt)
```

Listing 61.5: MODWT

Útil para isolar componentes cíclicos em diferentes frequências.

61.6 Processos de Hawkes

Um processo de Hawkes é um processo de pontos auto-excitante. Cada evento aumenta a intensidade condicional de eventos futuros por uma quantidade que decai exponencialmente.

```
1 let m_hawkes = hawkes(df, time, T=100)
2 print(m_hawkes)
```

Listing 61.6: Processo de Hawkes

A taxa de ramificação $\eta = \alpha/\beta$ indica quanto cada evento contribui para eventos futuros. $\eta < 1$ é necessário para estacionariedade.

Capítulo 62

Testes Diagnósticos

62.1 Após uma regressão

‘test(model, ...)’ e outros comandos de diagnóstico verificam se os pressupostos por trás de um estimador são plausíveis. Este capítulo cobre os testes pós-estimação e autônomos mais comuns.

62.2 Heterocedasticidade

```
1 test(m, "white")      // Teste de White
2 test(m, "bp")         // Breusch-Pagan
```

Listing 62.1: Testes de White e Breusch-Pagan

White é um teste geral baseado na regressão dos resíduos quadrados sobre produtos cruzados e quadrados de X . Breusch-Pagan é um teste multiplicador de Lagrange sob normalidade.

62.3 Autocorrelação

```
1 test(m, "dw")         // Durbin-Watson
2 test(m, "bg")         // Breusch-Godfrey LM
3 cusumtest(m)          // CUSUM de estabilidade
```

Listing 62.2: Testes de autocorrelação

Durbin-Watson testa autocorrelação de primeira ordem nos resíduos de OLS. Breusch-Godfrey testa até um defasamento especificado. `cusumtest` verifica se resíduos recursivos permanecem dentro dos limites de 5%.

62.4 Normalidade

```
1 swilk(df, y)           // Shapiro-Wilk
2 sfrancia(df, y)       // Shapiro-Francia
3 sktest(df, y)         // Assimetria/curtose (Jarque-Bera + D'
   Agostino)
4 jb(m)                 // Jarque-Bera nos resíduos
```

Listing 62.3: Testes de normalidade

62.5 Especificação

```
1 reset(m)               // Ramsey RESET
2 linktest(m)           // Link test para logit/probit
```

Listing 62.4: RESET e link test

RESET adiciona potências dos valores ajustados à regressão; um coeficiente significativo indica não-linearidade omitida. `linktest` é o análogo para modelos GLM.

62.6 Outliers e influência

```
1 influence(m)           // DFFITS, alavancagem
2 leverage(m)           // alavancagem
3 cooks(m)               // distância de Cook
```

Listing 62.5: Diagnósticos de influência

Alta alavancagem significa que uma observação tem regressores pouco comuns. Alto DFFITS ou distância de Cook significa que uma observação altera os coeficientes ajustados.

62.7 Multicolinearidade

```
1 vif(m)                 // fatores de inflação de variância
```

Listing 62.6: VIF

Um VIF acima de 10 (ou às vezes 5) sugere multicolinearidade problemática.

62.8 Raiz unitária

```

1 adf(df, y)           // Dickey-Fuller Aumentado
2 kpss(df, y)          // KPSS (nula de estacionariedade)
3 pp(df, y)            // Phillips-Perron
4 zivot(df, y)         // Zivot-Andrews (quebra estrutural)

```

Listing 62.7: Testes de raiz unitária

ADF, PP e KPSS são os três testes clássicos. KPSS tem nula de estacionariedade, complementando ADF e PP, que têm nula de raiz unitária.

62.9 Cointegração

```

1 engle_granger(df, y, x, lags=1) // equação única
2 johansen(df, y, x, lags=1)     // multivariado

```

Listing 62.8: Testes de cointegração

Engle-Granger é simples mas assume um único vetor de cointegração. Johansen testa o número de vetores de cointegração em um sistema multivariado.

62.10 Testes não paramétricos

```

1 spearman(df, x, y)           // Correlação de Spearman
2 ranksum(df, x, by=group)     // Wilcoxon rank-sum
3 kruskal(df, y, by=group)     // Kruskal-Wallis
4 signrank(df, x, y)           // Wilcoxon signed-rank

```

Listing 62.9: Testes não paramétricos

São alternativas livres de distribuição para testes t, ANOVA e correlação de Pearson.

Capítulo 63

Séries Temporais e Dinâmica de Painel Avançadas

63.1 Parâmetros variantes no tempo

Em `tvp` o vetor de coeficientes é um passeio aleatório observado com ruído:

$$y_t = x_t' \beta_t + \varepsilon_t, \quad \beta_t = \beta_{t-1} + \eta_t$$

`tvp` estima as variâncias de ε_t e η_t por MV e reporta o caminho suavizado de β_t .

```
1 let n = 200
2 generate df x = rnormal(n)
3 generate df y = (1 + 0.02*_n) + (0.5 - 0.003*_n)*x + rnormal(
  n)
4
5 let m_tvp = tvp(y ~ x, df)
6 print(m_tvp)
```

Listing 63.1: Regressão com parâmetros variantes no tempo

Use `tvp_var` para uma VAR completa com coeficientes variantes no tempo.

63.2 VAR de limiar e de mudança de regime Markov

`setar` permite dois regimes AR divididos por um valor de limiar da variável dependente defasada.

```
1 let m_setar = setar(y, df, order=2, delay=1)
2 print(m_setar)
```

Listing 63.2: SETAR

`msvar` permite que os coeficientes mudem de acordo com uma cadeia latente de Markov.

```
1 let m_msvar = msvar(y1 + y2, df, regimes=2, lags=1)
2 print(m_msvar)
```

Listing 63.3: VAR com mudança de regime Markov

63.3 Dinâmicas assimétricas e não lineares

`nardl` decompõe um regressor em somas parciais positivas e negativas, permitindo respostas assimétricas de longo prazo.

```
1 let m_nardl = nardl(y ~ x, df, lags=1)
2 print(m_nardl)
```

Listing 63.4: NARDL

`pstr` faz o mesmo em painel, com coeficientes que mudam suavemente de acordo com uma função de transição logística de uma variável observada.

```
1 let m_pstr = pstr(y ~ x1 + x2, df, q="z", id="firm")
2 print(m_pstr)
```

Listing 63.5: Regressão de Transição Suave em Painel

63.4 Coeficientes funcionais

`fcoef` estima coeficientes que variam suavemente com uma variável moderadora z , usando regressão kernel local linear.

```
1 let m_fcoef = fcoef(y ~ x1 + x2, df, z="z", points=20)
2 print(m_fcoef)
```

Listing 63.6: Modelo de coeficientes funcionais

63.5 Bayesian VAR e VAR de frequência mista

`bvar` estima uma VAR com priori de Minnesota, encolhendo defasagens próprias em direção a 1 e defasagens cruzadas em direção a 0.

```

1 let m_bvar = bvar(y1 ~ y2, df, lags=1)
2 print(m_bvar)

```

Listing 63.7: Bayesian VAR

`mfvar` combina variáveis de baixa e alta frequência usando agregação Almon MIDAS exponencial.

```

1 let m_mfvar = mfvar(df_q, yq, df_m, ym, agg=3, lags=1)
2 print(m_mfvar)

```

Listing 63.8: VAR de frequência mista

63.6 VAR em painel

`pvar` estima uma VAR em painel usando GMM estilo Arellano-Bond: valores defasados em níveis instrumentam as equações em primeiras diferenças.

```

1 let m_pvar = pvar(y1 ~ y2, df, id="firm", lags=1)
2 print(m_pvar)

```

Listing 63.9: VAR em painel

Esses comandos são poderosos, mas sensíveis a convenções. Sempre compare a saída com uma implementação de referência quando possível e inspecione as probabilidades de transição, autovalores ou estatísticas J reportadas pelo estimador.

Capítulo 64

Finanças

64.1 Fama-MacBeth

O procedimento de Fama-MacBeth estima regressões de corte transversal período a período e depois tira a média dos coeficientes resultantes. Produz erros padrão robustos à correlação de corte transversal.

```
1 let n = 1000
2 generate df mes = ceil(_n / 100)
3 generate df ret = rnormal(n)
4 generate df beta = rnormal(n)
5 generate df tamanho = rnormal(n)
6
7 let m_fmb = fmb(ret ~ beta + tamanho, df, time=mes)
8 print(m_fmb)
```

Listing 64.1: Regressão Fama-MacBeth

O comando roda uma regressão de corte transversal por período e tira a média das inclinações, reportando a média temporal e o erro padrão de cada coeficiente.

64.2 Sorts de portfólio

`portsort` forma portfólios ordenando ativos em quantis de uma característica. `doublesort` faz isso em duas dimensões.

```
1 let m_ps = portsort(df, ret, tamanho, n=5)
2 print(m_ps)
```

Listing 64.2: Sort de portfólio simples

```
1 let m_ds = doublesort(df, ret, tamanho, bm, n1=5, n2=5)
2 print(m_ds)
```

Listing 64.3: Sort duplo

A saída reporta o retorno médio de cada célula de portfólio. Sorts duplos são úteis para isolar a interação entre duas características.

64.3 Notas práticas

- Fama-MacBeth é apropriado quando betas são estimados em uma primeira etapa e depois usados como regressores em uma segunda.
- Sorts de portfólio são descritivos, não causais. Mostram padrões, não identificação.
- Use ‘if=’ para excluir observações extremas ou focar em um período amostral.

Capítulo 65

Equações Estruturais e Multivariadas

65.1 SUR

Regressões Aparentemente Não Relacionadas (Zellner, 1962) estimam várias equações lineares simultaneamente, explorando a correlação entre seus distúrbios. É um estimador GLS aplicado a um sistema empilhado.

```
1 let m_sur = sur(df, y1 ~ x1, y2 ~ x2)
2 print(m_sur)
```

Listing 65.1: SUR

Se as equações compartilham os mesmos regressores, SUR fornece as mesmas estimativas que OLS equação por equação, mas a estrutura de covariância ainda é útil para inferência.

65.2 Três estágios de mínimos quadrados

`three_sls` estende SUR para modelos com regressores endógenos. É 2SLS seguido de um passo GLS nos resíduos transformados.

```
1 let m_3sls = three_sls(df, y1 ~ x1, y2 ~ x2,
2                        instruments=["z1", "z2", "z3"])
3 print(m_3sls)
```

Listing 65.2: 3SLS

65.3 MANOVA

MANOVA testa se as médias dos grupos diferem em várias variáveis dependentes simultaneamente.

```
1 let m_manova = manova(df, [y1, y2], by=grupo)
2 print(m_manova)
```

Listing 65.3: MANOVA

A saída inclui Lambda de Wilks, Traço de Pillai e as estatísticas F correspondentes.

65.4 Correlação canônica

`cancorr` encontra combinações lineares de X e Y que maximizam a correlação.

```
1 let m_can = cancorr(df, xvars=["x1", "x2"], yvars=["y1", "y2"]
  )
2 print(m_can)
```

Listing 65.4: Correlação canônica

65.5 Modelos aumentados por fatores

`favar` aumenta uma VAR pequena com fatores de componentes principais extraídos de um painel amplo. É útil quando o número de preditores candidatos excede o número de observações.

```
1 let m_favar = favar(y1 ~ y2 + y3, df, observed="rate",
  factors=2)
2 print(m_favar)
```

Listing 65.5: VAR aumentada por fatores

`fapanel` adiciona fatores estimados a uma regressão em painel.

```
1 let m_fapanel = fapanel(y ~ x1 + x2, df, aux="aux_df",
  id="empresa", factors=2)
2
3 print(m_fapanel)
```

Listing 65.6: Painel aumentado por fatores

65.6 FM-OLS

`fmols` estima uma regressão cointegrada com correções não paramétricas para endogeneidade e correlação serial na covariância de longo prazo.

```
1 let m_fm = fmols(y ~ x1 + x2, df)
2 print(m_fm)
```

Listing 65.7: FM-OLS

Capítulo 66

Métodos Recentes

66.1 DiD linear com adoção escalonada

`lpdid` (DiD por Projeções Locais) e `eventstudy` estimam efeitos de tratamento em desenhos com adoção escalonada. `eventstudy` constrói dummies de tempo do evento em relação ao tratamento e omite o período de referência.

```
1 let m_e = eventstudy(y ~ x, df, time=ano, ref=-1,  
2                       min=-5, max=5)  
3 print(m_e)
```

Listing 66.1: Event study

Os coeficientes de cada dummy de tempo do evento mostram o caminho médio do resultado em relação ao período de tratamento.

66.2 Synthetic DiD e CUPED

Synthetic DiD combina a ideia de controle sintético com diferenças em diferenças. `synthdid` estima pesos de unidade e tempo a partir dos resultados pré-tratamento e reporta o ATT.

```
1 let m_sd = synthdid(df, y, treated, 10, unit="state", period=  
2                  "year")  
3 print(m_sd)
```

Listing 66.2: Synthetic DiD

CUPED ajusta o resultado com covariáveis pré-tratamento para reduzir a variância em experimentos randomizados.

```
1 let m_c = cuped(y ~ x, df, treated="treated")
2 print(m_c)
```

Listing 66.3: CUPED

66.3 Regressão MIDAS

Mixed Data Sampling (Ghysels, Santa-Clara e Valkanov, 2004) regrediz uma variável de baixa frequência sobre defasagens de alta frequência, com pesos restritos por um polinômio de Almon.

```
1 let m_midas = midas(y ~ x, df, freq=3, lags=12, poly=2)
2 print(m_midas)
```

Listing 66.4: MIDAS

É útil para nowcasting: usar preditores mensais para prever um alvo trimestral.

Capítulo 67

Métodos Robustos, Flexíveis e Imputação

67.1 M-estimadores robustos

`rlm` ajusta um modelo linear com M-estimadores que reduzem o peso de outliers. O padrão é uma perda de Huber com constante de ajuste, que dá comportamento tipo OLS no centro e tipo L1 nas caudas.

```
1 let m_rlm = rlm(y ~ x1 + x2, df)
2 print(m_rlm)
```

Listing 67.1: Regressão robusta

Use `rlm` quando os dados contiverem outliers influentes, mas a maior parte da distribuição for aproximadamente normal.

67.2 Modelos Lineares Generalizados

`glm` ajusta um preditor linear através de uma função de ligação. Generaliza o OLS para famílias exponenciais como Poisson, Binomial e Gamma.

```
1 let m_glm = glm(y ~ x1 + x2, df, family=poisson, link=log)
2 print(m_glm)
```

Listing 67.2: GLM

Famílias disponíveis incluem `gaussian`, `poisson`, `binomial`, `gamma`, `inverse_gaussian` e `negative_binomial`. Ligações incluem `identity`, `log`, `logit`, `probit`, `cloglog` e `inverse`.

67.3 GEE

Equações de Estimaco Generalizadas ajustam um modelo marginal considerando a correlaco intra-grupo.  o anlogo mdio-populacional dos modelos mistos.

```
1 let m_gee = gee(y ~ x1 + x2, df, id="grupo", family=poisson)
2 print(m_gee)
```

Listing 67.3: GEE

Estruturas de correlaco incluem `independence`, `exchangeable`, `ar1` e `unstructured`.

67.4 Regresso Beta

`betareg`  apropriada quando a varivel dependente  limitada em (0, 1).

```
1 let m_beta = betareg(share ~ x1 + x2, df)
2 print(m_beta)
```

Listing 67.4: Regresso Beta

Ela modela a mdia por uma ligaco logit e a disperso por um parmetro de preciso separado.

67.5 GAM e lowess

`gam` ajusta um modelo aditivo generalizado com splines de suavizaco para efeitos no lineares.

```
1 let m_gam = gam(y ~ x1 + s(x2) + x3, df)
2 print(m_gam)
```

Listing 67.5: GAM

`lowess`  um suavizador polinomial local para exploraco visual e regresso parcial.

```
1 let m_low = lowess(df, y, x2, frac=0.3)
2 print(m_low)
```

Listing 67.6: Lowess

67.6 Imputação múltipla

`mice` realiza imputação múltipla por equações encadeadas. Preenche valores ausentes usando uma sequência de modelos condicionais e retorna um conjunto de DataFrames completos.

```
1 let m_mice = mice(df, vars=["y", "x1", "x2"], m=5)
2 print(m_mice)
```

Listing 67.7: MICE

As regras de Rubin combinam os resultados de cada conjunto imputado em uma única estimativa com variância que reflete a incerteza da imputação.

Capítulo 68

Espaço de Estados, Suavização Exponencial e Modelos Mistos

68.1 Componentes não observados

`ucm` decompõe uma série em tendência, sazonalidade, ciclo e componente irregular, cada um com sua própria variância.

```
1 let m_ucm = ucm(df, y)
2 print(m_ucm)
```

Listing 68.1: UCM

O modelo é útil para dessazonalização e extração de um componente latente de ciclo de negócios.

68.2 Suavização exponencial

`ets` ajusta um modelo Error-Trend-Seasonal; `hwes` ou `holtwinters` fornece a variante aditiva de Holt-Winters; `ses` é a suavização exponencial simples.

```
1 let m_hw = holtwinters(df, y, trend="add", seasonal="add",
    period=12)
2 print(m_hw)
```

Listing 68.2: Holt-Winters

O comando estima os parâmetros de suavização (α , β , γ) e reporta os componentes ajustados de nível, tendência e sazonalidade.

68.3 Modelos mistos

`mixed` ou `mixedlm` ajusta um modelo linear misto com interceptos aleatórios e/ou inclinações aleatórias. Os efeitos fixos são interpretados como em `fe` ou `re`, enquanto os efeitos aleatórios capturam heterogeneidade não observada.

```
1 let m_mixed = mixed(y ~ x1 + x2, df, id="escola")
2 print(m_mixed)
```

Listing 68.3: Modelo linear misto

A saída reporta coeficientes de efeitos fixos, componentes de variância e previsões de empirical Bayes para os efeitos aleatórios.

68.4 Kalman e séries temporais estruturais

`kalman` (Capítulo 54) e `ucm` são as principais ferramentas de espaço de estados. Comandos estruturais adicionais incluem:

- `msauto` / `markov_ar` para autorregressões com mudança de Markov
- `structural_ts` para séries temporais estruturais genéricas

Esses modelos são estimados por máxima verossimilhança ou QMLE. Verifique a log-verossimilhança reportada e critérios de informação ao comparar especificações.

Capítulo 69

Outros Estimadores e Aliases

69.1 Comandos não cobertos em detalhe

Este capítulo reúne comandos e aliases adicionais implementados no HAYASHI, mas não tratados em capítulos dedicados.

69.2 Modelos discretos e de painel adicionais

- `cmnlogit`: logit multinomial condicional
- `clogit`: logit condicional
- `cpoisson`: Poisson condicional / PPML
- `panel_tobit`: Tobit em painel com efeitos aleatórios
- `panel_heckman`: Heckman em painel
- `panel_qreg`: quantil em painel
- `sysgmm`: GMM em sistema
- `pthresh`: modelo de limiar em painel

69.3 Séries temporais adicionais

- `varma` / `varmax`: VARMA/VARMAX
- `svar_irf` / `sirf`: funções de resposta a impulsos de SVAR
- `svar_fevd` / `sfevd`: decomposição de variância de erro de previsão estrutural

- `qvar`: VAR quantílico
- `tvar`: VAR de limiar
- `mstl`: decomposição STL multi-sazonal
- `modwt`: transformada wavelet de máxima sobreposição discreta
- `decompose`: decomposição clássica de séries
- `dfm`: modelo de fator dinâmico
- `midas`: regressão com amostragem de frequência mista
- `hawkes`: processo de pontos auto-excitante

69.4 Variantes espaciais adicionais

- `spatial_sar`, `spatial_sem`, `spatial_durbin`, `spatial_panel_sar`, `spatial_panel_sem`, `spatial_durbin_error`: as variantes espaciais também estão disponíveis pelos aliases `sdm` e `sdem`.
- `fuzzy_rd`: descontinuidade de regressão difusa

69.5 Testes e diagnósticos adicionais

- `breusch_godfrey` / `bg` / `bgodfrey`: teste LM de Breusch-Godfrey para auto-correlação
- `durbinwatson` / `dw`: teste de Durbin-Watson
- `phillips_perron` / `pp`: teste de Phillips-Perron para raiz unitária
- `zivot_andrews` / `za`: teste de Zivot-Andrews com quebra estrutural
- `engle_granger`: teste de cointegração de Engle-Granger
- `anderson_darling` / `adtest`: teste de Anderson-Darling para normalidade
- `lilliefors`: teste de Lilliefors para normalidade
- `harvey_collier`: teste de Harvey-Collier para especificação
- `sktest`: teste de assimetria/curtose

- `spearman`, `wilcoxon_rs`, `wilcoxon_signed_rank`, `kruskal_wallis`: testes não paramétricos
- `proptest`, `proptest2`, `propci`, `chi2_2x2`, `multipletests`: testes de proporção e múltiplas hipóteses

69.6 Testes pós-estimação

- `estat_overid` / `sargan`: teste de Sargan/Hansen J
- `estat_endog` / `dwh`: teste de Durbin-Wu-Hausman
- `estat_classification`: tabela de classificação para logit/probit
- `estat_gof` / `hltest`: Hosmer-Lemeshow de aderência

69.7 Aliases

Muitos estimadores têm aliases por conveniência. Os mais comuns são:

- `reg` para `ols`, `frontier` para `sfa_production`
- `ridge` / `ridge_reg` e `elasticnet` / `enet`: estimadores de regularização
- `neural_net` para `mlp`, `xgb` para `xgboost`
- `causal_forest` para `causalforest`, `random_forest` para `rf`
- `gaussian_process` para `gp`, `bayesian_trees` para `bart`
- `gmm_clustering` para `gmm_clust`, `pca_biplot` para `biplot`
- `three_sls`, `threesl`, `3sls`, `reg3`: aliases para o mesmo estimador 3SLS

Use o apêndice de referência rápida para a matriz completa de comandos.

Instalação Avançada

69.8 Compilação com suporte a ODBC

Para conectar HAYASHI a bancos de dados via ODBC (SQL Server, Oracle, etc.):

```
cargo install hayashi-lang --features odbc
```

Requer driver ODBC instalado no sistema (unixODBC no Linux).

69.9 Variáveis de ambiente

Variável	Efeito
HAY_HISTORY	Caminho do arquivo de histórico do REPL
HAY_NOCOLOR	Desabilita cores nas mensagens de erro
HAY_TRACE	Habilita trace de execução (depuração)

69.10 Módulos e funcionalidades opcionais

Modelos econométricos avançados

Os estimadores abaixo requerem a crate **greeners** como dependência do interpretador. Em builds de desenvolvimento (`cargo build`), ela é compilada automaticamente. Nenhuma instalação adicional é necessária.

Grupo	Estimadores
Dados em painel	fe, re, ab, pcse, gee, mundlak, xtglsl, mixedlm, clogit
Resposta qualitativa	logit, probit, mlogit, ologit, oprobit
Contagem/limitada	poisson, nbreg, zinb, tobit, heckman
GLM geral	glm (5 famílias, múltiplos links)
Regularização	lasso, ridge_reg, enet
Sobrevivência	km, cox
Multivariada	pca, factor, cancel, manova
Séries temporais	var, svar, vecm, garch, markov, arima
Filtros	hprescott, baxter_king, holtwinters, stl, christiano_fitzgerald
Inferência causal	psm, synth, did, rd

Uso da memória

Modelos computacionalmente intensivos podem requerer ajuste de stack:

```
RUST_MIN_STACK=8388608 hay script.hay // 8 MB de stack
```

Relevante para VAR/SVAR com muitas defasagens ou PCA em datasets amplos.

69.11 Integração com editores

Neovim

Adicione ao `init.lua` para reconhecimento de sintaxe básico:

```
vim.filetype.add({ extension = { hay = "hayashi" } })
```

Highlighting completo via Tree-sitter está no roadmap.

VS Code

Extensão disponível na marketplace como `hayashi-lang`.

69.12 Compilação de desenvolvimento

Para iterar com builds locais (sem `--release`):

```
git clone https://github.com/sheep-farm/hayashi
cd hayashi
cargo build // debug build (recomendado para dev)
```

```
./target/debug/hay script.hay
```

O build debug tem verificações extras de bounds e mensagens de erro detalhadas. Não usar `--release` em desenvolvimento — o ganho de velocidade não compensa a perda de diagnóstico.

Execução de scripts

```
./target/debug/hay script.hay      // executa script
./target/debug/hay                 // abre REPL interativo
./target/debug/hay < script.hay    // lê do stdin
```


Referência Rápida

69.13 Tipos

Tipo	Exemplo	Notas
Int	42, -7	64 bits, com sinal
Float	3.14, 1e-5	IEEE 754
Bool	true, false	
Nil	nil	Ausência de valor
String	"texto"	UTF-8
FString	f"val: {x}"	Interpolação
TString	t"x{n}"	Re-avalia código gerado
List	[1, 2, 3]	Índice base 0
Dict	{"a": 1}	Chave string ou int
DataFrame	load "f.csv"as df	COW, colunas Float

69.14 Operadores

Aritmético	+ - * / ^ %
Comparação	== != > < >= <=
Lógico	and or not
Pertencimento	in
Pipe	>
Atribuição	= += -= *= /=
Range	a..b (exclusivo) a..=b (inclusivo)

69.15 Operadores de séries temporais

Disponíveis dentro de `generate` `df col = expr:`

L.x	Lag de ordem 1
L2.x	Lag de ordem 2
F.x	Lead de ordem 1
D.x	Diferença primeira

Constante especial: `_n` = número de linha (base 1).

69.16 Palavras-chave

```
let  const  fn  return  if  else  for  parallel  in  while  break
      continue
match  try  catch  and  or  not  true  false  nil  quietly
```

`quietly on` suprime a saída automática; `quietly off` restaura. A flag respeita escopo.

69.17 Funções auxiliares

Função	Descrição
<code>dataframe({"x": [1, 2]})</code>	Constroi DataFrame a partir de dict
<code>is_int(x)</code>	Testa se <code>x</code> é int
<code>is_str(x)</code>	Testa se <code>x</code> é string
<code>is_df(x)</code>	Testa se <code>x</code> é DataFrame
<code>is_fn(x)</code>	Testa se <code>x</code> é função
<code>contains(s, sub)</code>	Verifica se <code>sub</code> está em <code>s</code>
<code>type(x)</code>	Retorna nome do tipo

69.18 Estatística descritiva

Função	Resultado	Formas
<code>mean(df, x)</code>	$E(X)$	lista / df / if =
<code>variance(df, x)</code>	$\text{Var}(X)$	lista / df / if =
<code>sd(df, x)</code>	$\sigma(X)$	lista / df / if =
<code>median(df, x)</code>	mediana	lista / df / if =
<code>quantile(df, x, p)</code>	percentil p	lista / df / if =
<code>cov(df, x, y)</code>	$\text{Cov}(X, Y)$	df / if =
<code>corr_pair(df, x, y)</code>	$\rho(X, Y)$	df / if =
<code>summarize(df, x)</code>	dict completo	+ <code>detail=true</code>
<code>correlate(df, x, y, ...)</code>	matriz de correlação	display
<code>codebook df</code>	sumário por coluna	display
<code>tabulate df col</code>	frequências	display
<code>xtsum(df, x, id=unit)</code>	painel: within/between	display

69.19 Manipulação de DataFrames

Função	Descrição
<code>dataframe(dict) / dataframe(n)</code>	Cria DataFrame a partir de dict, ou pré-dimensiona vazio
<code>load "f"as df [, opts]</code>	Carrega arquivo (CSV, TSV, JSON, Parquet, DTA, XLSX, SQLite) <i>opts: sheet=, table=, query=, sep=, columns=, where=</i>
<code>save df "f"</code>	Salva arquivo
<code>count(df [, cond])</code>	Número de linhas
<code>filter(df, cond)</code>	Filtra linhas
<code>select(df, cols...)</code>	Seleciona colunas
<code>drop(df, cols...)</code>	Remove colunas
<code>generate df col = expr</code>	Cria/modifica coluna
<code>replace df col = e if c</code>	Modifica com condição
<code>sort(df, col [desc])</code>	Ordena
<code>dropna(df [, cols...])</code>	Remove NaN
<code>ffill(df)</code>	Preenche NaN com último valor válido
<code>append(df1, df2)</code>	Empilha verticalmente
<code>rbind(lista_dfs)</code>	Concatena vários DFs (ignora nil)
<code>merge(df1, df2, on=col)</code>	Junção horizontal
<code>group_by(df, col, agg)</code>	Agrega por grupo
<code>collapse(df, expr, by=c)</code>	Colapsa por grupo
<code>pivot_longer(...)</code>	Largo → longo
<code>pivot_wider(...)</code>	Longo → largo
<code>reshape(df, ...)</code>	Reshape geral
<code>encode(df, col)</code>	String → numérico
<code>decode(df, col, labels)</code>	Numérico → string
<code>drop_collinear(df)</code>	Remove colunas colineares

69.20 Auxiliares de arquivo e I/O

Função	Descrição
<code>file_exists(path)</code>	Retorna true se o path existe
<code>ensure_dir(path)</code>	Cria diretório (e pais)
<code>write(content, path)</code>	Escreve string em arquivo
<code>export(df, "csv", path)</code>	Salva DataFrame em CSV
<code>load "path"as df [, opts]</code>	Carrega CSV/TSV/JSON/Parquet/DTA/XLSX/SQLite/ODBC; <i>opts: sheet=, table=, query=, sep=, columns=, where=</i>

69.21 Declaração de estrutura

Comando	Efeito
<code>xtset df id time</code>	Declara painel (unidade e tempo)
<code>tsset df time</code>	Declara série temporal (habilita L.x, F.x, D.x)

69.22 Geradores aleatórios

Disponíveis dentro de `generate` `df col = expr.` Todos respeitam `set_seed.`

Função	Distribuição
<code>rnormal()</code> / <code>rnormal(μ, σ)</code>	Normal
<code>rlognormal(μ, σ)</code>	Log-normal
<code>rskewnormal(loc, scale, shape)</code>	Skew-normal
<code>rcauchy(loc, scale)</code>	Cauchy
<code>rstudentt(df)</code> / <code>rt(df)</code>	t de Student
<code>rchisq(k)</code>	Qui-quadrado
<code>rf(d1, d2)</code>	Distribuição F
<code>rbeta(α, β)</code>	Beta
<code>rgamma(shape, scale)</code>	Gamma
<code>rexponential(λ)</code>	Exponencial (taxa λ)
<code>rweibull(scale, shape)</code>	Weibull
<code>rpareto(scale, shape)</code>	Pareto
<code>rpert(min, max, mode)</code> / <code>rpert(min, max, mode, shape)</code>	PERT
<code>rtriangular(min, max, mode)</code>	Triangular
<code>rfrechet(location, scale, shape)</code>	Fréchet
<code>rgumbel(location, scale)</code>	Gumbel
<code>rinversegaussian(mean, shape)</code>	Gaussiana inversa
<code>rnig(α, β)</code>	Normal-inversa-Gaussiana
<code>runiform()</code> / <code>runiform(a, b)</code>	Uniforme $[0, 1)$ ou $[a, b)$
<code>rbernoulli(p)</code>	Bernoulli (default $p = 0,5$)
<code>rbinomial(n, p)</code>	Binomial
<code>rpoisson(λ)</code>	Poisson
<code>rgeometric(p)</code>	Geométrica (falhas antes do primeiro)
<code>rhypergeometric(N, K, n)</code>	Hipergeométrica
<code>rzeta(a)</code>	Zeta ($a > 1$)
<code>rzipf(N, s)</code>	Zipf

69.23 Regressão linear e extensões

Estimador	Sintaxe
OLS	<code>ols(y ~ x1 + x2, df)</code>
IV/2SLS	<code>iv(y ~ x, ~ z, df)</code>
GMM	<code>gmm(y ~ x, ~ z1 + z2, df)</code>
WLS	<code>wls(y ~ x, df, weights="w")</code>
Rolling OLS	<code>rolling(y ~ x, df, window=50 [, date=col])</code>
LASSO	<code>lasso(y ~ x1+...+xk, df, alpha=0.1)</code>
Ridge	<code>ridge_reg(y ~ x1+...+xk, df, alpha=0.5)</code>
Elastic Net	<code>enet(y ~ x1+...+xk, df, alpha=0.5)</code>
Bootstrap	<code>bootstrap("ols", y ~ x, df, reps=500)</code>
Bootstrap SE	<code>bootse("ols", y ~ x, df, n=500)</code>
Regressão quantílica	<code>qreg(y ~ x, df, tau=0.5)</code>
Regressão robusta	<code>rlm(y ~ x, df)</code>
LOWESS	<code>lowess(df, y, x, frac=0.3)</code>
SUR (Zellner)	<code>sur(df, y1 ~ x1, y2 ~ x2)</code>

Regularização: em `lasso`, `alpha` é a força de penalização λ (maior = mais zeros). Em `enet`, `alpha` é o mixing $L1/(L1+L2)$ (0 = Ridge, 1 = LASSO).

69.24 Dados em painel

Estimador	Sintaxe
FE (within)	<code>fe(y ~ x, df, id=unit)</code>
RE (GLS)	<code>re(y ~ x, df, id=unit)</code>
FE com IV	<code>feiv(y ~ x, z ~ z+w, df, id="unit")</code>
Hausman	<code>hausman(m_fe, m_re)</code>
Mundlak (CRE)	<code>mundlak(df, y ~ x, id="unit")</code>
AB-GMM	<code>ab(y ~ x, df, id=unit, time=t, lags=2)</code>
PCSE	<code>pcse(y ~ x, df, id=unit, time=t)</code>
GEE	<code>gee(y ~ x, df, id=unit)</code>
xtgls	<code>xtgls(y ~ x, df, id=unit, time=t)</code>
Modelo misto	<code>mixedlm(y ~ x, df, id="unit")</code>
Logit cond. (FE)	<code>clogit(y ~ x, df, group="unit")</code>

69.25 Inferência causal

Método	Sintaxe
DiD	<code>did(y ~ treated + post, df)</code>
RDD	<code>rd(y ~ x, 0.0, df)</code>
Fuzzy RDD	<code>fuzzy_rd(y ~ x, "treat", 0.0, df)</code>
PSM	<code>psm(y ~ d + x1, df, k=1, caliper=0.05, boot=200)</code>
Controle sintético	<code>synth("y", treated_id, t0, df, id="col", time="col")</code>

PSM: sem `caliper`, ATT pode ser tendencioso mesmo com PSM. **synth:** `t0` = primeiro período pós-tratamento (inclusive).

69.26 Variáveis dependentes especiais

Modelo	Sintaxe
Logit / Probit	<code>logit(y ~ x, df)</code> <code>probit(y ~ x, df)</code>
Efeitos marginais	<code>margins(m, df)</code>
Logit multinomial	<code>mlogit(y ~ x, df)</code>
Logit ordenado	<code>ologit(y ~ x, df)</code>
Probit ordenado	<code>oprobit(y ~ x, df)</code>
Poisson	<code>poisson(y ~ x, df)</code>
Binomial negativa	<code>nbreg(y ~ x, df)</code>
Zero-inflacionada	<code>zinb(y ~ x, df)</code>
Tobit	<code>tobit(y ~ x, df)</code>
Heckman	<code>heckman(y_out ~ x, s ~ z, df)</code>
GLM geral	<code>glm(y ~ x, df, family=gamma, link=log)</code>

Família GLM	Links disponíveis
gaussian	identity, log, inverse
binomial	logit, probit, cloglog
poisson	log, identity
gamma	log, inverse, identity
inverseGaussian	inverse_squared

69.27 Análise de sobrevivência

Método	Sintaxe
Kaplan-Meier	<code>km(time, event, df)</code>
Cox PH	<code>cox(time ~ x1 + x2, df, event=event)</code>

Cox: `exp(coef)` = hazard ratio. `event` é coluna indicadora de falha (1) / censura (0).

69.28 Séries temporais

Modelo	Sintaxe
ARMA/ARIMA	<code>arima(df, y, p=1, d=0, q=1)</code>
AR(p) via OLS	<code>autoreg(df, y, lags=2, trend="c")</code>
ARDL(p, q)	<code>ardl(y ~ x1 + x2, df, lags=p, xlags=q)</code>
GARCH	<code>garch(df, y, p=1, q=1)</code>
EGARCH / GJR	<code>egarch(df, y, p=1, q=1)</code> <code>gjrgarch(df, y, p=1, q=1)</code>
ADF	<code>adf(df, var)</code>
KPSS	<code>kpss(df, var)</code>
Phillips-Perron	<code>phillips_perron(df, var)</code>
Zivot-Andrews	<code>zivot(df, var)</code>
VAR	<code>var(df, y1, y2, lags=2)</code>
VECM	<code>vecm(df, y1, y2, lags=1, r=1)</code>
Cointegração	<code>johansen(df, y1, y2, lags=1)</code>
Granger	<code>granger(df, y1, y2, lags=2)</code>
IRF (VAR reduz.)	<code>irf(m_var, steps=12)</code>
SVAR Cholesky	<code>svar(df, y1, y2, lags=1, id=cholesky)</code>
SVAR longo prazo	<code>svar(df, y1, y2, lags=1, id=longrun)</code>
IRF estrutural	<code>sirf(m_svar, steps=12)</code>
Markov Switching	<code>markov(df, y, k=2, p=1)</code>

69.29 Filtros e decomposição

Filtro	Sintaxe	Output
Hodrick-Prescott	<code>hprescott(df, y, lambda=1600)</code>	<code>y_trend, y</code>
Baxter-King	<code>baxter_king(df, y, low=6, high=32, k=12)</code>	<code>y_cycle</code>
Holt-Winters / ETS	<code>holtwinters(df, y, trend=add, seasonal=add, period=12)</code>	modelo ETS
STL	<code>stl(df, y, period=12)</code>	<code>y_trend, y</code>
Christiano-Fitz.	<code>christiano_fitzgerald(df, y, low=6, high=32)</code>	<code>y_cycle</code>

Perda de borda: HP perde pontas; BK perde k observações em cada extremo; CF e STL mantêm todos os pontos. **Nota:** `hamilton()` é alias do Markov Switching (Hamilton 1989), *não* do filtro Hamilton 2018. **autoreg trend:** "c" = constante (padrão); "ct" = const + tendência; "t" = só tendência; "n" = nenhum. **ARDL:** fórmula padrão $y \sim x$; `lags` = defasagens de y ; `xlags` = defasagens de cada regressor; inclui x contemporâneo automaticamente.

69.30 Análise multivariada

Método	Sintaxe
PCA	<code>pca(df, v1, v2, ..., n=2)</code>
Análise fatorial	<code>factor(df, v1, v2, ..., n=2, rotation=varimax)</code>
Correlação canôn.	<code>cancorr(df, xvars=["v1","v2"], yvars=["v3","v4"])</code>
MANOVA	<code>manova(df, y1, y2, by="grupo")</code>
KDE	<code>kde(df, var, bwidth=0.5)</code>
Biplot PCA	<code>biplot(df, x="v1,v2,v3", type="symmetric")</code>

69.31 Agrupamento e redução de dimensionalidade

Método	Sintaxe
K-Means	<code>kmeans(df, x="v1,v2", k=3)</code>
DBSCAN	<code>dbscan(df, x="v1,v2", eps=1.0, minpts=5)</code>
GMM (EM)	<code>gmm_clust(df, x="v1,v2", k=3)</code>
Espectral	<code>spectral(df, x="v1,v2", k=3)</code>
Hierárquico	<code>hclust(df, x="v1,v2", linkage="ward")</code>
t-SNE	<code>tsne(df, x="v1,v2", perplexity=30)</code>
UMAP	<code>umap(df, x="v1,v2", neighbors=15)</code>

69.32 Testes de hipóteses

Teste	Sintaxe
t — uma amostra	<code>ttest(df, var, mu=0.0)</code>
t — dois grupos	<code>ttest(df, var, by=grupo)</code>
t — pareado	<code>ttest(df, var1, var2, paired=true)</code>
ANOVA	<code>anova(df, var, by=grupo)</code>
Kruskal-Wallis	<code>kruskal_wallis(df, var, by=grupo)</code>
Normalidade (SW)	<code>swilk(df, var)</code>
Normalidade (SF)	<code>sfrancia(df, var)</code>
Homocedasticidade	<code>vif(m_ols)</code>
Hausman	<code>hausman(m_fe, m_re)</code>
Hausman robusto	<code>hausman_robust(m_fe, m_re)</code>
F-test robusto	<code>fctest_robust(m, vars="x1,x2")</code>
Teste linear	<code>test(m, "x1 = x2")</code>
Teste conjunto	<code>testparm(m, ["x1", "x2"])</code>
Combinação linear	<code>lincom(m, "x1 + x2")</code>
White	<code>test(m, "white")</code>
Breusch-Pagan	<code>test(m, "bp")</code>
Durbin-Watson	<code>test(m, "dw")</code>
Goldfeld-Quandt	<code>gqtest(m, split=0.2)</code>
RESET	<code>reset(m)</code>
CUSUM	<code>cusumtest(m)</code>
Jarque-Bera	<code>jb(m)</code>
Ljung-Box	<code>ljungbox(df, var, lags=10)</code>
ARCH-LM	<code>archtest(df, var, lags=5)</code>
FAC / FAC parcial	<code>acf(df, var) pacf(df, var)</code>
Breusch-Pagan LM (painel)	<code>bptest(df, formula, id="entity")</code>
F-test FE	<code>fctest_fe(df, formula, id="entity")</code>
Wooldridge	<code>wooldridge(df, formula, id=, time=)</code>
Pesaran CD	<code>pesaran(df, formula, id=, time=)</code>
Arellano-Bond	<code>abtest(df, formula, id=, time=)</code>
Mundlak	<code>mundlak(df, formula, id="entity")</code>
Pesos de Akaike	<code>akaike_weights(m1, m2)</code>
Razão verossimilhanças	<code>lrtest(m1, m2)</code>
1ª etapa F (IV)	<code>weak_iv(endog, instr, df)</code>
Sargan/J (IV)	<code>estat_overid(endog, instr, df)</code>
Endogeneidade (IV)	<code>estat_endog(endog, instr, df)</code>
Classificação (logit)	<code>estat_classification(m)</code>
ROC/AUC (logit)	<code>lroc(m)</code>
Hosmer-Lemeshow	<code>estat_gof(m)</code>
Linktest	<code>linktest(m)</code>

69.33 Aprendizado de máquina e ML causal

Método	Sintaxe
Random forest	<code>rf(y ~ x1 + x2, df, trees=100)</code>
Gradient boosting	<code>gbm(y ~ x1 + x2, df, trees=100)</code>
Quantile RF	<code>qrf(y ~ x1 + x2, df, quantiles="0.1,0.5,0.9")</code>
XGBoost	<code>xgboost(y ~ x1 + x2, df)</code>
MLP	<code>mlp(y ~ x1 + x2, df, hidden=10)</code>
LSTM	<code>lstm(df, y, hidden=10, seqlen=12, forecast=5)</code>
Transformer	<code>transformer(df, y, d_model=8, seqlen=12)</code>
BART	<code>bart(y ~ x1 + x2, df, trees=20)</code>
Processo Gaussiano	<code>gp(y ~ x1 + x2, df)</code>
Causal forest	<code>causalforest(y ~ treated, df, x="x1,x2")</code>
Generalized RF	<code>grf(y ~ treated, df, x="x1,x2")</code>
DR-Learner	<code>dr_learner(y ~ treated, df, x="x1,x2")</code>
TMLE	<code>tmle(y ~ treated, df, w="x1,x2")</code>
ORF	<code>orf(y ~ treated, df, x="x1,x2", w="w1")</code>
Bayesian SC	<code>bsc(df, y, "x1,x2", 5)</code>
DML cross-fit	<code>dml_crossfit(y ~ d, df, x="x1,x2")</code>

69.34 Econometria espacial

Modelo	Sintaxe
SAR espacial	<code>spatial_sar(y ~ x1 + x2, df, w=W)</code>
SEM espacial	<code>spatial_sem(y ~ x1 + x2, df, w=W)</code>
Durbin espacial	<code>spatial_durbin(y ~ x1 + x2, df, w=W)</code>
SAR em painel	<code>spatial_panel_sar(y ~ x, df, w=W, id="e")</code>
SEM em painel	<code>spatial_panel_sem(y ~ x, df, w=W, id="e")</code>
Durbin error em painel	<code>spatial_durbin_error(y ~ x, df, w=W, id="e")</code>

69.35 Apresentação de resultados

Função	Descrição
<code>display m</code>	Exibe resultado do modelo
<code>esttab(m1, m2, ...)</code>	Tabela comparativa
<code>eststo(m)</code>	Armazena modelo para <code>esttab</code>
<code>estclear()</code>	Limpa modelos armazenados
<code>predict(m, df)</code>	Adiciona coluna <code>yhat</code> ao <code>df</code>
<code>margins(m, df)</code>	Efeitos marginais médios (AME)
<code>tidy(m)</code>	DataFrame organizado de coeficientes
<code>glance(m)</code>	DataFrame de resumo do modelo (1 linha)

69.36 Construção de painel (fórmulas)

Para construir painel a partir de DataFrame empilhado (N unidades, T períodos):

```
generate df unit = (_n - 1) % N + 1
generate df t     = (_n - (_n - 1) % N - 1) / N + 1
```

Onde N é o número de unidades. Substitua N pelo valor numérico.

69.37 Atalhos do REPL

Atalho	Ação
<code>exit</code>	Sair do REPL
<code>Ctrl-D</code>	Sair do REPL (EOF)
<code>Ctrl-C</code>	Cancelar linha atual
<code>Ctrl-R</code>	Buscar no histórico

Código Equivalente por Plataforma

Este apêndice reproduz DGPs representativos em Stata, R e Python, lado a lado com o código HAYASHI. O objetivo é duplo: permitir validação cruzada de resultados e evidenciar diferenças de sintaxe.

Nota

Os geradores de números aleatórios diferem entre plataformas — os valores numéricos serão distintos, mas as propriedades estatísticas (recuperação de parâmetros, direção do viés, decisão do Hausman) são idênticas para qualquer semente.

69.38 OLS — DGP sem ruído e comparação com variável omitida

Hayashi

```
1 seed(42)
2 input df
3 id
4 1
5 end
6 for i in 1..=10 { df = append(df, df) }
7 df |> filter(_n <= 1000)
8 generate df x1 = rnormal()
9 generate df x2 = rnormal()
10 generate df y = 2.5 + 1.8*x1 - 0.7*x2
11 let m1 = ols(y ~ x1 + x2, df)
12 let m2 = ols(y ~ x1, df)
13 esttab(m1, m2)
```

Stata

```
clear
set obs 1000
set seed 42
gen x1 = rnormal()
gen x2 = rnormal()
gen y = 2.5 + 1.8*x1 - 0.7*x2
reg y x1 x2
estimates store m1
reg y x1
estimates store m2
esttab m1 m2          // ssc install estout
```

R

```
set.seed(42)
n <- 1000
x1 <- rnorm(n); x2 <- rnorm(n)
y <- 2.5 + 1.8*x1 - 0.7*x2
m1 <- lm(y ~ x1 + x2)
m2 <- lm(y ~ x1)
library(stargazer)
stargazer(m1, m2, type = "text")
```

Python

```
import numpy as np, pandas as pd
import statsmodels.formula.api as smf
from statsmodels.iolib.summary2 import summary_col
np.random.seed(42)
n = 1000
x1 = np.random.randn(n); x2 = np.random.randn(n)
y = 2.5 + 1.8*x1 - 0.7*x2
df = pd.DataFrame({'y': y, 'x1': x1, 'x2': x2})
m1 = smf.ols('y ~ x1 + x2', data=df).fit()
m2 = smf.ols('y ~ x1', data=df).fit()
print(summary_col([m1, m2], stars=True))
```

69.39 IV — Endogeneidade com instrumento válido

Hayashi

```

1  seed(42)
2  ...
3  generate df z    = rnormal()
4  generate df v    = rnormal()
5  let d1           = cov(df, z, v) / variance(df, z)
6  let d0           = mean(df, v) - d1 * mean(df, z)
7  generate df eps  = v - d0 - d1*z
8  generate df x    = 0.8*z + eps
9  generate df y    = 1.5 + 2.0*x + 0.7*eps
10 let m_ols = ols(y ~ x, df)
11 let m_iv  = iv(y ~ x, ~ z, df)
12 esttab(m_ols, m_iv)

```

Stata

```

gen z = rnormal()
gen v = rnormal()
reg v z
predict eps, residuals
gen x = 0.8*z + eps
gen y = 1.5 + 2.0*x + 0.7*eps
reg y x
ivregress 2sls y (x = z)

```

R

```

eps <- resid(lm(v ~ z))
x    <- 0.8*z + eps
y    <- 1.5 + 2.0*x + 0.7*eps
library(ivreg)
ivreg(y ~ x | z, data = data.frame(y,x,z))

```

Python

```
from linearmodels.iv import IV2SLS
import statsmodels.api as sm
IV2SLS(y, sm.add_constant(x),
       None, sm.add_constant(z)).fit()
```

69.40 Painei — FE, RE e Hausman

Hayashi

```
1 seed(42) / ... / df |> filter(_n <= 1000)
2 generate df id      = (_n - 1) % 100 + 1
3 generate df alpha   = id * 0.05
4 generate df x       = alpha + rnormal()
5 generate df y       = 1.0 + 2.0*x + alpha + rnormal()
6 let m_fe  = fe(y ~ x, df, id=id)
7 let m_re  = re(y ~ x, df, id=id)
8 hausman(m_fe, m_re)
```

Stata

```
xtset id
xtreg y x, fe
estimates store m_fe
xtreg y x, re
estimates store m_re
hausman m_fe m_re
```

R

```
library(plm)
pd  <- pdata.frame(df, index = "id")
m_fe <- plm(y ~ x, data = pd, model = "within")
m_re <- plm(y ~ x, data = pd, model = "random")
phtest(m_fe, m_re)
```


Python

```
from linearmodels import PanelOLS, RandomEffects
m_fe = PanelOLS(df['y'], df[['x']], entity_effects=True).fit()
m_re = RandomEffects(df['y'], df[['x']]).fit()
```

69.41 Logit e Probit

Hayashi

```
1 generate df p = 1 / (1 + exp(-(-1.0 + 2.0*x)))
2 generate df y = runiform() < p
3 let m_l = logit(y ~ x, df)
4 let m_p = probit(y ~ x, df)
5 margins(m_l, df)
```

Stata

```
logit y x
probit y x
margins, dydx(x)
```

R

```
m_l <- glm(y ~ x, family = binomial("logit"))
m_p <- glm(y ~ x, family = binomial("probit"))
library(margins)
summary(margins(m_l))
```

Python

```
import statsmodels.formula.api as smf
m_l = smf.logit('y ~ x', data=df).fit()
print(m_l.get_margeff().summary())
```

69.42 Modelos de contagem

Hayashi

```
1 generate df lam = exp(0.5 + 1.0*x)
2 generate df y   = floor(lam + runiform())
3 let m_p  = poisson(y ~ x, df)
4 let m_nb = nbreg(y ~ x, df)
```

Stata

```
poisson y x
nbreg   y x
```

R

```
glm(y ~ x, family = poisson("log"))
library(MASS)
glm.nb(y ~ x)
```

Python

```
smf.poisson('y ~ x', data=df).fit()
smf.negativebinomial('y ~ x', data=df).fit()
```

69.43 Tobit e Heckman

Hayashi

```
1 let m_t = tobit(y_tobit ~ x, df)
2 let m_h = heckman(y_out ~ x, s ~ z, df)
```

Stata

```
tobit y_tobit x, ll(0)
heckman y_out x, select(s = x z)
```

R

```
library(AER)
tobit(y_tobit ~ x, left = 0)
library(sampleSelection)
heckit(s ~ x + z, y_out ~ x)
```

Python

```
# Tobit: sem implementação nativa no statsmodels
# Heckman: via heckit do pyheckit ou statsmodels
from statsmodels.regression.linear_model import OLS
# implementação manual via two-step
```

69.44 Modelos multinomiais ordenados

Hayashi

```
1 let m_ol = ologit(y ~ x, df)
2 let m_op = oprobit(y ~ x, df)
3 let m_ml = mlogit(y ~ x, df)
```

Stata

```
ologit y x
oprobit y x
mlogit y x
```

R

```
library(MASS)
polr(factor(y) ~ x, method = "logistic") # ologit
polr(factor(y) ~ x, method = "probit") # oprobit
library(nnet)
multinom(y ~ x) # mlogit
```

Python

```
from statsmodels.miscmodels.ordinal_model import OrderedModel
OrderedModel(y, X, distr='logit').fit()
OrderedModel(y, X, distr='probit').fit()
smf.mnlogit('y ~ x', data=df).fit()
```

69.45 Regularização (LASSO, Ridge, Elastic Net)

Hayashi

```
1 let m_las = lasso(y ~ x1+x2+...+x10, df, alpha=0.1)
2 let m_rid = ridge_reg(y ~ x1+...+x10, df, alpha=0.5)
3 let m_ent = enet(y ~ x1+...+x10, df, alpha=0.5)
4 display m_las
```

Stata

```
// requer Stata 16+
lasso linear y x1-x10
cvlasso y x1-x10
```

R

```
library(glmnet)
X <- model.matrix(y ~ ., df)[,-1]
# LASSO (alpha=1), Ridge (alpha=0), Enet (alpha=0.5)
cv.glmnet(X, df$y, alpha = 1) # LASSO com CV
cv.glmnet(X, df$y, alpha = 0) # Ridge com CV
cv.glmnet(X, df$y, alpha = 0.5) # Enet com CV
```

Python

```
from sklearn.linear_model import Lasso, Ridge, ElasticNet
Lasso(alpha=0.1).fit(X, y)
Ridge(alpha=0.5).fit(X, y)
ElasticNet(alpha=0.1, l1_ratio=0.5).fit(X, y)
```

Nota de escala: alpha em Hayashi e statsmodels é λ (força de penalização). Em glmnet (R), os dados são padronizados automaticamente e `lambda` é escolhido por validação cruzada. Em scikit-learn, alpha é análogo a λ .

69.46 Análise de sobrevivência

Hayashi

```
1 let m_km = km(time, event, df)
2 let m_cox = cox(time ~ x, df, event=event)
3 display m_cox
```

Stata

```
stset time, failure(event)
sts graph           // Kaplan-Meier
stcox x             // Cox PH
stcox x, nohr       // coeficientes log-hazard
```

R

```
library(survival)
km_fit <- survfit(Surv(time, event) ~ 1)
cox_fit <- coxph(Surv(time, event) ~ x)
summary(cox_fit)
```

Python

```
from lifelines import KaplanMeierFitter, CoxPHFitter
kmf = KaplanMeierFitter().fit(df['time'], df['event'])
cph = CoxPHFitter().fit(df, 'time', 'event')
```

69.47 SVAR — Cholesky e Blanchard-Quah

Hayashi

```
1 let m_ch = svar(df, y1, y2, lags=1, id=cholesky)
2 let m_bq = svar(df, y1, y2, lags=1, id=longrun)
3 let m_ir = sirf(m_ch, steps=12)
4 display m_ir
```

Stata

```
var y1 y2, lags(1)
// Cholesky (padrao do IRF pos-VAR):
irf create myirf, step(12) replace
irf table sirf
// Blanchard-Quah requer restrições manuais via svar
matrix A = (1, 0 \ ., 1)
matrix B = (., 0 \ ., .)
svar y1 y2, lags(1) aeq(A) beq(B)
```

R

```
library(vars)
m <- VAR(cbind(y1, y2), p = 1)
# Cholesky:
irf(m, n.ahead = 12, ortho = TRUE)
# Blanchard-Quah:
BQ(m)
```

Python

```
from statsmodels.tsa.api import VAR
m = VAR(df[['y1', 'y2']]).fit(1)
# Cholesky:
m.irf(12).orth_ma # orthogonalized IRF
# BQ: requer implementação manual em Python
```

69.48 Filtros de decomposição

Hayashi

```
1 hprescott(df, y, lambda=1600)
2 baxter_king(df, y, low=6, high=32, k=12)
3 stl(df, y, period=12)
4 christiano_fitzgerald(df, y, low=6, high=32)
```

Stata

```
// ssc install hprescott
hprescott y, smooth(1600)      // HP
// ssc install bking
bking y, minperiod(6) maxperiod(32) stub(bk)
// ssc install cfitzroy
// stl: via Python/R (nao disponivel nativamente no Stata)
```

R

```
library(mFilter)
hp <- hpfilter(y, freq = 1600)
bk <- bkfilter(y, pl = 6, pu = 32, nfix = 12)
cf <- cffilter(y, pl = 6, pu = 32)
library(stats)
stl(ts(y, frequency=12), s.window="periodic")
```

Python

```
from statsmodels.tsa.filters.hp_filter import hpfilter
from statsmodels.tsa.filters.bk_filter import bkfilter
from statsmodels.tsa.seasonal import STL
_, trend = hpfilter(y, lamb=1600)
cycle_bk = bkfilter(y, low=6, high=32, K=12)
stl = STL(y, period=12).fit()
```

69.49 PSM e Controle Sintético

Hayashi

```
1 let m_psm = psm(y ~ d + x1, df, k=1, caliper=0.05, boot=200)
2 display m_psm
3
4 // Controle Sintético (painel)
5 let m_sc = synth("y", 1, 11, df, id="unit", time="year")
6 display m_sc
```

Stata

```
// ssc install psmatch2
psmatch2 d x1, outcome(y) neighbor(1) caliper(0.05)
// ssc install synth
synth y x1, trunit(1) trperiod(11) xperiod(1/10)
```

R

```
library(MatchIt)
m <- matchit(d ~ x1, data=df, method="nearest",
             caliper=0.05)
library(Synth)
dataprep.out <- dataprep(...) # setup
synth(dataprep.out)
```

Python

```
# PSM:
from sklearn.linear_model import LogisticRegression
# calcular propensity scores e fazer matching manual
# Controle Sintético:
# pip install pysynth
from pysynth import Synth
```

69.50 Resumo comparativo

Tarefa	Hayashi	Stata	R	Python
<i>Regressão</i>				
OLS	ols()	reg	lm()	smf.ols()
IV/2SLS	iv()	ivregress	ivreg()	IV2SLS()
GMM	gmm()	gmm	gmm()	LinearIVGMM()
WLS	wls()	vwls	lm(weights=)	WLS()
Rolling OLS	rols()	rolling()	rollregres()	RollingOLS()
LASSO	lasso()	lasso linear	glmnet(a=1)	Lasso()
Ridge	ridge_reg()	—	glmnet(a=0)	Ridge()
Elastic Net	enet()	—	glmnet(a=.5)	ElasticNet()
Bootstrap	bootstrap()	bootstrap:	boot()	resample()
Bootstrap SE	bootse()	—	—	—
LOWESS	lowess()	lowess	lowess()	lowess()
Quant. reg.	qreg()	qreg	rq()	QuantReg()
SUR	sur()	sureg	systemfit()	SUR()
<i>Dados em painel</i>				
FE (within)	fe()	xtreg, fe	plm(within)	PanelOLS()
RE (GLS)	re()	xtreg, re	plm(random)	RandomEffects()
Hausman	hausman()	hausman	phptest()	manual
Hausman robusto	hausman_robust()	manual	phptest(robust)	manual
AB-GMM	ab()	xtabond2	pgmm()	FirstDifferenceGMM()
PCSE	pcse()	xtpcse	pcse()	—
GEE	gee()	xtgee	geeglm()	GEE()
Mundlak (CRE)	mundlak()	manual	mundlak()	manual
xtgls	xtgls()	xtgls	pggls()	—
Modelo misto	mixedlm()	mixed	lme4::lmer()	MixedLM()
Logit FE	clogit()	clogit	clogit()	ConditionalLogit()
Resumo painel	xtsum()	xtsum	—	—
<i>Variáveis dependentes especiais</i>				
Logit	logit()	logit	glm(logit)	smf.logit()
Probit	probit()	probit	glm(probit)	smf.probit()
Logit ordenado	ologit()	ologit	polr()	OrderedModel
Probit ordenado	oprobit()	oprobit	polr()	OrderedModel
Logit multinom.	mlogit()	mlogit	multinom()	MNLogit()
Poisson	poisson()	poisson	glm(poisson)	smf.poisson()
Neg. Binomial	nbreg()	nbreg	glm.nb()	smf.negativebinomial
Zero-inflated	zinb()	zinb	zeroinfl()	ZeroInflatedNB
Tobit	tobit()	tobit	AER::tobit()	manual
Heckman	heckman()	heckman	heckit()	manual
GLM geral	glm()	glm	glm()	GLM()
Ef. marginais	margins()	margins	margins()	get_margeff()
<i>Inferência causal</i>				

(continua na próxima)

(continuação)

Tarefa	Hayashi	Stata	R	Python
DiD	did()	diff	lm()	smf.ols()
RDD	rd()	rdrobust	rdrobust()	rdd()
Fuzzy RDD	fuzzy_rd()	rdrobust	rdrobust()	rdd()
PSM	psm()	psmatch2	matchit()	manual
Controle sint.	synth()	synth	Synth	pysynth
<i>Sobrevivência</i>				
Kaplan-Meier	km()	sts	survfit()	KaplanMeierFitter
Cox PH	cox()	stcox	coxph()	CoxPHFitter
<i>Séries temporais</i>				
AR/MA/ARMA	arima()	arima	arima()	ARIMA()
AR(p) OLS	autoreg()	arima	arima()	AutoReg()
ARDL(p, q)	ardl()	ardl	dynlm()	ardl()
GARCH	garch()	arch	garch()	arch()
Raiz unit. (ADF)	adf()	dfuller	adf.test()	adfuller()
Phillips-Perron	phillips_perron()	pperron	PP.test()	PhillipsPerron()
Zivot-Andrews	zivot()	zandrews	ur.za()	ZivotAndrews()
Cointegração	johansen()	vecrank	ca.jo()	coint_johansen
VAR	var()	var	VAR()	VAR()
IRF (reduzida)	irf()	irf create	irf()	irf().plot()
SVAR Cholesky	svar(chol.)	svar	id.chol()	manual
SVAR BQ	svar(long.)	svar	BQ()	manual
IRF estrutural	sirf()	irf create	irf()	manual
Markov Switch.	markov()	mswitch	msmFit()	MarkovRegression
<i>Filtros e decomposição</i>				
HP	hprescott()	hprescott*	hpfilter()	hpfilter()
Baxter-King	baxter_king()	bking*	bkfilter()	bkfilter()
Holt-Winters	holtwinters()	tssmooth	HoltWinters()	ExponentialSmoothing()
STL	stl()	—	stl()	STL()
CF filter	christiano_fitzgerald()	cfitzroy	cfilter()	—
<i>Análise multivariada</i>				
PCA	pca()	pca	prcomp()	PCA()
Análise fatorial	factor()	factor	factanal()	FactorAnalysis()
Cor. canônica	cancorr()	canon	cancor()	CCA()
MANOVA	manova()	manova	manova()	MANOVA()
<i>Agrupamento e redução de dimensionalidade</i>				
K-Means	kmeans()	cluster kmeans	kmeans()	KMeans()
Hierárquico	hclust()	cluster single	hclust()	AgglomerativeClustering()
DBSCAN	dbscan()	—	dbscan()	DBSCAN()
t-SNE	tsne()	—	tsne()	TSNE()

(continua na próxima página)

(continuação)

Tarefa	Hayashi	Stata	R	Python
UMAP	<code>umap()</code>	—	<code>umap()</code>	<code>UMAP()</code>
Biplot PCA	<code>biplot()</code>	<code>pca</code>	<code>biplot()</code>	manual
<i>Pós-estimação</i>				
Coefs. tidy	<code>tidy()</code>	—	<code>broom::tidy()</code>	<code>statsmodels summary</code>
Glance	<code>glance()</code>	—	<code>broom::glance()</code>	manual
<i>Inferência e testes</i>				
Teste <i>t</i>	<code>ttest()</code>	<code>ttest</code>	<code>t.test()</code>	<code>ttest_ind()</code>
ANOVA	<code>anova()</code>	<code>anova</code>	<code>aov()</code>	<code>f_oneway()</code>
Kruskal-Wallis	<code>kruskal_wallis()</code>	<code>kwallis</code>	<code>kruskal.test()</code>	<code>kruskal()</code>
Normalidade	<code>swilk()</code>	<code>swilk</code>	<code>shapiro.test()</code>	<code>shapiro()</code>
Teste conjunto	<code>testparm()</code>	<code>testparm</code>	<code>linearHypothesis()</code>	<code>wald_test()</code>
Tabela	<code>esttab()</code>	<code>esttab[†]</code>	<code>stargazer()</code>	<code>summary_col()</code>
Armazenar modelo	<code>eststo()</code>	<code>eststo</code>	—	—
Limpar modelos	<code>estclear()</code>	—	—	—

* HP e BK no Stata requerem `ssc install hprescott` e `ssc install bking`.

[†] `esttab` no Stata requer `ssc install estout`.

Nota sobre geradores aleatórios: `rnormal()` corresponde ao gerador normal padrão usado nos exemplos de Stata, R e Python. Use `runiform()` quando o DGP exigir um sorteio $U(0, 1)$.

69.51 Matriz de validação

Além dos exemplos de código deste apêndice, todo HAYASHI é validado sistematicamente contra implementações de referência. O programa de validação está no diretório `validation/` e é executado com:

```
1 hay validate
```

A Tabela 69.2 lista os casos de validação atuais, com a família de estimadores, a fonte dos dados e as referências (R, Python e/ou Stata) usadas na comparação. Os detalhes completos — tolerâncias, notas e status — estão em `validation/MATRIX.md`.

ID do Caso	Família	Dataset/Fonte	Referências (R/Python/Stata)
ab_grunfeld	ab	<code>wooldridge::grunfeld</code>	R
ar_book	arima	<code>simulated_ar1</code>	R, Python
ardl_gdp	ardl	<code>statsmodels::macrodata</code>	R, Python

(continua na próxima página)

(continuação)

ID do Caso	Família	Dataset/Fonte	Referências (R/Python/Stata)
arima_book	arima	simulated_rw	R, Python
arima_gdp	arima	statsmodels::macrodata	R, Python
arma_book	arima	simulated_arma11	R, Python
autoreg_gdp	autoreg	statsmodels::macrodata	R, Python
coint_book	vecm	simulated_cointegrated	R, Python
cox_heart	cox	statsmodels::heart	R, Python
did_kielmc	did	wooldridge::kielmc	R, Python
ets_gdp	ets	statsmodels::macrodata	R, Python
garch_book	garch	simulated_garch11	Python
garch_nyse	garch	wooldridge::nyse	R, Python
glsar_hprice1	glsar	wooldridge::hprice1	R, Python
gmm_card	gmm	wooldridge::card	R, Python
heckman_mroz	heckman	wooldridge::mroz	R, Python
iv_card	iv	wooldridge::card	R, Python
lasso_hprice1	lasso	wooldridge::hprice1	R, Python
logit_mroz	logit	wooldridge::mroz	R, Python
ma_book	arima	simulated_ma1	R, Python
ologit_beauty	logit	wooldridge::beauty	R, Python
ols_wooldridge_wage1	ols	wooldridge::wage1	R, Python
panel_fe_grunfeld	panel_fe	wooldridge::grunfeld	R, Python
poisson_fertil2	poisson	wooldridge::fertil2	R, Python
probit_mroz	probit	wooldridge::mroz	R, Python
psm_jtrain3	psm	wooldridge::jtrain3	R, Python
quantile_wage1	qreg	wooldridge::wage1	R, Python
re_grunfeld	re	grunfeld	R, Python
rdd_book	rdd	rdd_book	R, Python
synth_smoking	synth	synth_smoking	R, Python
tobit_mroz	tobit	wooldridge::mroz	R, Python
var_book	var	simulated_var1	R, Python
var_macro	var	statsmodels::macrodata	R, Python
wls_hprice1	wls	wooldridge::hprice1	R, Python

Índice Remissivo

2SLS, *veja* dois estágios, mínimos quadrados de

`ab()`, [215](#)

ADF, *veja* Dickey-Fuller, teste de

`adf()`, [159](#)

agrupamento de volatilidade, [177](#)

AIC, [153](#)

ANOVA, [253](#)

`anova()`, [253](#)

análise de componentes principais, [231](#)

análise de sobrevivência, [209](#)

análise fatorial, [231](#)

ARCH, *veja* GARCH

ARDL, [277](#)

`ardl()`, [277](#)

Arellano-Bond, [215](#)

ARIMA, [159](#)

`arma()`, [153](#)

ARMA, [153](#)

ATT, *veja* efeito médio do tratamento sobre tratados, *veja* efeito médio do tratamento sobre tratados

autocorrelação, [153](#)

AutoReg, [277](#)

`autoreg()`, [277](#)

autoregressivo, [153](#)

Baxter-King, filtro de, [243](#)

`baxter_king()`, [243](#)

BIC, [153](#)

binomial negativa, [197](#)

Blanchard-Quah, decomposição de, [269](#)

BLUE, [95](#)

bootstrap, [227](#)

`bootstrap()`, [227](#)

bounds test, *veja* Pesaran, teste de cointegração de

Box-Jenkins, metodologia de, [153](#)

caliper, [185](#)

`cancorr()`, [231](#)

cargas fatoriais, [231](#)

categoria de referência, [205](#)

causalidade de Granger, [165](#)

censura, [209](#)

Cholesky, decomposição de, [247](#)

choque permanente, [269](#)

choque transitório, [269](#)

Christiano-Fitzgerald, filtro de, [265](#)

`christiano_fitzgerald()`, [265](#)

ciclo, [243](#)

`clogit()`, [257](#)

cointegração, [171](#)

composição de funções, [71](#)

condição de exclusão, [109](#)

condição de relevância, [109](#)

- condições de momento, [147](#)
- consistência, [95](#)
- controle sintético, [189](#)
- correlação canônica, [231](#)
- correlação contemporânea, [219](#)
- `cox()`, [209](#)
- Cox, modelo de, [209](#)
- CRE, *veja* Mundlak, estimador de
- dados em painel, [117](#)
- DataFrame, [57](#)
- decomposição da variância, [165](#)
- decomposição sazonal, [265](#)
- defasagens distribuídas, [277](#)
- Dickey-Fuller, teste de, [159](#)
- DiD, *veja* diferenças em diferenças
- `did()`, [125](#)
- diferenças em diferenças, [125](#)
- `display`, [57](#)
- distribuição de probabilidade, [87](#)
- doadores, pool de, [189](#)
- dois estágios, mínimos quadrados de, [109](#)
- duração esperada do regime, [239](#)
- efeito médio do tratamento sobre tratados, [125](#)
- efeitos aleatórios, [117](#)
- efeitos correlacionados aleatórios, *veja* Mundlak, estimador de
- efeitos fixos, [117](#)
- efeitos marginais, [131](#)
- eficiência, ganho de, [219](#)
- EGARCH, [177](#)
- Elastic Net, [223](#)
- endogeneidade, [109](#)
- `enet()`, [223](#)
- equações de estimação generalizadas, [235](#)
- equivalências Stata/R/Python, [359](#)
- erros-padrão robustos, [95](#)
- escore de propensão, [185](#)
- esparsidade, [223](#)
- esperança matemática, [87](#)
- estacionariedade, [153](#)
- estado não-observável, [283](#)
- estimação local, [273](#)
- `esttab()`, [95](#)
- ETS (Error-Trend-Seasonal), [243](#)
- event study, [128](#)
- `eventstudy()`, [128](#)
- excesso de zeros, [197](#)
- `factor()`, [231](#)
- `fe()`, [117](#)
- `filter()`, [57](#)
- filtragem de Hamilton, [239](#)
- filtro de Kalman, [283](#)
- filtro passa-banda, [265](#)
- filtros de decomposição, [243](#)
- função de ligação, [235](#)
- função de risco, [209](#)
- função impulso-resposta, [165](#)
- função impulso-resposta estrutural, [247](#)
- fórmula
 - interações, [100](#)
 - sintaxe, [100](#)
 - transformações, [100](#)
- gamma, distribuição, [235](#)
- GARCH, [177](#)
- `garch()`, [177](#)
- GEE, [215](#)
 - painel não-linear, [259](#)
- `gee()`, [215](#)
- `generate`, [57](#)
- GJR-GARCH, [177](#)

- GLM, *veja* modelos lineares
generalizados
`glm()`, [235](#)
GMM, *veja* método dos momentos
generalizados
`gmm()`, [147](#)
GMM em diferenças, [215](#)
`granger()`, [165](#)
- Hamilton, modelo de, [239](#)
`hausman()`, [117](#)
Hausman, teste de, [117](#)
hazard ratio, [209](#)
`heckman()`, [201](#)
Heckman, modelo de, [201](#)
heterocedasticidade, [95](#), [137](#)
heterocedasticidade condicional, [177](#)
Hodrick-Prescott, filtro de, [243](#)
Holt-Winters, [243](#)
`holtwinters()`, [243](#)
`hprescott()`, [243](#)
- identificação estrutural, [247](#)
IIA, axioma de, [205](#)
independência de alternativas
irrelevantes, *veja* IIA, axioma
de
instalação, [341](#)
instrumentos internos, [215](#)
integração de ordem, [159](#)
intervalo de confiança percentil, [227](#)
`irf()`, [165](#)
IV, *veja* variáveis instrumentais
`iv()`, [109](#)
- `johansen()`, [171](#)
Johansen, teste de, [171](#)
`kalman()`, [283](#)
Kaplan-Meier, estimador de, [209](#)
`km()`, [209](#)
`kpss()`, [159](#)
KPSS, teste de, [159](#)
Kruskal-Wallis, teste de, [253](#)
`kruskal_wallis()`, [253](#)
- LASSO, [223](#)
`lasso()`, [223](#)
lei dos grandes números, [87](#)
limiar de corte, [141](#)
local level, modelo, [283](#)
local linear trend, modelo, [283](#)
Local Projections
Difference-in-Differences, [129](#)
loess, [265](#)
log-verossimilhança de predição, [283](#)
logit, [131](#)
`logit()`, [131](#)
logit condicional, [257](#)
logit multinomial, [205](#)
logit ordenado, [205](#)
LOWESS, [273](#)
`lowess()`, [273](#)
`lpdid()`, [129](#)
- MANOVA, [231](#)
`margins()`, [131](#)
`markov()`, [239](#)
Markov Switching, [239](#)
matching por escore de propensão,
[185](#)
mediana, [137](#)
`mixedlm()`, [257](#)
`mlogit()`, [205](#)
modelo de correção de erros, *veja*
VECM
modelo de espaço de estados, [283](#)

- modelo misto, [257](#)
- modelos de contagem, [197](#)
- modelos lineares generalizados, [235](#)
- mudança de regime, [239](#)
- multiplicador de longo prazo, [277](#)
- `mundlak()`, [257](#)
- Mundlak, estimador de, [257](#)
- máxima verossimilhança, [131](#)
- média móvel, [153](#)
- método dos momentos generalizados, [147](#)
- mínimos quadrados ordinários, [95](#)
- mínimos quadrados ponderados, [273](#)
- módulos, [341](#)
- `nbreg()`, [197](#)
- Newey-West, variância de, [261](#)
- não-paramétrico, teste, [253](#)
- odds ratio, [131](#)
- `ologit()`, [205](#)
- OLS, *veja* mínimos quadrados ordinários
- `ols()`, [95](#)
- `oprobit()`, [205](#)
- ordenação causal, [247](#)
- PCA, *veja* análise de componentes principais
- `pca()`, [231](#)
- PCSE, [215](#)
- `pcse()`, [215](#)
- penalização L1 (lasso), [223](#)
- penalização L2 (ridge), [223](#)
- Pesaran, teste de cointegração de, [277](#)
- Phillips-Perron, teste de, [261](#)
- `phillips_perron()`, [261](#)
- placebo, testes de, [189](#)
- `poisson()`, [197](#)
- Poisson, regressão de, [197](#)
- PPML, [235](#)
- primeiro estágio, [109](#)
- probabilidade, [87](#)
- probabilidade de transição, [239](#)
- probit, [131](#)
- `probit()`, [131](#)
- probit ordenado, [205](#)
- pseudo-máxima verossimilhança, [197](#)
- PSM, *veja* matching por escore de propensão
- `psm()`, [185](#)
- `qreg()`, [137](#)
- quantil, [137](#)
- quebra estrutural, [261](#)
- raiz unitária, [159](#)
- razão inversa de Mills, [201](#)
- `rd()`, [141](#)
- RDD, *veja* regressão por descontinuidade
- `re()`, [117](#)
- reamostragem, [227](#)
- referência rápida, [345](#)
- regressão por descontinuidade, [141](#)
- regressão quantílica, [137](#)
- regularização, [223](#)
- relação de longo prazo, [171](#)
- REML, [257](#)
- REPL, [341](#)
- restrições de longo prazo, [269](#)
- Ridge, [223](#)
- `ridge_reg()`, [223](#)
- riscos proporcionais, hipótese de, [209](#)
- RMSPE, [189](#)
- `rnormal()`, [341](#)
- rolling OLS, [273](#)

- `rols()`, [273](#)
RTS, *veja* suavizador de
 Rauch-Tung-Striebel
running variable, [141](#)

sazonalidade, [243](#)
`seed()`, [341](#)
seemingly unrelated regressions, *veja*
 SUR
seleção amostral, [201](#)
seleção de variáveis, [223](#)
sintaxe, [345](#)
`sirf()`, [247](#)
sobreidentificação, [147](#)
`sort()`, [57](#)
STL, [265](#)
`stl()`, [265](#)
suavizador de Rauch-Tung-Striebel,
 [283](#)
suavização não-paramétrica, [273](#)
superdispersão, [197](#)
SUR, [219](#)
`sur()`, [219](#)
SVAR, *veja* VAR estrutural
`svar()`, [247](#)
SVEC, [269](#)
`synth()`, [189](#)

tendência, [243](#)
tendências paralelas, [125](#)
teorema do limite central, [87](#)
teste J, [147](#)
teste t, [253](#)
Tobit, [201](#)

`tobit()`, [201](#)
`ttest()`, [253](#)

VAR, [165](#)
`var()`, [165](#)
VAR estrutural, [247](#)
varimax, rotação, [231](#)
variáveis instrumentais, [109](#)
variável dependente limitada, [201](#)
variância, [87](#)
VECM, [171](#)
`vecm()`, [171](#)
vetor autoregressivo, *veja* VAR
viés de censura, [201](#)
viés de Nickell, [117](#), [215](#)
viés de seleção, [185](#)
viés de variável omitida, [95](#)
volatilidade condicional, [177](#)

Welch, teste de, [253](#)
within estimator, *veja* efeitos fixos
WLS, *veja* mínimos quadrados
 ponderados
`wls()`, [273](#)

`xtgls()`, [257](#)
`xtlogit()`, [259](#)
`xtpoisson()`, [259](#)
`xtprobit()`, [259](#)

Zellner, estimador de, [219](#)
ZINB, [197](#)
`zinb()`, [197](#)
`zivot()`, [261](#)
Zivot-Andrews, teste de, [261](#)